

让 Hopfield 网络像生命系统一样学习，可能吗？

一篇 NeurIPS 2023 立场论文提炼出三种生物适应机制，并给出把它们嵌入 Hopfield 网络自优化（self-optimization）模型的具体路径。

如今的深度学习很强大，但它的学习方式和任何生物都不一样。它需要庞大的数据集、监督或奖励式的训练信号，以及可观的能耗；而当它按顺序学习新任务时，往往会覆盖掉旧任务，这就是所谓的灾难性遗忘（catastrophic forgetting）。生命系统面对同样多变的世界，用的却几乎是相反的预算：它们能从稀疏数据中学习和适应，能耗很低，也很少需要大量训练迭代，就能建立起有用的联想。

这道鸿沟，正是这篇 NeurIPS 2023 立场论文的出发点。作者 Aisha Belhadi 来自 Okinawa Institute of Science and Technology。与其把网络一味做大，论文提出了一个更接近生物学的问题：究竟是哪些机制让生命系统始终保持适应性，我们能不能把它们直接迁移进一个联想记忆模型？论文提炼出三种这样的机制，并为每一种给出了低成本嵌入 Hopfield 网络自优化（self-optimization）模型的具体做法。

这一思路刻意保持“节俭”。它不主张增加参数，而是主张提升网络的自由度——让模型已有的组件承担更多工作，这恰恰是生物采用的办法。下面这张图是整篇论证的地图：左边是三种机制，右边是模型中三个可以介入的位置。




图 1. 论文的核心提案：把三种生物适应机制——元可塑性（metaplasticity）、稳态（homeostasis）、抑制与遗忘——分别对应到自优化（SO）模型的三处具体改造。此图是对论文文字所述关系的示意；原论文本身不含任何插图。

论文链接：<https://openreview.net/forum?id=WjHYgEfXiV>

论文真正关心的那对张力

要在多变的世界中行动，任何系统都必须一边整合新信息，一边保持足够稳定，才能守住已经学到的东西。太偏向新奇，学习就永远无法收敛；太依赖过去，系统又会锁死在陈旧的模式里。生物靠多种机制的相互作用来维持这种平衡，而论文读出的，正是机器学习反复撞上的“稳健性对灵活性”这同一道难题。它的赌注是：生物用来管理平衡的那些机制，才是缺失的关键，而不是更大的规模。

论文选定的载体是自优化（SO）模型——一个带 Hebbian 权重更新、并周期性重置节点状态的 Hopfield 网络。若不加改动，标准 Hopfield 网络只是一个能力有限的联想记忆，对 N 个节点大约只能可靠存储 $0.14N$ 个模式。SO 模型之所以更有意思，是因为这些重置让它能积累一份“访问过的吸引子”的记忆，并逐步扩大全局能量极小值周围的吸引域，这种行为已经与生物的吸收子动力学相呼应。这也让它成为继续注入生物机制的天然场所。

第一个杠杆：让学习率自适应

最主要、也展开得最充分的一个提案，瞄准的是元可塑性（metaplasticity）——决定一个突触被允许改变多少的那种生物特性。在朴素的 Hebbian 规则里，学习率是用户设定的固定常数。论文把它改成了一个函数，并给出两种形式。在局部元可塑性中，学习率跟随每条连接自身的权重，于是对某个权重的更新，变成了“该权重的函数乘以两端节点状态”，从而快速增强共同激活的连接、缓慢削弱相互对立的连接。在网络级元可塑性中，学习率则跟随网络能量的变化，其行为类似在能量地形上做梯度下降。




图 2. 元可塑性的两种形式。（a）局部：学习率跟随每条连接自身的权重，于是 Hebbian 更新变成与权重相关。（b）网络级：学习率跟随网络能量的变化，在陡坡处加快、在平坦处放慢，从而更容易逃出局部极小值。

两种形式都不额外增加参数。它们复用了网络本就在计算的量——权重与能量——把它们变成一个自我调节的“可塑性旋钮”。其中能量驱动的形式更具启发性：学习在地形陡峭处加速、在趋于平坦处放缓，这是一种避免困在浅局部极小值里的合理办法。

第二、三个杠杆：激活规则与模块化

稳态（homeostasis）——把系统调节在某个设定点附近——启发了第二处介入：把常用的激活规则换成一种带振荡的规则，比如三角函数，让网络动力学围绕一个基线自带节律，而不是平平地稳定下来。第三处介入针对结构。带自适应模块内、模块间连接的模块化架构，配合模块之间的抑制，可以支撑时间整合、简并（degeneracy）与持续学习；它呼应了生物学中“突触标记与捕获”的思想——一个不断强化内部连接的模块会自动得到加强，而抑制则把整体能量约束在可控范围内。

为什么约束是要点，而不是代价

论文中最有意思的主张是概念层面的。人们很容易把生物约束读成灵活性的对立面，读成一套把系统圈起来的规矩。论文反其道而行：约束与自由度是互补的。架构提供了一个约束性的框架，而在这个框架之内，增加的自由度才能打开真正意义上的新适应行为。一旦抽掉框架，同样多出来的自由度就没有东西去塑形，于是塌缩成毫无信息量的噪声。




图 3. 统一的核心思想。正是架构上的约束，才让新增的自由度成为有用、有结构的适应，而不是塌缩成噪声。

它是什么，又不是什么

有必要说清楚这篇论文的定位。它是一份提案，而非实证研究：没有数据集，没有基准测试，也没有训练好的模型。它的成果是一套自洽的设计框架，把元可塑性、稳态与抑制分别映射到自适应学习率、改造后的激活规则以及自适应模块化；并把这些想法扎根于既有的 SO 模型计

算工作之上，包括一个 *C. elegans* 连接组的模型，以及若干求解组合可满足性问题的 SO 模型。所提出的每一个函数，都仍有待在算法上被明确定义并接受检验。

这样看，它的贡献是一份组织原则格外清晰的研究议程。如果联想记忆模型要像生命系统那样，从稀疏数据中自适应地学习，论文押下的方向是：让可塑性自我调节，并让结构——而非规模——来充当那个约束者。至于这些具体函数究竟是否奏效，恰恰是论文交给后来者去回答的实证问题。

对做实践的人来说，这里的具体启示虽小却很有针对性。在伸手去要更多数据或更多参数之前，或许值得先问一句：系统本就在跟踪的某个量——一个权重，或一个能量值——能不能被改造成自行调节学习的机制；以及能不能让结构、而非规模，来承担把模型稳住的工作。