

ICLR 2022 | 给无穷棵软树一把「核」尺子： Tree NTK 首次为软树集成提供理论解释

日本国立情报学研究所 Kanoh 与 Sugiyama 推导出树的神经正切核（TNTK），一套理论同时解释了软树集成的全局收敛、参数共享为何免费、深树为何退化、以及分裂更硬为何更好。

在表格数据（tabular data）上，基于决策树的模型至今仍是最难被超越的一类。近年来一个受关注的变体是「软树集成（soft tree ensemble）」：它不像经典决策树那样在每个节点做硬性贪心划分，而是把每条分裂规则都改造成可微分形式，于是整片森林可以像神经网络一样用梯度下降端到端训练。这类模型在许多任务上表现很好，实践者也积累了一套训练技巧：节点间共享参数、调节分裂软硬、把集成过参数化。唯一缺的是理论——几乎没有工作能解释它们为何这样训练、何时能泛化，以及这些经验技巧为何有效。

对神经网络来说，填补类似空白的工具正是「神经正切核（Neural Tangent Kernel, NTK）」。在隐藏单元数趋于无穷的极限下，用梯度下降训练的宽网络等价于一个固定、有闭式表达的核所对应的核回归；这一观察解释了 MLP、CNN 等众多架构的训练动力学与泛化，而每种架构都会诱导出属于自己的核。但此前没有人为树模型推导出对应的 NTK，于是表格世界里软树这一侧一直处在理论的暗处。

这篇发表于 ICLR 2022 的论文，由日本国立情报学研究所（NII）与综合研究大学院大学（SOKENDAI）的 Ryuichi Kanoh 和 Mahito Sugiyama 完成，补上了这块拼图。他们提出「树的神经正切核（Tree Neural Tangent Kernel, TNTK）」，即由无穷多棵软树组成的集成所诱导的核。从这一个闭式核出发，作者推导出训练的全局收敛，证明 oblivious 树的参数共享在该极限下不损失表达力，并解释了深软树为何反而不再泛化、以及把分裂做硬为何更有用。




图 1 由 M 棵软树组成的集成。每棵完全二叉树把输入沿可微分的内部节点（蓝色，带权向量 w ）向下路由，直到叶子取值（绿色，即响应 π ）。每棵树输出叶子上的加权和，集成再把 M 棵树的输出以 $1/\sqrt{M}$ 的比例平均。TNTK 研究的是 $M \rightarrow \infty$ 的极限。

论文链接：<https://arxiv.org/abs/2109.04983>

从软树到一个固定的核

软树把每个硬分裂替换成一次平滑的决策。在每个内部节点上，输入不再被严格地分到左边或右边，而是用一个「缩放误差函数（scaled error function）」计算向两侧走的概率——本质上是一个平滑的 sigmoid，其陡峭程度由缩放参数 α 控制。 α 较小时分裂很温和、接近线性； α 增大时分裂变硬，而在 $\alpha \rightarrow \infty$ 的极限下就还原成普通决策树的硬分裂。由于每一步操作都可微分，内部权重和叶子取值都能用梯度下降联合学习。

作者取 M 棵深度为 d 的完全二叉软树组成集成，随机初始化参数，再让 M 趋于无穷。他们的核心结论是：该集成的神经正切核会依概率收敛到一个确定性的核，不再依赖随机初始化。TNTK 有一个清晰、可解释的结构：一部分来自内部分裂节点，一部分来自叶子，二者以闭式组合。关键在于，分裂的期望有解析表达式，所以整个核是一个公式而非一次模拟。又因为这个公式并不是对深度逐层递归的，计算 TNTK 的开销与树有多深无关——这一点在后面很重要。

这个公式把在一对输入上求值的两个量组合在一起： T ，即两个输入在某节点被路由到同一侧的概率，以及它对输入相似度的导数。写得紧凑一些，深度为 d 的核是 $2^d \cdot d \cdot \Sigma \cdot T^{(d-1)} \cdot \dot{T} + (2T)^d$ ，其中 Σ 是两个输入的内积。第一项是内部节点的贡献，第二项是叶子的贡献；一旦选定 α 与 d ，二者都被固定下来。

为什么训练一定会收敛

固定的核之所以是个如此有用的对象，是因为它把一个关于梯度下降的难题，转化为一个关于线性代数的简单问题。作者证明，训练过程中 TNTK 基本保持不变，于是训练一个无穷软树集成就退化为用 TNTK 做核回归。由于该核是正定的，这个回归有唯一解，梯度下降会全局收敛到它——不会卡在糟糕的局部极小值里。不过在信任这个极限之前，值得先确认有限规模的集成确实向它靠近。




图 2 有限集成的核向闭式 TNTK 收敛。左：对夹角被逐步扫过的两个输入，经验核（彩色）随着树的数量 M 从 16 增到 4096，逐渐贴合到解析极限（黑色虚线）。中与右：经验核与极限核之间的相对误差，在不同分裂硬度 α 与深度 d 下都按理论预期的 $M^{-1/2}$ 速率下降。

这种收敛并不是空泛的渐近说辞。随着集成变大，经验核以理论预测的 $M^{-1/2}$ 速率贴合解析 TNTK，并且在改变分裂硬度 α 和树深度 d 时都保持一致。极限核得到验证之后，就可以直接检验训练的核回归图景了。




图 3 训练动力学与核回归的预测吻合。每种颜色是一个训练点（左）或测试点（右）；粗的解析曲线是极限 TNTK 预测的轨迹，虚线是用梯度下降真实训练的软树集成 ($M = 1024$)。即便是较小的集成 ($M = 16$ ，点线) 也能跟上预测，而 $M = 1024$ 几乎与之重合。

当作者真正训练软树集成，并把 TNTK 预测的输出轨迹叠加上去时，两者吻合—— $M = 1024$ 时贴合紧密， $M = 16$ 时也能辨认出同样的走势。这说明无穷宽度的理论描述的是有限、可训练模型的行为，而不只是一个理想化的极限。

Oblivious 树是「免费」的

在 NODE 等模型里有一个流行的设计选择：oblivious 树——在同一深度上，所有内部节点共享同一条分裂规则，这大幅减少了参数量，也让树容易向量化。人们自然会担心，这种约束是否牺牲了表达能力。TNTK 给出了一个干净的答案。




图 4 普通树（左）与 oblivious 树（右）。在 oblivious 树中，同一深度上的分裂规则被共享（框内的 w 向量彼此相同），而叶子响应 π 仍可不同。论文证明，二者在无穷极限下诱导出完全相同的 TNTK。

作者证明，oblivious 软树集成会收敛到与普通软树集成完全相同的 TNTK。在无穷极限下，在同一深度共享分裂规则在核的意义上不付出任何代价——正是那个让 oblivious 树高效的架构约束，结果是免费的。这为许多实践者早已在用的设计，提供了一个令人安心的理论依据。

分裂更硬更好，树更深却退化

因为 TNTK 有闭式表达，我们可以直接把它画出来，读出两个旋钮——分裂硬度 α 与深度 d ——如何重塑这个核。理论也正是从这里开始解释那些经验性的「老规矩」。




图 5 α 与深度如何塑造核，横轴是两个输入的内积。左侧三幅（按 α 上色）：分裂越硬，核越偏离直线，弯成更有表达力的非线性形状。右侧一幅（按深度 d 上色）：树越深，核在几乎所有相似度上都被压平到零，只在完全相似处才有响应——这就是预示泛化变差的退化现象。

从这些曲线可以直接读出两点。第一，当 α 很小时核几乎是线性的，模型几乎无法表达非线性结构； α 增大后核弯成更丰富的形状。这与「太温和的近线性软分裂没什么用」的直觉一致。第二，也更不易察觉：随着深度增加，核会退化，坍塌成一个近乎常数、只在两个输入几乎完全相同时才有反应的核。一个把几乎所有输入对都视作同样不相似的核，是无法很好泛化的——这正是论文对「很深的软树表现变差」的解释。

到底管不管用？90 个数据集上的核回归

有了理论，作者把 TNTK 当作一个实用的核来检验。他们在 90 个真实世界数据集上用 TNTK 做核回归，把深度从 $d = 1$ 调到 29，并与无穷宽 MLP 诱导的核以及经典的 RBF 核作对比。




图 6 左：90 个数据集上的平均准确率随树深度的变化（多条曲线对应不同分裂硬度 α ），并以 MLP 诱导的 NTK 与 RBF 作参照；准确率随深度先升后降，正是核形状所预测的退化。右：核计算耗时，TNTK（橙）基本平坦，MLP 诱导 NTK（蓝）随深度线性增长。

深度扫描直接复现了预测的退化：对每一个 α ，平均准确率都在最初几层上升，随后随着树变深而下降。耗时那一幅则把闭式的好处落到实处——由于 TNTK 不对深度递归，它的开销基本是平的，而 MLP 诱导的 NTK 则随深度线性增长。在准确率对比上，MLP 诱导的核平均更强，但树的核并不只是个摆设：它在超过 30% 的单个数据集上取胜，也就是那些树的归纳偏置更契合数据的场景。

分裂硬度的扫描量化了「越硬越好」这个故事。下表给出在每个 α 下，TNTK 在 90 个数据集中胜过 MLP 诱导 NTK 的比例。胜率从近线性的 $\alpha = 0.5$ 时的 13.6% 一路爬升，到 $\alpha = 32$ 时达到峰值 34.9%，而整个硬分裂区间都明显高于 RBF 核的 11.8%。

表 1 在 90 个数据集上，TNTK 相对 MLP 诱导 NTK 的胜率，随分裂硬度 α 变化（深度从 $d = 1$ 到 29 调优）。RBF 核作为参照。

α	0.5	1.0	2.0	4.0	8.0	16.0	32.0	64.0	RBF
胜率 (%)	13.6	18.8	22.2	28.6	32.5	31.6	34.9	27.2	11.8

小结

这篇工作最持久的贡献是观念上的：原本只用于神经网络的 NTK 框架，可以干净地推广到树集成上。由此得到的 Tree NTK 用一套理论解释了软树的一系列行为——训练全局收敛、oblivious 参数共享在无穷极限下免费、深树退化成近乎常数的核、分裂更硬则核更有表达力。它同时给出一个实用、与深度无关的核：与 MLP 诱导的 NTK 有竞争力，在超过 30% 的数据集上更优，且随深度增长计算成本远低于后者。

边界也值得说明。分析建立在无穷集成极限之上，且针对完全二叉树；实证是表格数据上的核回归而非大规模深度学习，平均而言 MLP 诱导的核仍略胜一筹。即便如此，TNTK 给了软树集成此前缺少的东西——一个关于它们为何这样训练、这样泛化的原理性解释。