

# MIT Media Lab | 别再笼统地说「分布漂移」： 从测试集到生产环境，真正的问题是「情境漂 移」

---

Matthew Groh 的一篇 perspective 论文，用 context shift（情境漂移）重新框定模型鲁棒性问题，并给出三条可落地的方法

我们习惯用一个数字来判断模型好不好：它在某个 benchmark（基准测试集）上的准确率。当一个模型在 benchmark 上追平、甚至超过人类水平，我们往往就默认它「可以用了」。可一旦把它放进真实的生产环境，它却频繁出错——在分布外的样本、或经过对抗扰动的输入上，表现远不如测试集上那么亮眼。这种「测试集很强、真实场景就翻车」的落差，几乎是每个做过部署的人都熟悉的痛。

学界通常把这道鸿沟叫作 distribution shift（分布漂移），并进一步细分成 covariate shift、prior probability shift、concept shift 等一串术语。MIT Media Lab 的 Matthew Groh 在这篇 perspective 论文中指出：这套框架同时「说得太细」又「说得太粗」——它能精确地度量两份数据分布差在哪里，却完全没告诉你这种差异是怎么产生的。而对想真正改进模型可靠性的人来说，后者才是能下手干预的地方。

论文提出一个更有解释力的概念：context shift（情境漂移）——数据在「如何被创建、收集、整理」这一生成过程中发生的、语义上有意义的变化。一句话概括作者的立场：分布漂移只是症状，情境漂移才是病因。围绕这个重新框定，作者给出三条互补的应对方法，并用三个反复出现的计算机视觉「模式生物」——人脸表情识别、深度伪造检测、皮肤病诊断——把道理讲透。

论文：<https://arxiv.org/abs/2207.01059>（Matthew Groh，MIT Media Lab，2022）。

## 为什么「分布漂移」这个框架不够用

benchmark 在研究里同时扮演两个角色：它让研究者在统一尺度上比较不同方法，也充当真实世界的一个（不完美的）替身。问题在于，任何一个静态测试集都无法完整刻画真实任务那种动态、高维的复杂度。于是那些在 benchmark 上看起来媲美人类的模型，一碰到分布外或对抗扰动的生产数据就频频出错。把这种落差叫作 distribution shift 本身没错，但作者认为它的解释力被高估了。

更关键的是，covariate shift、prior probability shift、concept shift 这些定义，本就是为「精确比较两份样本」而设计的：它们能告诉你  $P(x)$ 、 $P(y)$  或  $P(y|x)$  变了多少，却回答不了「为什么会变」。而在过去十年里，这类术语的数量本身也在飞速膨胀——如图 1 所示，关注在涨，指向的对象却始终没变。




图1 2012–2021 年 Google Scholar 上，「machine learning」与四类分布漂移术语组合的论文数量。covariate shift 相关论文到 2021 年已逼近每年九千篇，可见整个领域对「分布漂移」的关注在过去十年急速升温。但作者的观察是：术语越堆越多，指向的仍只是差异这个症状，而非产生差异的过程。

这种增长并不代表问题正在被解决，只说明它被更频繁地命名。膨胀的术语底下，其实是同一个动作：度量两份数据相距多远。但没有任何一个度量，能捕捉到真正上游的那一步——某个采样选择、某条标注准则、某次「谁来贡献数据」的变化——正是它，让两份数据从一开始就不一样。

这套定义对「评估数据生成过程」而言又太粗。现实中的漂移很少乖乖落进某一个整齐类别，它往往同时牵动特征、标签以及两者的关系，于是几乎所有值得关心的情形，最后都被塞进「Other Distribution Shift」这个兜底类别。图2列出四种教科书式的情形，也说明了为什么现实几乎总是落在那个兜底类别里。




图2 四类分布漂移的示意（依 Moreno 等人 2012 的定义）：空间位置代表特征空间，形状与颜色代表真实标签，实线是模型从原始样本学到的判别边界，虚线是从漂移后样本学到的边界。现实中的漂移大多同时改变特征、标签及两者关系，落入最下方的「Other Distribution Shift」。关键在于：这些定义只回答了「两份样本差在哪」，没触及「差异从何而来」。

## context shift：把注意力从「差异」移到「差异的来源」

context（情境）指的是驱动分布漂移的、语义上有意义的上游因素。作者请研究者不要盯着「两个分布差多少」，而是去追问「是哪几种过程制造了这种差异」。论文归纳出三种：sample selection bias（样本选择偏差），比如新数据集采样自旧数据集里根本没有的人群；adversarial perturbations（对抗扰动），人眼几乎无法察觉、却足以改变模型行为的噪声；以及 non-stationarity（非平稳性），也就是世界本身在变，比如 2010 年前的翻盖手机和 2018 年后的智能手机所拍出的照片。作者进一步指出，非平稳性可以看作样本选择偏差在时间维度上的特例。

这也点出情境漂移和分布漂移最本质的差别：分布漂移可以在两份现成数据集之间测量出来，情境漂移却只有在理解整个总体的数据分布、以及它如何随空间和时间演变之后，才谈得上被真正应对。换句话说，它要求你回到数据是怎么来的这一步去思考。




图 3 情境漂移两种来源的直觉图。左侧「Sample Selection Bias（样本选择偏差）」：总体（漏斗上方）包含多种形状，但有偏的原始样本只采到圆形和星形，随机样本则保留了高得多的多样性；于是在原始样本上学到的边界，在超过一半的观测上失效。右侧「Adversarial Perturbations（对抗扰动）」：扰动后的样本混入人眼几乎察觉不到的旋转形状，模型据此产生误分类。两种情形都同时改变了特征与「给定特征下的标签」，因而也都属于「Other Distribution Shift」。

## 三条应对方法

第一，借助 human intuition 与 expert knowledge（人的直觉与领域专家知识）。人类往往能先验地指出模型大概率会在哪些语义特征上翻车——某种光照、某类肤色、某个拍摄角度——从而把评测和数据收集引向这些高风险的情境，而不是等生产事故发生后再补救。

第二，采用 dynamic benchmarking（动态基准测试）。与其用一个固定的静态测试集打分，不如针对一个「说明清楚、有质量控制」的数据生成过程持续评测，得到作者所说的 corroborated accuracy（相互印证的准确率）——也就是模型在许许多 benchmark 上得分的整体分布，而不是某一个数字。作者把 BREEDS、WILDS、Dynabench 视为这个方向的范例。

第三，也是见效最快的一条：clarify a model's limitations（清楚地写明模型的边界）。作者建议每篇工作都应有一个显式的 limitations 小节，明确说清模型在哪些情境下被评测过、在哪些情境下表现仍是未知。这一步几乎零成本，却能直接挡住大量「拿着测试集分数当通行证」的误用。

## 证据：换一个 benchmark，结论就变了

论文最有说服力的证据，是模型分数随 benchmark 的剧烈摆动。同一个基于 AlexNet 的人脸表情识别模型，在七个 benchmark 上的准确率从 SFEW 的 48.6% 一路跨到 MultiPie 的 94.8%，而随机基线只有 14.2%——你选哪个 benchmark，几乎就决定了你要讲的故事。这种模式并非孤例：当研究者忠实地重建 ImageNet 和 CIFAR-10 的测试集时，当时最强模型的准确率下滑了 3–15%。

另外两个域同样触目。在深度伪造检测里，一个领先的 DFDC 检测器，对两位世界领导人的真实换脸视频只给出了 2% 和 8% 的伪造可能性——恰恰是最该被识破的高情境样本。在皮肤病诊断里，某些评测 benchmark 里第二深肤色（Fitzpatrick 类型）的人只占 2.7%，最深肤色更是仅有一人，系统性的误差就这样藏在了几乎无人代表的情境里。

表 1 论文中的关键数字：同一问题、换个情境，结论就可能翻转。

| 证据                                 | 数字                                           |
|------------------------------------|----------------------------------------------|
| 同一 FER (AlexNet) 模型跨 7 个 benchmark | 48.6% (SFEW) - 94.8% (MultiPie) , 随机基线 14.2% |
| 忠实重建的 ImageNet / CIFAR-10 测试集      | 当时最强模型准确率下滑 3–15%                            |
| 领先 DFDC 检测器对两位世界领导人的真实换脸视频         | 仅给出 2% 与 8% 的伪造可能性                           |
| DFDC 深度伪造基准规模                      | 128,154 段视频 / 960 位演员                        |
| 某皮肤病评测 benchmark 中第二深肤色占比          | 2.7% (最深肤色仅 1 人)                             |

## 小结：把鲁棒性问题重新框定

这篇论文留下的不是一个新模型或新数据集，而是一次视角的转换：别再把「测试集到生产环境」的落差当成两份数据之间的统计距离，而要把它看作 context shift——数据生成方式上语义有意义的变化。应对之道，是把机器学习与人的直觉和专业判断结合起来，从静态 benchmark 走向评估数据生成过程的动态 benchmark，并诚实地写明每个模型的边界。

作者也坦承，情境漂移比分布漂移更难被量化——它没法在两份现成数据集之间简单算出来，而要求对整个总体及其随时空的演变有所理解。但恰恰因为如此，最简单、最立竿见影的一步反而不是更复杂的方法，而是坦诚：清楚地说明一个模型在哪些情境下被验证过，又在哪些情境下表现仍是未知。