

让质量自由增减的最优传输

NubOT：用循环一致的半耦合做不守恒的神经最优传输，预测单细胞药物响应

最优传输（Optimal Transport, OT）已经悄悄成为机器学习中比较两个分布的常用工具。给定一个源群体和一个目标群体，它会找到把前者搬运到后者最经济的方式，并顺带交回一样很有价值的东西：一个耦合（coupling），告诉你源里的哪些点对应目标里的哪些点。当你无法直接追踪个体、只能观测到群体的两张不成对快照时，这种对应关系恰恰是你最想要的。

但经典 OT 带着一个容易被忽略的前提：质量守恒。离开源的每一份质量都必须落到目标里的某处，途中既不凭空产生，也不凭空消失。当两个群体只是彼此形变时，这没有问题；可一旦群体规模本身发生变化，它就会失效，而这恰恰是 OT 如今被应用的一些领域里最要紧的情形。

单细胞生物学是最清楚的例子。对细胞做测量往往会破坏它，因此同一个细胞永远无法被测量两次，跨时间的对应关系只能从群体的不成对副本中推断出来。而在药物作用下，细胞不只是在特征空间里移动，它们还会增殖和死亡，群体因此时大时小。这篇 NeurIPS 2022 的论文提出了 NubOT，一种建立在半耦合（semi-couplings）形式化之上的神经不平衡最优传输方法。通过一套循环一致（cycle-consistent）的训练机制，NubOT 同时学习细胞往哪里移动，以及它们的质量该如何重标，从而显式地刻画质量的产生与消失。




图 1 (a) 一对半耦合 (γ_1, γ_2) 共同求解不平衡 OT 问题： γ_1 描述质量离开源时去往何处， γ_2 描述质量到达目标时来自何处，因此一个正在消失的亚群可以直接不被匹配。(b) NubOT 把半耦合参数化为重标函数 (η, ζ) 与平衡 Monge 映射的复合，后者由对偶势 f, g 的梯度给出。

论文: <https://arxiv.org/abs/2209.15621> 代码: <https://github.com/FrederikeLuebeck/nubot>

问题：当质量不再守恒时如何传输

在自然科学中反复出现的一个问题是：当你只能观测到不成对的快照、而无法跟踪个体时，如何刻画一个群体在干预之后的变化。在单细胞生物学里这是无法回避的。最优传输给出了一条有原则的路径，通过在源分布与目标分布之间学习最优耦合来还原缺失的对应关系，而神经 OT 方法把传输映射本身参数化为神经网络，让这件事变得可扩展。

难点在于，细胞对药物的响应是高度异质的。不同的细胞类型和状态可能朝相反方向反应，一些亚群增殖，另一些死亡，于是两次测量之间细胞总数发生变化。要刻画这一点，需要单细胞层面的非线性映射，而不是对整体求平均。此前的神经 OT 方法要么假设质量守恒的平衡设定，

要么像当前最先进的不平衡 GAN 方法那样，只捕捉到增长与收缩的大致趋势，而无法还原每个亚群所需的精确重标。一直缺席的，是一种既准确刻画质量往哪走、又准确刻画有多少质量被产生或消灭的方法。

NubOT：把传输和重标拆开

NubOT 建立在半耦合理论之上，它把平衡 OT 中的单个耦合松弛成一对。如图 1a 所示，一个耦合 γ_1 描述质量离开源时去往何处，另一个耦合 γ_2 描述质量到达目标时来自何处。因为两者被允许彼此不一致，一个亚群可以损失质量、也可以获得质量，而不必强行把每一份都送到某处。论文的贡献在于让这套形式化变得可学习、可扩展，并配上一套能泛化到从未见过的细胞的训练机制。

核心思路是把困难的不平衡问题拆成两个相互耦合的部分：特征变换与质量重标。NubOT 引入代理测度（proxy measures），它们只是源与目标的重标版本，由标量场 η 和 ζ 加权，并使两个代理测度的总质量相等。在这对已经平衡的代理测度之间，它求解一个标准的 OT 问题，把前向与后向的 Monge 映射学习为凸势的梯度，而凸势由输入凸神经网络（ICNN）表示。从学到的重标函数和映射出发，原始的半耦合可以被精确还原出来。

由于每次更新重标函数时边缘分布本身都会移动，NubOT 无法一步到位地同时求解两个部分，而是交替进行：先用一个高效的单步不平衡 Sinkhorn 更新来估计质量重标，再通过一个极小极大目标更新传输势，如此循环。循环一致性正是在这里发挥作用，它把前向与后向映射绑在一起，让交替迭代收敛到一个自洽的解。关键之处在于，重标函数被学习为神经网络，因此在测试时模型可以接过一个新细胞，把它映射到预测的未来状态，同时预测它的质量该增长还是收缩。

一个合成的压力测试

在接触真实数据之前，作者先搭了一个可控的基准：一个二维的三高斯簇混合，目标保留相同的簇，但改变它们的相对比例并在空间中平移，覆盖三个不平衡程度递增的场景。任务是在把源映射到目标的同时，既把位置搞对，也把每个簇的质量搞对。图 2 把 NubOT 与不平衡 GAN 基线做了对比。两种方法都把搬运后的样本放到了大致正确的位置，但只有 NubOT 还原出了每个簇所需的重标，在目标簇更密处产生质量、更稀处消灭质量，而不会在不对应的簇之间泄漏质量。




图 2 合成基准上的不平衡样本映射。在每个场景 (a, b, c) 中，源（灰）与目标（蓝）结构相同，但平移和各簇采样比例不同。NubOT 与 ubOT GAN 预测搬运后样本的位置（中）与权重（右），每个簇旁的数字是其平均预测权重。两者都映射到了正确位置，但 NubOT 对匹配目标所需权重的预测要准确得多。

预测真实的药物响应

真正的考验是一份单细胞黑色素瘤药物响应数据集，由成像技术 4i 生成。它追踪 2 个共培养的黑色素瘤细胞系，用互斥的蛋白标记物 MelA 与 Sox9 加以区分，观察它们对 25 种不同药物的响应。细胞在 0h、8h 和 24h 被测量；只接触溶剂的对照细胞作为源，后续时间点的扰动群体作为目标。评价指标是预测扰动细胞与观测扰动细胞之间的加权核最大均值差异（MMD），对 NubOT 和不平衡 GAN 而言，这一差异由预测的逐细胞权重加权。




图 3 每种药物在 8h (左) 与 24h (右) 下，预测与观测扰动细胞状态的分布拟合（加权核 MMD，越低越好）。NubOT (红) 与 CellOT、ubOT GAN、Identity 基线以及 Observed (观测细胞的一个置换，近似下界) 对比。在 25 种扰动的几乎全部当中，NubOT 都不高于任何基线。

在真实任务上，NubOT 在几乎全部 25 种药物扰动中都胜过所有基线，包括 CellOT 和此前最先进的不平衡 GAN。而且它是在把质量变化也搞对、而不只是把特征映射搞对的前提下做到这一点的，这一组合正是它区别于那些位置对、重标却估错的方法之处。

预测出的权重在生物学上有意义吗

分布指标是可以被投机取巧的，因此更苛刻的问题是：预测出的质量变化是否对应真实的生物学。作者的检验方式是把 NubOT 在每个亚群内预测的权重求和，再与独立观测到的细胞计数作比较。在 8h，二者高度吻合，相关系数 $R = 0.95$ ($P = 2.2e-25$)。在 24h 则降到 $R =$

0.44 ($P = 0.004$)：对某些药物，诱导的细胞死亡过于严重，剩下的细胞太少而难以可靠评估，但整体趋势依然成立。

表 1 预测权重与观测细胞计数的相关性。

时间点	相关系数 R	P 值
8h	0.95	2.2e-25
24h	0.44	0.004

各亚群预测权重之和与观测到的细胞计数变化对比。8h 的强吻合在 24h 减弱，因为严重的药物诱导死亡使可观测群体收缩。

图 4 进一步考察权重落在特征空间的什么位置。预测权重与增殖标记物 Ki67 相吻合（在细胞分裂处权重大于 1），也与凋亡标记物相吻合（在细胞死亡处权重小于 1）。例如在 Ulixertinib 作用下，NubOT 预测 MelA 阳性群体增殖，并预测 Sox9 阳性群体在 24h 时细胞死亡增加，与实验观测一致。模型还原的是真实的增殖与死亡信号，而不是对分布的表面拟合。




图4 Ulixertinib 作用下对照细胞在 (a) 8h 与 (b) 24h 的 UMAP 投影, 按观测与预测的标记物取值、以及预测权重着色。NubOT 为 MeIA 阳性群体中增殖的细胞预测权重大于 1, 为 Sox9 阳性群体在 24h 增加的死亡预测权重小于 1, 与实验细胞计数测量一致。

小结

NubOT 给出的启示是：不平衡最优传输可以同时做到实用与生物学上的忠实。通过用可学习的半耦合重新表述它，并用循环一致的交替机制训练映射和重标函数，NubOT 在单细胞层面同时预测质量的移动与产生、消灭。在预测癌细胞系如何响应药物这一困难任务上，它胜过了以往的神经 OT 方法，而其预测的权重与已知的增殖、死亡标记物相吻合。

也应当如实说明它的边界。重标相关性在 24h 减弱，恰恰是药物诱导死亡把可观测群体变稀的时候，因此最凶险、致死性最强的情形仍然最难验证；而这里的结果也集中在同一个黑色素瘤系统、同一种成像技术上。尽管如此，显式地建模细胞的出生与死亡，而不是假设质量守恒，是朝着忠实预测那些真正驱动治疗结果的异质响应迈出的具体一步。