

ICLR 2024 | CFG 只是「一阶近似」：把无分类器引导写成泰勒展开

清华大学与华为提出 Inner Classifier-Free Guidance (ICFG)，无需重训即可为 Stable Diffusion 换来更好的保真度-多样性平衡

用扩散模型做文生图，几乎绕不开 classifier-free guidance (CFG，无分类器引导)。它用一个引导强度 w 在「图像更贴合文本」和「生成更多样」之间做取舍：调大更贴合、调小更多样。这个开关如今已是 Stable Diffusion 等模型的默认配置。

但 CFG 把「条件」当成一个不透明的标签，对条件所在空间的几何结构不作任何假设。当条件其实是连续的，比如一段文本经过 text encoder 得到的嵌入向量，这种连续性就被白白浪费了。一个自然的问题是：如果条件生活在一个有结构的连续空间里，我们能不能做得比朴素 CFG 更好，把这份被忽视的连续结构真正利用起来？

这篇 ICLR 2024 论文给出了一个新视角：Inner Classifier-Free Guidance (ICFG，内在无分类器引导)。作者把引导写成关于强度 β 的泰勒展开，于是我们熟悉的 CFG 恰好只是它的一阶项。补上二阶项，就能在完全不改动训练方式的前提下，为 Stable Diffusion 换来更好的保真度-多样性平衡，而且只需要几行额外代码。

论文：<https://openreview.net/forum?id=0QAziMq32X> (Shikun Sun 等，清华大学、BNRist、华为、中国科学技术大学)。

CFG 忽略了什么

要理解 ICFG 的出发点，不妨先看看采样过程内部到底发生了什么。作者记录了 Stable Diffusion 在采样时几个量的变化：条件得分 $\epsilon_{\theta}(x_t|c)$ 的范数、无条件得分 $\epsilon_{\theta}(x_t)$ 的范数，以及两者之差的范数，后者正是 CFG 真正用来「推」图像的引导方向。




图 1 Stable Diffusion 采样过程中的定量关系。在 50 步采样、扩散时间步 t 从 0 到 1000 的过程中，曲线分别是条件得分 $\epsilon_{\theta}(x_t|c)$ 的范数、无条件得分 $\epsilon_{\theta}(x_t)$ 的范数，以及两者之差的范数；前两幅图引导强度 $w=3$ ，后两幅 $w=80$ ，提示词统一为「一名宇航员骑马的照片」。可以看到条件与无条件得分的范数几乎重合，而真正承载引导信息的差值范数量级很小、且随时间非单调地起伏，正是这一结构启发了对高阶项的利用。

换句话说，两条得分曲线几乎贴在一起，真正决定引导方向的只是它们之间那点差异。CFG 只用一个线性权重放大这点差异，却没有利用条件空间本身的连续几何。作者假设：在 Stable

Diffusion 的文本嵌入空间里，条件近似构成一个「锥（cone）」结构，沿锥移动，就能获得 CFG 拿不到的新信息。

方法：把引导做成泰勒展开

ICFG 首先把「被增强的」中间分布写成一个幂次形式： $q_{\theta}(x_t | c, \beta) \propto q_{\theta}(x_t) \cdot [q_{\theta}(x_t | c) / q_{\theta}(x_t)]^{\beta}$ ，其中 $\beta = w + 1$ 。直觉上， β 控制了条件相对无条件被放大的程度。接着，作者对得分预测器 $\epsilon_{\theta}(x_t | \beta c)$ 关于 β 在 $\beta=1$ 处做泰勒展开。

关键在于：这个展开的一阶项恰好就是标准 CFG：CFG 并非引导的全部，而只是泰勒级数的第一项。二阶项则是全新信息，用一个位于 0 与 1 之间的中点 m 来估计，只需在缩放条件 mc 上多做一次前向计算。

落到实现上，二阶（非严格版）采样器可以写成： $\epsilon_t = \epsilon_{\theta}(z_i, c) + w \cdot [\epsilon_{\theta}(z_i, c) - \epsilon_{\theta}(z_i)] + (v / [m(1-m)]) \cdot [(1-m) \cdot \epsilon_{\theta}(z_i) + m \cdot \epsilon_{\theta}(z_i, c) - \epsilon_{\theta}(z_i, mc)]$ 。其中 w 之后的那一项就是原来的 CFG， v 之后的那一项是新增的二阶修正，需要用到额外的一次评估 $\epsilon_{\theta}(z_i, mc)$ 。因为所有量都来自已经训练好的网络，二阶 ICFG 可以几行代码「插进」现成的 Stable Diffusion，由一阶权重 w 和二阶权重 v 两个旋钮控制，无需任何重训。

结果：一次同时改善保真度与对齐度

作者在 MS-COCO 上做文生图评测：FID 衡量图像保真度（越低越好），CLIP Score 衡量图文对齐度（越高越好）。核心结论很直接：补上二阶项，就能把 CFG 的权衡曲线整体推向「更低 FID、更高 CLIP」。




图 2 不同 w 、 v 与条件空间 C 下的 FID-CLIP Score 权衡曲线。左图把 CFG 与多种二阶 ICFG 设置画在同一张「保真度(FID)-对齐度(CLIP Score)」平面上：ICFG 的曲线整体位于 CFG 的左下方，意味着在相近对齐度下 FID 更低。右图放大 $w=3$ 时全条件空间 C_{all} 与名词子空间 C_{nouns} 的对比。

最直接的对比是在相同引导强度下把两种方法摆在一起。以 $w=2.0$ 、 $v=0.25$ 、条件空间取 C_{all} 为例，二阶 ICFG 达到 FID 15.28 / CLIP 26.11，而同样设置下的 CFG 是 FID 15.42 / CLIP

25.80，两个指标同时更好。作者据此把最佳平衡点定在 $w=2.0$ 、 $v=0.25$ ，并观察到全条件空间 C_{all} 在权衡两个指标时拥有更有利的「锥」几何。

表 1 在 MS-COCO 验证集上比较 CFG 与二阶 ICFG ($v=0.25$, $C=C_{all}$)。

方法	w	FID ↓	CLIP Score ↑
CFG	1.0	17.24	25.03
CFG	2.0	15.42	25.80
CFG	3.0	16.68	26.12
ICFG ($v=0.25$)	1.0	16.40	25.46
ICFG ($v=0.25$)	2.0	15.28	26.11
ICFG ($v=0.25$)	3.0	16.59	26.37

消融：中点 m 、采样步数与 U-ViT

二阶项要用一个中点 m 来估计， m 取多少有讲究。作者扫过一遍发现 FID 呈「U」形曲线：两点靠得太近，估计不出长程的曲率；而 m 太接近 0 或 1，模型又很难对这些点打分，最佳值大约在 $m=1.1$ 处，对应 FID 15.42。

采样步数上 ICFG 也很省：在 C_{all} 上只用 10 步就能得到 FID 15.80，加到 50 步也只是温和改善到 15.28，二阶项的收益在很少步数下便已兑现。

为验证普适性，作者还在类条件的 U-ViT 架构上做了对照。如下表所示，训练预算越低，ICFG 优势越明显：50k 步时 FID 从 34.23 降到 24.69，而在 800k 步的高预算下也仍以 FID 7.92 对 8.10 小幅但稳定地胜出。

表 2 类条件 U-ViT 上 CFG 与 ICFG 的 FID（越低越好），按训练步数。

方法	50k	100k	400k	800k
CFG	34.23	13.64	8.76	8.10
ICFG	24.69	13.51	8.68	7.92

代价与边界

ICFG 并非没有代价：二阶采样每步需三次而非两次前向计算（多一次用于估计 m_c 处得分），采样时间随之增加，但可复用前序采样点来摊薄。其训练策略也依赖更精确的数据配对，可借助相关性度量 $r(x, c)$ ，也就是衡量条件与数据契合程度的指标来缓解。

小结

一句话总结：CFG 并非「基本原理」，而只是内在无分类器引导的一阶近似。这样看待引导，补上二阶便顺理成章，无需重训即可为 Stable Diffusion 换来更好的保真度-多样性平衡；因为整个框架是一条泰勒级数，当条件空间具备合适的「锥」结构时，它还自然指向了更高阶的引导。