

损失曲线很平稳，回报却在剧烈抖动：SGD 噪声的「蝴蝶效应」

ICLR 2024 · MIT 与 Microsoft Research NYC：把长程训练不稳定追溯到优化器噪声，解法是对权重做指数滑动平均（EMA）。

你训练一个模仿学习的策略，盯着行为克隆（behavior cloning）的损失一路下滑、最后趋于平稳，于是判断训练很健康——屏幕上所有信号都在支持这个结论。可当你真正把策略放回环境里跑一遍，去看你真正在乎的那个指标，也就是长程回报（long-horizon reward），它却在相邻两个 checkpoint 之间从「接近专家」猛地掉到「接近失败」。损失很平静，回报却很混乱。这篇论文讲的就是这道裂缝，以及它为什么如此容易被忽略。

这道裂缝之所以重要，是因为现代模型几乎都活在反馈回路里：语言模型的下一个 token 取决于它自己已经生成的 token，控制器的下一次观测取决于它刚刚采取的动作。但我们训练它们时，几乎总是用一个替代目标（surrogate objective）——下一 token 预测、单步模仿——悄悄假装这个回路不存在。替代目标往往平滑下降，于是我们放心地信任它。又因为在每个 checkpoint 都跑一遍真实任务、评估真实回报的代价很高，这些抖动通常根本看不见，你随手拿到的那个 checkpoint 很可能就是个糟糕的。




图 1. 用 4 层 MLP 对 Walker2d-v4 专家做行为克隆，rollout 长度 $H = 1000$ 。回滚回报（蓝色）在训练迭代之间剧烈摆动，而单步 BC 误差（灰色）始终平稳且很低。对权重取指数滑动平均后的模型（绿色）几乎完美地贴合专家策略（红色虚线）。你在乎的回报在震荡，你盯着的损失却从不显示这一点。

作者的判断是：罪魁祸首既不是数据也不是模型，而是优化器自身的噪声。小批量 SGD 的梯度噪声，对单步训练损失完全无害，却会通过闭环被放大成长程回报的剧烈震荡。他们把这个机制命名为梯度方差放大（gradient variance amplification, GVA），论证它是算法性的而非统计性的，并证明一个几乎免费的解法——对权重取指数滑动平均（EMA）——能在连续控制和自回归语言模型上同样有效地驯服它。

论文：<https://arxiv.org/abs/2310.11428>（Block、Foster、Krishnamurthy、Simchowitz、Zhang；MIT 与 Microsoft Research NYC）。

你盯着的损失，不是你想要的回报

行为克隆是模仿专家最朴素的做法：收集示范数据，最小化一个单步预测误差，也就是 BC 损失。理论上，把这个误差压到零，你就复现了专家策略。可现实中，配上深度网络和有限算力，故事要古怪得多。作者刻意让数据量与 rollout 长度相等（ $N = H = 1000$ ），以排除过拟合这个解释，结果回滚回报依然在相邻迭代之间大幅震荡。

放大到连续几步梯度更新来看，这一点更加触目：把回报看成策略参数的函数，它是一张锯齿状、近乎分形的曲面，好策略与坏策略沿着随机梯度方向紧挨在一起。而这些锯齿在单步 BC 目标里完全看不出来——这正是为什么盯着训练损失会给人虚假的安心。回报和替代目标，已经彻底脱钩了。

排除常见嫌疑：GVA 是算法性的，不是统计性的

对这种震荡有两种可能的解释。一种是统计性的——数据不够多，或模型容量不足。另一种是计算性的、即算法性的——问题出在优化过程本身。为了把两者分开，作者做了一轮罕见地彻底的扫描，在连续控制任务上进行了 278 次不同的干预，逐一改变数据量（一直到近乎无限的数据）、结构（从 2 层到 6 层的 MLP，再加上 Transformer）、模型规模，以及一整套正则化手段，比如 dropout、权重衰减和数据增广。




图 2. 回滚回报（蓝色为 20 个初始条件上的均值，青色为逐条 episode 的回报）在改变结构、数据量、模型规模和正则化手段时始终保持锯齿状，只有方差缩减策略（底行）才能把它压平。标准正则化手段并不能消除震荡，反而常常让它更糟——这说明不稳定是算法性的、由 SGD 噪声驱动，而非统计性的。

图 2 这一张图，几乎就是整个论证。震荡不会因为数据变多、结构改变或加了正则化而消失——正则化往往还让它更糟。它只对真正的方差缩减低头：大得多的批量、激进的学习率衰减、大动量，以及最干净利落的一招——迭代平均。这恰好就是「梯度噪声是元凶」时你会预期看到的指纹，因为只有削减这份噪声才应当奏效。作者把这个机制称作梯度方差放大：单步几乎可忽略的 SGD 噪声，在 rollout 的闭环中被层层放大。

解法：对你的迭代取平均

如果病根是梯度噪声，那么取平均就是最显然的药方，而且效果好得惊人。对权重维护一个指数滑动平均，每一步都更新： $\theta \leftarrow (1 - \gamma) \cdot \theta + \gamma \cdot \theta$ ，然后拿这个被平均过的模型去评估。它的代价只是多存一份参数，既不改动学习率调度，也不改动批量大小，更不会拖慢底层优化器。




图 3. EMA (绿色) 在不同结构、更小的数据集，以及更多 MuJoCo 任务 (Hopper、Ant、HalfCheetah、Humanoid) 上，把原始迭代的回报震荡 (浅蓝) 统统压平，且完全不动调学习率调度或批量大小。配方很关键：每一步都更新，配上 burn-in 预热和退火的平均率；跳过 burn-in 或更新得太稀疏 (中列) 都会削弱效果。

图 3 显示这剂药方在不同结构、不同数据量以及其他运动任务上都成立。配方是具体的：在每一次迭代都更新平均，用一段初始 burn-in 把早期粗糙的权重排除掉，并让平均率按 $\gamma(t) = t^{(-\alpha)}$ 退火。跳过 burn-in，或只是偶尔更新平均，它的稳定作用就会减弱。此外还有附赠好处：当数据稀缺时（少到 0.1x 的轨迹），震荡会更严重，而 EMA 能把这一点转化为实打实的样本效率提升；EMA 甚至可以替代学习率衰减。

表 1. 各种干预手段对 GVA 引起的回报震荡有何影响。只有真正的方差缩减才管用，而迭代平均以几乎为零的代价拿到了这个效果。

策略	能否压住震荡？	代价
标准正则化 (dropout、权重衰减、数据增广)	不能——有时更糟	低
激进的学习率衰减	能	算力高
大批量 (借助梯度累积做到 16x)	能	算力高
迭代平均 (EMA)	能——最稳健	几乎免费

语言模型里同样的蝴蝶效应

GVA 并不是机器人控制的专属怪癖。作者用在 TinyStories 上训练的 270M 参数 (12 层) Transformer 重现了整个故事——TinyStories 是一个由简单儿童故事构成的小型合成语料。在一条平滑单调下降的验证损失曲线之下，相邻 checkpoint 的下一 token 损失只有极其微小的波动，然而它们用 argmax 解码生成的文本却分岔成了完全不同的故事：相邻迭代在 >50% 的带提示补全上彼此不一致，而 EMA 迭代之间这个比例低于 <5%。




图 4. 自回归语言建模中的 GVA：在 TinyStories 上训练的 270M 参数（12 层）Transformer。EMA 模型的验证损失（绿色）在整个训练过程中都低于原始模型（蓝色），并达到最低困惑度。在这些平滑曲线之下，相邻训练 checkpoint 生成的故事却各不相同——正是控制任务里那种迭代到迭代的蝴蝶效应。

被平均过的模型带来的不止是生成上的稳定。因为 EMA 把优化和稳定化解耦，它让你可以在恒定学习率下训练、省去通常的末段衰减，从而减轻过拟合，并在对比中得到困惑度最低的模型。同一个几乎免费的小技巧，既能稳住一个行走的机器人，也能训出一个更好的语言模型。

一个简短的理论小品

为了说明这种放大并非深度网络的产物，作者在一个带不连续「悬崖损失」的简单确定性控制设定里补了一段凸优化小品。在那里，一个只把 BC 损失改变了 $H \cdot \delta^2$ 量级的参数扰动 Δ ，却能把长程回报的差距按 $\exp(H \cdot \delta)$ 的因子放大——在 rollout 长度 H 上呈指数增长。一份对单步目标可忽略不计的误差，一旦在长回滚上层复合，就会变得灾难性。这样一看，实验里的蝴蝶效应，恰恰就是闭环动力学理应产生的东西。

该带走什么

结论既简单又可操作。随机梯度噪声对你监控的那条单步损失是隐形的，可一旦你的模型置身于反馈回路，同一份噪声就会被放大成混乱的长程失败——这就是梯度方差放大。所以在任何闭环场景里，一条平坦的替代损失都不能当作部署行为稳定的证据；而迭代平均值得被当作一等公民的「稳定器」，与优化器和调度器并列：便宜、普适，从机器人控制到语言生成都用得上。

如果只从这篇论文里带走一个习惯，那就让它是这个：在任何模型置身于回路的场景里，都对权重维护一个指数滑动平均，经过一小段 burn-in 之后每一步都更新，并用这个被平均过的模型、而不是最新的那个迭代去评估。它几乎不花成本、也很少帮倒忙，而且——正如会走路的机器人和 TinyStories 语言模型都展示的那样——它能把一段剧烈震荡的训练，变成一段稳定、可部署的训练。

也要诚实地说清边界。这个机制是实验诊断出来的，靠凸优化小品而非一套完整的深度模仿理论来支撑，而且 GVA 的严重程度因任务而异——比如维度更高的 Humanoid，震荡就要温和得多。但抛开这些，实用的讯息依然成立：当一个模型在回路里行动时，去看回报、去缩减方差、去平均你的权重。