

ICML 2024 | 把图神经网络的节点「集体」认证，而不是逐个认证

面向图注入攻击的首个集体式鲁棒性认证方案，把认证比例从 0% 提升到 80% 以上

图神经网络（GNN）支撑着引文检索、推荐系统、欺诈检测等诸多应用，但它们出奇地容易被欺骗。图注入攻击（graph injection attack，GIA）只需向图中注入少量恶意节点，把它们连到几个真实的目标节点上，就能悄悄改写模型的预测。

当模型守护着重要的东西时，我们想要的不仅是「看起来鲁棒」，而是认证鲁棒性（certified robustness）——一种数学保证：只要攻击者不超过给定的预算，预测结果就不会改变。问题在于，现有针对注入攻击的认证方法都是一次只考虑一个目标节点。这种逐样本（sample-wise）的视角过于悲观：一旦攻击预算稍有增加，它的认证比例就会跌到 0.0%，几乎认证不了任何一个目标节点。

这篇来自香港理工大学、发表于 ICML 2024 的论文，从真实攻击的运作方式出发给出了一个朴素的观察：攻击者无法为每一个想欺骗的节点单独变出一张图；他们注入的是同一张扰动图，而这一张图必须同时干扰整个目标节点集合。如果把整个目标集合「集体」地一起认证，而不是逐个认证，保证就会强得多。由此，作者提出了首个面向图注入攻击的 GNN 集体式认证方案。




图 1 集体认证的核心思想。逐样本认证（上方黄框）假设攻击者能为每个目标节点单独构造一张扰动图，因而极度保守；集体方案（下方）只面对同一张扰动图，用一个线性规划同时刻画所有目标节点的最坏情形，从而认证出更多鲁棒节点（右侧带盾标记）。

论文：<https://arxiv.org/abs/2403.01423>
代码：<https://github.com/Yuni-Lai/CollectiveLPCert>

代

逐个认证为什么行不通

逐样本认证隐含了一个不切实际的假设：攻击者可以针对每个目标节点分别定制一张扰动图。现实中攻击者只能提交同一张图。此前唯一的集体式方案（Schuchardt 等，2020）是为边修改攻击设计的，它假设感受野（receptive field）固定不变；而 GIA 在注入节点后还会添加新边，会扩大感受野，因此那套方法无法直接迁移到注入攻击上。集体认证必须为注入攻击彻底重新构建。

从最坏情况攻击者到一个线性规划

该认证建立在节点感知的双重平滑（node-aware bi-smoothing）之上：随机删除边和节点，以模糊攻击者的影响，再对平滑后的图进行分类。关键在于局部性（locality）——一个注入节点，只有在与目标节点之间至少存在一条经过平滑后仍然「存活」的消息传递路径时，才可能影响该目标。作者据此对这种消息干扰的概率 $p(E_v)$ 给出上界，并把它转化为「某个目标节点仍然可认证鲁棒」的明确条件。

为了对整个集合联合认证，作者直接提出对抗性的问题：在最多注入 p 个节点、每个注入节点最多连 τ 条边的预算下，最坏情况的攻击者最多能同时攻破多少个目标节点？这个预算分配问题是一个二值整数二次约束线性规划（binary integer quadratic constrained linear program, BQCLP），而它是 NP 难的。

论文的工程贡献在于把这个困难的整数规划松弛成一个普通的线性规划（LP），求解器几秒即可求解。由于 LP 的可行域比整数规划更大，它给出的答案始终是真实认证比例的一个可靠下界——认证永远不会高估。作者给出两种松弛：Collective-LP1 对二次项采用标准线性化，需要 $O(p^2|T|)$ 个额外变量；Collective-LP2 是一种定制化重构，先把二次项合并，把额外变量降到 $O(p|T|)$ ，同时提升了解的质量和速度。

集体认证到底带来多少收益

作者在两个标准引文图上评测——Cora-ML（2,810 个节点、7,981 条边、7 类）与 Citeseer（2,110 个节点、3,668 条边、6 类），骨干网络为 GCN 与 GAT（隐藏层维度 64）。注入节点预算 p 从 20 一直扫到 160，每个注入节点的连边上限 τ 取各图的平均度（Cora-ML 为 6，Citeseer 为 4）。平滑分类器用 $N = 100,000$ 次蒙特卡洛采样、置信水平 $\alpha = 0.01$ 估计，所有 LP 都统一通过 CVXPY 调用 MOSEK 求解器完成计算。

结果的反差是天壤之别。随着注入节点数增加，逐样本基线迅速塌陷到零，而两种集体认证都稳稳守住。




图 2 Cora-ML 上认证比例随注入节点数 ρ 的变化 ($\tau = 6$, $\alpha = 0.01$, $N = 100,000$)。逐样本曲线在很小的 ρ 处就骤降到 0，而集体曲线在重度攻击下依然能认证很大一部分目标，其中 Collective-LP2 始终位于最上方。

在 Citeseer 上、当注入节点数 $\rho = 140$ 时，逐样本认证只能认证 0.0% 的目标节点，而 Collective-LP1 认证了 73.0%、定制化的 Collective-LP2 更是达到 81.2%。Cora-ML 上呈现同样的规律，见下表。

表 1 Cora-ML 上认证比例随注入预算 ρ 的变化 ($\tau = 6$, $p_e = 0.7$, $p_n = 0.9$)。逐样本认证几乎立刻跌到 0.000，而 Collective-LP2 始终显著高于另外两者。

方法	$\rho = 20$	$\rho = 50$	$\rho = 100$	$\rho = 120$	$\rho = 140$
Sample-wise	1.000	0.000	0.000	0.000	0.000
Collective-LP1	0.920	0.768	0.452	0.316	0.178
Collective-LP2	0.926	0.836	0.686	0.624	0.564

Collective-LP2 在各种设置下都不逊于、甚至优于 Collective-LP1；在 Cora-ML 的一组设置下 ($p_e = 0.7$, $p_n = 0.9$, $\rho = 140$)，它把认证比例相对提升了 216%。

快到足以实用

一个认证方法只有真正算得出来才有用，而定制化松弛在这里带来了第二重回报——运行时间。




图 4 Cora-ML 上两种集体 LP 模型的运行时间对比。Collective-LP1（上方曲线）的耗时随 ρ 超线性增长，在大预算下冲到 1000 秒以上；Collective-LP2（下方曲线）几乎保持水平，始终维持在约 1 分钟。

Collective-LP1 的运行时间超线性增长，在大预算下超过 1000 秒；而 Collective-LP2 即便在 $\rho = 140$ 时也保持在约 1 分钟，在高端预算处大约快 700 秒。能在约 1 分钟内为数千个节点求出认证，正是让集体方案从「理论可行」走向「实际可用」的关键。

松弛的代价

把 NP 难的整数规划松弛成 LP，会带来一个显而易见的担忧：这个下界有多松？为了度量它，作者把 Collective-LP2 与精确的整数 BQCLP 作比较——后者只有在很小的预算（ $\rho \leq 12$ ）下才可解。差距很小：认证比例上大约只损失 5%。也正是这 5% 的损失，解释了集体方案唯一会落后于逐样本的地方——在极小的 ρ 处，逐样本本已接近完美，松弛的代价便显现了出来。

为什么重要

这个教训很凝练：把一组节点集体地一起认证，而不是逐个认证，就能把近乎无用的 0.0% 保证，变成面向图注入攻击的 80% 以上认证比例；而定制化的 LP 松弛让它在约 1 分钟内可解。由于集体方案复用了与逐样本认证相同的平滑分类器，它是对现有认证的补充而非替代，在大小攻击预算下都能保持强劲。

当然，评测覆盖的是两个引文图与消息传递型 GNN，认证也继承了随机平滑的假设；把这一保证扩展到更大规模的图和其他领域，仍留待未来工作。但即便如此，从 0% 走到 80% 以上，已经是朝着「能在真实的单图注入攻击下站得住脚的可证明防御」迈出的实实在在的一步。