

NeurIPS 2022 | 给 Vision Transformer 的切分学习补上隐私：DP-CutMixSL

延世大学、MIT 等提出 patch 级随机 CutMix，让 split learning 在更强隐私下反而更准

分布式训练里一个反复出现的诉求是：在不把用户数据集中到一处的前提下训练模型。两条主流路线各有分工。联邦学习（federated learning）让原始数据留在本地、只交换模型参数；切分学习（split learning）则把模型切成两段，客户端只把切割层（cut-layer）的中间激活，也就是所谓的「smashed data」，上传给服务器。谁传得少、谁泄露得少，是这两条路线长期博弈的核心。

但 Vision Transformer（ViT）的普及打破了切分学习原本的隐私假设。ViT 没有 CNN 那样的 pooling 和 convolution 层，切割层输出的 smashed data 几乎不对输入做压缩失真，因此和原图在视觉上高度相似。相似意味着两件坏事：一是反演攻击更容易还原出原始图像，隐私更脆弱；二是保留的信息太多，通信开销也更大。

这篇发表于 NeurIPS 2022、来自延世大学、Deakin、MIT 与奥卢大学的工作提出了 DP-CutMixSL：先按高斯差分隐私机制给 smashed data 加噪，再在 patch 粒度上把不同客户端的激活随机 CutMix 拼接起来。作者证明这一步能收紧 Rényi 差分隐私（RDP）的隐私界，而实验里它还反过来提升了精度，隐私和精度这次不必二选一。

论文 Paper：<https://arxiv.org/abs/2210.15986>

为什么 ViT 让切分学习更容易泄露

先厘清两条路线的取舍。联邦学习把原始数据锁在本地，代价是要来回搬运整个模型；而 ViT 参数量大，在边缘设备上反复传输整模型的能耗和通信成本都很高。切分学习换了个思路：只在切割层交换 smashed data，模型本体不动，通信量本该更省。

问题恰恰出在 ViT 的结构上。因为缺少 pooling 与 convolution，ViT 隐藏表征对输入的失真极小，smashed data 与原图之间的互信息很高。换句话说，服务器收到的中间激活「太像」原图了：既方便攻击者做反演还原，也让本想省下的通信量重新变大。切分学习针对 CNN 时代总结出的那套隐私假设，在 transformer 上不再成立，这正是本文要重新回答的问题。

一图看懂 DP-CutMixSL

本文的核心贡献 DP-CutMixSL，可以先用一张整体流程图建立直觉：它把「加噪」和「跨客户端混合」两步串联在服务器之前，让每个客户端只暴露一小部分、而且是带噪的 smashed data。




图 1 DP-CutMixSL 的整体流程。mixer 为各客户端生成互补的伪随机二值掩码；每个客户端先按高斯 DP 机制加噪、再按掩码做 Cutout，得到 DP-Cutout smashed data；服务器把不同客户端的互补 patch 相加，拼成 DP-CutMix smashed data，之后照常做前向与反向传播。关键在于：每个客户端始终只上传被掩码遮挡后、且加过噪声的一部分 smashed data。

整个流程分四步。第 0 步，一个 mixer（可以是第三方）生成一组互补的伪随机二值掩码，分发给各客户端；第 1 步，每个客户端按高斯 DP 机制给自己的 smashed data 加白噪声；第 2 步，用各自的掩码把激活「打孔」成 Cutout smashed data；第 3 步，服务器把不同客户端留下的互补 patch 直接相加，得到没有空洞的 DP-CutMix smashed data。由于各客户端的掩码在 patch 层互斥且完备，相加后不会出现空白 patch，而任何一个客户端也从未把完整的 smashed data 交出去。

方法细节与隐私证明

把流程展开来看：mixer 从 Dirichlet 分布抽取混合比例 λ （各客户端的 λ 之和为 1），并据此生成二值掩码，某个客户端掩码里「保留」的 patch 数量正比于它的 λ 。客户端把输入过一遍下段模型得到 smashed data，用二值序列做掩码得到 Cutout smashed data，再叠加白高斯噪声，就是要上传的 DP-Cutout smashed data。

服务器端更简单：因为掩码互斥且完备，它只需把不同客户端的带噪 Cutout smashed data 相加，就得到 DP-CutMix smashed data，同时按同样的 λ 权重混合标签。此后的前向、反向传播与普通切分学习完全一致。这样一来，暴露给服务器的既只是每个客户端的一部分 patch，而且这部分还是加过噪的。

隐私一侧，作者证明了三种机制的 RDP 预算存在固定次序： $\epsilon_{\text{Mix}} \leq \epsilon_{\text{CutMix}} \leq \epsilon_{\text{O}}$ ，其中 ϵ 越小代表隐私越强。这一不等式说明，patch 级随机 CutMix 相比原始的 DP-SL 能收紧隐私界，同时它的隐私增益又被像素级 Mixup 版本从下方 bound 住，也就是说收紧是有限度的，而不是无限变强。

为什么是 patch 级 CutMix，而不是像素级 Mixup

把 CutMix 放到 patch 层，并不是随手的选择，而是顺着 ViT 的三点特性推导出来的。其一，没有 pooling，隐藏表征几乎不失真，因此在表征上做正则化和直接在输入上做几乎等效；其二，自注意力捕捉的是全局空间信息，对图像局部施加的大噪声相当鲁棒，这天然适合 Cutout / CutMix 这类「遮一块、换一块」的操作；其三，ViT 的一切运算本来就发生在 patch 层。三点叠加，指向的正是「在隐藏表征上做 patch 级随机 CutMix」。




图 2 三种插值方案在图像上的直观对比。从原图（Raw Image）及其 Cutout 版本出发：Patch CutMix 只在 patch 粒度替换内容、保留每个 patch 内部的局部结构；CutMix 替换的是一块连续区域；Mixup 则把两张图整体按比例叠加。论文在 smashed data 上做的是对应的同类操作。

对比之下就能看出差别：Mixup 把两张图整体融在一起，局部结构被抹平；patch CutMix 只在 patch 之间做替换，每个 patch 内部依旧清晰。对依赖全局注意力的 ViT 来说，打乱 patch 排列几乎不损失可用信息；但对偏重局部特征的 CNN，整块替换 patch 反而会丢掉更多信息，这也预告了后面 VGG-16 上会出现的那个例外。

结果：隐私更强，精度反而更高

先看无噪声设置下的精度对比（论文 Table 1）。实验覆盖 CIFAR-10 与 Fashion-MNIST 两个数据集，以及横跨 CNN 到 transformer 谱系的三种模型：ViT-Tiny（纯 transformer）、PiT-Tiny（带 pooling、介于两者之间）、VGG-16（卷积网络），客户端数 $|C| = 10$ ，切割层都放在 embedding 之后。CutMixSL 在几乎所有配置上都取得最高 Top-1 精度。

表 1 CIFAR-10、无噪声设置下的 Top-1 精度（%）。CutMixSL 在 ViT-Tiny、PiT-Tiny 上明显超过最佳基线，但在卷积网络 VGG-16 上略逊于 SL + Mixup。

模型（CIFAR-10，无噪声）	最佳基线	CutMixSL
ViT-Tiny	67.88 (SplitFed)	73.77
PiT-Tiny	55.63 (SplitFed)	71.26

VGG-16	68.20 (SL + Mixup)	67.53
--------	--------------------	-------

在 CIFAR-10 加 ViT-Tiny 上，CutMixSL 达到 73.77%，比普通切分学习的 57.21% 高出 16.56 个百分点，也比 SplitFed 的 67.88% 高 5.89 个百分点；换成 PiT-Tiny，它的 71.26% 同样大幅领先 SplitFed 的 55.63%。在 Fashion-MNIST 加 ViT-Tiny 上，它取得 89.75%，是所有方法里最高的。唯一的例外是 CIFAR-10 加 VGG-16：此时 SL + Mixup 的 68.20% 略高于 CutMixSL 的 67.53%。这与前面的直觉一致：卷积网络更看重局部信息，整块替换 patch 造成的损失比 transformer 更大，所以 Mixup 更适合 CNN，而 patch CutMix 更适合 ViT。

隐私与精度的权衡

加上噪声后，精度和隐私如何联动？作者扫描了不同的噪声方差，同时报告精度和 RDP 隐私预算 ϵ 。




图 3 CIFAR-10 上，随噪声方差 σ^2 变化的精度 (Acc@1, 蓝色, 左轴) 与 RDP 隐私预算 ϵ (橙色, 右轴)。DP-CutMixSL 在几乎每个噪声水平上精度最高；它的 ϵ 比 DP-SL 更小 (隐私更强)，但比 DP-MixSL 略大，这正是精度与隐私之间的权衡。

图里可以读出一个清晰的权衡：DP-CutMixSL 在几乎每一个噪声水平上都拿到最好的精度，且始终优于 DP-MixSL；在隐私一侧，它的 ϵ 比 DP-SL 更紧 (隐私更强)，却比 DP-MixSL 更松，这与前面证明的 ϵ 次序完全吻合，因为 Mixup 会把信息摊薄到整张表征上。作者还观察到，扩大混合的客户端组会同时拉低精度和 ϵ ，他们将其归因于一种「藏在人群里」的效应。

另有两组补充实验。反演攻击 (论文 Table 2) 按重建 MSE 衡量鲁棒性，排序为 Cutout > patch CutMix > Mixup > 原始 smashed data：patch CutMix 的重建误差约为 0.0434，而原始 smashed data 仅 0.0056，把反演难度抬高了约 8 倍。可扩展性方面，客户端数从 2 增加到 10

时精度持续提升；再叠加 SplitFed 式的下段模型参数平均（记作 CutMixSFL），还能进一步提高。

小结与边界

这篇工作给出的结论是：对 Vision Transformer 而言，切分学习里的精度与隐私不必互相牺牲。先加高斯噪声、再跨客户端混合随机遮挡的 patch，DP-CutMixSL 既相对普通切分学习收紧了差分隐私界，又提升了精度，而且这份隐私增益被一个 Mixup 版本可证明地 bound 住。它之所以成立，是因为 transformer 依赖全局自注意力、又天然在 patch 层运算，换掉整块 patch 对它几乎无损。

边界也很明确。这套方法是为 transformer 量身定制的：在偏重局部特征的卷积网络（如 VGG-16）上，patch CutMix 反而略逊于 Mixup。隐私上的收紧同样有上限：它被 Mixup 版本从下方 bound，并不是可以无限增强的免费午餐。放在更大的图景里，patch 级 CutMix 更像是一种为「transformer 时代的分布式学习」专门设计的隐私正则化手段。