

ICLR 2024 | 一台笔记本就能解的 Schrödinger Bridge

LightSB 把熵正则最优传输 (Entropic Optimal Transport) 压缩成一个高斯混合目标：CPU 上几分钟出结果，无需对抗训练，并且被证明是 Schrödinger Bridge 的通用逼近器。

Schrödinger Bridge (薛定谔桥) 想回答一个看似简单的问题：给定两个概率分布，把其中一个「搬」到另一个上，最自然的随机路径是什么？这里的「最自然」，指的是在所有满足两端边缘分布的扩散过程中，与参考的 Wiener 过程（也就是普通布朗运动）最接近的那一个。它是熵正则最优传输 (Entropic Optimal Transport, EOT) 的动态形式，在机器学习里出现得非常频繁：从追踪单细胞随时间的分化，到无配对的图像风格迁移，再到生成模型。

问题在于，真正把一个 Schrödinger Bridge 算出来，如今几乎成了「重装备」的代名词。主流求解器往往要堆叠好几个神经网络，依赖对抗式的 min-max 目标或迭代比例拟合 (IPF)，并且在训练的每一步都要模拟整条随机过程。它们需要精心设计网络结构，在 GPU 上一跑就是几个小时，还对一长串超参数很敏感。这个领域有很强的求解器，却始终缺一个简单、可靠的默认基线，也就是 Schrödinger Bridge 版本的「k-means / Sinkhorn」，那种你会最先拿来一试、之后再考虑要不要上更复杂方法的工具。

来自 Skoltech 与 AIRI 的论文 Light Schrödinger Bridge (LightSB)，目标正是成为这样一个基线。它的核心思路是：把 Schrödinger 势函数 (Schrödinger potential) 参数化成一个高斯混合 (Gaussian mixture)，再把这个势函数的对数看作一个能量函数 (energy function)。在这样的选择下，整个问题坍缩成一个非 min-max 的单一优化目标，而其中最关键的两部分：传输计划与过程的漂移项 (drift)，都能写出闭式表达式。最终，它在中等维度上几分钟内、仅用 CPU 就能求解 Schrödinger Bridge，几乎不用调参，并且被证明是 Schrödinger Bridge 的通用逼近器 (universal approximator)。



图 1 LightSB 在 ALAE 自编码器的 512 维隐空间中完成的无配对「男→女」人脸迁移 (1024x1024 的 FFHQ 图像)。每行最左为真实男性照片；由于桥是随机的，同一个输入会对应一片合理输出。4 个 CPU 核心上不到 1 分钟收敛。

论文：<https://arxiv.org/abs/2310.01174>

代码：<https://github.com/ngushchin/LightSB>

问题：求解器很重，却没有基线

严格来说，源分布 p_0 与目标分布 p_1 之间的 Schrödinger Bridge，就是在被这两个边缘分布「钉住」的所有扩散过程里，与 Wiener 先验的 KL 散度最小的那一个。噪声水平 ε 决定了过程可以「乱走」到什么程度： ε 小，轨迹几乎笔直、近似确定性； ε 大，轨迹就会明显扩散。解出这座桥，同时会得到一个传输计划 $\pi^*(x_1 | x_0)$ （某个起点最可能落到哪里），以及连接两端的完整时间演化过程。

但在多数实际应用里，人们真正在意的只有两端。做单细胞研究的人想把早期某天的细胞映射到较晚某天，做图像迁移的人想把一个域翻译成另一个域，他们关心的是条件计划 $\pi^*(x_1 | x_0)$ ，而不是每条中间轨迹的精确形状。「用很重的神经网络去完成一个其实并不复杂的目标」，这种错配正是 LightSB 想要弥合的落差。要建立直觉，不妨先在二维上看看它要连接的是什么。




图 2 一个二维玩具问题：让 LightSB 把输入的高斯分布（绿色，源分布 p_0 ）搭桥到瑞士卷形状的目标（橙色，目标分布 p_1 ）。正因为求解器足够轻，才能低成本地在这种任务上观察噪声水平 ε 如何改变学到的过程： ε 小时传输近乎笔直， ε 增大时轨迹会明显变得更「摇摆」。

LightSB 是怎么做到的

LightSB 从最自然的目标出发：直接最小化 $KL(\pi^* \parallel \pi_\theta)$ ，也就是真实 EOT 计划 π^* 与参数化计划 π_θ 之间的散度。障碍很明显：我们并不知道真实计划 π^* 。关键的观察是，其实不需要知道。最优计划有已知的形式，可以写成 $\pi_\theta(x_1 | x_0)$ 正比于 $\exp(\langle x_0, x_1 \rangle / \varepsilon) \cdot v_\theta(x_1)$ ，于是唯一还需要学习的对象，就只剩下那个调整之后的 Schrödinger 势函数 v_θ 。换句话说，这一步把问题从「学习整个传输计划」缩小成了「只学习一个势函数」。

LightSB 把这个势函数参数化成一个未归一化的高斯混合： $v_{\theta}(x_1) = \sum_k \alpha_k \cdot N(x_1 | r_k, \varepsilon S_k)$ 。仅这一个选择，就让两个原本难算的量变得有闭式解：计划的条件分布 $\pi_{\theta}(x_1 | x_0)$ ，以及归一化常数 $c_{\theta}(x_0)$ 。有了它们，KL 目标就能改写成两个期望之差，即在源分布上取 log 归一化常数、在目标分布上取 log 势函数，两者都能用样本做 Monte Carlo 估计，并用普通的随机梯度下降（SGD）来最小化。

$$L(\theta) = E_{\{x_0 \sim p_0\}}[\log c_{\theta}(x_0)] - E_{\{x_1 \sim p_1\}}[\log v_{\theta}(x_1)]$$

整个过程没有 min-max 博弈，没有迭代比例拟合，训练时也不需要模拟任何轨迹，而这三样恰恰是过去求解器又慢又脆的根源。又因为同一个学到的势函数能直接给出闭式的漂移项，一旦真的需要中间动态，完整的桥过程可以在事后重建出来。作者还证明了这个高斯混合求解器是 Schrödinger Bridge 的通用逼近器（并指出这是首个此类结果），并说明其泛化误差会以标准的参数收敛速率随样本量增加而消失。

结果：既准又快

第一项测试用的是一个已知真实计划的基准（Gushchin et al., 2023b），覆盖维度 $D = 2$ 到 128、噪声水平 $\varepsilon = 0.1、1、10$ 。在这里 LightSB 不只是有竞争力，而是大幅领先：它的条件 Bures-Wasserstein 误差（cBW-squared-UVP）落在约 0.03% 到 0.62% 之间，而此前最好的求解器则在约 1.04% 到 18.05% 之间。当目标分布越贴合 LightSB 的高斯混合归纳偏置，这个差距就越大。

更抢眼的是速度。在 MSCI 单细胞数据集上（来自四位捐赠者、跨越多天的细胞，经 PCA 投影到 50、100、1000 维），LightSB 在能量距离（energy distance）上与强大的 GPU 求解器持平，却只用 4 个 CPU 核心、耗时 65 到 146 秒完成训练，而那些连续型基线在 V100 GPU 上大约需要 8 到 71 分钟。最难的设置最能说明问题：CPU 上的能量距离为 1.27，而一个 min-max GPU 求解器为 1.32，两者相当，但 LightSB 的训练耗时只是后者的零头。

表 1（DIM = 1000 的 MSCI 单细胞任务）：LightSB 在能量距离上追平一个强大的 min-max GPU 求解器，训练却只用 CPU、耗时只是其零头（数据取自论文）。

求解器	能量距离（越低越好）	硬件	训练时间
LightSB（本文）	1.27	4 个 CPU 核心	146 秒
Minimax 求解器	1.32	V100 GPU	71 分钟

同样的「轻」也延续到了维度高得多的问题上：在预训练 ALAE 自编码器的 512 维隐空间中做无配对人脸迁移。LightSB 在这里完成「男→女」与「成人→儿童」的迁移，同样在 4 个 CPU 核心上不到一分钟就收敛。由于计划是随机的，一张输入人脸会得到一片合理的输出，而不是唯一确定的结果。



图 3 两张不同源人脸（每对的左侧）上的「男→女」迁移，以及 LightSB 给出的结果（右侧）。迁移在改变目标属性的同时，保留了姿态、光照、表情等与身份相邻的细节，全部在 ALAE 隐空间中、无需配对训练数据学得。

ϵ 到底带来了什么

噪声水平 ϵ 是真正会改变解的「性格」的那个旋钮，而二维「高斯→瑞士卷」的研究把它的作用直接可视化了出来。把 ϵ 从小到大扫过一遍（论文取 $2 \cdot 10^{-3}$ 、 10^{-2} 、 10^{-1} ）： ϵ 小时，轨迹几乎笔直、近乎确定性，把每个源点映射到一个很集中的终点； ϵ 增大，轨迹变得更摇摆，条件分布 $\pi_{\theta}(x_1 | x_0)$ 也随之铺开。这正是理论预期的行为， ϵ 就是控制桥有多随机的那个刻度。这也意味着，用户可以根据自己想要多大的输出多样性来选 ϵ ，而不是为了迁就优化器去调它。

小结

LightSB 留下的核心讯息是：Schrödinger Bridge 求解器并不一定要「重」。把传输势函数写成高斯混合、再最小化一个直白的目标，LightSB 就能在 CPU 上几分钟内求解熵正则最优传输与 Schrödinger Bridge，无需对抗训练、无需过程模拟、几乎不用调参，同时追平甚至超过重得多的 GPU 求解器，还带着通用逼近的理论保证。

需要诚实说明的是它的边界，也就是适用范围。LightSB 面向的是中等维度的分布，其图像结果生活在预训练自编码器的隐空间里，而非原始像素空间，所以它是一个传输求解器，而不是一个从零开始的图像生成器。但在这个范围之内，它做到了这个领域一直缺的一件事：提供一个简单、快速、可靠的默认基线，一个你可以先在手头现有硬件上跑一遍，再决定是否值得上更重方案的起点。