

NeurIPS 2023 | 一个流模型，同时给你贝叶斯后验、模型选择和频率派解路径

University of Basel 提出 Conditional Matrix Flow (CMF)，在正定矩阵上统一稀疏高斯图模型的两套推断范式

在很多科学问题里，我们真正想知道的不是「谁和谁相关」，而是「排除掉其他所有变量之后，谁和谁还直接相关」。高斯图模型 (Gaussian Graphical Model, GGM) 正是干这件事的经典工具：它把变量间的条件独立结构，编码进精度矩阵 Ω (协方差矩阵的逆) 里。 Ω 中某个元素为零，就意味着对应的两个变量在给定其余变量后条件独立，于是「恢复一张稀疏的精度矩阵」就等价于「恢复变量之间的网络」。

问题出在如何逼出这种稀疏。最理想的做法是用 l_0 惩罚直接数非零边，但这是个组合优化问题，不可解； q 小于 1 的 sub- l_1 伪范数是对 l_0 很好的近似，却是非凸的，出了名的难优化。于是绝大多数方法退回到凸的 l_1 范数 (Graphical Lasso)，代价是众所周知的「过度收缩」：真实存在的边被压得太小甚至被误删。当变量数远多于样本数 (d 大于 n) 时问题更棘手，样本协方差奇异、根本无法直接求逆，只能靠稀疏惩罚来估计。

这篇发表于 NeurIPS 2023 的工作给出的答案是 Conditional Matrix Flow (CMF，条件矩阵流)：一个直接定义在对称正定矩阵空间上的矩阵变量归一化流 (normalizing flow)，同时以正则强度 λ 和伪范数指数 q 为条件。训练一个模型，就等于一次性拟合了「所有 λ 、所有 l_q 范数」构成的一整族稀疏回归模型，其中自然包含此前方法避之不及的非凸 sub- l_1 区域。




图 1 CMF 的整体架构。基向量 z 经过 Sum-of-Sigmoids 层，再依次做 Fill-Triangular (填成下三角)、Positive-Diagonal (softplus 保证对角为正) 和 Cholesky 乘积 $\Omega=LL^T$ ，输出天然是一个合法的正定精度矩阵；一个超网络 (Hyper-Network) 把 λ 和 q 注入流中。浅灰表示无约束值，深灰为正值，白色为零。

论文与代码：arXiv 论文 <https://arxiv.org/abs/2306.07255>；官方代码 <https://github.com/marcello-negri/CMF>。

为什么这件事一直没被统一

稀疏 GGM 推断历来有两个阵营。频率派的 Graphical Lasso 很优雅地把「随 λ 变化的整条解路径」一次性刻画出来，但它只给点估计，没有不确定性。贝叶斯版的 Graphical Lasso (BGL) 在非对角元上放一个 Laplace 先验，能给出完整后验，还附带一个可用于模型选择的边际似然 (marginal likelihood)；代价是它依赖 Gibbs 采样，在高维下混合很差、每换一个 λ 就要重跑，而且只对少数几种可解先验有效。

变分推断 (variational inference) 本该是两者的桥梁，把采样问题变成优化问题。但常用的平均场近似 (mean-field) 假设变量彼此独立，而这恰恰是图模型想要揭示的依赖结构本身。换句话说，最省事的变分近似，假设掉了我们最想研究的东西。作者需要的是一个既尊重依赖结构、又能在 λ 和 q 两个维度上自由伸缩的变分族，这正是 CMF 想扮演的角色。

方法：在 Cholesky 分解上搭一条流

CMF 的关键在于让「输出永远是合法的正定矩阵」这件事由构造保证，而不是靠额外约束或投影。任何对称正定矩阵都能写成 $\Omega = LL^T$ ，其中 L 是下三角，因此一个 d 维精度矩阵只需要 $d(d+1)/2$ 个数就能完整描述。流从一个这么长的基向量出发，先经过灵活的 Sum-of-Sigmoids 层，再重排成下三角矩阵，用 softplus 把对角线逼成正数，最后取 Cholesky 乘积。每一步的雅可比行列式都很便宜，而输出必然正定。

条件化由一个超网络完成：把 λ 和 q 喂进去，同一套流就能给出对应设置下的后验。训练目标很直接，就是流与未归一化后验之间的 KL 散度，其先验取广义正态分布 $\exp(-\lambda|\omega_{ij}|^q)$ ： $q=1$ 时退化为 Laplace 先验，也就是 Lasso 和 BGL； $q=2$ 时是正态先验，对应 Ridge； q 小于 1 就进入 sub-l1 区域。一个额外的好处几乎是白送的：边际对数似然 $\log p(S|\lambda, q)$ 正是损失里的归一化常数，可直接读出用于模型选择，不额外花钱。

最后一块拼图是温度。给后验加一个人工温度 T ，把它写成 $p(\Omega|S, \lambda, q)$ 的 $1/T$ 次幂，再用模拟退火 (simulated annealing) 把 T 慢慢降到接近零，尖锐化的后验就会收敛到最大后验 (MAP) 估计，也就是频率派的解。于是同一个训练好的模型，通过调节 T ，就能在贝叶斯后验和频率派解路径之间平滑滑动。




图 2 $q=1$ 时，精度矩阵各元素的 75% 后验可信区间随 λ 的变化（此处为 $T=1.0$ ，CMF 退化为贝叶斯 Graphical Lasso）。随 λ 增大所有元素被逐步收缩向零；把温度降到 $T=0.01$ ，同一模型就还原出频率派的解路径（图中虚线）。

sub-l1 如何缓解过度收缩

论文最能说明问题的一组实验，是固定其他条件、只改变伪范数指数 q 。直觉上 q 越小，惩罚越接近数边的 l_0 ，对已经明显非零的系数惩罚就越轻，过度收缩也就越弱。图 3 用一个精度矩阵元素的可信区间把这件事讲清楚了。




图 3 精度矩阵某一元素的 95% 后验可信区间，随 $q=\{0.25, 0.5, 0.75, 1\}$ 变化，并与 BGL 和频率派 GLasso（红色虚线）对比。可以看到 q 越小，后验中位数被拉向零的程度越轻：在 $\lambda=0.3$ 处， $q \in \{0.25, 0.5, 0.75\}$ 的可信区间都把零排除在外，而 $q=1$ （即 BGL）的区间仍然包含零，会把这条边判为不存在。

这正是 sub-l1 的价值所在：它在该保留的边上更「敢」保留。把这一点放到边恢复任务上，收益在样本稀缺时最明显。




图 4 边恢复的 F1 分数随样本数变化（d=30，在 10 个真实精度矩阵上平均）。CMF 在 $q=\{0.25, 0.5, 0.75, 1\}$ 下与贝叶斯 Graphical Lasso（BGL）对比。样本越少（n 越接近或小于 d），sub-l1（尤其 $q=0.25$ ）相对 BGL 的优势越大；在 $n=15$ 这一最难的低样本区，优势最为突出。

论文进一步把 CMF（ $q=0.25$ ）与一批以 l_0 近似为惩罚的频率派方法（atan、selo、log、sica）对比：CMF 在所有样本量下都胜出，且在 $n=15$ 时优势最大。也就是说，能连续、一致地探索整个 l_q 范数族，本身就带来了实打实的收益，而不只是理论上的优雅。

模型选择与采样效率

既然边际似乎是白送的，模型选择就顺理成章。CMF 用自己的边际似然峰值挑出 $\lambda^*=3.52$ ，而 Graphical Lasso 用交叉验证挑出 $\lambda^*=3.36$ ，两者基本一致：一个内生于贝叶斯框架的选择，独立地印证了频率派的交叉验证结果。效率上的对比更直接：Gibbs 采样器在 CPU 上约每秒 5.6 个样本（500 个样本要 89 秒），而 CMF 在一块消费级 GPU 上每秒能抽约 2000 个独立样本，快出约两个数量级。

表 1 CMF 的几个关键数字

指标	结果
解路径重构误差（对频率派路径）	MSE = 0.052
模型选择的 λ^*	CMF 3.52 vs. GLasso 交叉验证 3.36
采样吞吐（近似）	CMF $\approx$ 2000 样本/秒（GPU） vs. Gibbs $\approx$ 5.6 样本/秒（CPU）
真实数据规模	6 个临床变量 + 312 个基因，190 名患者

注：合成实验中 $d=15$ 的玩具例用于可视化，边恢复实验 $d=30$ 、 $n \in \{15, 25, 35, 45\}$ ，在 10 个真实精度矩阵上平均。

真实数据：结直肠癌网络

作者还把 CMF 用在一个真实的结直肠癌队列上：原始数据含 7 个临床变量和 312 个基因表达测量、260 名患者；剔除 p53 突变状态变量并只保留信息完整的记录后，剩下 190 名患者、6 个临床变量和 312 个基因。这里的高维（变量远多于样本）正是稀疏 GGM 的用武之地。为了避免估计整张昂贵的精度矩阵，模型只对与查询相关的子块 Ω_{11} 、 Ω_{12} 建流。




图 5 CMF 在真实结直肠癌数据上推断出的网络结构 ($q=1.0$)。正边为黑色、负边为灰色，临床变量以红色标出。可以看到肿瘤分期 GS 与 TNM 分类的各个部分 (T、N、M) 之间存在明显的边，符合临床先验。

在 $q=1.0$ 的这张图里，几个临床变量（红色节点）各自成为局部枢纽：肿瘤分期 GS 与 TNM 分类的 T、N、M 直接相连，年龄 AGE、性别 SEX 以及各肿瘤描述子则各自连出一组基因邻居。这些以临床变量为中心的星形结构，正是「条件独立网络」想要暴露的直接依赖，而不是笼统的两两相关；也正因为只对 Ω_{11} 、 Ω_{12} 子块建流，模型不必估计整张精度矩阵就能读出这些关系。

把 q 从 1 降到 0.6，同一套方法给出的网络明显更稀疏、更干净：弱连接被进一步压掉，留下结构性更强的骨架。这与前面合成实验里「小 q 缓解过度收缩、更敢做取舍」的结论一致，只是这次呈现为一张更易读的图。




图 6 同一真实数据、改用 $q=0.6$ 推断出的网络结构。相比图 5 的 $q=1.0$ ，更小的伪范数指数带来更稀疏的图：临床变量（红色）与其邻居之间的核心连接被保留，大量弱边被削去。

小结与边界

CMF 的核心贡献，是用一个设计良好的归一化流替换掉一整套工具箱。把流直接建在正定矩阵上、并以正则强度和范数指数双重条件化，作者一次性拿到了贝叶斯后验、基于边际似然的模型选择，以及频率派解路径，覆盖所有 λ 和所有 l_q 伪范数，包括老方法回避的非凸 sub- l_1 区域，全程无需替代惩罚，也无需为每个 λ 重新采样。因为 sub- l_1 缓解了 Lasso 松弛带来的过度收缩，边恢复在最低样本区反而更好，同时采样比 Gibbs 快上百倍。

需要清醒看待的是边界：论文的合成实验规模不大（ d 在 15 到 30 之间），真实实验也只在单个癌症队列上、且只对精度矩阵的子块建模；把这套方法推到成百上千维、或换到其他领域的的数据上，表现还有待更大规模的检验。但作为一次范式统一，它把原本需要分开机器的两套传统，干净地收进了一个模型里。