

ICML 2022 | 把「上下文」交给 Transformer，让神经网络学出更好的拍卖机制

北京大学与 Google 提出 CITransNet：一个置换等变、可处理变长输入的上下文拍卖设计网络

拍卖设计是计算经济学里最经典、也最顽固的问题之一。目标听上去很朴素：写下一套规则，让卖方的期望收益最大，同时保证「激励相容」（incentive compatibility），即如实报价对每个参与者都是最优选择，没人有动机撒谎。单物品的情形早在 1981 年就被 Myerson 解决，但一旦进入多物品场景，即便只有两个买家、两件商品，最优拍卖机制在四十多年后依然没有解析答案。

近年来深度学习给这个老问题带来了新思路：把拍卖机制本身当成一个神经网络，用数据训练它，在「零后悔」（zero regret）的约束下最大化收益。但已有的神经拍卖设计器，如 RegretNet 和 EquivariantNet，都带着一条约束——要么只能处理固定数量的买家和物品，要么强行假设拍卖是对称的。真实市场恰恰两条都不满足：在电商广告竞价里，每一轮的参与者数量都在变，买家和物品各自带着丰富的公开特征（context），而收益最优的机制往往是不对称的。

这篇发表于 ICML 2022 的工作提出 CITransNet（Context-Integrated Transformer Network），把买家和物品的公开上下文当作「一等输入」直接喂给网络。它以 Transformer 为骨架，天然对买家和物品保持置换等变（permutation-equivariant），既能表达不对称机制，参数量又与拍卖规模无关——这意味着在一个规模上训练好的模型，可以直接用于它从未见过的、更大或更小的拍卖。




图 1 CITransNet 的整体结构。网络接收竞价矩阵 b 、买家上下文 x 和物品上下文 y ，先把上下文嵌入并与竞价拼成每个「买家-物品」对的初始表示 E ，再经过一层或多层 Transformer 交互层建模买家与物品间的相互影响，最

后由输出层给出分配 g 和支付 p 。每个交互层同时融合三种视角——全局平均、按列的 Transformer 和按行的 Transformer——从而在保持置换等变的同时捕捉复杂的交互关系。

论文地址：<https://arxiv.org/abs/2201.12489>

开源代码：<https://github.com/zjduan/CITransNet>

为什么「上下文」和「变长输入」这么关键

传统的自动拍卖设计把每一场拍卖看成孤立的数值问题：给定若干买家对若干物品的估值，输出分配和支付。但在真实的广告竞价里，买家和物品都不是匿名的——用户画像、广告主行业、商品类目这些公开特征会显著影响什么才算好机制，忽略它们等于把一份本可利用的信息扔掉。与此同时，每一轮竞价的买家数和广告位数都在变，一个把网络结构绑死在某个固定规模上的设计器，在实际系统里很难部署。CITransNet 想同时解决这两件事：吃进上下文，并接受变长的输入。

CITransNet 是怎么构造的

CITransNet 建立在 RegretNet 的学习框架之上，把「设计最优拍卖」写成一个约束优化问题：在所有满足个体理性（IR）的机制中，最小化负的期望支付（即最大化收益），同时把每个买家的期望「后悔」（regret，即谎报能带来的最大额外效用）约束为零。个体理性由网络结构直接保证，零后悔则借用 RegretNet 的增广拉格朗日方法，在训练中作为软约束逐步逼近。针对这个上下文版本，论文还证明了一个样本复杂度上界，说明用有限样本训练出的机制，其泛化误差是可控的。

网络的核心是「交互层」。如图 1 所示，买家上下文 x 和物品上下文 y 先被嵌入成向量，再和竞价 b 拼接成一个「买家 $\times$ 物品 $\times$ 特征」的三维张量。这个张量随后流过一层或多层 Transformer 交互层，每一层把数据的三种视角相加：一个对全体求平均的全局视角，一个沿「每一列」（同一物品下的所有买家）运行的 Transformer，以及一个沿「每一行」（同一买家下的所有物品）运行的 Transformer。这样的设计让模型既能捕捉买家与物品之间复杂的相互影响，又对买家和物品的排列顺序保持等变——交换两个买家的输入，输出也只是相应交换，机制本身不变。正因为参数不绑定到具体的买家数或物品数，同一个网络可以处理不同规模的拍卖。

实验：先复现已知最优，再赢过强基线

论文在九个合成的上下文拍卖设定上做了评测。其中设定 A–C 是单物品拍卖，最优机制可由 Myerson 1981 年的理论解析给出，用来做「体检」；设定 D–I 是多物品拍卖，规模最大到 5 个买家 $\times$ 10 件物品（据作者所知，这是深度拍卖设计文献里考察过的最大规模），上下文既有离散的，也有连续的十维向量。所有数字都是 5 次运行的平均。

在单物品设定上，CITransNet 几乎精确复现了 Myerson 最优：以设定 A 为例，它拿到 0.593 的收益，对应的理论最优是 0.594，后悔值低于 0.001。值得注意的是，不带上下文的

RegretNet 和 EquivariantNet 在这些简单设定上都够不到最优，这直接说明「把上下文整合进来」不是锦上添花，而是必要的。

真正的看点在多物品设定上——这里没有解析解，只能和强基线比。下表对比了几种方法在三个代表性设定上的收益：E（3×10，离散）、F（5×10，离散，最大规模）和 G（2×5，连续上下文）。Item-wise Myerson 是把 Myerson 单物品拍卖逐个物品独立应用得到的强基线；CIRegretNet 和 CIEquivariantNet 则是把 CITransNet 的 Transformer 交互层分别换成 RegretNet 的全连接层和 EquivariantNet 的等变层，但同样吃上下文。

表 1 三个代表性多物品设定下的收益对比（数值越高越好；所有设定中后悔均 ≤ 0.003 ）。CITransNet 在全部六个多物品设定中都取得最高收益，此处展示其中三个；在设定 E 上比 Item-wise Myerson 高约 5.6%，在连续上下文的设定 G 上领先约 9.9%。

方法	E (3×10)	F (5×10)	G (2×5, 连续)
Item-wise Myerson	6.509	7.376	1.071
CIRegretNet	5.846	6.339	1.104
CIEquivariantNet	6.703	7.602	1.147
CITransNet	6.872	7.778	1.177

CITransNet 在全部六个多物品设定里都拿到了最高收益，表 1 里的三个只是代表。它不仅稳定超过 Item-wise Myerson 这个强基线，也超过了同样带上下文的 CIRegretNet 和 CIEquivariantNet。由于这三者唯一的区别就是交互层的结构，这个对比把性能提升干净地归因到了 Transformer 交互层本身。

训练一个规模，迁移到另一个规模

CITransNet 参数量与拍卖规模无关这一性质，带来一个有意思的能力：在某个规模上训练，直接在另一个规模上评测，作者称之为「out-of-setting 泛化」。图 2 展示了三组这样的实验：把在某个设定上训练好的模型，分别放到买家数或物品数不同的拍卖上运行，并和 Item-wise Myerson 基线比较收益。




图 2 Out-of-setting 泛化结果。模型在一个固定规模上训练，再在买家数或物品数不同的同类拍卖上评测，所有实验的后悔均低于 0.001。(a) 在设定 E（3×10 离散）上训练，评测不同买家数；(b) 在设定 D（2×5 离散）上训练，评测不同物品数；(c) 在设定 G（2×5 连续）上训练，评测不同物品数。蓝线（CITransNet）在大部分未见规模上都稳定高于红线（基线）。

可以看到，即便面对训练时从未出现过的买家数或物品数，CITransNet 依然保持低后悔，并在大多数未见规模上超过基线。对于一个需要频繁应对不同参与者数量的线上系统来说，这种「训一次、跨规模用」的性质相当实用。

一句话总结与边界

CITransNet 的核心信息很简单：把公开上下文当作一等输入，用一个置换等变的 Transformer 去处理，就能学出接近最优、必要时不对称、且激励相容的拍卖机制；又因为网络规模与买家数、物品数无关，一个训练好的模型可以迁移到未见过的拍卖规模上。需要留意的是，这些结论都建立在合成数据、最大 5×10^4 的规模上，零后悔是作为软约束逼近而非严格保证，离真实工业级广告系统仍有距离。但作为把上下文特征、不对称机制和跨规模泛化三者统一到一个架构里的尝试，它给「用神经网络设计拍卖」这条路指出了一个务实的方向。