

ICML 2024 | 让视觉语言模型说清楚：这张街景到底拍在哪里

GeoReasoner 通过筛选“可定位”的街景、并借用地理游戏中的人类线索，在更少数据下超越更大的地理定位模型，还能为每次判断给出理由。

给一个人看一张随手拍的街景照片，几秒钟内他往往能说出国家，有时还能说出城市。靠的是读线索：店招上的文字、车牌的颜色、路灯的样式、车辆靠哪一侧行驶。GeoGuessr、Tuxun 这类地理游戏的玩家社区，已经把这项技能打磨成一门手艺，整理出成千上万条这样的定位线索。相比之下，机器地理定位系统往往只丢回一个坐标，别的什么都不说。

这种沉默，正是 GeoReasoner 想要解决的问题。这篇发表于 ICML 2024 的工作（作者来自香港科技大学（广州）、同济大学等机构）指出，街景地理定位存在两个相互纠缠的盲点。数据问题：街景数据集里混杂了大量在隧道里、对着空白墙面、或只拍到路边绿化的图像，它们都不含可用的线索。推理问题：检索式与分类式模型是黑箱，只给位置、不给任何人能检查或信任的解释。GeoReasoner 把二者视为一个整体，同时改善数据质量与可解释性。




图1 街景地理定位的三种范式。检索式方法（左上）在带地理标签的图库中做相似匹配；分类式方法（左下）把地球划分为网格单元；GeoReasoner 采用的 LVLM 式方法（右）在给出位置的同时给出可读的推理理由，并按可定位性（locatability）筛选训练图像。

它的做法，是把大型视觉语言模型（LVLM）与从地理游戏中收集的人类推理知识配对，并且只喂给模型真正可定位的街景。回报是：在 F1 指标上，它在国家级超过最强的同类 LVLM（Qwen-VL）达 25.02%，在城市级超过 38.61%，并且在使用远少于对手的数据的情况下，略微超过专门为地理定位打造的模型，同时还能对每一步给出解释。

论文：<https://arxiv.org/abs/2406.18572> 代码：<https://github.com/lingli1996/GeoReasoner>

两个盲点：脏数据与黑箱预测

检索式方法在带地理标签的图库中找最近邻，返回其坐标，精度受限于图库是否足够完整，而完整的图库代价高昂、难以维护。分类式方法把地图切成网格并预测所属网格，忽略了招牌文字这类语义线索，同样无法说出为什么。两者还都会继承训练集中的噪声，而街景数据恰恰很脏。用没有可查内容的图像训练，模型几乎学不到什么，因此作者从清洗数据本身入手。

先量化：一张图到底能不能被定位

作者的第一步，是让可定位性（locatability）变得可度量。直觉上，当一张街景包含可供推理的东西（清晰的招牌、独特的外立面、地标）时，它就是可定位的；而当它只是隧道墙壁、或哪里都有的灌木时，就无从定位。一旦打上分数，这种反差就非常明显。




图 5 “可定位性”长什么样。上排为高可定位街景（loc. = 0.70 至 0.71），含招牌、独特建筑与地标；下排为低可定位街景（loc. = 0.08 至 0.19），分别是隧道、空白墙面与随处可见的植被，几乎没有可用的地理线索。

具体而言，可定位性是对图像语义内容的加权求和。MaskFormer 把每张街景分割成若干类别（建筑、天空、车辆、植被等），并给出每类的面积占比；Sentence-BERT 再评估每个类别与地理游戏文本线索的相关度，得到每类的权重。一张图像的可定位性，就是它的类别面积向量与这组相关度权重的点积。分数高于阈值 0.4 的图像被保留；施加该筛选后，130,000 张原始街景被筛到约 70,000 张高质量图像。

而这组相关度权重本身，来自一个 CLIP 图文配对网络，它无需任何额外的人工标注，就能学会把图像与文字对齐。




图 2 可定位性量化网络。以 CLIP 的方式，将街景图像与从地理游戏中挖掘的文本线索配对，得到图文相似度矩阵，再归约为每张图像的单一定位性分数。

游戏中的文本线索（例如“绿底白字的路牌在韩国常用于标示高速公路信息”）由文本编码器编码，街景由图像编码器编码，两个模态之间的相似度为每张图像给出单一的可定位性分数。除了这些本就存在的游戏线索，网络不需要额外的人工标注就能完成工作。

GeoReasoner：先推理，再定位

有了干净的数据，模型以 Qwen-VL 为底座（一个视觉编码器 Vision Encoder、一个视觉语言适配器 VL Adapter、一个预训练 LLM），并用轻量的 LoRA 适配器分两阶段微调，全程保持底座权重冻结。




图 3 GeoReasoner 的结构与两阶段微调。模型基于 Qwen-VL（Vision Encoder、VL Adapter、预训练 LLM），先在游戏线索上学习国家级推理（Stage 1，LoRA 1），再在筛选后的街景上强化城市级预测（Stage 2，LoRA 2）；推理时同时输出 country、city 与 reasons。

阶段一是推理微调，在约 3,000 对来自 GeoGuessr 与 Tuxun 的图文线索上训练 LoRA 1，教会模型说出国家、并解释支持它的视觉证据。阶段二是位置微调，叠上第二个适配器 LoRA 2，在 70,000 张筛选后的街景上训练，强化细粒度的城市级预测。推理时，模型以固定的 JSON 形式作答（country、city 与一串 reasons），因此每个预测都自带依据。

结果：更少的数据，更高的精度，还有解释

在留出的街景测试集上，GeoReasoner 的国家级 F1 达到 0.9033，城市级 F1 达到 0.8585。这比 Qwen-VL 在国家级高出 25.02%，在城市级高出 38.61%。更值得注意的是，它略微超过 StreetCLIP，一个专为地理定位打造、在 1.1M 街景上训练的模型，而它自己只用了其中的 70,000 张，规模相差悬殊。

表 1 国家级与城市级地理定位的精确率、召回率与 F1。带 * 表示在高可定位街景上训练的模型；GeoReasoner 在两个 F1 列均领先。

Model	Country P	Country R	Country F1	City P	City R	City F1
StreetCLIP	0.7943	1.00	0.8854	0.7457	1.00	0.8543
LLaVA	0.4029	1.00	0.5744	0.2400	1.00	0.3871
Qwen-VL	0.5829	0.95	0.7225	0.3743	0.89	0.5270
GPT-4V	0.8917	0.34	0.4923	0.5083	0.31	0.3851
ViT*	0.7100	1.00	0.8304	0.6762	1.00	0.8068
GeoReasoner *	0.8237	1.00	0.9033	0.7521	1.00	0.8585

增益从何而来？一项针对数据构成的消融，在训练预算固定的前提下，单独隔离出质量本身的作用。




图 7 数据质量决定精度。当训练集中高可定位图像的占比从 0% 提高到 100%，国家级（蓝）与城市级（橙）准确率都稳步上升，说明真正带来提升的是数据筛选，而非单纯的数量。

在其他条件不变、只改变高可定位图像比例的情况下，随着它从 0% 增加到 100%，两级准确率都稳步上升。起作用的是质量，而非数量。

抛开数字，定性表现才是这篇论文真正的重点，而它并排放在一起时最容易体会。




图 8 带推理的地理定位对比。在三张街景上，GeoReasoner 的判断与 LLaVA、Qwen-VL、GPT-4V 相当或更好；与黑箱基线不同，它会为每个预测给出解释（正确答案标绿，有效线索标蓝）。

在新加坡，ComfortDelGro 出租车直接给了 GeoReasoner 答案；在拉斯维加斯大道，它读出霓虹灯与仿制地标；在拉萨，它援引藏文与中国国旗。LLaVA 与 Qwen-VL 常常判错或凭空猜测，GPT-4V 推理不错，而 GeoReasoner 只用一小部分训练预算就与之持平。

两个阶段各自贡献了什么

第二项消融把两个微调阶段拆开来看。从 Qwen-VL 基线（国家级/城市级 F1 为 0.7225 / 0.5270）出发，只做推理微调可到 0.8215 / 0.5813，只做位置微调可到 0.8766 / 0.8255。只有两者叠加，GeoReasoner 才达到 0.9033 / 0.8585。位置微调贡献了大部分城市级精度；推理微调带来进一步提升，更关键的是带来了解释。

表 2 对两个微调阶段的消融。推理微调与位置微调互补，完整的两阶段模型在每个 F1 上都最优。

Model	Reasoning	Location	Country F1	City F1
Qwen-VL	✗	✗	0.7225	0.5270
w/o location tuning	✓	✗	0.8215	0.5813
w/o reasoning tuning	✗	✓	0.8766	0.8255
GeoReasoner	✓	✓	0.9033	0.8585

小结

GeoReasoner 的启示很简单：顶尖的地理定位模型不需要数百万张街景，而是需要对的图像与对的知识。先量化哪些街景可定位，再借用人类在地理游戏中的推理技巧，两阶段的 LVLM 就能在一小部分数据上追平甚至超越专用模型，并解释每一次判断。它也很诚实：面对真正的歧义仍会失手，比如分不清巴黎、拉斯维加斯与杭州的埃菲尔铁塔；掌握的知识也只与游戏社区写下的线索一样宽。但它给出了一条务实的路径：让地理定位既可解释，又省数据。