

NeurIPS 2023 | 把矩阵压到每个元素只用 1 比特

斯坦福提出 LPLR：一次随机化的低秩 + 低精度分解，在图像、嵌入向量与 LLaMa 权重上媲美甚至反超传统压缩

矩阵是科学计算和机器学习里最基础的数据结构，但现代矩阵动辄包含数十亿个元素，光是把它存下来、搬运和参与计算，就会给显存和算力带来沉重压力。好在一个常被忽视的事实是：许多真实世界的矩阵都近似低秩，它们携带的有效信息远比自身的尺寸暗示的要少。

面对这种冗余，业界通常从两个方向压缩。一是低秩近似（low-rank approximation），把矩阵写成一个「高瘦」因子和一个「矮胖」因子的乘积，元素总数随之骤降；二是低精度量化（low-precision quantization），把每个数值从 32 比特浮点压到区区几个比特。两条路各自都已相当成熟，但要把它们拧进同一次分解、并且还能给出可证明的误差保证，一直是一块空白。

在 NeurIPS 2023 上，来自斯坦福大学的这篇论文提出了 LPLR（Low-Precision Low-Rank，低精度低秩分解）：用一次随机化的分解，同时得到低秩且低精度的两个因子，使得 $A \approx LR$ ，并为它的近似误差推导出与目标秩、比特预算相关的上界。在从医学图像、嵌入向量到 LLaMa-7b 权重矩阵的一系列任务上，LPLR 能把矩阵压到平均每个元素约 1 比特，同时精度媲美、在部分设置下甚至反超传统方法。




图 1 在标准医学测试图 Shepp-Logan phantom 上的压缩对比。在总比特数相同（约 $2 \cdot 10^6$ 比特）的前提下：(a) 原图；(b) 朴素量化（每像素 2 比特）几乎抹平了内部结构；(c) 直接量化 SVD 因子（DSVD）引入明显伪影；(d) LPLR 与 (e) LSVD（本文方法）把图像分解成瘦长因子的乘积，从而让每个元素能用更高精度表示，最完整地保留了内部的小椭圆等细节。

论文：<https://arxiv.org/abs/2310.11028>

代码：<https://github.com/pilancilab/matrix-compressor>

为什么「两条路一起走」这么难

直觉上，如果一个矩阵是低秩的，就可以把它写成一个瘦因子和一个胖因子的乘积，元素数量大幅减少；如果再把这些因子的元素用低精度存储，就能省得更多。看起来只要把两步简单叠加即可，但真正做起来有两个障碍。

第一个障碍是精度。把低秩分解和量化粗暴地拼在一起，尤其是在极低比特预算下，误差会迅速累积、精度崩塌。第二个障碍是计算成本。得到低秩因子最精确的途径是奇异值分解（SVD），但它的计算量高达 $O(nd^2)$ ，对于当今 GPU 上最大的那些矩阵而言几乎不可行。论文要回答的正是：能否用一条又快又可分析的随机化路径，一次性拿到低秩且低精度的因子，同时把近似误差牢牢控制住。

LPLR 是怎么做的

LPLR 的流程可以拆成几步。首先，它抽取一个高斯随机矩阵 S ，构造草图（sketch） AS ——这是一个随机化的「值域探测器」（rangefinder），用来近似 A 的列空间。然后它把这个基底量化，得到 $Q(AS)$ ，这就是第一个因子 L 。

接下来，它把 A 的列向量投影到这个量化后的基底上，求解最小二乘问题 $W^* = \operatorname{argmin}_W \|Q(AS) \cdot W - A\|_F^2$ ，这个问题有闭式解，也可以用共轭梯度迭代求解。最后，它用第二个量化器把 W^* 量化为 $R = Q'(W^*)$ ，并返回两个因子 $L = Q(AS)$ 与 $R = Q'(W^*)$ 。整个过程只需 $O(ndm)$ 的计算量（ m 为草图尺寸），远低于直接 SVD 的 $O(nd^2)$ 。

论文进一步给出近似误差的上界： $\|LR - A\|_F^2 \leq (1 + k/(m-k-1)) \cdot \|A_k - A\|_F^2 + \varepsilon$ ，其中 A_k 是 A 的最优 k 秩近似， k 为目标秩， ε 由量化比特预算决定。这个式子把「低秩带来的截断误差」和「量化带来的精度误差」清晰地分成了两项，让实践者可以在压缩率与精度之间明确地权衡。

为什么压到 1 比特还扛得住

LPLR 能在如此激进的比特预算下依然稳定，关键来自高斯草图的一个性质。高斯矩阵是一种 Johnson-Lindenstrauss (JL) 嵌入，它带来一种「均衡化」（equalization）效应：重建量 $\hat{x} = S^T Q(Sx)$ 的量化误差保持在 $O(1)$ ，而不会像逐元素量化那样随维度 d 线性增长到 $O(d)$ 。正是这个性质，让 LPLR 即便在每个坐标只用 1 比特（符号量化）时，误差也不会失控。这也解释了本文一个反直觉的现象：把因子分解得更「瘦」、给每个元素更多比特，往往比在原矩阵上直接堆比特更划算。

证据一：嵌入向量的下游分类

第一组实验检验的是「压缩后还能不能用」。作者用 MobileNetV3 生成 CIFAR-10 / CIFAR-100 的图像嵌入、用 BERT 生成 IMDB / Emotion 的文本嵌入，压缩这些嵌入矩阵后，再用 k 邻近分类器测量下游的准确率与加权 F1。所有方法都在相同的总比特预算（parity）下比较，其中 Bnq 表示朴素量化基线所用的每元素比特数。

表 1 嵌入分类准确率 (%)，比较基线量化预算 $B_{nq} = 1$ 比特，LPLR 系方法取 $B = B' = 8$ 比特。朴素量化在 1 比特下几乎完全失效，而 LPLR 与 LSVD 保持甚至反超未量化基线 (k 近邻在去噪后表现更好)。

数据集	LPLR	LPLR-SVD	DSVD	朴素量化	未量化
CIFAR-10	92	92	92	11	91
CIFAR-100	79	82	82	1	76

对比非常鲜明：在每比特预算 $B_{nq} = 1$ 的极端设置下，朴素量化在 CIFAR-10 上准确率跌到 11%、在 CIFAR-100 上更是跌到约 1%，基本等同于瞎猜；而 LPLR 分别保持 92% 与 79%，与未量化的 91%、76% 持平甚至更高。换句话说，LPLR 在把嵌入压到约 1 比特的同时，几乎没有牺牲任务性能。

证据二：压缩 LLaMa-7b 的权重

更能说明问题的是大语言模型。作者逐层压缩 LLaMa-7b 的权重矩阵，用相对 Frobenius 范数误差衡量重建质量——误差越低，压缩后的权重越接近原始权重。下图按层的原始顺序，把 LPLR、LPLR-SVD 和朴素量化的逐层误差画在一起。




图 2 在 LLaMa-7b 各层权重矩阵上，LPLR (蓝)、LPLR-SVD (绿) 与朴素量化 (橙) 的相对 Frobenius 范数误差，按层的原始顺序排列。朴素量化在多数层误差高且抖动剧烈 (不时冲到 1.5 以上)，而 LPLR 与 LPLR-SVD 的误差始终更低、更平稳。

图中橙色的朴素量化曲线剧烈抖动，在不少层冲到 1.5 甚至 3.0 以上；而蓝色的 LPLR 与绿色的 LPLR-SVD 则贴着一更低、更平的水平带走。汇总成数字后，这个优势同样清晰。

表 2 LLaMa-7b 权重矩阵上的平均相对 Frobenius 范数误差 (越低越好)。在两种比特预算下，LPLR-SVD 的误差都明显低于朴素量化，且层间方差更小。

比特预算	LPLR	LPLR-SVD	朴素量化
$B = B' = 8, Bnq = 4$	0.672	0.537	0.836
$B = B' = Bnq = 4$	0.548	0.540	0.836

在 $B = B' = 8$ 、 $Bnq = 4$ 的设置下，LPLR-SVD 的平均相对误差为 0.537，而朴素量化为 0.836；不仅均值更低，标准差（0.079 对 0.470）也小得多，意味着它在不同层上的表现更稳定、更可预测。

拆解：低秩与低精度各自的贡献

LPLR 的收益到底来自「低秩结构」还是「量化精度」？论文通过一组消融实验把两者分开。作者在固定压缩率的前提下扫描比特三元组 (B, B', Bnq) ，结果显示：当把预算从低秩因子（ B ）挪向非量化参照（提高 Bnq ）时，LPLR 及其 SVD 变体的 Frobenius 误差会系统性地下降。在各个嵌入实验里，把 Bnq 从 1 比特提到 4 比特，会让 LPLR 从「在激进端大幅领先朴素量化与 Direct-SVD」逐渐走向「在宽松端与它们打平」。这恰恰说明：压缩越激进，LPLR 的优势越大。

小结与边界

这篇工作传达的核心信息是：低秩与低精度是互补的，把它们放在一起利用才能把压缩推到极致。通过一次高斯随机投影加两次量化，LPLR 把矩阵压到平均每个元素约 1 比特，同时保持在图像、嵌入向量与大模型权重上的精度，并且带有可证明的误差上界。它绕开了昂贵的 SVD，只需 $O(ndm)$ 的计算量，因而对那些连精确方法都塞不下的超大矩阵格外实用。

需要说明的是，LPLR 的误差保证建立在矩阵近似低秩这一前提上；对于本身秩就很高、奇异值衰减缓慢的矩阵，低秩分解本身能省下的空间有限。论文也观察到，随着 Bnq 放宽到 4 比特，LPLR 相对朴素量化的优势会收窄到基本持平——它最闪光的区间，正是压缩最激进、别的方法最先崩溃的那一端。