

ICML 2023 | 把图“排成一行”，就能用 CNN 卷积了

中科院计算所等提出 CoCN：用可学习的置换把节点排成一行，将图像式卷积搬到图上，在节点分类与图分类上刷新当前最优。

卷积神经网络（CNN）的成功，很大程度上来自两个朴素的设计：在规则网格上滑动的局部卷积核，以及在整张图像上共享的同一套参数。正因如此，CNN 几乎“免费”地学到了多尺度特征。但图（graph）不是网格：节点没有天然的先后顺序，邻居的数量也参差不齐，于是在像素上如此好用的卷积，在图上找不到直接对应。

常见做法是用邻接矩阵的多项式来构造图上的卷积核。这类卷积式图神经网络（convolutional GNNs）优雅，且天然满足置换不变性（permutation invariance），但在参数量受限时表达能力有限；而且一旦离开额外的节点聚类或丢弃式池化（node-drop pooling），就无法自行学到分层的、多尺度的表示。

ICML 2023 的《All in a Row: Compressed Convolution Networks for Graphs》换了一条路：与其为图重新设计卷积，不如把图“改造”成卷积能直接处理的形状。模型学习一个与任务相关、可微的置换（permutation），把一张图的所有节点排成一行，再让 CNN 式的卷积核沿着它们滑动。由此得到的模型 CoCN（Compressed Convolution Network，压缩卷积网络）端到端地学习节点特征与结构特征，在节点分类和图分类上都取得了当前最好的结果。




图 1 CoCN 整体流程。可学习的置换矩阵先把节点特征矩阵与边特征矩阵重排，让相关节点彼此相邻；随后对角卷积沿重排后矩阵的对角线滑动，同时提取每个节点的特征以及其周围的局部结构。斜纹标记的非对角元素留待后续层处理。

论文：<https://proceedings.mlr.press/v202/sun23k.html>
码：<https://github.com/sunjss/CoCN>

代

矛盾所在：卷积对顺序敏感，图却要求顺序无关

卷积天生对顺序敏感——卷积核挪动一格，读到的就是另一块局部。而图神经网络恰恰相反：无论怎样给节点重新编号，预测都应当保持不变。早期工作也尝试过先给节点排个序，但那

个顺序是作为预处理独立确定的，与后面的任务脱钩，既无法随任务调整，又常常丢掉有用的结构信息。CoCN 的关键，是把这个“排序”变成端到端学习、并且可证明置换不变的过程。

不是挑一个顺序，而是学一个顺序

CoCN 包含四个模块：输入、置换生成、卷积与输出，核心在置换生成。它先为每个节点回归一个位置：用一个 MLP 作用在节点特征上，并用图拉普拉斯（graph Laplacian）做平滑，使得相连或相似的节点获得相近的位置。相似的节点因此在这一行里成为邻居，正是局部卷积核所期望的排布。

这些位置再被转成一个松弛置换矩阵（relaxed permutation matrix），即一个可微的“软排序”，由 τ 控制，并可证明随 τ 增大收敛到真正的置换。由于置换是“回归”得到、而非在所有排列中搜索，其建模复杂度从 $O(n!)$ 降到 $O(n^2)$ ，因而能在几十万节点的大图上做小批量（mini-batch）训练。

对角卷积与压缩池化

节点排成一行后，CoCN 不再逐行逐列扫描，而是改走对角线：卷积核沿重排后边特征与节点特征矩阵的对角线滑动，一次读入一个节点及其周围结构。压缩池化（compressed pooling）从反对角方向压缩结构矩阵，逐层得到更粗的图；需要逐节点输出时，转置卷积（TConv）把特征上采样回原分辨率。




图 2 CoCN 面向两类任务的网络结构。图分类（上）用压缩卷积层与池化层堆叠成编码器；节点分类（下）再用转置卷积层镜像地把特征上采样回节点分辨率，类似 U-Net。置换模块为两者共同提供排序。

置换到底学到了什么

如果这套思路成立，学到的顺序就应当把相关节点排到一起——让原本杂乱的邻接矩阵显现出局部核可以利用的块状或带状结构。图 4 正说明了这一点：随着拉普拉斯平滑参数 t 增大，重排后的邻接矩阵与节点特征相似度矩阵，把数值越来越集中到块与对角线上，而不是四处散布。




图 4 不同平滑参数 t 下的置换结果。上排为重排后的邻接矩阵，像素越亮表示两节点相连；下排为重排后的节点特征相似度。随着 t 增大，块状与对角结构愈发清晰，正是局部卷积核可以利用的形态。

这种逐渐显现的块结构，正是小小的对角卷积核之所以有效的原因——节点需要的信息此时都集中在局部，就像图像里的一个小块。

对任何松弛都会有一个合理的担忧：把硬置换软化，会不会丢信息？作者用一个图重建实验直接检验：训练一个自编码器，从被置换后的特征去恢复原始特征，重建误差就衡量了松弛置换丢掉了多少信息。




图 3 在不同松弛因子 τ 下，从松弛置换重建网格（上）与环形（下）结构。即使 τ 只取中等值，几何结构也几乎被完整还原，说明这一可微置换几乎是无损的。

当 τ 取到中等大小时，重建已近乎完美——也就是说，这种可微松弛换来了可训练性，却几乎不损失信息：软置换保留的内容，与一个硬置换基本一致。

实验结果

收益体现在最难的基准上。在六个异配（heterophilic）节点分类数据集上，CoCN 取得最好的平均排名 1.83，位居榜首，其中 Chameleon 达 79.17%、Squirrel 达 72.95%、Cornell 达 86.22%。最亮眼的是 Squirrel：比最强的先前模型 LINKX 高出十一个百分点以上（72.95% 对 61.81%）。在图分类上，它在六个 TU 数据集中赢下五个，COLLAB 达 86.15%，IMDB-MULTI 达 56.32%，两者都是各自数据集上的最好结果。

异配基准中已知存在重复节点，可能造成标签泄漏，因此作者又在去除重复节点后的 Chameleon 与 Squirrel“过滤版”上评测。CoCN 依然在 18 个模型中排名第一，这说明它的优势并非来自数据泄漏。

表 1 原始 / 过滤版 Chameleon 与 Squirrel 上的节点分类准确率（%）。过滤版去除了重复节点。CoCN 在两个原始数据集上均排第一，过滤后仍具竞争力。

模型	Chameleon 原始	Chameleon 过滤	Squirrel 原始	Squirrel 过滤
FAGCN	64.23	41.90	47.63	41.08
GCN	50.18	40.89	39.06	39.47
ResNet+adj	71.07	38.67	65.46	38.37
FSGNN	77.85	40.61	68.93	35.92
CoCN (本文)	79.61	41.95	73.27	39.69

既然排一次顺序有用，那么用几种不同的顺序会不会更好？每一种置换都让卷积看到一种不同的排列，于是 CoCN 并行地学习多个置换。图 5 显示，在 MUTAG、Chameleon、Cornell、Wisconsin 上，准确率随置换数目增加而稳步上升。




图 5 置换数目的消融实验。在四个数据集上，准确率随置换数目增加而稳步上升，约到 8 个之后趋于平缓——少数几个互补的排序就能拿到大部分收益。

增益在大约八个置换之后趋于平缓，这提供了一个实用的取舍：少数几个互补的排序就能拿到大部分收益，而且模型会逐渐学着让这些排序彼此更不冗余。

小结

CoCN 的贡献既是实证的，也是概念上的。一旦能学到一个可微的置换、把图的节点排成一行，图像卷积的整套工具——滑动卷积核、池化、分层特征、上采样——就都能用到图上，而且 $O(n^2)$ 的代价可以扩展到大图。作者也诚实地指出了边界：在 MUTAG、Texas 这类连接较弱的图上，可供对角核压缩的局部结构较少，提升也就有限。但只要结构存在，“先把图排好序、再当成图像来卷积”，就是一个出奇有效的思路。

什么时候适合用 CoCN

一个实用的经验法则是：当图本身具有可供排序的局部结构——社区或同配（homophily）模式，或者清晰的节点特征簇——CoCN 往往能带来收益，因为这正是对角卷积核所压缩的东西；而在近乎无结构的图上，收益会明显变小，MUTAG 与 Texas 的结果即是例证。无论如何，有两点让它值得留在工具箱里：置换是端到端学出来的，而非手工设计； $O(n^2)$ 的代价让这一 CNN 式模型能在几十万节点的大图上做小批量训练，而这正是多数“图上卷积”思路难以扩展的区间。

论 文： <https://proceedings.mlr.press/v202/sun23k.html> · 代
码：<https://github.com/sunjss/CoCN>