

ICLR 2024 | 非线性 RNN 为什么记不住长期依赖，又该如何松绑

一个逆向逼近定理证明：非线性 RNN 能够稳定学到的目标，其记忆必然随时间指数衰减；而一种有原则的稳定重参数化可以缓解这一限制。微软亚洲研究院与新加坡国立大学的工作。

面对序列数据，比如时间序列、语音、文本、情感，循环神经网络（Recurrent Neural Network, RNN）往往是我们最先想到的基础模型。但它也有一个反复出现的短板：当输出依赖于很久之前发生的事情时，普通 RNN 常常会“断线”。对此，人们通常给出的是一个优化层面的解释，即梯度在沿着许多时间步反向传播时会消失或爆炸，让长距离依赖变得难以训练。

但这个解释回避了一个更尖锐的问题：RNN 在长期记忆上的困难，究竟只是一个可以靠更好的优化器修复的训练假象，还是模型本身能表示什么这件事上的结构性限制？两种诊断对应着完全不同的应对方式，而要把它们区分开，需要的是逼近理论（approximation theory）的视角，而不是优化的视角。

这篇 ICLR 2024 的论文为非线性 RNN 给出了答案。它证明了一个逆向（inverse，即 Bernstein 型）逼近定理：如果一个非线性 RNN 能够稳定地逼近某个目标序列关系，那么这个目标的记忆必然随时间指数衰减。换句话说，长期依赖上的困难是写进 RNN 假设空间里的，而不只是优化器的问题。更进一步，同一套分析还指向了一剂解药，即对循环权重做一种稳定重参数化（stable reparameterization），它在理论和实验上都能缓解这一限制。

作者：Zhong Li（微软亚洲研究院），Shida Wang、Qianxiao Li（新加坡国立大学；Institute for Functional Intelligent Materials）。

论文：<https://arxiv.org/abs/2305.19190>

逼近理论的两个方向

逼近理论提供了两类互补的陈述。正向（forward，即 Jackson 型）定理告诉你：对一个足够光滑的目标，模型能逼近到多好。逆向（inverse，即 Bernstein 型）定理则反过来走：先假设一个目标可以被高效逼近，再反推这个目标本身必须具备什么样的正则性。机器学习里的逼近结果大多是正向定理，这也是它们很少能揭示某种结构真正天花板的原因；而逆向定理，恰恰是干这件事的工具。

在此之前已有一个先例。早先的工作针对线性 RNN 证明了一个 Bernstein 型结果：线性 RNN 能高效逼近的任何线性目标，其记忆都必须指数衰减，这一现象被称为“记忆诅咒”（curse of memory）。真正悬而未决、也更迫切的问题是：非线性能不能打破这个诅咒？非线性大幅提

升了模型容量，直觉上，更强的模型应当能记住更多过去的信息。这篇论文要问的，正是这个直觉在严格的逆向定理面前能否站得住。

两件工具：记忆函数与稳定逼近

整套分析立足于两个要素。第一个是记忆函数（memory function），它把线性情形下的定义推广到了任意的非线性泛函序列。它用 Heaviside 阶跃输入去探测模型，通过响应对时间的导数，度量时刻 t 的输出仍然对输入有多强的依赖。关键在于，这个记忆函数不只是一个抽象定义，它可以从训练好的模型中被数值地查询出来，于是我们真的能把一个网络记忆的衰减方式画成曲线。

第二个要素是稳定逼近（stable approximation）的概念。基于梯度的训练要想奏效，参数的小改动就必须只带来模型的小改动。为此，作者把隐藏维度为 m 时的扰动误差（perturbation error）定义为：当参数在半径为 β 的球内被扰动时，输出误差的最坏情况值。如果这个扰动误差在某个正半径以内始终连续，就称该目标被稳定逼近，这个半径被称为稳定半径。这是一个温和、且对优化友好的要求，也是整个论证的枢纽。

图 1 把“好”的情形具体化了。对一个记忆指数衰减的目标，不同隐藏维度对应的扰动误差曲线会穿过同一个公共点，而在一个正稳定半径的左侧，极限曲线保持连续。也就是说，稳定逼近是存在的。




图 1 隐藏维度 $m = 2$ 到 14 时，扰动误差随扰动强度 β 的变化，目标为记忆指数衰减的线性泛函。存在一个正的稳定半径（红色标注）：在其左侧极限误差曲线保持连续，因此该目标可被稳定逼近。

逆向定理：非线性并没有帮上忙

有了这两件工具，主定理就是一个干净的逆命题：如果一个记忆衰减的目标，能被权重范数与扰动后记忆都被一致控制住的非线性 RNN 稳定逼近，那么这个目标的记忆必然指数衰减。证明利用稳定性把隐藏状态的导数逼向零，再借助 Hartman-Grobman 定理去约束循环矩阵的特征值，从而强制出指数衰减。结果是：非线性并没有解除记忆诅咒，而是继承了它。

数值实验从另一面讲了同样的故事。当目标的记忆只是多项式衰减时，图 1 中那种稳定性就消失了。不同隐藏维度的扰动误差曲线不再收敛到一条连续的极限曲线，而是随着维度增大，交点不断向左移动，于是没有任何正的稳定半径能够存活下来。图 2 用一个非线性 tanh RNN 展示了这一点，它与线性情形如出一辙。




图 2 非线性 tanh RNN 逼近一个记忆多项式衰减的目标（在 1000 个 epoch 时拟合完成），隐藏维度 $m = 4$ 到 64。随着 m 增大，曲线交点持续向左移动，不存在正的稳定半径：该目标无法被稳定逼近。

最直接的证据来自一个筛选实验。作者构造了若干个随机初始化、隐藏维度很大 ($m = 256$) 的 RNN 作为教师模型，再用一系列学生 RNN 去逼近每一个教师，并数值检验这个逼近是否稳定。只保留那些既可被逼近、逼近又稳定的教师之后，剩下的恰好只有一类：记忆函数指数衰减的教师。图 3 左侧是稳定性检验，右侧是一个存活教师指数衰减的记忆函数。




图 3 按稳定性筛选随机教师 RNN（隐藏维度 $m = 256$ ）。左：学生逼近在 $m = 4$ 到 64 时的扰动误差。右：一个存活教师的记忆函数，呈指数衰减。只有记忆指数衰减的教师能通过稳定性筛选。

解药：稳定重参数化

既然问题在于普通训练会把循环权重推到“小扰动就会放大”的区域，那么解法就是重新参数化，让所有可达到的权重从一开始就是稳定的。作者用一个连续映射来替换循环权重矩阵，这个映射的取值始终落在“特征值实部为负”的矩阵集合里，例如指数映射或 `softplus` 映射。网络仍然可以把特征值推向稳定的边缘以捕捉更多记忆，但再也无法越过这条边，于是逼近在扰动下保持连续。

图 4 在合成数据上确认了这种恢复。对一个多项式衰减的目标，用指数和 `softplus` 重参数化的线性 RNN 去逼近，图 2 中缺失的连续极限曲线又回来了，这正是理论预测稳定参数化应当带来的效果。




图 4 仍是前面那个多项式衰减目标，改由带指数和 `softplus` 重参数化的线性 RNN 逼近，隐藏维度 $m = 2$ 到 14。极限曲线重新变得连续：稳定性，连同可逼近性，都被恢复了。

在真实任务上有用吗：MNIST

这套方法的回报并不只停留在理论上。在 MNIST 图像分类任务上，从完全相同的权重初始化出发、训练 10 个 epoch、并对 3 次重复取平均后，三种稳定重参数化都胜过了“直接”（direct）这种把循环权重原样使用的不稳定参数化。其中 softplus 取得了最好的测试准确率；而由于重参数化并不改变模型固有的容量，这一提升反映的是优化与稳定性上的收益，而非容量的变化。

表 1 不同循环权重参数化方式在 MNIST 上的测试损失与准确率（训练 10 个 epoch，对 3 次重复取平均）。三种稳定映射都优于直接的不稳定基线。

参数化方式	测试损失	测试准确率 (%)
softplus (稳定)	0.8903	71.36
exp (稳定)	0.9028	70.55
inverse (稳定)	0.9082	70.77
direct (不稳定)	0.9177	68.47

差距不大但很一致：softplus 达到 71.36%，而不稳定基线为 68.47%，提升接近 3 个百分点，exp 与 inverse 也都在 70% 以上。合成实验则把关于“难度”的这一点说得更透彻：记忆指数衰减的目标大约 10 个 epoch 就能拟合，而记忆多项式衰减的目标需要约 1000 个 epoch，并且即便如此依然通不过稳定性检验。

小结

一句话总结：无论你怎么训练，普通的非线性 RNN 只能稳定逼近那些记忆随时间指数衰减的序列关系，因此它们在长期依赖上众所周知的挣扎，是架构本身的性质，而不仅仅是优化器的问题。这是这个否定性结论诚实的边界。而它建设性的一半在于，同一套分析给出了解药：用指数或 softplus 这样的稳定映射去重参数化循环权重，可以让特征值贴近稳定的边缘却不越界，从而在理论上缓解记忆诅咒，并在 MNIST 这样的真实任务上训练更快、泛化也略好。

而且，这里引入的两件工具，即可被数值查询的记忆函数，以及基于扰动的稳定逼近概念，足够通用，能够向 GRU、LSTM 这类门控架构延伸，为“某个循环模型到底能学到、又学不到哪些序列关系”提供一条有原则的分析路径。