

# ICLR 2022 | 强化学习的鲁棒性，不只是测出来，还要证出来

---

CROP：用函数平滑为强化学习策略提供可证明的鲁棒性认证，覆盖动作与累积奖励两个层面

强化学习正在悄悄走出游戏和仿真环境，进入那些「一步走错、代价高昂」的场景：自动驾驶里的车道保持、自动交易中的仓位决策、机器人里的控制回路。在这些系统里，智能体（agent）不断观察状态（state），并在每一步选择一个动作。令人不安的是，这些观测是可以被篡改的。已有研究表明，只要对手对输入状态施加一点人眼几乎察觉不到的扰动，就能稳定地改变智能体的决策，而若干个被改变的决策，往往就足以把一个策略推向危险的方向。

常见的应对方式，是让策略在经验上「更抗揍」：对抗训练、光滑性正则、噪声注入。它们各自能挡住测试时用到的那些攻击，却又一次次被更强、更有针对性的攻击攻破。这个循环暴露出真正的缺口：能扛住今天的攻击，几乎说明不了明天会怎样。安全攸关的强化学习真正需要的，是一份认证（certification）：证明策略在给定扰动预算内、面对任意扰动都保持可靠，而不仅仅是面对有人恰好试过的那几种攻击。

CROP 正是为强化学习提供这样一份证明的首个统一框架，来自伊利诺伊大学厄巴纳-香槟分校、圣路易斯华盛顿大学与卡内基梅隆大学，发表于 ICLR 2022。它在 2 个层面上认证鲁棒性：每一步所选动作的稳定性，以及整条轨迹上累积奖励的可证明下界；并用这套工具，在 4 个环境上对 9 种已有的鲁棒 RL 方法做了统一、可证明的评测。

论文：<https://arxiv.org/abs/2106.09292> · 项目与排行榜：<https://crop-leaderboard.github.io>

## 为什么强化学习的鲁棒性难以「认证」

对图像分类器来说，认证鲁棒性已经是一个相对成熟的问题，背后的主力工具是随机平滑（randomized smoothing）：给输入加上高斯噪声、对分类器输出取平均，得到的平滑分类器就自带一个可证明的半径——在这个半径内，输入无论怎么扰动，预测都不会改变。把这套配方直接搬到强化学习里，看起来很诱人，但有两处障碍横在中间。

第一处障碍在输出本身。分类里的置信度落在一个已知的、从零到一的区间里，像一个概率，正是这一点让半径的推导成立；而 Q 网络的输出既不在已知范围内、也不是概率。第二处障碍更偏概念：认证单步动作，并不等于认证整个智能体。真正重要的是一整串决策累积出的奖励，一个策略可能在每个状态上都局部稳定，却仍然在持续攻击下不断损失奖励。CROP 要同时跨过这两道坎。

## 函数平滑：两类标准，三种算法

CROP 的核心引擎是函数平滑（functional smoothing）。在每个状态、针对每个候选动作，方法先用高斯噪声扰动状态，再对训练好的 Q 网络输出在噪声上取平均，得到一个平滑后的值函数。一条关键引理表明，这个平滑值函数是 Lipschitz 连续的，也就是变化不会太快，而且这个常数会随着平滑方差  $\sigma$  增大而减小。连续性正是撬动一切的杠杆：既然值函数不会剧烈摆动，小扰动也就无法让所选动作发生翻转。

由这份连续性，论文定义了 2 类认证标准，并把每一类都落成一个具体算法。为了驯服「输出范围未知」这个问题，Q 输出的范围会先在一小部分状态上预估出来，再用集中不等式给平滑值加上界，使得证书在噪声的蒙特卡洛采样下依然可靠。

表 1 CROP 的三种算法、各自使用的平滑方式，以及它们分别认证的目标。

| 算法         | 平滑方式    | 认证目标                              |
|------------|---------|-----------------------------------|
| CROP-LoAct | 局部平滑    | 单步动作的认证半径 $r$ ；扰动在 $r$ 内动作被证明不变   |
| CROP-GRe   | 全局平滑    | 累积奖励的期望界 JE 与 50% 分位界 $J_p$ 两个全局界 |
| CROP-LoRe  | 自适应局部搜索 | 累积奖励的绝对下界 $J$ ，三者中最紧              |

CROP-LoAct 负责动作层面。对每个状态，它用最优动作与次优动作的平滑值之间的间隔，算出一个认证半径  $r$ ：只要扰动小于  $r$ ，排在最前的动作就仍然最前，策略的决策便被证明不会改变。这个半径也揭示了  $\sigma$  上一个真实的权衡——平滑越多，值函数越稳，这是好事；但它同时压窄了前两个动作之间的间隔，这是坏事。于是最优的噪声量是一个平衡点，而不是越大越好。

## 认证结果告诉了我们什么

把 CROP-LoAct 跑遍 9 种方法，就能得到每一步的认证半径，它可以被直接读作：在动作发生翻转之前，每个策略还能吸收多大的扰动。下图记录了这个半径在两款 Atari 游戏 Freeway 和 Pong 上随时间的变化，每一列对应一个不同的平滑水平  $\sigma$ 。




图 1 全部 9 种方法在 Freeway（上）与 Pong（下）上、每一步的动作认证半径  $r$  随时间的变化；每一列对应一个平滑方差  $\sigma$ 。在 Freeway 上，RadialRL（品红）是最可证明鲁棒的方法；在 Pong 上则是 SA-MDP (CVX)（紫色）领先。阴影为标准差，且很小。

两位赢家浮现出来，而且随环境而不同。在 Freeway 上，RadialRL 在每个平滑水平下都保持最高的认证半径，这与它的设计相符：它显式地针对最坏情况扰动做优化。在 Pong 上，采用凸松弛的 SA-MDP (CVX) 最为可证明鲁棒。令人安心的是，这些「可证明」的排名，与人们此前在经验上观察到的结果相互吻合——证明与实践一致，正是这种一致性让一份证书值得信赖。

逐状态的视角还揭示出一个被「单一鲁棒性数字」掩盖的结构。在 Pong 上，每种方法的认证半径并非一条平线，而是有规律地起伏；把这条曲线和游戏画面对齐，原因便一目了然。




图 7 Pong 上认证半径的两个连续周期（每格上方），与其对应的游戏画面（下方）对齐。鲁棒性在「有把握」的时刻达到峰值——例如球正朝球拍飞来时——而在下一步动作无关紧要时回落。两个周期几乎完全相同。

这个解读很直观：当球正朝球拍飞来，正确的动作毫无悬念，最优与次优动作之间的间隔很宽，认证半径就大；而在两个回合之间的间歇里，选哪个动作都差不多，半径随之塌缩。这表明，鲁棒性并不是策略的一个固定属性，而是随着「每个状态有多关键」而涨落——这也暗示，未来的防御或许可以把力气集中在那些真正要紧的状态上。

## 从单步动作到整条轨迹

认证动作只是 CROP 的一半。另一半回答的是实践者真正关心的问题：在任意有界攻击下，策略能保证拿到多少奖励？CROP 给出三个由松到紧的奖励界。CROP-GRe 用全局平滑给出期望奖励界（JE）和 50% 分位奖励界（Jp）；CROP-LoRe 则在轨迹上做自适应树搜索，认证出一个绝对下界（J）。下图把这三者对攻击幅度  $\epsilon$  作图：实线是认证界，虚线是在真实 PGD 攻击下的经验奖励。




图 3 全部 9 种方法的累积奖励认证界随攻击幅度  $\epsilon$  的变化：期望界  $J_E$ （上行）、50% 分位界  $J_p$ （中行）与绝对下界  $J$ （下行）。每一列对应一个平滑方差  $\sigma$ 。实线为认证界，虚线为 PGD 下的经验奖励。

三个界并非同样有用，它们之间的差距才是重点。期望界  $J_E$  很松——随攻击增大迅速下滑，很快就失去信息量。分位界  $J_p$  要紧得多。而 CROP-LoRe 给出的绝对下界  $J$  更紧：在很大一段攻击幅度范围内，它几乎与经验 PGD 曲线严丝合缝地重合，这种「零间隙」说明证书不只是成立，而是基本精确。当一个可证明的下界，恰好等于现有最强攻击真正打出的结果时，几乎就没有多少鲁棒性被漏算了。

## 到底该平滑多少

既然平滑方差  $\sigma$  决定了整份证书，论文就直接研究它，结论是：合适的噪声量取决于环境。在能容忍大扰动的 Freeway 上，强方法的鲁棒性会随  $\sigma$  一路上升，直到 1.0。Pong 上则相反：平滑过头会抹平值间隔，对几乎所有方法而言，0.01 到 0.03 之间的中等  $\sigma$  最好。并不存在一个通用设置—— $\sigma$  是一个要按环境去调的旋钮，而 CROP 让这个权衡变得可度量，而不是靠猜。

## 为什么这项工作重要

CROP 留下的核心信息是：强化学习的鲁棒性，不必只是一种「但愿如此」。通过平滑值函数，你可以证明智能体的动作在一个认证半径内保持不变，也可以证明它在给定预算内任意攻击下所能拿到奖励的下界。把这套方法用到 4 个环境上的 9 种方法，得到的证书不仅成立，而且常常很紧——与真实攻击打出的结果相当。

该说清的边界也值得一提。这些证书针对的是状态观测上  $L_2$  范数有界的扰动，依赖蒙特卡洛采样、也就带着相应的统计假设，并且继承了那个需要按环境调的  $\sigma$  权衡。CROP 真正贡献的，是一把「可证明」的统一标尺：与其比较各种鲁棒 RL 方法「碰巧扛住了哪些攻击」，这个领域现在可以按「能被证明保证什么」来比较它们。作者把结果做成了一个开放排行榜，邀请更多人来认证更多方法、更多环境。