

只凭序列，预测 RNA 与蛋白质是否相互作用

弗莱堡大学与 ELLIS Institute Tuebingen 提出同源分离数据集 RNAInterAct 与轻量 Transformer 模型 RPIembeddor (GEM workshop, ICLR 2024)

非编码 RNA (non-coding RNA) 在细胞中主要通过结合蛋白质来发挥调控作用，但用 SELEX、CLIP-seq 等实验手段逐一测定这些相互作用，既慢又贵。已有的计算方法大多回避了通用问题：它们为每个蛋白质单独训练一个模型，而这需要该蛋白质专属的大规模相互作用数据。这样的数据集，只覆盖了大约 2000 个人类 RNA 结合蛋白中的几百个。

领域真正缺少的，是一个能回答更朴素也更困难问题的预测器：给定任意一条 RNA 和任意一个蛋白质，仅凭它们的序列，判断二者是否相互作用。两条近期思路让这件事变得可行。一是跨多种相互作用类型一起学习，而不是一次只学一个蛋白质，这在标注稀缺时更有优势；二是在海量无标注生物物料上训练的基础模型 (foundation model)，能够暴露原始序列本身并不直接显示的结构与功能信号。

这项来自弗莱堡大学 (University of Freiburg) 与 ELLIS Institute Tuebingen 的工作，补齐了缺失拼图的两半：RNAInterAct，一个带同源分离划分的大规模非编码 RNA 与蛋白质相互作用数据集；以及 RPIembeddor，一个仅 1.4M 参数、只用序列嵌入就能分类相互作用的轻量 Transformer 模型。与以往工具不同，它能泛化到训练中从未见过的 RNA 家族。

论文 (bioRxiv 预印本) : <https://www.biorxiv.org/content/10.1101/2024.11.08.622607v1> 。
数据集 (RNAInterAct 存档) : <https://ml.informatik.uni-freiburg.de/research-artifacts/RNAInterAct/RNAInterAct.tar.gz> 。
两者均由作者公开发布，供研究使用。

为什么“只凭序列、跨家族泛化”很难

像 IPMiner 和 XRPI 这样的既有方法，当训练集和测试集共享 RNA 家族时可以取得不错的分数，因为序列同源性会在二者之间泄漏信息。真正的考验是泛化：一个在部分 RNA 家族上训练的模型，能否为它从未见过的家族判断相互作用？RPIembeddor 正是面向这一设定构建和评测的，其数据划分保证训练与测试不共享任何 RNA 家族。

RPIembeddor：两个基础模型，一个分类器

模型依托两个预训练基础模型。RNA 序列用 RNA-FM 嵌入，蛋白质序列用 150M 参数的 ESM-2 嵌入；之所以选 ESM-2 而非 AlphaFold 这类结构预测器，是因为它不需要多序列比对。两者都产生 640 维的嵌入，携带着原始字母序列并不直接显示的结构与功能先验。

如图 1 所示，两路并行的前馈层把两种嵌入归一化到统一尺寸，基于注意力的编码器层再对称地处理 RNA 与蛋白质表示，让任何一种模态都不会压过另一种。随后把潜在表示拼接起来，

经过进一步的前馈层，最后一个带 sigmoid 的线性层输出这一对是否相互作用的概率。整个分类器只有 1.4M 参数，用二元损失和 AdamW 优化器训练。




图 1 RPIembeddor 架构。RNA 与蛋白质的嵌入先由两路并行的前馈层归一化，再经基于注意力的编码器层对称处理，使两种模态影响力相等；随后拼接，并通过最后一个带 sigmoid 的线性层，输出相互作用的概率。

RNAInterAct：一个考虑同源性的基准

一个模型的可信度，取决于它在什么样的数据上被检验。作者从 RNAInter 数据库出发构建 RNAInterAct，通过交叉比对 NCBI、UniProt 和 Ensembl 恢复序列，并用 Rfam 标注 RNA 家族、用 Pfam 标注蛋白质 clan。正是这些家族与 clan 标注，让他们能够生成生物学上合理的负样本，而不是随机配对。




图2 RNAInterAct 数据构建流程：来自 RNAInter 的正相互作用，先与外部数据库（NCBI、UniProt、Ensembl、miRBase、NONCODE）中的序列匹配，再用 Rfam 家族与 Pfam clan 标注，并结合家族-clan 相互作用网络生成有生物学意义的负样本。

最终数据集包含 122,217 条非编码 RNA 与蛋白质相互作用，正负比为 1:2。关键在于，它按 RNA 家族划分为训练集 TRinter（109,214 条相互作用，覆盖 976 个家族）和测试集 TSfam（13,003 条相互作用，覆盖 172 个家族），两者不共享任何家族。此外，模型还在外部的、仅含正样本的 RPI2825 集（871 条相互作用）上测试，用以检验跨数据分布而非分布内的泛化能力。

结果：基线接近随机，模型学到真实信号

在同源分离的 TSfam 测试集上，“学习”与“记忆”的差别变得格外明显。一个仅仅靠同源性取巧的模型会在这里失灵，因为没有任何测试家族在训练中出现过。




图3 TSfam 上的 ROC 曲线。RPIembeddor 的 AUC 达到 0.70，而 XRPI (0.48) 和 IPMiner (0.50) 几乎贴着对角线，说明它们在未见过的 RNA 家族上表现接近随机。

RPIembeddor 取得 0.586 的 F1 和 0.667 的准确率，ROC AUC 为 0.70；而 XRPI 与 IPMiner 的 AUC 分别只有 0.48 和 0.50，处于或低于随机水平。具体来说，RPIembeddor 在 TSfam 上正确判别了 4,887 条正样本中的 2,971 条、8,116 条负样本中的 5,586 条；而 XRPI 几乎把 91% 的样本都判为相互作用，尽管其中约 62% 实为负样本。

表 2 在同源分离的 TSfam 测试集上的平均性能。RPIembeddor 在兼顾精确率的 F1 与准确率上领先，而基线要么牺牲精确率换召回率，要么反之。

Model	Prec.	Rec.	F1	Acc.
RPIembeddor	0.550	0.627	0.586	0.667
IPMiner	0.357	0.375	0.366	0.512
XRPI	0.375	0.909	0.531	0.398

在外部 RPI2825 集上，RPIembeddor 也取得第二好的 F1 (0.8)，显示模型能够跨数据分布迁移，而不是只对单一基准过拟合。

消融实验：两个嵌入缺一不可

基础模型的嵌入究竟是不是承载信号的关键，还是注意力网络自己就能搞定？作者把 RNA-FM 嵌入、ESM-2 嵌入或两者，替换成随机向量或 one-hot 编码后重新训练 RPIembeddor，再看还剩下什么。

表 3 TSfam 上的消融实验。移除任一嵌入都会让模型退化成只预测负类的分类器；只有完整的双嵌入模型才能正确分类。

Model	Prec.	Rec.	F1	Acc.
RPIembeddor	0.563	0.659	0.605	0.678
One-Hot	0.0	0.0	0.0	0.624
Random-Protein	0.0	0.0	0.0	0.624
RNA-Random	0.0	0.0	0.0	0.624

每一个变体都退化成只会预测负类的分类器：精确率、召回率和 F1 都降到 0.0，准确率卡在 0.624，恰好等于测试集中负样本的比例。只有当 RNA-FM 与 ESM-2 两个嵌入同时存在时，模型才能达到 0.605 的 F1 和 0.678 的准确率。这两个基础模型嵌入并非可有可无的附加项，结构与功能信息正藏在其中。

小结

这项工作留下的核心信息是：当你站在基础模型的肩膀上，通用的、只凭序列的 RNA 与蛋白质相互作用预测就变得可行。一个用 RNA-FM 和 ESM-2 嵌入喂入的轻量注意力网络，不仅胜过专用工具，还能泛化到从未见过的 RNA 家族。同样重要的是，做了同源分离的 RNAInterAct 数据集，为社区提供了一个衡量泛化能力、而非同源性泄漏的基准。作者也指出了清晰的下一步：引入 RNA 结构模型，并放宽当前的序列长度限制。