


ICLR 2024 | 把大模型的预训练范式带进系统神经科学：Neuroformer

加州大学圣塔芭芭拉分校提出面向脑数据的多模态、多任务生成式预训练框架

系统神经科学正在进入自己的“大数据时代”。今天的一次实验，往往能在细胞分辨率下同时记录成千上万个神经元的放电，并同步采集视觉刺激、眼动、身体运动等多种行为信号。数据的规模和模态数量都在快速增长，但用来分析它们的工具，很多仍然是为更小、单模态的记录设计的经典统计方法。

结果是数据的丰富程度和分析手段之间出现了越来越大的落差：我们能记录到神经环路和行为如何一起变化，却很难用统一的方法把它们联系起来。与此同时，视觉和语言领域给出了一个很有说服力的参照——大型预训练 Transformer 通过自监督的“预测下一个”任务，从原始数据里学到通用表示，再用很少的标注就迁移到各种下游任务。

这篇发表于 ICLR 2024 的工作提出了 Neuroformer：一个专为脑数据设计的多模态、多任务生成式预训练 Transformer。核心想法是把神经放电的分析重新表述为一个自回归的时空生成问题（autoregressive spatiotemporal generation）——像语言模型逐个预测 token 那样，逐个预测“哪个神经元在什么时间放电”。整个模型完全自监督训练，不需要标签，却能恢复出神经环路的连接结构，并在极少量微调数据下迁移到解码动物行为的任务上。



论文与开源代码：

论文 (arXiv) : <https://arxiv.org/abs/2311.00136>

代码 (GitHub) : <https://github.com/a-antoniades/Neuroformer>

问题：为什么需要一个新的分析范式

传统的神经数据分析方法，大多是任务专用、单模态、且随神经元数量增长而扩展性变差的。当一个实验同时给出神经活动、视觉刺激和行为时，用一套方法把这些异质信号联合建模、并迁移到新的下游任务，一直是件很难的事。作者的判断是：既然自监督生成式预训练能在视觉和语言里学到可迁移的通用表示，那么同样的配方也可能解锁对大规模神经放电数据的可扩展分析。

方法：把放电当作 token，自回归地生成

Neuroformer 给每个神经元分配一个 ID，把每一次放电看作一个 token。它按时间上下文窗口把活动切成“当前状态”（Current State）和“过去状态”（Past State）两部分。视频帧经过一个小的 3D 卷积编码器后被切成 patch，行为则作为独立的特征流进入模型。

在融合之前，一个多模态对比模块会先对齐神经、视觉和行为表示：它最大化真实配对之间的相似度，让不同模态落在可比较的空间里。随后，一串级联的交叉注意力模块把较小的“当前状态”与更大的特征序列融合——正是这个设计把注意力的复杂度从随特征数平方增长降到近似线性增长（当前状态长度远小于特征长度时）。最后，一个带因果掩码的 Transformer 解码器在每一步同时预测“哪个神经元放电”和“它落在哪个子区间时间格”，从而让同时发生的放电也能被顺序地生成出来。整个模型用对比损失和两个放电交叉熵损失的加权和联合优化。

验证一：在有标准答案的仿真网络上，注意力恢复出真实连接

要判断模型学到的到底是不是真实的环路结构，最干净的办法是先在“答案已知”的系统上检验。作者构造了一个仿真的脉冲神经网络，其中三个“枢纽”（hub）神经元与大量其他神经元强连接，从而提供一份地面真值的连接矩阵。下图对比了不同分析方法能否还原这份连接结构。




图 2 用地面真值验证 Neuroformer。(a) 仿真网络中三个红色枢纽神经元与许多神经元强连接；(b) 真实连接矩阵作为参照；(c) Neuroformer 的放电预测（红）与真实放电（黑）高度吻合，预测-真值相关系数普遍为正且大于

0.1；(d) 简单的 Pearson 相关只能看到三个子网络，却因为缺少方向性和因果性而漏掉枢纽神经元；(e) Neuroformer 的注意力能推断因果方向，从而正确显现出枢纽神经元。这说明模型学到的不只是共变，而是带方向的连接结构。

对比 (d) 和 (e) 是这张图的重点：Pearson 相关本身没有方向性，因此看不出谁在驱动谁，也就找不到枢纽神经元；而 Neuroformer 的注意力矩阵能推断出带方向的连接，把三个枢纽清晰地标出来。换句话说，注意力在这里扮演了一个数据驱动的因果性探针。

验证二：在真实小鼠视觉皮层数据上，预测更准

光在仿真上成功还不够。作者接着转向真实数据：用大视场双光子钙成像，记录小鼠视觉皮层 V1 和 AL 两个区域的神经活动，筛选出 386 个响应可靠的神经元，让小鼠观看光栅 (gratings) 和自然视频 (naturalistic videos) 两类刺激。




图 3 在真实数据上的表现。(a) 用双光子钙成像记录 V1 与 AL 两个视觉区，筛选后保留 386 个可靠神经元；(b) 无论对光栅还是自然视频，Neuroformer 生成的放电 (红) 都能贴合真实放电 (黑)；(c) 与广义线性模型 (GLM) 相比，Neuroformer 对群体响应的预测与真值更相关 (t 检验， $p = 0.0196$)；(d) 注意力给出了数据驱动的刺激图，标出与神经响应存在统计依赖的部分。

(c) 的散点图把每个神经元的“Neuroformer 预测相关度”对“GLM 预测相关度”作图：多数点落在对角线上方，意味着在同一批神经元上，Neuroformer 的群体响应预测整体上比 GLM 更接近真值，且差异在统计上显著 ($p = 0.0196$)。

从预测放电到解码行为：预训练带来的少样本迁移

Neuroformer 最引人注意的结果，是它能把在神经放电上学到的表示迁移到一个全新的任务——从神经活动解码小鼠的奔跑速度。作者在一个虚拟导航 (Visnav) 数据集上做这件事，该数据集同步记录了神经活动和小鼠的运动。




图 5 行为解码与少样本学习。(a) Neuroformer 预测的速度与真实速度高度相关 (Pearson $r = 0.97$) ; (b) 只用 1% 行为数据微调的预训练模型 (浅绿) , 显著超过用 10% 数据从头训练的非预训练模型 (深蓝) —— $r = 0.51$ 对 0.33 ; (c) 行为损失曲线 : 预训练模型 (绿) 收敛更快、测试损失更低。这说明在神经放电上做的自监督预训练, 确实学到了与行为相关、可迁移的结构。

(b) 是关键 : 一个先在神经响应上做过掩码预训练、再只用 1% 行为标签微调的模型, 其解码相关度 ($r = 0.51$) 反而超过了一个用十倍数据、从随机初始化训练的等价模型 ($r = 0.33$) 。这正是预训练范式在其他领域里那种“少样本也能打”的迁移能力, 第一次在脑数据上被清楚地展示出来。下表进一步给出在完整数据上训练时, 各方法的行为预测相关度。

表 1 在完整数据上训练时的行为 (速度) 预测相关度 (Pearson r) , 分别针对 Visnav 的 Lateral 和 Medial 两个数据集。Neuroformer 在两个数据集上都取得最高相关度 (0.95 / 0.97) , 明显优于 Lasso 回归、GLM、MLP 和双向 GRU 等常规方法。

方法	Lateral	Medial
Lasso Regression	0.62	0.73
GLM	0.69	0.81
MLP	0.83	0.85
Bidirectional GRU	0.83	0.88
Neuroformer	0.95	0.97

消融 : 每个组件都在起作用, 联合建模更好

既然 Neuroformer 由多个部分拼成, 一个自然的问题是 : 到底是哪一块在贡献性能 ? 作者逐一移除组件来观察其影响。




图 6 各组件对性能的影响。逐步加入“当前状态”“过去状态”“视频”“行为”和“对比”组件后，模型在不同数据集和脑区上的预测能力（F1）总体持续提升。这表明每个部分都带来了可测量的增益，其中把神经响应与行为联合建模，效果好于只用其中之一。

两点结论值得强调：其一，把神经响应和行为放在一起联合训练，效果好于单独用任何一个信号——说明模型以一种无监督的方式，学会了把神经表示和行为表示关联起来；其二，对比对齐目标在数据稀缺时尤其有用，能抑制模型对噪声较大的神经信号过拟合。

小结与边界

Neuroformer 传达的核心信息是：那套重塑了视觉和语言的预训练范式，同样可以用在大脑上。把神经放电当作一个自回归的多模态生成问题，单个自监督 Transformer 既能恢复出神经环路的有向连接，又能在只有少量样本时迁移到解码动物行为。它给出了一条通向可扩展神经科学基础模型的实际路径，也暗示了未来把这类模型与大语言模型连接起来的可能。

对实践者来说，吸引力很具体：一个预训练骨干可以同时服务于环路推断和行为解码，而且随着记录到更多模态还能持续变好。这正是其他领域里那种“规模加自监督”的复利式回报，如今在神经数据上也变得触手可及。

同时也要注意结果的边界：论文的验证围绕仿真网络和小鼠视觉皮层 / 虚拟导航数据展开，最大的模型约为一亿参数量级；注意力恢复出的“连接”是在有地面真值的仿真上被校验的，迁移到没有标准答案的真实环路时仍需谨慎解读。这些都是把该范式进一步放大时需要面对的问题，而非对现有结论的否定。