

NeurIPS 2022 | 缺失也是信息：让临床生存模型在实践变化时依然可靠

剑桥大学与曼彻斯特大学提出 DeepJoint，把「数据是怎么被观测到的」也一起建模，而不只看数值本身。

凌晨三点开的一次血检、每小时重复的一组化验、始终没有出现的某项指标：在临床医生眼里，这些都不是随机事件，而是对「谁病得重、谁需要盯着」的判断。然而，大多数在电子病历上训练的生存模型，却把检测的时间和缺失当成噪声，要么插值补齐、要么直接忽略，只从记录下来的数值里学习。

什么时候、开哪些检查，这种模式本身就带着信息，作者称之为「临床在场（clinical presence，指临床数据被观测、采集的整个过程）」。更关键的是，它并不稳定：不同医院不一样，随年份漂移，甚至工作日入院和周末入院都不同。一个悄悄学到了某家医院开单习惯的模型，一旦部署到习惯不同的地方就可能失灵，而这恰恰是任何模型离开训练数据后都会遇到的处境。

DeepJoint (NeurIPS 2022) 来自剑桥大学 MRC 生物统计中心与曼彻斯特大学 Health e-Research Centre，它问的问题是：如果不再忽略观测过程，而是把它明确地建模，会怎样？它是一个多任务循环神经网络，把临床在场的三个维度与生存结局一起预测。论文显示，这样做既让短期预测更准，更重要的是，当临床实践发生变化时，预测明显更稳。




图 1 DeepJoint 深度联合模型。一个 LSTM 把病人不规则的化验序列压成嵌入 h ，再由 h 驱动四个「头」：L 负责数值的纵向演变，I 负责观测的间隔时间，M 负责缺失模式，S 负责生存结局。四个头里有三个描述的是数据「怎么被观测到」，而非「测到了什么」。

论文地址：<https://arxiv.org/abs/2205.13481>

代码地址：<https://github.com/Jeanselme/MultitaskTransportability>

临床在场：把观测过程当成信号

机器学习研究分布漂移已有多年，大多集中在协变量漂移（covariate shift，输入变了）或标签漂移（label shift，结局比例变了）。临床在场是第三种、被讨论得少得多的漂移：产生观测的过程本身变了。同一个病人，因为被监护的密切程度不同，在数据里可以呈现出很不一样的样子，而各家医院的监护方式并不相同。

常见做法是想办法让采样过程「消失」：把缺失值补上、重采样到规则的时间网格，最后交给模型一个干净的矩阵。DeepJoint 的立场恰好相反：缺失、时间间隔、以及测量值的走势，都携带着病人状态的信息，模型应该去学习它们，而不是抹掉它们。这背后的赌注是，一个理解了观测过程的表示，既会预测得更好，也会迁移得更稳。

一个嵌入，四个头

模型的核心是一个 LSTM（长短期记忆网络）。它读入病人入住 ICU 后不规则的化验序列，压缩成一个嵌入 h 。这个嵌入再驱动四个头，每个头都是一个小网络、带自己的似然：纵向头 L 用高斯似然预测下一次的检测数值；缺失头 M 用伯努利似然预测下一步会出现哪些检测；间隔头 I 用累积强度对测量之间的时间建模；生存头 S 则是一个 DeepSurv 的 Cox 模型，负责预测结局。

四个头一起训练。生存损失与三个临床在场损失被合成一个目标，由超参数 α 和一套动态加权平均（dynamic weighting-average）机制来平衡，避免任何单一任务主导：粗略地说，总损失是 $(1 - \alpha)$ 乘以生存项，加上 α 乘以纵向、间隔、缺失三项的加权和。由于四个头共享 h ，强迫这个嵌入去解释「数据是怎么被观测的」，等于对它做了一层正则化，而这正是它在漂移下占便宜的原因。

论文给出三个变体。DeepJoint 只用共享嵌入做生存预测；DeepJointFeature 在嵌入之上再加入显式的临床在场特征；DeepJointFineTune 则先训练联合模型，再把生存头端到端微调，追求最强的区分度。后面的结果会看到，这三者落在「准确度」与「稳健性」权衡上的不同位置。

数据：MIMIC-III 的 30,834 名 ICU 病人

实验使用 MIMIC-III，这是一个重症监护数据库，收录了 Beth Israel Deaconess 医学中心 2001 到 2012 年间匿名的化验、生命体征与诊断。数据库共 38,597 名病人，研究保留了入院后至少存活 24 小时的 30,834 人，并用第一天窗口内最后一次观测时的嵌入来预测院内生存。模型在病人层面按 90% / 10% 划分，用时间依赖 C-index（一致性指数，越高越好）和 Brier 分数评估，预测时程为 1、7、14 天。

建模观测过程确有回报，但集中在短时程

在总体的随机划分上，回报在 1 天时程最明显。下图请按行读：每个模型在 1、7、14 天的 C-index，带 95% 置信区间，加粗的是本文方法。最能说明问题的是 1 天这一列。只看化验数值

的 DeepJoint 达到 0.862，高于忽略临床在场的 LSTM（Ignore，0.853），也高于 GRU-D（0.855）这个把缺失当输入喂进去的强基线。也就是说，仅仅去建模观测过程，即便不把它作为输入，也能得到一个更有预测力的嵌入。




图 2 随机划分下的时间依赖 C-index，分别在 1、7、14 天（95% 置信区间，越高越好）。本文方法（加粗）在短时程领先，随着时程拉长逐渐与基线趋同，这与「临床在场主要反映短期不稳定」相吻合。

加特征、再微调能把成绩继续往上推：DeepJointFeature 在 1 天达到 0.873，DeepJointFineTune 达到 0.878，是全表最高。但优势依赖于时程。到 7 天、14 天，各模型基本挤到一起，因为临床在场更多反映的是短期不稳定，也就是「病人此刻被盯得有多紧」，而非长期走向。具体数字见下表。

表 1 随机划分下的时间依赖 C-index（均值，越高越好）。标注了本文方法。短时程的优势真实存在，但到第 14 天已明显收窄。

模型	1 天	7 天	14 天
Last	0.851	0.734	0.691
Count	0.860	0.746	0.699
Ignore	0.853	0.740	0.697
Resample	0.844	0.739	0.695
GRU-D	0.855	0.743	0.697
Feature	0.873	0.750	0.697
DeepJoint (本文)	0.862	0.742	0.695
DeepJointFeature (本文)	0.873	0.749	0.697
DeepJointFineTune (本文)	0.878	0.751	0.700

真正的考验：实践变了，模型还撑得住吗

随机划分上的区分度是简单情形，因为训练集和测试集共享同一套观测过程。论文真正想证明的是稳健性，因此需要一个可控的漂移。它用的是「周末效应」：周末入院的病人被监护的方式不同，其死亡率也已知与工作日入院不同。这就让「工作日 vs 周末」成为观测过程上一个天然、可控的变化。

由于两组病人的结局本身就有差异，它们的分数不能直接对比。论文转而借用稳健性文献里的迁移设置，如下图：在一组上训练、到另一组上测试，再单独在目标组自身上训练一个

「oracle（理想上限）」模型。把迁移模型和它的 oracle 相比，就能单独分离出：有多少性能纯粹是被临床在场的漂移「吃掉」的。



图 3 稳健性评估协议。模型 1 在周末入院上训练、到工作日入院上测试；模型 2 在工作日入院内部训练并测试，作为该目标组的 oracle。两者的差距衡量的是对漂移的敏感度，而不是结局差异本身。

结果要对着对角线来读。下图中，每个模型的迁移表现（纵轴）对它的 oracle 表现（横轴）作图，覆盖三个时程；落在虚线对角线上，意味着漂移没有造成任何损失。落在线下方的点，就是把精度输给了观测过程的变化，越靠下，模型越不稳健。




图 4 工作日到周末漂移下的稳健性：迁移 C-index（纵轴）对 oracle C-index（横轴），覆盖各时程，越靠近对角线越稳健。DeepJointFeature（橙色）最贴近对角线，同时保持强区分度；而在随机划分上最准的 DeepJointFineTune（蓝色）掉得更靠下。

在这里，排名翻转了。在随机划分上最锋利的 DeepJointFineTune，此刻却更靠对角线下方：为了区分度而狠狠微调，让它依赖上了训练组特有的开单习惯，于是对观测过程发生了过拟合。DeepJointFeature 则最贴近对角线，同时仍有不错的区分度，成为漂移下综合最优的选择。准确度冠军和稳健性冠军并不是同一个模型，而论文认为：对于真正的部署，重要的是那个稳的。

临床在场是信号，不是噪声

贯穿全文的线索很朴素：临床数据「是怎么被观测到的」，而不只是记录下来的数值，本身就是信息；一个把观测过程和结局一起学习的模型，既在短时程上更准，也在实践变化时更能迁移。它把缺失和不规则时间，从预处理的麻烦重新定义为值得直接建模的信号。

边界也值得如实说清：预测优势集中在短时程，到两周时已消退；研究只基于单一数据库（MIMIC-III）和单一结局（院内生存）；而最锋利的那个变体，也正是最容易对观测过程过拟合的，稳健性得主动去选。但核心信息远不止这份数据：当模型要被部署到训练习惯并不成立的地方，把观测过程当成信号，正是让预测在迁移后依然站得住的关键。