

NeurIPS 2022 | 给星系动力学建模提速 300 倍，让哈勃常数测得更准

SKiNN：用一个卷积网络替换引力透镜宇宙学里最慢的物理计算，精度损失不到 1%

宇宙到底膨胀得有多快？这个用哈勃常数（Hubble constant, H_0 ）刻画的问题，如今是天文学里最受关注的争论之一：用早期宇宙推算出的 H_0 和用近邻宇宙直接测量出的 H_0 对不上，差距已经无法用统计误差解释。引力透镜时间延迟（time-delay cosmography）提供了一条独立的测量路线，它不依赖传统的距离阶梯，因此格外重要。

它的原理是：一个前景星系的引力把背景类星体的光弯折成多个像，不同像的光走过不同路径、到达时间相差几天到几个月；把这个时间延迟和星系质量模型对起来，就能反推出宇宙的尺度，进而得到 H_0 。问题在于，透镜本身存在“质量片退化”（mass-sheet degeneracy）等简并——很多不同的质量分布能拼出几乎一样的成像，单靠成像数据无法区分。要打破这种简并，就需要一份独立的约束：星系内恒星的运动学（kinematics），也就是恒星的速度弥散。

麻烦的是运动学建模太慢。要把运动学和成像放在一起自洽求解，需要用 JAM 这类基于物理的轴对称动力学代码来预测速度场，而在 MCMC 采样里，每评估一次似然就要把 JAM 重新算一遍。单次计算就要十几秒，成千上万次叠加下来，联合探索透镜和运动学两个参数空间在计算上几乎不可行，实践中只能退而求其次，把两部分分开拟合。本文提出的 SKiNN（Stellar Kinematics Neural Network，恒星运动学神经网络）正是针对这个瓶颈：用一个神经网络去“模仿”JAM 的输出，把最慢的一步换成一次前向推理。




图 1 SKiNN 在联合建模框架中的位置。上半部分（蓝色）是传统透镜建模：用源、透镜质量、透镜光的模型合成一张成像图，与成像数据对比得到 χ^2_{lens} 。下半部分（橙色）是 SKiNN：输入透镜质量、透镜光和运动学参数，直接输出一张 v_{rms} 速度图，与运动学数据对比得到 χ^2_{kin} 。两者合成的 χ^2_{tot} 被联合最小化，从而对整个模型同时优化。SKiNN 只替换了运动学这一块，框架其余部分的物理保持不变。

论文链接 (NeurIPS 2022) : <https://neurips.cc/virtual/2022/57003>

代码仓库 : <https://github.com/mattgomer/SKiNN>

为什么运动学建模会成为瓶颈

过去用球对称的 Jeans 模型来近似星系动力学, 对新数据来说太粗糙, 而且和透镜里用的椭圆质量模型并不自治。随着 JWST 等望远镜带来空间分辨的运动学数据, 自然的下一步是用 JAM 这类轴对称模型来自洽建模。但 JAM 的代价很高: 它必须嵌在似然评估的最内层循环里被反复调用, 而 MCMC 动辄需要几十万次评估。换句话说, 慢的不是算一次, 而是要算很多很多次。

本文的关键判断是: JAM 虽然慢, 但它是可计算、有确定输入输出的。既然如此, 就可以用一批 JAM 生成的样本训练一个神经网络去逼近这个映射。训练是一次性的开销, 训练好之后每次推理都很便宜。整个模型的物理并没有被神经网络取代——被替换的只是“把参数变成速度图”这一段纯计算, 框架其余部分仍然是原来的物理。

SKiNN 是怎么设计的

形式上, SKiNN 是一个函数 $\Psi\theta$, 把一个 8 维的星系参数向量映射成一张 $d \times d$ 的 v_{rms} 图 (v_{rms} 是速度弥散与转动速度的平方和)。这 8 个输入描述了一个幂律椭圆质量分布 (Power-law Elliptical Mass Distribution, PEMD) 加上一个椭圆 Sérsic 光分布, 共 6 个形状参数, 再加上星系的倾角 i 和轨道各向异性 β 。网络是一个卷积结构, 共 5 个模块, 每个模块包含两层二维卷积、一层上采样和 ReLU 非线性, 最终约有 707 万个可训练参数。训练用标准的均方误差 (MSE) 损失和 Adam 优化器, 让网络学着复刻 JAM 的输出。

训练数据完全由 JAM 生成, 共 5000 个输入-输出对, 其中 4000 个用于训练、500 个用于验证、500 个留作测试。每张速度图是 551×551 像素, 分辨率高于真实观测数据。用 JAM 生成一张这样的图大约要 15 秒, 这也从反面说明了为什么值得做仿真加速。网络用 PyTorch 加 PyTorch Lightning 实现, 在 5 块 Tesla P100 GPU (每块 16 GB) 上训练约一天。所有参数的取值范围都有物理动机, 而不是随意采样。

速度提升 300 倍, 精度损失不到 1%

训练完成后, SKiNN 在单块 GPU 上从参数向量生成一张速度图只需约 50 毫秒, 相比 JAM 的约 15 秒, 大约快了 300 倍 (在 GPU 上又比 CPU 快约 10 倍)。真正关键的问题是: 这么快, 精度还够用吗? 作者在 500 张留出的测试图上逐像素计算相对误差来回答。




图 2 两个由 SKiNN 生成的 v_{rms} 图与 JAM 真值的对比。左两列分别是 SKiNN 预测和 JAM 真值，第三列是逐像素相对误差，黑色圆圈标出最内 2 角秒——真实数据约束力最强的区域。可以看到误差在图像外围可能达到几个百分点，但在圆圈内几乎处处小于 1%；最右列的直方图进一步显示，圆内相对误差集中分布在 $\pm 1\%$ 以内。

结论很清楚：图像外围的确会出现几个百分点的误差，但外围本身几乎不受真实数据约束，影响有限；而在最内 2 角秒这个数据真正说话的区域，误差对几乎所有像素都控制在 $\pm 1\%$ 以内。把整张图平均下来，500 张测试图的绝对误差中位数约为 0.47%，第 90 百分位约为 1.1%——两者都明显低于真实速度测量里通常 $\approx 2\%$ 的系统不确定度。也就是说，仿真带来的误差被真实观测的噪声“淹没”了，不会成为科学结论的主要误差来源。

表 1 SKiNN 与 JAM 的速度和精度对比（单张 v_{rms} 图）。

指标	JAM (物理代码)	SKiNN (神经网络)
单张图生成时间	约 15 秒	约 50 毫秒 (GPU)
相对加速	$1\times$ (基准)	约 $300\times$
内 2 角秒区域误差	真值	几乎处处 $< 1\%$
整图误差中位数 / 90 分位	—	约 0.47% / 约 1.1%

意义与边界

SKiNN 把联合建模里最慢的一步换成了一次廉价的前向推理，让引力透镜与空间分辨运动学的联合拟合在计算上第一次变得可行——而正是运动学约束，能纠正 H_0 测量里最大的一类不确定性。作者也如实说明了它的定位：这是一个概念验证（proof-of-concept），没有给出正式的消融表，性能由测试集上的逐像素误差分布刻画；仿真只在参数取样的既定范围内有效，外围区域的误差也确实更大。

更值得关注的也许是它背后的思路：当模型里存在“昂贵但可计算”的组件时，可以用一个神经网络仿真这一块，同时把周围的物理原样保留，既借到神经网络的速度，又不牺牲整体模型的物理可解释性。这种“只换最慢的一块”的策略，很可能迁移到天体物理之外的许多科学建模问题上。