

ICML 2024 | 让 SAM 学会「潜水」：水下显著实例分割的第一个大规模数据集与专用模型

海南大学等提出 USIS10K 数据集与 USIS-SAM，把 Segment Anything Model 带进浑浊的海底世界

在陆地上的照片里，让模型「找出画面里最重要的物体并精确抠出轮廓」已经不算难事。可一旦把镜头沉进海里，情况就完全不同：光线被水吸收和散射，颜色发生偏移，悬浮的颗粒（marine snow，海雪）像雪花一样糊在画面上。这类退化让即便是最先进的分割模型也频频失手，而水下显著实例分割（Underwater Salient Instance Segmentation，USIS）正是海洋探索、水下机器人等任务的第一步。

问题不止在图像本身，还在于数据。这个方向长期缺少一个带像素级标注的大规模显著实例数据集，训练现代模型无米下锅。与此同时，Segment Anything Model（SAM，分割一切模型）这类基础模型展示了惊人的通用分割能力，但它是在自然图像上训练的，直接搬到水下并不好用，而且它需要人工给出点或框提示（prompt），这恰恰与「自动」找显著物体的目标相矛盾。

这篇发表于 ICML 2024 的工作同时补上了这两块短板。作者构建了 USIS10K，第一个大规模水下显著实例分割数据集（10,632 张图像，像素级标注，7 个类别）；并提出 USIS-SAM，一个专为水下场景改造的 SAM 架构，让模型既能「看懂」水下画面，又能自己给自己出提示。下图先给出一个直观印象：在同样的数据上，USIS-SAM 相比多种主流方法明显减少了误检、定位错误和实例混淆。




图 1 USIS-SAM 与多种最新方法在 USIS10K 上的对比。左侧折线给出各方法在 AP50、AP75 与 mAP 上的成绩，USIS-SAM（红色）全程领先；右侧可视化显示，WaterMask 出现多余预测与定位偏差，URank+RDPNet 出现低精度与实例混淆，而 USIS-SAM 的分割结果最接近真值（GT）。不同颜色代表不同的显著实例。

为什么水下显著分割这么难

显著实例分割要求模型在一张图里定位视觉上最重要的物体，并逐像素地把每个实例分开。放到水下，任务被两重困难放大。其一是成像退化：光的散射与吸收造成低对比度和色偏，海雪进一步引入噪声，物体与背景的边界变得模糊。其二是数据匮乏：以往的显著实例数据集规模小、且大多不区分类别，既不足以训练现代大模型，也无法支撑对「多类别水下显著性」的研究。

一个自然的想法是借力 SAM 这样的基础模型。但作者观察到，直接把 SAM 用到水下会在两个层面失效：一是它的特征并未适配浑浊、低对比度的海洋环境；二是它依赖人工前景提示，而在自动显著分割的设定里根本没有人来点这个提示。作者由此给出判断：要在这个领域用好 SAM，必须同时准备两样东西，一个覆盖水下显著性多样性的大规模数据集，以及一个能教会 SAM「看懂水下、并自己出提示」的架构。这篇论文两样都给了。

USIS10K：第一个大规模水下显著实例数据集

为了打破数据瓶颈，作者构建了 USIS10K。它包含 10,632 张来自多样水下场景的图像，每张都配有像素级的显著实例标注，覆盖 fish、reefs、plants、ruins、human、robot、seafloor 共 7 个类别。下图展示了几组标注样例：左侧为原图，右侧为标注掩码，不同颜色对应不同的显著实例，既有单实例，也有多实例、多类别共存的复杂场景。




图 2 USIS10K 中的显著实例标注样例。每组左侧为原始水下图像，右侧为对应的标注掩码，不同颜色代表不同实例。样例涵盖从清晰到浑浊的多种水况，以及单实例与多实例场景。

作者还对数据集做了细致的统计分析，帮助理解水下显著性的分布特点。下图汇总了三个方面：(a) 各类别的显著实例数量，可见 fish 与 reefs 明显占多数；(b) 每张图像包含的显著实例数量分布，并与陆地数据集 SIS10K 对比；(c) USIS10K 与 SIS10K 在全局与局部颜色对比度上的差异。图 (c) 尤其值得注意：水下图像的颜色对比度整体更低，量化地印证了「水下更难」这一直觉。




图 3 USIS10K 的基本特征。(a) 各类别显著实例数量；(b) 每张图像显著实例数量的分布，与 SIS10K 对比；(c) USIS10K 与 SIS10K 在全局/局部颜色对比度上的分布对比，水下数据整体对比度更低。

USIS-SAM : 教会 SAM 看水下、并自己出提示

USIS-SAM 的设计思路是：冻结 SAM 强大的预训练主干不动，只增加两个轻量但有针对性的模块。第一个是水下自适应 ViT 编码器（Underwater Adaptive ViT，UA-ViT），负责把水下领域知识注入冻结的 Transformer；第二个是显著特征提示生成器（Salient Feature Prompt Generator，SFPG），负责替代 SAM 原本的人工点/框提示，自动产生显著提示。整个网络端到端训练。下图给出了完整框架与 UA-ViT 模块的内部结构。




图 6 (a) USIS-SAM 整体框架：在冻结的 SAM 之上加入水下自适应 ViT 编码器与显著特征提示生成器（SFPG），端到端输出实例掩码；(b) UA-ViT 模块结构，其中 SFFM 为显著特征融合模块，CA 为通道适配器（Channel Adapter）。火焰表示可学习参数，雪花表示冻结参数。

先看 UA-ViT 如何「看懂水下」。它通过适配器（adapter）向冻结的 ViT 注入水下视觉提示：一个通道适配器（CA）对特征做重新校准，多尺度卷积（3×3, 5×5, 7×7）在不同尺度上捕捉结构，再用「平均残差」把多尺度结果平衡起来以抑制噪声。用公式概括，多尺度特征为各尺度卷积在通道适配后特征上的求和，随后与其均值按系数 λ 做加权融合，得到注入主干的自适应特征。这样，冻结的强主干在几乎不增加大量参数的前提下，获得了应对浑浊海洋场景的能力。

再看 SFPG 如何「自己出提示」。它的核心是显著特征融合模块（SFFM），把 UA-ViT 各层的特征聚合起来，自动生成显著提示嵌入（prompt embedding），再送入 SAM 的掩码解码器。这一步的意义在于：它让模型不再依赖人工提示，把 SAM 从「需要有人点一下」变成「开

箱即用」地面向显著目标。整个模型用一个组合损失训练，同时覆盖区域候选（RPN）、分类、框回归与掩码分割四部分。

SFPG 到底做了什么？下图把它生成的特征可视化出来。对比「不带 SFPG」与「带 SFPG」两列可以看到，加入 SFPG 后，网络的注意力更集中地聚焦在显著实例上（如蝠鲼、潜水员与雕塑），而背景区域的响应被抑制。这说明 SFPG 不只是简单地融合特征，它还起到了把注意力引向显著区域的作用。




图 7 SFPG 生成特征的可视化。从左到右依次为原图、真值（GT）、不使用 SFPG 与使用 SFPG 的特征响应。
加入 SFPG 后，高响应（暖色）更集中在显著实例上，背景响应被抑制。

实验结果：两种设定下均刷新最优

作者在 USIS10K 上评测了两种设定。类别无关（class-agnostic）设定只要求定位并精确分割显著物体、不关心类别；多类别（multi-class）设定则更难，还要判对类别。在类别无关设定下，USIS-SAM 取得 59.7 mAP，超过最好的显著方法 OQTR 3.1 个点、水下方法 WaterMask 0.7 个点、基于 SAM 的 RSPrompter 1.5 个点；其 AP50 与 AP75 分别为 81.6 与 67.7。在更难的多类别设定下，USIS-SAM 达到 43.1 mAP，把领先幅度扩大到相对 WaterMask 4.4 个点、相对 RSPrompter 5.1 个点。

表 1 USIS10K 上的主要结果（mAP，%）。类别无关设定下的基线分数由论文报告的领先幅度反推得到。

方法	类别无关 mAP	多类别 mAP
OQTR (TMM'23)	56.6	—
RSPrompter (TGARS'24)	58.2	38.0
WaterMask (ICCV'23)	59.0	38.7
USIS-SAM (本文)	59.7	43.1

为了验证两个模块各自的贡献，作者做了消融实验（结果以更难的多类别 mAP 为准）。从完整模型的 43.1 出发：把水下自适应 ViT 块换回原始 ViT 块，性能下降 1.6 个点（降到 41.5），

说明通过适配器注入水下信息确实帮助了冻结主干；把 SFPG 替换为一个通用的多尺度特征增强器（Multi-scale Feature Enhancer），性能下降 0.9 个点（降到 42.2），说明 SFPG 的价值不止于融合特征，还在于把注意力聚焦到显著区域。此外，冻结图像编码器、简化多尺度卷积等对照也进一步验证了具体设计选择的合理性。

表 2 关键模块消融（多类别 mAP，%）。两个模块各自都带来明显收益。

配置	多类别 mAP
完整 USIS-SAM	43.1
去掉水下自适应 ViT 编码器	41.5
SFPG 替换为多尺度特征增强器	42.2

小结与意义

这项工作给出的经验很朴素：把一个强大的基础模型迁移到困难的新领域，最好同时补上「对的数据」和「让它自己出提示」的能力。通过构建 USIS10K，第一个大规模水下显著实例分割数据集，并用适配器教会 SAM 看懂水下、再让它自动生成显著提示，USIS-SAM 在水下显著实例分割上刷新了最优结果。作者还报告，模型在陆地数据集 SIS10K 上重新训练后同样优于既有方法，表明该设计并非只对水下过拟合。

需要如实说明的是，论文的结论建立在特定设定之上：ViT-H 主干、24 个训练轮次、6 张 NVIDIA 3090 GPUs，评测集中在 USIS10K（及作为泛化性验证的 SIS10K）。对更大规模、更多样的真实部署，仍需进一步验证。好在数据集与代码均已公开，为社区继续研究水下视觉提供了一个可用的起点。