

ICLR 2024 | 不用训练、不用提示、不用正常样本，让测试图像互相“打分”挑瑕疵

华中科技大学等提出零样本工业异常检测方法 MuSc：把一批无标注测试图变成自己的监督信号

在工业质检里，自动化的异常检测要同时回答两个问题：这张产品图有没有缺陷（分类，Anomaly Classification, AC），以及缺陷具体落在像素级的什么位置（分割，Anomaly Segmentation, AS）。过去的主流做法有两类：一类是基于记忆库（memory bank）的单类方法，需要为每种产品预先收集大量正常参考图；另一类是基于 CLIP 的零样本方法，需要人工设计文本提示（text prompt）。

这两条路都有现实门槛。收集正常样本对新产品、小批量生产并不友好；而手写提示既依赖经验，又很难覆盖形态各异的真实缺陷。真正贴近工厂落地的设定其实更苛刻：没有训练、没有提示、也没有任何正常参考图，却仍要在图像级判定异常、在像素级定位缺陷。

本文（ICLR 2024）提出的 MuSc（Mutual Scoring，互相打分）正是针对这一设定。它的核心观察很朴素：一批无标注的测试图像本身就藏着足够的“正常”与“异常”线索。正常区域的外观会在其他图像里反复出现，而缺陷罕见且各不相同，只要让这些图像互相打分，就能把异常从正常中区分出来，全程不需要任何标签。




图 1 三种范式对比：(a) 基于记忆库的单类方法需要大量正常参考图；(b) 基于 CLIP 的零样本方法依赖额外的文本提示；(c) MuSc 只利用无标注测试图像，在 patch 级与图像级同时完成分割与分类。

论文地址：<https://arxiv.org/abs/2401.16753> | 开源代码：<https://github.com/xrli-U/MuSc>

为什么“互相打分”能行

MuSc 的出发点是一个可验证的统计规律：把同一产品的一批测试图切成小块（patch），一个正常 patch 往往能在其他图像里找到很多相似 patch，因为正常外观是重复的；而一个异常

patch 只能找到极少数相似的，因为缺陷稀少且形态各异。这种“相似邻居数量”的不对称，本身就是一个无需训练的判别信号。

MuSc 的三步流水线

MuSc 用一个冻结的视觉 Transformer (ViT-L/14-336，来自 OpenAI CLIP，全程不做微调) 提取特征，再串起三个模块：多度局部邻域聚合 (LNAMD)、互相打分机制 (MSM) 与图像级约束邻域重打分 (RsCIN)。看图时可以从左到右、跟着数据流走一遍。




图 2 MuSc 架构。冻结 ViT 提取的 patch token 经 LNAMD 在多个聚合度 r 下表示不同尺寸的缺陷，MSM 让测试图像互相打分得到分割结果，RsCIN 再利用图像级 class token 优化分类分数。

第一步 LNAMD (Local Neighborhood Aggregation with Multiple Degrees) 把 patch token 在多个空间尺度上聚合。论文取聚合度 $r \in \{1, 3, 5\}$ ：小的 r 关注细小缺陷（在 VisA 上常见），大的 r 关注大面积缺陷（在 MVTec AD 上常见），三者结合覆盖不同缺陷尺寸。

MSM：让图像互相打分

第二步 MSM (Mutual Scoring Mechanism) 是方法的核心。每个 patch 的异常分，取它在“其他每一张测试图”里最近邻的距离；正常 patch 因为处处有相似邻居，最近邻距离很小，异常 patch 则偏大。但直接对所有图像的分数求平均并不稳妥，因为异常 patch 偶尔也会在个别图里撞上相似区域，把平均值拉低。

MuSc 的做法是：对每个 patch，只保留所有互相打分里最小的 30% 区间再取平均。下面这组直方图解释了为什么这样更好。




图 4 上排：所有正常 patch (a) 与异常 patch (b) 的原始最近邻距离分布。下排：对全区间取平均 (c) 与只对最小 30% 区间取平均 (d) 后的分数分布，蓝色为正常、橙色为异常。只取最小区间后，正常与异常的重叠明显减小。

对比 (c) 与 (d)：只保留最小 30% 区间求平均，正常与异常分布的重叠（棕色部分）明显收窄，两类更容易被一个阈值分开。消融实验也印证了这一点——在 MVTEC AD 上，“30% + 取平均”策略把图像级 AUROC 做到 97.8%，而换成取最大值的策略只有 83.8%。

RsCIN：把图像级判断再擦亮一遍

第三步 RsCIN（Re-scoring with Constrained Image-level Neighborhood）专门优化图像级分类。它在 class token 上构建一个受约束的邻域图，并配合多窗口掩码：只有当一张图和它的近邻都“看起来正常”时，才把它判为正常，从而抑制个别被误判的样本。




图 5 上排：使用 RsCIN 前 (a) 与后 (b) 的图像级异常分数直方图，蓝色为正常、橙色为异常。下排：一个正常与一个异常样本的重打分示例。RsCIN 之后正常与异常的分数更易区分。

在 VisA 上，RsCIN 把图像级 AUROC 从 90.0% 提升到 92.8%。值得一提的是，RsCIN 是即插即用的：把它接到别的分类方法上，同样能带来稳定的提升。

效果：零样本，却逼近甚至超过有标注方法

在两个标准工业基准 MVTec AD（15 类，10 个物体 + 5 种纹理）和 VisA（12 类物体）上，MuSc 都刷新了零样本的最好成绩。分类用 AUROC、AP、F1-max 衡量，分割额外用像素级 AUROC、F1-max、AP 与区域重叠度 PRO。




图 6 MVTec AD（左）与 VisA（右）上的异常分割可视化对比：从左到右依次为输入图、真值掩码、APRIL-GAN 的 0-shot 与 4-shot 结果，以及 MuSc 的 0-shot 结果。MuSc 的热力图更完整地覆盖了真实缺陷区域。

数字上，MuSc 在 MVTec AD 上达到 97.8% 图像级 AUROC 与 97.3% 像素级 AUROC；在分割指标上，比第二好的零样本方法高出 +21.1% PRO、+21.9% AP、+18.4% F1-max。在 VisA 上，分类与分割相比第二名都提升超过 10 个百分点。

表 1 MVTec AD 与 VisA 上零样本方法对比（%）。AUROC-cls 为图像级分类，AUROC-segm 为像素级分割，PRO 为区域重叠度。

数据集	方法	AUROC-cls	AUROC-segm	PRO-segm
MVTec AD	WinCLIP	91.8	85.1	64.6
MVTec AD	APRIL-GAN	86.1	87.6	44.0
MVTec AD	MuSc (ours)	97.8	97.3	93.8
VisA	WinCLIP	78.1	79.6	56.8
VisA	APRIL-GAN	78.0	94.2	86.8
VisA	MuSc (ours)	92.8	98.8	92.7

更有意思的是横向对比：不用任何参考图的 MuSc，超过了大多数 4-shot 方法，胜过用 32 张样本的 RegAD，与 8-shot 的 GraphCore 相当，甚至可以和用上全部正常训练集的 full-shot 方法（如 CutPaste、IGD、NSA）掰手腕。

小结与边界

MuSc 的价值在于把一个被忽略的事实用好了：一批无标注测试图像可以充当自己的监督信号——正常结构在图像间反复出现、缺陷各自孤立，互相打分就能把两者分开，于是零样本也能逼近全监督的分类与分割效果。

当然，这套方法也有前提：MuSc 需要一批同类产品的测试图一起推理（batch），单张孤立图像无法互相打分；逐图两两比较也带来推理开销——论文把数据集分成 s 份来降低单图耗时与显存（分成 3 份可把单图耗时从约 999ms 降到约 514ms）。在具备成批测试数据的场景里，MuSc 是一个无需训练、无需提示、也无需正常样本的实用起点。