

让集成模型「学会不一样」，换个空间成本更低

ICLR 2024 · FoRDE：在输入梯度空间中互斥集成成员，换来图像损坏下更强的鲁棒性与校准。

深度集成（Deep Ensemble）是一种「简单却出奇有效」的做法：用不同随机种子把同一个网络训练好几遍，再把它们的预测取平均，往往就能同时拿到更高的准确率、更好的校准（calibration），以及在没见过的输入上更稳的表现。它之所以有效，关键在于多样性（diversity）：每个成员都落到了对数据的一种不同解释上，而它们之间的分歧，正是「取平均」值得信任的原因。

于是一个自然的想法是：不要把多样性交给运气，而是主动去制造它。基于粒子的变分推断（particle-based variational inference）就是这么做的：把每个网络当作一个粒子，在训练中加入一项互斥力（repulsion），主动把成员往两边推开。但这里藏着一个影响很大的问题：应该在哪个空间里把成员推开？在权重空间（weight space）里推，会和「神经网络严重过参数化」这个事实作对，因为无数个不同的权重其实编码的是同一个函数；在函数空间（function space）里推，又要面对「比较两个完整函数」这种难以计算的操作，逼着方法走近似捷径，反而容易欠拟合。结果是：这两条路都没能比普通深度集成好多少。

本文提出的 FoRDE（First-order Repulsive Deep Ensembles，一阶互斥深度集成）给出了第三个「制造分歧」的空间。它不比较权重，也不比较输出，而是在输入梯度（input gradient，即输出对输入的导数）空间里把成员推开。这个选择并不只是换个说法：输入梯度可以在「相差一个平移」的意义上唯一刻画一个函数；它的维度和输入一样小，远小于庞大的权重向量；而且强迫成员的输入梯度不同，等于强迫每个网络去依赖不同的输入特征。最终得到的集成，在输入被损坏（corruption）时明显更鲁棒、校准也更好。




图1 一维回归玩具问题中，三个网络的输入梯度互斥过程。左：训练早期，三个模型都拟合了数据，却几乎处处一致，功能多样性很低。中：互斥项在每个数据点上，把成员的输入梯度（箭头）沿单位圆推开。右：训练结束时，三条函数真正分开，获得了让集成有价值的多样性。

论文：<https://arxiv.org/abs/2306.02775> · 代码：<https://github.com/AaltoPML/FoRDE>

为什么「在哪个空间互斥」如此关键

要理解为什么输入梯度是个好地方，可以把神经网络的三种「视角」摆在一起比。权重是我们真正在优化的东西，但它并不适合用来衡量多样性：过参数化意味着两个差别很大的权重向量

可能算出完全相同的函数，所以在权重空间里互相推开，可能白费力气，行为却没变。函数值是我们最终真正关心的，但比较完整的函数需要一个定义在函数空间上的核，计算代价很高；早期的互斥方法只能在训练输入上近似它，结果把模型推向欠拟合，相比普通集成几乎没有真实收益。

输入梯度恰好落在这两个极端之间。一个函数在「相差一个常数」的意义上由它的梯度场决定，所以两个网络只要输入梯度不同，就一定是不同的函数，而不是同一个函数的冗余改写。同时，梯度的维度和输入一样，对图像来说远小于权重向量，用核比较起来很便宜。还有一个后来被证明是实证关键的额外好处：输入梯度告诉你一个网络对哪些输入特征敏感。让两个成员的梯度指向不同方向，就等于让它们关注互补的特征，而这恰恰是输入之后被扰动时你最希望模型具备的性质。

FoRDE 是怎么训练的

FoRDE 建立在 Wasserstein 梯度下降之上，这是一种基于粒子的变分推断。集成里的每个成员都是一个粒子，每次更新都由两股力组成：驱动力（driving force）把粒子拉向贝叶斯后验的高密度区域，本质上就是带先验的普通训练；互斥力（repulsion force）则由一个核加权，把粒子从其他成员那里推开。一切的关键，都落在这个核到底比较什么。

FoRDE 的核比较的是「真实标签对应 logit」的输入梯度，在训练数据上取平均，并且先把每个梯度归一化到单位长度。两个设计让它变得可行：其一，只用真实标签的梯度、而不是完整的雅可比矩阵，让计算代价对训练样本数保持线性；其二，归一化到单位球、比较方向很重要，因为随着训练收敛，梯度的模会不断变小，比较方向能让互斥在训练后期依然有意义，也正是它促使成员去依赖互补特征。在 RBF 基核之上，FoRDE 用数据的主成分分析（PCA）来设定每个维度的长度尺度（lengthscale），使互斥在信息量最大的输入方向上最强。作者指出，这个数据驱动的核，行为上很接近一种特征鲁棒性先验（EmpCov），这也干净地解释了鲁棒性收益的来源。

多样性是真的吗：两个玩具实验

在大规模数字之前，两个玩具问题先把机制变得可见。在一维回归里，检验集成是否诚实的方式，是看它在远离训练数据的地方怎么表现：一个多样的集成应当在没见过的区域散开、报告高不确定性。FoRDE 明显比深度集成、以及权重空间和函数空间的互斥变体散得更开。




图 2 一维回归中的预测不确定性。在远离数据簇的区域，FoRDE（最右）散成明显更宽的置信带，超过深度集成、Weight-RDE 和 Function-RDE，说明它在最需要的地方拥有更强的功能多样性。

二维分类任务在平面上讲了同一个故事。用预测后验的熵来衡量，FoRDE 是唯一一个在训练簇之外几乎所有区域都保持不确定的方法，而不会在它本没有理由自信的地方，把一条清晰的决策边界自信地外推出去。




图 3 二维分类问题的预测熵图。暖色代表自信、冷色代表不确定。FoRDE（最右）在标注簇之外的整个输入平面上都保持高不确定性，而各基线在远离数据处仍然自信地下结论。

损坏输入下的鲁棒性

主实验在 CIFAR-10、CIFAR-100 和 TinyImageNet 上进行，骨干网络为 ResNet-18 与 PreActResNet-18，集成含 10 个成员。鲁棒性在损坏基准 CIFAR-10-C、CIFAR-100-C 和 TinyImageNet-C 上测量，这些基准施加 19 种损坏类型、每种 5 个严重等级，并在干净指标之外报告损坏准确率（cA）、损坏 NLL 和损坏 ECE。结论一致：采用 PCA 长度尺度的 FoRDE 在每一项损坏指标上都是最强的，同时在干净数据上保持有竞争力。相比第二名，它在 CIFAR-10-C 上准确率提升约 +2.4%，在 CIFAR-100-C 上提升约 +1.3%。

表 1 ResNet-18、10 成员集成在 CIFAR-10/CIFAR-100 上的干净准确率与损坏准确率（cA），5 个随机种子平均。FoRDE-PCA 干净准确率与最优仅差零点几个百分点，损坏下则明显领先。

方法	C10 Acc	C10-C cA	C100 Acc	C100-C cA
Deep Ensembles	96.3	78.1	81.8	54.3
Weight-RDE	96.2	78.0	81.7	54.2
Function-RDE	95.8	77.1	80.1	51.9
FoRDE-PCA (ours)	96.1	80.5	81.4	56.1

所有列均为越高越好。C10-C / C100-C 为损坏基准（19 种损坏类型 × 5 个严重等级）。数字取自论文表 1 与表 2。

迁移学习实验把画面进一步铺开，覆盖 NLL、ECE、准确率和认知不确定性（epistemic uncertainty），并同时考察自然分布偏移（CINIC-10）和损坏偏移。FoRDE 在各项上都优于基线，而它在分布外数据上更高的认知不确定性，正是这套方法所要制造的额外功能多样性的直接读数。




图 4 迁移学习结果。在同分布、自然偏移（CINIC-10）与损坏测试集上，FoRDE 在 NLL、ECE 和准确率上都追平或超过基线；最右两列显示它在分布外数据上还拥有最高的认知不确定性，这正是更强功能多样性的标志。

长度尺度从哪来，代价是什么

核的长度尺度决定了互斥如何分布到各个输入维度上，是本文重点消融的旋钮。强调高方差特征的 PCA 长度尺度带来最好的损坏鲁棒性；恒等（Identity）长度尺度则在 CIFAR-100 上给出最好的干净准确率、在 CIFAR-10 上给出最好的 NLL，代价是鲁棒性略弱；在两个极端之间做加权插值的 FoRDE-Tuned，往往能在干净和损坏数据上都取胜。另一项在 WideResNet-16x4 上的研究，把这种多样性的「性价比」讲得很具体：一个 10 成员的 FoRDE，在损坏鲁棒性上追平甚至超过一个 30 成员的深度集成，尽管在干净数据上略逊于深度集成。

这一切并非免费。由于每次更新都要额外做一次前向-反向传播来计算输入梯度，FoRDE 的训练时间大约是普通深度集成的三倍（在作者的 A100 设置下约为每轮 101 秒）。这笔账是否划算，取决于部署场景有多在意损坏或偏移的输入，而那恰恰是 FoRDE 拉开差距的区间。

小结

FoRDE 留下的长久启示是：你在哪个空间里强制多样性，和你强制多大力度同样重要。权重空间因为过参数化而浪费；函数空间难以直接比较；输入梯度恰好是两者之间的甜蜜点——足够小，比较起来便宜；足够有表达力，能保证成员成为不同的函数；又足够有语义，把它们推开就等于让成员依赖互补特征。再配上数据驱动的 PCA 长度尺度，这个选择换来的，是在真实世界常见的那类输入损坏下更鲁棒、更好校准的集成，代价大约是三倍的训练时间。