

ICML 2023 | 强化学习的世界并非一成不变：一个稳健的平稳性检验

密歇根大学与伦敦政治经济学院提出双重稳健 CUSUM 检验，判断离线 MDP 是否漂移并定位变点

强化学习(RL)的目标是学到最优策略，但几乎所有算法都默认了一个前提：环境永远不变。用统计语言说，就是马尔可夫决策过程(MDP)的状态转移函数和奖励函数不随时间改变——这被称为平稳性(stationarity)假设。它藏在推导的深处，很少被拿出来检验，却几乎决定了学到的策略是否值得信任。

现实很少这么理想。在移动健康、交通信号控制、机器人等长周期场景里，系统会缓慢漂移。以本文关注的 Intern Health Study(IHS，实习医生健康研究)为例：这是一项针对美国住院医师、通过手机推送鼓励健康行为的微随机化试验(MRT)，推送带来的效果会随时间衰减。如果把一个把世界当成被冻结的策略直接部署，它会在错误的时刻发送提醒，长期回报被悄悄侵蚀。

于是问题变成：在信任一个离线学到的策略之前，我们能不能可靠地检验它所依赖的平稳性假设是否成立？本文给出的答案是一个模型驱动、双重稳健(doubly robust)的统计检验，它既能判断 MDP 是否平稳，又能定位变点(change point)，而且在状态维度很高时依然有效。

论文：<https://proceedings.mlr.press/v202/wang23ai/wang23ai.pdf>

代码：https://github.com/jtwang95/Double_CUSUM_RL

为什么现有方法不够用

检验平稳性并不新鲜，但已有方法各有硬伤。一类需要预先知道真实的 MDP 模型；另一类依赖线性近似，在高维状态空间中迅速失效，例如 Padakandla 等提出的 ODCP、以及 Li 等提出的 CUSUM-RL；还有一类为每个时间点单独学习一个策略，当过程实际上是分段同质时白白浪费样本。真正的难点在于：现代应用往往是高维、复杂的，要在这种环境里做出可信的统计推断很难。

双重稳健的 CUSUM 检验

本文的核心是一个 CUSUM(累积和)型统计量。对每一个候选变点，检验把它之前和之后的转移动态拼起来做比较：如果环境平稳，两段应当一致；如果发生漂移，差异会在真实变点附近被放大。

直接把神经网络、随机森林这类灵活的机器学习估计器插进这个比较里，会带来严重的插件偏差(plug-in bias)。作者的做法是给朴素估计量加上一个均值为零的修正项，得到一个双重稳健

的估计函数。所谓双重稳健，是指只要转移函数模型 M_1 与状态-动作分布模型 M_2 中至少有一个设定正确，检验就能控制第一类错误(type-I error)。随后，样本切分与交叉拟合(cross-fitting)在候选变点与检验函数上对统计量做归一化，再用高斯乘子自助法(Gaussian multiplier bootstrap)近似原假设下的分布，算出 p 值。最终的检验统计量是对时间与检验函数取最大之后、带 CUSUM 权重的归一化量。

那么至少一个模型正确就够了，这一承诺到底有多稳？图 1 给出了最直接的证据。作者在一个可控的合成环境里，把 M_1 与 M_2 的设定错误程度(misspecification level)从 0.1 逐步加到 0.9，每种设定重复 500 次。




图 1 在不同的模型设定错误程度下，四种情形(同时错设 M_1 与 M_2 、只错设 M_2 、只错设 M_1 、都不错设)的经验拒绝概率。左图是原假设成立时的检验水平(size)，右图是备择假设成立时的功效(power)，结果基于 500 次重复。

左图看水平：只要 M_1 或 M_2 至少有一个正确，经验拒绝概率就牢牢贴在名义 5% 水平($\alpha = 0.05$)附近；只有当两个模型同时错设时，水平才随错误程度一路飙到 0.9 附近。右图看功效：无论哪种情形，检验都能在真实存在变点时保持约 0.7 的拒绝概率。这正是双重稳健的含义——一个模型错了，另一个能兜底。

维度越高，优势越明显

双重稳健解决了模型可能设错的问题，而真正把已有方法拉开差距的是高维。作者把状态维度 d_S 设为 1、10、20、30，并与两个基线 ODCP 和 CUSUM-RL 正面比较。真实变点固定在 $t = 25$ ，检验通过扫描区间长度 κ 来定位它：当 κ 小于 25 时原假设为真，应当控制水平；当 κ 超过 25 时备择为真，功效应当上升。




图 2 在状态维度 $dS = 1、10、20、30$ 下，各方法随扫描区间长度 κ 变化的经验拒绝概率(纵轴)。上排为奖励函数变化，下排为状态转移变化， κ 从 10 到 40，结果基于 100 次重复。

结果很干净。本文方法在从 $dS = 1$ 到 30 的所有维度上都表现一致： κ 小于 25 时把拒绝概率压在 0.05 以下， κ 越过 25 后迅速升到 1.0，准确锁定变点。相比之下，CUSUM-RL 只在 $dS = 1$ 时勉强可用，维度一升就彻底失灵；ODCP 则在原假设为真时就把拒绝概率抬到远高于 0.05，根本控制不住第一类错误。换句话说，只有本文的检验在高维下同时做到了该拒绝时拒绝、不该拒绝时不拒绝。

表 1 三种检验在高维下的定性对比。

方法	控制第一类错误	可恢复变点的最高状态维度
Proposed	Yes	30
CUSUM-RL	Yes	1
ODCP	No	-

检测到变点之后：策略能挽回多少回报

检验的价值最终要落到策略上。如果能正确定位变点，就能只用变点之后这段平稳数据重新学习策略。作者在一个 4×4 网格世界里，比较了几种更新方式：oracle(已知真实变点)、random(随机切分)、slide(滑动窗口)、stationary(假设平稳、用全部数据)。




图3 本文方法与其他四种策略更新方式(oracle、random、slide、stationary)在策略价值上的差异箱线图。左图不存在变点的情形，右图存在多个变点的情形。

当数据里确实存在变点时(右图)，本文方法学到的策略与 oracle 几乎持平，明显优于随机切分、滑动窗口和假设平稳三种做法——后者把变点前后的异质数据混在一起，学出的策略价值更低。而当数据本就平稳、没有变点时(左图)，本文方法不会误伤：它与 oracle、滑动窗口、平稳假设基本一致。也就是说，检测并适应变点在需要时能挽回接近 oracle 的回报，在不需要时也不会付出代价。

真实数据：实习医生健康研究

最后，作者把检验用到真实的 IHS 数据上。该研究通过手机 App 向美国的实习医生推送提醒，鼓励与身体活动、睡眠和情绪相关的健康行为，本文分析覆盖 21 周。作者按专业把住院医师分为 Internal Medicine(内科)与 Family Practice(家庭医学)两组，分别扫描 κ 从 3 到 18 计算 p 值。




图4 对 IHS 数据两个专业分组应用本文检验，p 值随扫描区间长度 κ 的变化， κ 从 3 到 18，虚线为 0.05 显著性水平。

对内科住院医师(左图)，p 值在 $\kappa = 16$ 附近多次落到 0.05 显著性线以下，说明其 MDP 在第 16 周附近发生了变化——这与推送效果随时间衰减的临床直觉一致；而家庭医学组(右图)的 p 值

始终远高于 0.05，检验正确地没有报出变点。一个能在该报警时报警、不该报警时沉默的检验，正是可信推断的标志。

小结与边界

这项工作把现代机器学习的灵活性与半参数统计的严谨性结合在一起：一个双重稳健的 CUSUM 检验，能在离线 RL 环境不再平稳时可靠地发出信号，即使状态维度高达 30 也依然成立；只要两个 nuisance 模型至少一个正确，就能把第一类错误控制在名义 5% 水平($\alpha = 0.05$)。理论上，作者在双向渐近框架下证明了水平控制与双重稳健性——轨迹数 N 或时间跨度 T 任一发散即可。实验上，方法在四个数值研究和真实 IHS 数据上都站住了脚，典型设置为 $N = 100$ 、 $T = 50$ ，并用 5000 次自助抽样近似原假设分布(真实数据用 $B = 1000$)。

当然，方法也有边界：基于检验的策略再学习只在数据具备一定同质性时可行——需要各条轨迹的变点位置有重叠，且 MDP 分段恒定。但在这一前提下，先检验、再定位、后适应，能把假设平稳或滑动窗口白白留在桌上的回报重新收回来。对任何要把离线学到的策略部署到会漂移的真实系统的人，这都是一件值得先做的事：在信任策略之前，先检验它脚下的地面是否真的没有移动。

论文：<https://proceedings.mlr.press/v202/wang23ai/wang23ai.pdf>；代码：https://github.com/jtwang95/Double_CUSUM_RL