

InfinityGAN：只在小图块上训练，却能合成「无限大」的图像

ICLR 2022 | UC Merced、Snap、CMU 等提出面向任意尺寸图像合成的框架
InfinityGAN

生成模型这几年在分辨率上一路狂飙，但有一个隐藏的天花板很少被谈起：几乎所有高分辨率 GAN 都只能生成它「训练时那个尺寸」的图像。想让 StyleGAN2 之类的模型输出比训练分辨率更大的图，通常有两个下场：要么显存和算力随边长平方级暴涨、直接跑不动，要么全局结构崩坏、画面开始机械式重复。换句话说，模型学到的是「一张固定大小的画」，而不是「一片可以无限延展的风景」。

InfinityGAN 想直接拆掉这个天花板。它提出一个用于任意尺寸（arbitrary-size），乃至无限像素（infinite-pixel）图像合成的框架：只在小图块上训练，推理时却能一块一块地拼出任意大的画面，而且显存占用始终恒定。这篇工作发表在 ICLR 2022，来自 UC Merced、Snap Inc.、CMU、延世大学与 Google Research。它最惊人的一点是：无论训练还是任意尺寸的推理，全程只用一块 GTX TITAN X 显卡。

先看一眼「无限大」到底长什么样。下面这张 512×4096 的宽幅风景，由 258 个各自独立生成的图块拼接而成，中间还平滑地融合了四种不同风格——而生成它的模型，只在 101×101 的小图块上训练过。



图 1 空间风格融合（Spatial Style Fusion）。这张 512×4096 的宽幅图由 258 个独立生成的图块拼成，横向平滑过渡了四种风格。请注意：每个图块都是分别生成的，却能无缝拼接成一整片连续的风景——这正是 InfinityGAN 的核心能力。

论文：<https://arxiv.org/abs/2104.03963>

代码：<https://github.com/hubert0527/infinityGAN>

项目主页：<https://hubert0527.github.io/infinityGAN/>

为什么现有生成器「放不大」

要理解 InfinityGAN 的巧思，得先弄清一件反直觉的事：像 StyleGAN2 这样的生成器，其实是偷偷靠「边界」来判断自己在画哪里的。卷积网络里那些补零（zero-padding）操作，在训练时形成了一套固定的边界模式，网络便把它当成了位置信息记了下来。

问题在于，一旦要合成更大的图，特征图的空间尺寸变了，这套由补零推导出来的位置编码也随之错位。此时画面中心离任何边界都「无穷远」，网络拿不到有意义的位置信号，结果就是内容开始机械重复、全局结构崩坏。要想生成真正无限大的图，就必须有一种在离边界无穷远处依然有效的位置信息，以及一个能独立生成图块、却又能无缝拼接的生成器。

把一张图拆成：全局外观、局部结构、纹理

InfinityGAN 的核心思路，是把「生成一张图」重新拆解为三件事：全局的整体外观、局部的结构变化、以及细粒度的纹理。生成器 G 由两个模块组成——结构合成器 G_S 和纹理合成器 G_T ，分别负责「画面长什么样」和「像素怎么渲染」。

结构合成器 G_S 是一个神经隐式函数（neural implicit function）：它接收一个决定整幅画面整体外观的全局隐变量 z_g 、一个描述局部结构变化的局部隐变量 z_l ，以及一组连续坐标 c ，输出该区域的结构表示 z_S 。因为它由连续坐标驱动，你可以直接查询任意一小块区域，哪怕这块区域在坐标系里离原点无限远。坐标在水平方向用正弦/余弦编码（利用风景的自相似性），在垂直方向用 tanh 饱和（对应从地面到天空的变化）。




图 2 InfinityGAN 总览。结构合成器 G_S （隐式函数）接收全局隐变量 z_g 、局部隐变量 z_l 与连续坐标 c ，输出结构表示；纹理合成器 G_T （全卷积）再结合随机噪声 z_n 渲染出图块 p_c 。由于每块像素只由其坐标决定，任意区域都能被独立生成，再拼成一整幅任意大小的图。

纹理合成器 G_T 则是一个去掉了全部补零的全卷积 StyleGAN2：它拿到结构表示 z_S 、全局风格 z_g 和随机噪声 z_n ，渲染出最终的图块。整个前向过程可以写成两步： $z_S = G_S(z_g, z_l, c)$ ， $p_c = G_T(z_S, z_g, z_n)$ 。训练时除了对抗损失，还加入 R1、路径长度正则、一个抑制重复的模式寻找多样性损失（mode-seeking diversity loss），以及一个回归垂直坐标的辅助损失。

关键设计：去掉补零，让图块「各画各的」也能严丝合缝

既然补零是罪魁祸首，InfinityGAN 干脆把生成器里所有的补零都移除，做成一个「无补零生成器」（Padding-Free Generator）。这样一来，纹理合成器就只学纹理本身，不再夹带位置信息；位置信息全部由前面那个坐标驱动的隐式函数负责供给。

下图对比了两种生成器的行为。左边的传统生成器因为补零，同一个位置在不同图块里会算出不一致的像素值，而且这种不一致会随网络加深呈指数级扩散；右边的无补零生成器则能保证：无论某个位置落在感受野的哪里，算出来的像素值都一致。正是这个性质，让「分别独立生成的图块」可以拼成一整片特征值连续、看不出接缝的图像。




图3 无补零生成器。（左）传统生成器因补零，导致相邻图块在重叠位置算出不一致的像素，且不一致区域随网络加深指数级扩大。（右）无补零生成器则在任意位置都能给出一致的像素值，从而支持「先各自独立生成、再无缝拼接」。

放得越大，优势越明显：ScaleInv FID 与用户研究

怎么评价一个「比训练尺寸大好几倍」的合成图？这些尺寸下根本没有真实图像可作参照。作者为此提出 ScaleInv FID：把大图用双线性插值缩回训练尺寸，再算 FID； $N \times$ ScaleInv FID 表示评测图是训练尺寸的 N 倍。他们在自建的 Flickr-Landscape（45 万张高质量风景图）上，把 InfinityGAN 和一众基线做了对比。

结果呈现出一个诚实而有说服力的趋势：在 $1\times$ 、 $2\times$ 这些接近训练尺寸的设定下，InfinityGAN 并不占优（它本就在更小的视野、不同分辨率下训练，属于「让利」设定）；但一旦把图放大到 $4\times$ 及以上，它的质量下滑得最慢，反超所有基线。更关键的是，它的显存始终是 $O(1)$ 恒定，而 StyleGAN2 类方法是 $O(\text{size}^2)$ ，放到 $16\times$ 时直接显存溢出。一项 50 人的用户研究里，超过 90% 的人在每一组对比中都更偏爱 InfinityGAN 的结果。

表 1 Flickr-Landscape 上的 ScaleInv FID（越低越好）。InfinityGAN 在接近训练尺寸时不占优，但在 $4\times$ 与 $8\times$ 大幅反超，且显存恒为 $O(1)$ 。

方法	1×	2×	4×	8×	显存
SinGAN	4.21	57.10	145.12	210.22	$O(\text{size}^2)$
StyleGAN2+NCI	4.19	18.31	79.83	189.65	$O(\text{size}^2)$
InfinityGAN (本文)	21.84	28.83	61.41	121.18	$O(1)$

NCI：Non-Constant Input。8× 时 InfinityGAN 为 121.18，最强基线为 189.65；StyleGAN2 在 $16\times$ 设定下显存溢出。

顺手解决的难题：任意尺寸外扩（Outpainting）

既然模型天生就能沿任意方向长出新内容，把它当作深度图像先验（deep image prior）来做外扩（outpainting）就顺理成章。作者把 InfinityGAN 与 In&Out 结合，在 Places365 与 Flickr-Scenery 的风景子集上做长距离外扩。下图对比了几种方法：Boundless 和 NS-outpaint 在远离原图的区域很快开始崩坏，而 In&Out + InfinityGAN 能一路生成连续、可信的画面。




图 4 长距离外扩对比。红框是给定的真实区域（256×128 像素）。Boundless、NS-outpaint 在远处逐渐失真，In&Out + InfinityGAN 则能持续外扩出连贯、合理的风景。

数字上，In&Out + InfinityGAN 把外扩的 FID 从 In&Out 的 23.57 / 30.34 降到 9.11 / 15.31（Places365 / Flickr-Scenery，越低越好），几乎腰斩，取得该任务上的 SOTA。此外，得益于图块之间彼此独立、可并行生成，在 8192×8192 像素下用并行批处理还能把单张推理时间从 137.44 秒压到 19.09 秒，提速最高约 7.20×。

同一个框架，还能做全景与任意长度补间

把不同的局部隐变量与风格喂给同一套坐标，或者在不同位置反演（invert）一张真实图像，InfinityGAN 还能自然衍生出更多玩法：多模态外扩、任意长度的循环全景（cyclic panorama），以及任意长度的图像补间（inbetweening）。下图展示了通过反演真实图像得到的补间与循环全景结果，最上一行的图像尺寸为 256×2080 像素。




图 5 用反演隐变量做图像补间。通过在不同位置反演真实图像，InfinityGAN 可以合成任意长度的循环全景与补间图像；由于像素值保证一致，拼接天然无缝。顶行图像尺寸为 256×2080 像素。

小结与边界

InfinityGAN 传递的核心观点是：一旦不再把生成绑死在某个固定输出分辨率上，无限像素图像合成就变得可行。把全局外观、由坐标隐式函数负责的局部结构、以及由无补零卷积负责的纹理三者拆开，生成出的图块既彼此独立又严格一致，于是能以恒定显存拼出任意大的图，还能并行加速。同一套设计顺带解锁了空间风格融合、多模态外扩与任意长度全景/补间。

作者也坦诚了边界：ScaleInv FID 只反映趋势，1× 下与基线并非严格可比；在 LSUN 桥梁、塔这类以物体为中心、垂直视角变化很小的数据集上，模型常会在画面上下方填入空白的「留白纹理」。但作为一个只在小图块、单块消费级显卡上训练，却能生成无缝、全局一致的任意尺寸图像的框架，InfinityGAN 给「把图放大」这件事提供了一条真正可扩展的新路径。