

NeurIPS 2023 | 不用砍步数，也能让扩散模型采样快 2-4x

斯坦福提出 ParaDiGMS：把去噪重写成可并行的 Picard 迭代，用算力换速度

扩散模型（diffusion model）能生成惊艳的图像，如今在机器人动作生成上也越来越强，但它有一个绕不开的短板：慢。生成一个样本往往要顺序跑上千步去噪，每一步都要过一次神经网络，而且下一步必须等上一步算完。对任何需要实时交互的场景来说，这个延迟就是第一道墙。

业界通行的解法是「少走几步」。DDIM、DPMSolver 这类快速采样器把上千步压缩到几十步，效果确实很好，但代价也很实在：步数压得越低，样本质量下降得越明显。大家基本上默认了这笔交易，用质量去换速度。

这篇来自斯坦福的论文换了一个问题来问：与其用质量换速度，能不能用算力换速度？也就是每一步去噪都保留，只是不再严格地一步接一步地算。答案就是 ParaDiGMS（Parallel Diffusion Generative Model Sampling，并行扩散生成模型采样）——第一个用额外并行算力给「预训练好的」扩散模型加速的通用方法，不需要重新训练，采样质量也没有可测量的损失。




图 1 计算一条去噪轨迹的两种方式。左：顺序采样一次只算一步，第 t 步算完才能开始第 $t+1$ 步。右：ParaDiGMS 用 Picard 迭代同时更新所有时间步（上标 k 是迭代轮数），引入跨步依赖，让信息能在整条链上并行传播。

论文地址：<https://arxiv.org/abs/2305.16317>

代码地址：<https://github.com/AndyShih12/paradigms>

难点：难的是「单个样本」的延迟

先把「慢在哪」说清楚。扩散采样天生是顺序的：每一步去噪都要读上一步的输出，所以上千步构成了一条看似无法抄近路的链。你当然可以在「样本之间」轻松并行，一次生成一整批图，但那只提升吞吐量（throughput），对用户正在等待的那「一个」样本的延迟毫无帮助。让单个样本在真实时间（wall-clock）里更快出现，才是真正困难的问题，而这正是 ParaDiGMS 要攻的点。

作者的关键洞察是：这条顺序链其实就是在用最朴素的积分器求解一个常微分方程（ODE），而求解 ODE 的方法，远不止「一步一步往前挪」这一种。

方法：把去噪变成可并行的不动点迭代

ParaDiGMS 建立在 Picard 迭代之上，这是一种用不动点迭代求解常微分方程的经典技巧。它的思路是：把每个时间步的取值写成「起点 + 沿途累积的漂移量（drift）」，然后一次性地把整条轨迹一起精修。具体做法是先给每个时间步一个粗糙的猜测，并行地在所有时间步上评估模型给出的漂移，再用这些漂移一次性更新整条轨迹的猜测，如此反复，直到猜测不再变化。

它之所以能加速，靠的是一个经验性但相当稳健的现象：收敛所需的精修迭代次数，远远少于去噪步数，常常要少一个数量级以上。而每一轮迭代都在所有时间步上并行完成，于是真实时间只跟「较小的迭代次数」挂钩，而不是「较大的步数」。为了照顾 GPU 显存，ParaDiGMS 并不会一次精修整条轨迹，而是让一个固定大小为 p 的批处理窗口（batch window）沿时间轴滑动，一旦窗口前端的时间步收敛，就把窗口往前推。对于随机（SDE）采样器，噪声会被提前一次性采好，这样得到的 ODE 才能保持良态（满足 Lipschitz 条件）。




图 2 批处理窗口内部。ParaDiGMS 在大小为 p 的窗口内同时评估每个点的漂移（蓝色箭头），用累积漂移把每个点推向真实轨迹（黑色曲线），一旦前端的点收敛到误差容忍度以下，窗口就向前滑动。

由于它只改变「一条既定轨迹如何被计算」，ParaDiGMS 和大家已经在用的快速采样器是正交（orthogonal）的。把它叠加到 DDPM、DDIM、DPMSolver 上，就得到 ParaDDPM、ParaDDIM、ParaDPMSolver：并行带来的加速，直接叠在这些方法本就有的「减步数」加速之上。它也兼容 classifier-free guidance。

结果：稳定的 2-4x 加速，质量几乎不动

最值得注意的是这个提升有多稳定。它奏效的底层原因是：并行收敛所需的迭代次数，最多可以比顺序步数少 20x。正是凭借这一点，跨越机器人控制和图像生成两个差异极大的领域、跨

越测试过的每一种采样器，ParaDiGMS 都能把采样延迟降低 2-4x，而任务奖励、FID、CLIP score 都没有可测量的下降。

在机器人方向，作者在三个操作任务上评测 DiffusionPolicy 模型，用 200 个评测回合的平均任务奖励来衡量。把 ParaDiGMS 用在完整 100 步的 DDPM 策略上（即 ParaDDPM）后，采样加速 3.4x 到 3.9x，一个 100 步策略的单样本采样时间降到约 0.2 秒，而任务奖励基本保持不变。

表 1 机器人 DiffusionPolicy（100 步 DDPM，容忍度 0.1，窗口 20，单张 A40）。奖励为 200 回合平均，时间为每回合耗时。ParaDDPM 在奖励保持不变的情况下把延迟降低 3.4-3.9x。

任务	奖励（顺序 → 并行）	时间（顺序 → 并行）	加速
Robosuite Square	0.85 → 0.85	37.0s → 10.0s	3.7x
PushT	0.81 → 0.83	32.3s → 8.33s	3.9x
FrankaKitchen	0.85 → 0.84	112s → 33.3s	3.4x

图像生成这边情况完全一致。StableDiffusion-v2 从 COCO caption 生成 768x768 图像，用 ParaDDPM 后单样本从 50.0 秒降到 14.6 秒（3.4x），CLIP score 保持在 32.1 不变；把并行方案叠加到本就更快的 DDIM 和 DPMSolver 上，加速达到 4.0x，而 CLIP 稳定在 31.7-31.9。在像素空间的 LSUN Church 上，ParaDDPM 的 FID 与完整 DDPM 持平（12.8 对 12.9），加速 3.9x。

表 2 图像生成（A100）。StableDiffusion-v2 用 CLIP score 衡量质量（越高越好，基于 COCO2017 caption）；LSUN Church 用 FID 衡量（越低越好，5000 个样本）。所有配置下质量都得以保持。

模型	质量（顺序 → 并行）	时间（顺序 → 并行）	加速
SD-v2, ParaDDPM (1000)	CLIP 32.1 → 32.1	50.0s → 14.6s	3.4x
SD-v2, ParaDDIM (200)	CLIP 31.9 → 31.9	10.3s → 2.6s	4.0x
SD-v2, ParaDPMSolver (200)	CLIP 31.7 → 31.7	10.3s → 2.6s	4.0x
LSUN Church, ParaDDPM (1000)	FID 12.8 → 12.9	24.0s → 6.1s	3.9x

两张表里真正值得注意的，不是某一个具体数字，而是这份提升的一致性。如果一个方法只对隐空间的图像模型有效，或者只在质量本已饱和时才生效，那它就只是个狭窄的技巧。而从 100 步的机器人策略到 1000 步的图像模型，从 FID 到 CLIP score 再到任务奖励，都能看到同样的 2-4x，这才让「算力换速度」看起来是扩散采样的一个普遍性质，而不是针对某个设定精调出来的结果。

因为加速的同时质量不变，样本本身看起来和顺序采样的输出没有区别。下面这张图就是用 ParaDDPM 跑完整 1000 步的 StableDiffusion-v2 调度、在其 4x96x96 的隐空间（latent space）上生成的，延迟比顺序基线低约 3.4x。



图 3 StableDiffusion-v2 在提示词「a beautiful castle, matte painting」下的采样结果，用 ParaDDPM 跑完整 1000 步调度、在 A100 上生成。并行采样在延迟降低约 3.4x 的同时，产出同等质量的输出。

唯一的旋钮：收敛容忍度

ParaDiGMS 只暴露一个可解释的旋钮：不动点迭代的误差容忍度（tolerance）。容忍度越紧，需要的迭代越多，保真度更高但加速更少；容忍度越松，收敛越早，跑得越快。有价值的发现是：存在一个相当宽的「舒适区」，容忍度放得比较松时质量依然纹丝不动，只有当它真正调得很大时，质量才开始被拉低。

表 3 容忍度消融（StableDiffusion-v2，200 步 DDIM，CLIP 基于 1000 样本，A100）。随着容忍度放松，加速稳步上升；在容忍度变得很大之前，CLIP score 一直保持不变。

容忍度 τ	并行迭代数	CLIP score	加速
seq	200	31.9	-
5e-3	36	31.9	1.4x
1e-2	28	31.9	2.0x
5e-2	19	31.9	3.1x
1e-1	15	31.9	4.0x
5e-1	13	31.5	4.9x
1e-0	12	31.5	5.4x

还有一个对照实验证明这份加速是「真」的，而不是偷偷减了步数。在 LSUN Church 上，ParaDDPM 以近 4x 的速度匹配完整 DDPM 的 FID，而单纯把 DDIM 缩到 500 步则会得到明显更差的图像。也就是说，收益确实来自「对所有步数做并行」，而不是悄悄少走几步。

小结

ParaDiGMS 为加速扩散模型开辟了一条新的轴：不是靠减步数牺牲质量，而是花并行算力把所有步数跑得更快，把采样延迟降低 2-4x 且质量无损，还能和大家已经在用的快速采样器叠加。需要诚实说明的边界是：这是一笔「算力换速度」的交易，额外的并行模型评估并不免费，因此它的收益在「有富余的并行硬件、且更在意延迟而非总算力」时最大。

往前看，这个视角本身才是最有意思的地方。随着 GPU 在大批量并行上越来越强，采样的真实耗时将主要受限于那少数几轮 Picard 迭代，而不再是那条长长的步数链——这指向一种会随硬件规模持续变快、又始终不必用质量买单的扩散采样。