

ICML 2023 | 两个都收敛到低损失的模型，凭什么说它们“想的不一样”

Michigan、Harvard、NTT Research 与 Cambridge 提出：线性连通性的缺失能揭示模型是否依赖同一套机制，并据此给出微调方法 Connectivity-Based Fine-Tuning (CBFT)。

一个深度网络往往有无数组能把训练损失压到几乎为零的权重，而近年关于「模式连通性 (mode connectivity)」的研究给出了一个反直觉的结论：这些极小值点并不是彼此孤立的孤岛，通常可以在它们之间画出一条简单的、低损失的路径，仿佛所有好解都落在同一片连通的平台。但「损失相同」并不等于「模型相同」。两个网络可以都在训练集上做到近乎完美，却依赖完全不同的输入特征来做预测：一个看物体的形状 (shape)，另一个则依赖它通常出现的背景 (background)。以往的模式连通性研究从未追问：被连通起来的这些极小值，究竟用的是哪一套机制？本文认为这个问题绝非纯理论：如果我们不知道一条低损失路径是否保留了模型的机制，也就无法确信微调真的按我们期望的方式改变了模型的行为。

ICML 2023 的这篇 Mechanistic Mode Connectivity 正是要补上这块空白。它给出了「两个模型机制相似 (mechanistic similarity)」的定义，证明了两个极小值之间缺乏线性连通性就意味着它们使用了不同的机制，并把这一结论转化为一种微调方法 Connectivity-Based Fine-Tuning (CBFT)：通过刻意破坏连通性，剥离模型对某个虚假特征 (spurious attribute) 的依赖。




图 1 模式连通性的「机制视角」。两个极小值 $\theta_{Background}$ 与 θ_{Shape} 都能达到低损失，却分别依据背景和形状来预测。论文由此提出三个问题：这类机制不同的解之间是否存在低损失路径？路径是线性还是非线性能否揭示机制的差异？我们能否利用连通性，把模型迁移到我们想要的机制上？

什么才算「同一套机制」

本文的第一步，是把「机制」从一个比喻变成可度量的东西。它把数据看作由一个隐向量 z 生成，其中不同的坐标控制不同的属性：一个管形状，一个管背景，以此类推。所谓单位干预（unit intervention），就是翻动其中某一个坐标，比如保持一条鱼的形状不变，只把池塘换成开阔水域。如果改变某个属性时两个模型的预测都不受影响，我们就说它们对这次干预都保持不变（invariance）；对同一组干预都保持不变的两个模型，就被定义为「机制相似」。




图 2 用反事实（counterfactual）定义机制相似。每一行是对某个隐变量做干预后得到的图像（ A_1 改变形状， A_2 改变背景），每一列是一个模型。两个形状模型对相同的干预都保持不变，机制相似（ $\sim$ ）；而背景模型的反应不同，机制相异（ $\neq$ ）。

一个已知「正确机制」的基准

要检验这个想法，需要一批「正确机制」与「捷径机制」都事先已知的数据集。作者的做法，是在数据原有的自然隐变量（ z_n ）之外，额外注入一组合成隐变量（ z_s ），并让它们诱导出的线索（cue）与标签相关：这是一条极易分离的捷径，网络会乐于学它而不去学真正的物体。他们把这种线索嵌入三个数据集：CIFAR-10 加入位置由标签决定的 3×3 色块线索；CIFAR-100 的色块线索按标签数字着色和定位；Dominoes 则把每张 CIFAR-10 图像与同类别的 Fashion-MNIST 图像拼接在一起。线索与标签的相关比例从 60% 扫到 100%。关键在于，每个数据集都配有反事实测试集（保留线索、去掉线索、随机化线索、随机化自然图像），于是模型到底更依赖虚假线索还是自然属性，可以被直接读出来。




图 3 数据生成过程。自然隐变量 z_n （蓝色）决定物体本身；合成隐变量 z_s （红色）注入线索，其取值以标签 y 为条件，使线索成为一条「有预测力但虚假」的捷径。

核心结论：线性不连通，就说明机制不同

有了可度量的机制，论文的理论给出一个尖锐的预测：如果两个极小值机制相异，那么即便考虑了会重排等价神经元的排列对称性（permutation symmetry），也无法用一条线性低损失路径把它们连起来。图 4 在 ResNet-18 上验证了这一点。用线索训练的模型（ θ_C ）与不用线索训练的模型（ θ_{NC} ）确实机制相异：随机化线索时， θ_{NC} 的准确率纹丝不动， θ_C 却大幅下滑。二次（quadratic）路径几乎没有损失壁垒就能把两者连通，而它们之间的线性路径无论怎么排列都压不低损失。损失地形的几何本身就携带了机制信息，线性不连通，是两个解「想法不同」的可靠信号。

这也顺带解释了微调的一个困惑。微调后的模型往往仍与其预训练解保持线性连通，而按同一条定理，这意味着微调根本没有改变它的机制。只把数据洗干净是不够的：模型会继续依赖它最先学到的那条捷径。




图 4 ResNet-18 在 CIFAR-10 上的线性与二次连通性（线索比例 60% 到 100%）。二次路径全程保持高准确率，线性路径即便排列后也避开损失壁垒，证实依赖线索 (θ_C) 与不依赖线索 (θ_{NC}) 的两个极小值机制相异。

把壁垒变成工具：CBFT

既然线性路径上的损失壁垒是机制改变的标志，那么刻意制造这样一道壁垒，就能反过来强行触发机制的改变。这正是 Connectivity-Based Fine-Tuning 的思路。给定一个很小的无线索数据集，CBFT 同时最小化三项：一个普通的交叉熵损失，保证模型仍能分类；一个壁垒损失（barrier loss），主动抬高通往依赖线索解那条线性路径上的损失，把模型推向一个机制不同的位置；以及一个不变性损失（invariance loss），让模型倒数第二层的表示在每一类的反事实版本之间对齐，从而钉住「要采用哪一套机制」。




图 6 CBFT 所利用的两条线索。沿着从无线索模型 θ_{NC} 到依赖线索模型 θ_C 的线性路径，损失呈现出 (i) 中间的壁垒，以及 (ii) θ_{NC} 端点处的不变性：在该点，有没有该属性损失都一样。CBFT 的壁垒损失与不变性损失正是分别针对这两个性质。

成效：一个不再去读捷径的模型

在 60% 线索比例的 CIFAR-10 上，CBFT 在各反事实测试集上的准确率几乎持平：去掉线索 74.1%、保留线索 71.5%、随机化线索 73.4%。这份「持平」正是一个对线索视而不见的模型该有的表现。相比之下，标准微调在有线索时看起来很漂亮（98.7%），一旦线索被随机化就崩到 17.5%，暴露出它有多依赖这条捷径。而当底层自然图像被随机化时，CBFT 掉到接近随机猜测的水平（8.75%），说明它确实是在依据物体本身、而非线索来预测。

表 1 60% 线索比例下的 CIFAR-10：CBFT 在四个反事实测试集上的准确率（%）。线索存在、缺失或被随机化时准确率都保持稳定，而一旦连自然图像本身也被随机化，准确率就掉到接近随机猜测。

反事实测试集	CBFT 准确率 (%)
去掉线索	74.1
保留线索	71.5
随机化线索	73.4
随机化图像	8.75

两个损失都不可少

CBFT 的两个辅助损失都不可少吗？消融实验的回答是肯定的，而且干净地区分了它们各自的分工。去掉壁垒损失，模型就停在原来那个依赖线索的解附近，根本不会迁移到一个机制不同的解；去掉不变性损失，模型虽然会离开原地，却不再可靠地落到用户想要的那个特定的无线索机制上。一句话，壁垒损失决定模型往哪走（远离捷径），不变性损失决定它最终落在哪套机制上，两者缺一不可。

结语

更大的启示是：模式连通性不只是关于损失地形形状的几何趣味，它携带着模型「学到了什么」的信息。两个低损失模型是否线性连通，能告诉你它们是否共享同一套机制；而这一事实可以被反过来当作抓手：CBFT 用它来有意地编辑模型的机制，在普通的「干净数据微调」会悄悄失效的地方，剥离掉模型对虚假属性的依赖。这些结果是在带有可控捷径的合成基准、以及 ResNet-18 与 VGG 规模的模型上得到的，因此自然的下一个问题是：面对大模型那些更纠缠、更难解耦的特征，同样的连通性信号会如何表现。但作为一种既能诊断、又能引导网络「该关注什么」的工具，连通性这个抓手无疑是新的。