

不止旋转整张图，还要旋转每个 patch：为 Vision Transformer 量身定制的自监督方法

PatchRot 让 ViT 同时预测整图与每个 patch 的旋转角度，在四个数据集上稳定超越从零监督训练。来自 Arizona State University 与 Georgia State University。

Vision Transformer (ViT，视觉 Transformer) 已经成为图像识别的主流骨干网络，但它有一个众所周知的软肋：吃数据。ViT 把一张图切成一串 patch token，再由自注意力自己去决定这些 token 之间的关系，这带来了极大的灵活性，却几乎没有卷积网络 (ConvNet) 与生俱来的那套先验假设。ConvNet 天然内建了局部性和平移结构，ViT 却要从数据里把这一切重新学出来。于是在标注稀缺时，ViT 往往落后于 ConvNet，只有在超大规模有标注数据上训练时才能反超。

这让自监督预训练，即在接触任何有标注任务之前先从无标注图像里学到有用特征，成为一个顺理成章的选择。麻烦在于，主流的自监督预训练任务（拼图、上色、图像旋转预测）都诞生于 ConvNet 时代。ConvNet 输出的是一张全局特征图，因此这些任务只对整张图问一个全局问题，从不利用让 Transformer 之所以是 Transformer 的那个结构特性：它为每一个 patch 都产生一个独立输出。

PatchRot 正是从这个空白切入。它的想法一句话就能说清：把整张图旋转、也把它的每个 patch 独立旋转一个随机的 90 度倍数，再训练 ViT 去预测每一处的旋转角度。原本用来预测物体类别的 class token 负责预测整图的旋转，因此必须抓住全局结构；每个 patch token 上新增的 MLP head 负责预测该 patch 自己的旋转，因此必须抓住局部细节。全局与局部监督，来自同一个无需标注的任务，而且恰好贴合这套架构。




图 1. PatchRot 的预训练任务。输入图像经过两条共享权重的前向通路：一条把整张图旋转一个随机的 90 度倍数，由 class token 预测这个角度；另一条把每个 patch 独立旋转，由每个 patch token 上新增的 MLP head 预测各自的角度。同一个无标注任务同时监督全局结构（经 class token）与局部细节（经 patch head）。

论文：<https://arxiv.org/abs/2210.15722>

代码：<https://github.com/s-chh/PatchRot>

为什么 Transformer 需要一个属于自己的自监督任务

PatchRot 承接的前作是 RotNet，它揭示了一个反直觉的现象：只要让一个 ConvNet 去预测图像被旋转了多少（0、90、180 或 270 度），它就能学到出人意料地丰富的特征，因为猜旋转角度会逼着网络去认识物体在正立状态下的样子。RotNet 对每张图只问一个问题，而 ViT 却能对每个 patch 各问一个问题。顺理成章的一步，就是把旋转预测下沉到 patch 级别，这种 patch 级别的信号，正是一个以 token 为单位的模型天生擅长消化的，然而此前还没有哪个自监督方法这样做过。

PatchRot 是怎么工作的

预训练阶段，PatchRot 同时进行两个任务。在图像旋转任务里，整张图被旋转一个随机的 90 度倍数，class token 以一个 4 类分类的形式预测这个唯一的角度。在 patch 旋转任务里，每个 patch 被独立旋转，挂在每个 patch token 上的专属 MLP head 预测该 patch 的角度，同样是 4 类分类。两个任务分别在各自的前向通路里进行，而不是一次全压上去，两条通路共享同一套 encoder 权重，于是 Transformer 无需从一团被打乱的输入里再去拆分信号，就能同时学到两种信息。

这种分工正是关键所在。class token 会汇聚整张图的信息，因此让它去预测整图旋转，会把它推向全局结构；patch head 只看单个 token，因此让每个 head 去预测各自 patch 的旋转，会把模型推向局部细节。预训练结束后，额外的 patch head 直接被丢弃，只保留 class token 那一路的 head，并在真正的分类任务上做微调。

这里有一个让 patch 旋转真正变难的细节。如果 patch 彼此紧贴着切开，模型就能作弊：它可以对齐相邻 patch 之间连续的边缘，不理解任何内容就直接读出旋转角度。PatchRot 用一个办法堵住这条捷径，从一个略大的网格里裁出 patch 并随机裁剪，在相邻 patch 之间留出一段随机的缓冲间隙（论文把缓冲设为 patch 尺寸的四分之一）。接缝被打断后，边缘连续性不再泄露答案，模型只能去学真正的局部结构。

还有一个务实的细节：自监督训练在较低分辨率下进行以节省开销，下游微调再切回原始分辨率，并把位置编码插值到更多的 patch 数上。全程使用的骨干是一个紧凑的 ViT，带 6 个 Transformer encoder block，CIFAR 与 FashionMNIST 在 32×32 下评测，Tiny-ImageNet 在 64×64 下评测。

有用吗？从任意深度微调看效果

评判一个预训练特征提取器，最干净的方式是看你需要微调它多少。图 2 扫的正是这件事：横轴从几乎全部冻结（NF，以及只训练最后一层 head、也就是线性探测的 MLP）一路走到逐步

解冻更深的层。每个子图对应一个数据集，三条曲线分别是 PatchRot、RotNet 和从零监督训练的基线。




图 2. 在 CIFAR-10、CIFAR-100、FashionMNIST 和 Tiny-ImageNet 上，准确率随微调多少而变化（NF 与 MLP 冻结得最多，encoder block EB1-EB7 逐步解冻）。PatchRot 曲线几乎在每个深度都高于 RotNet 与监督基线。值得注意的是，即便只做线性探测（MLP）也逼近监督训练的水平，而只微调单个 encoder block 就已超过从零训练。

有两点特别突出。其一，PatchRot 曲线在四个数据集上处处高于 RotNet，并在有用的区间内高于从零监督训练那条线。其二，也更能说明问题的是，这些收益在大幅冻结下依然存在：仅做线性探测（在冻结的 PatchRot 特征之上只训练最后一层）就能逼近完全监督的数字，而只微调单个 encoder block 已经胜过从零训练的网络。这正是特征真正有用、而非微调假象的标志。

在完全微调下取值的核心数字，把这个效应的量级说得很具体。

表 1. PatchRot 预训练对比从零监督训练（完全微调下）。

数据集	指标	监督训练	PatchRot	提升
CIFAR-10	Top-1	83.9	92.6	+8.7
CIFAR-100	Top-1	50.2	70.6	+20.4
CIFAR-100	Top-5	81.6	90.2	+8.6
FashionMNIST	Top-1	89.8	94.1	+4.3
Tiny-ImageNet	Top-5	66.4	73.4	+7.0

任务越难、标注越稀薄的地方，提升越大：在 CIFAR-100 上，PatchRot 把 top-1 准确率从 50.2 提到 70.6，涨了超过 20 个百分点；而在更简单的 CIFAR-10 上也仍然加了 8.7 个百分点。每种情况下干活的都是同一个紧凑 ViT，唯一的区别只在于它是从零开始，还是从 PatchRot 学到的特征出发。

Transformer 到底学到了什么

数字说明特征有帮助，注意力图则透露出原因。由于 PatchRot 在预训练时从未见过类别标签，它本没有明显的理由去关心物体，可它偏偏学会了。



图 3. 一个用 PatchRot 在 Tiny-ImageNet 上预训练的 ViT 的注意力图（上排为输入图像，下排为模型的注意力）。在从未见过标签的情况下，模型把注意力集中到了每个场景中最显著的物体上，这说明旋转预测把它推向了以物体为中心的特征。

这些注意力图集中在每张图里最显著的物体上，瓶子、野猪、汽车、人与狗、水塔，而不是散落到背景中。这为特征之所以能很好迁移提供了一个合理解释：要判断一个 patch 被转到了哪个方向，模型就得知道这个 patch 里的东西是什么，而这种知识恰恰是下游分类器想要的。

预训练越多，特征越好

如果自监督信号是真实的，那么给得越多就应当持续见效。图 4 在 CIFAR-100 上改变 PatchRot 预训练的轮数，并在几个不同的微调深度上追踪下游准确率。




图 4. CIFAR-100 上的下游准确率随 PatchRot 预训练量增加而变化（右图放大了后期的轮数）。在各个微调深度（NF、EB5、MLP）上，更多的自监督预训练都稳定提升准确率，而冻结特征的那几条曲线始终远高于 81.6 的监督基线。

准确率随预训练稳步上升然后趋于平缓，正是我们希望看到的边际递减曲线：收益不是某次幸运早停的假象，而是随着模型在预训练任务上花更多时间而累积起来的。即便网络大部分被冻结，PatchRot 的曲线也安稳地位于监督基线之上，再次印证价值在于学到的特征，而非微调本身。

能迁移的特征，也能救活少标注场景

一个好的预训练任务，还应当产出能搬到新数据集上的特征。作者用一种方式来检验：在一个数据集上用 PatchRot 预训练，再到另一个数据集上微调，并在 CIFAR-10 与 CIFAR-100 之间双向都做一遍。




图 5. CIFAR-100 与 CIFAR-10 之间的双向迁移学习。在每一个微调深度上，用 PatchRot 在源数据集上预训练得到的特征（蓝色）都比在同一源数据集上做监督预训练（绿色）迁移得更好，说明学到的表示并未狭隘地绑定在某一套标签上。

两个迁移方向上，PatchRot 曲线在每个深度都高于监督预训练，可见这套表示并没有被某一套标签狭隘地限定。标注稀缺时同样的优势更为醒目：在 CIFAR-10 的半监督设置里，只用 4000 张有标注图像，PatchRot 达到 81.1 的准确率，而在同样这一小撮标注上做监督训练只有 53.7。当标注成为瓶颈时，无需标注的特征最为值钱。

哪些设计真正起作用

PatchRot 有几个可拆解的部件，作者在 CIFAR-10 上逐一做了消融。去掉任意一半监督都会掉点：只预测 patch 旋转（丢掉整图信号）或只预测图像旋转（本质上是把 RotNet 搬到 ViT 上），都落在完整方法之下。其余设计选择，把图像旋转与 patch 旋转分成两条通路、在较低分辨率下预训练、以及为 patch 新增 head 而不是复用 class token 的 head，各自贡献一份更小但稳定的收益。

表 2. CIFAR-10 上的消融实验（top-1 准确率）。PatchRot 的每个部件都有贡献。

变体	Top-1
完整 PatchRot	92.6

去掉图像旋转（仅 patch）	91.8
去掉 patch 旋转（仅图像）	91.0
图像与 patch 一起旋转	90.7
在原始分辨率下预训练	92.1
复用 class token 的 head 预测 patch	91.1

小结

PatchRot 提醒我们，一个自监督任务只有贴合它所训练的架构时才最有效。预测整张图的旋转是个老想法，新意在于把每个 patch 的旋转也一并预测，这就把一个单一的全局问题变成了 Transformer 天生就该回答的、逐 token 的稠密信号。class token 学到全局结构，patch head 学到局部细节，由此得到的特征在四个数据集上都胜过从零监督训练与 RotNet，能在数据集之间干净地迁移，并在标注稀缺时收益最大，而这一切靠的是廉价、通用的部件（patch 之间的缓冲间隙与低分辨率预训练），而非笨重的机制。

诚实的边界藏在前提里：PatchRot 依赖旋转本身是有信息量的，因此在方向意义不大的类别上它的优势最薄，这也是作者为什么要单独考察像 SVHN 和 MNIST 里的数字这类旋转不变物体。不过对于有清晰正立方向的自然图像这种常见情形，它是一个轻量而务实的配方，能在有标注数据紧缺时，用来预训练视觉 Transformer 这类模型。