

ICML 2024 | 用无限宽理论解释：为什么 Jacobian 正则能让网络又准又稳

KAIST 将 NTK 类无限宽理论首次推广到网络的输入-输出 Jacobian，证明鲁棒训练在极限下等价于一次核回归。

过去几年，无限宽理论（infinite-width theory）为理解深度网络提供了一批异常干净的结论。像 Neural Tangent Kernel（NTK，神经正切核）这样的工具，能告诉我们一个很宽的网络如何初始化、梯度下降如何移动参数、训练最终会收敛到哪里。但这些结论有一个共同的边界：它们描述的都是网络的输出（output），几乎没有触及网络的输入-输出 Jacobian，也就是刻画输出如何随输入变化、从而衡量网络有多“平滑”的那个对象。

这个空白很关键，因为“平滑”正是我们追求鲁棒性时真正关心的东西。Jacobian 正则（Jacobian regularisation）就是这样一个“朴素但好用”的方法：在训练时对每个样本点上网络的输入-输出 Jacobian 加一个惩罚，它就成了对抗扰动（adversarial perturbation）的一个简单而强力的防御手段。尴尬之处在于，几乎没人能从理论上说清它为什么有效。那套已经攻克了普通训练的无限宽视角，此前从未被推广到 Jacobian，更不用说推广到专门惩罚 Jacobian 的训练了。

这篇 ICML 2024 论文（Taeyoung Kim、Hongseok Yang，KAIST）正是来补上这块空白。作者证明：随着宽度增大，一个多层感知机（MLP）和它的 Jacobian 会联合收敛到一个高斯过程（Gaussian process）；他们定义了一个支配训练过程的 Jacobian Neural Tangent Kernel（JNTK，Jacobian 神经正切核）；并证明这种带 Jacobian 惩罚的训练（作者称之为 robust training，鲁棒训练）在无限宽极限下，其行为恰好等价于一次固定核的核回归（kernel regression）。顺带地，他们第一次从无限宽的角度解释了：为什么惩罚 Jacobian 能得到既准确又鲁棒的网络。

论文链接：<https://arxiv.org/abs/2312.03386>

从“输出”到“Jacobian”

先用一段话把术语理顺。无限宽理论主要研究两个极限核。NNGP 核描述随机初始化网络输出的分布，当宽度趋于无穷时，该输出收敛到一个高斯过程；NTK 则描述这个输出在梯度下降下如何移动，它的关键优点是：在宽极限下，NTK 在初始化时变成确定性的（deterministic），并且在训练全程保持不变（constant），这就把学习过程化简成一个可解的线性系统。注意，这一切说的都是网络的输出。

鲁棒训练改变了优化目标。在常规的均方误差（mean-squared error）之外，它再加上系数 λ 乘以网络输入-输出 Jacobian 各分量平方的惩罚，并在每个训练点上计算。 λ 越大，网络就越被推向一个更平滑的输入-输出映射。论文要问的是：同一套无限宽机制（初始化时

的高斯过程收敛、训练中核保持不变)，能否从“输出”推广到“网络与其 Jacobian”这个联合对象上？

四步理论推导

整个分析分四步走。第一步，作者证明在初始化时，MLP 和它的 Jacobian 会联合收敛到一个零均值高斯过程，并按深度归纳地写出其极限协方差，即 Jacobian NNGP 核。证明的关键是把这种联合收敛改写成一个张量程序（tensor program），再套用 Tensor-Program 框架的 Master 定理——正是这一步，让他们能把网络和它的导数放在一起处理，而不是分别处理。

第二步，作者用输出以及每个 Jacobian 分量的参数梯度（parameter-gradient）之内积定义了 Jacobian NTK（JNTK），并证明了它在宽极限下具备 NTK 那两条核心性质：JNTK 在初始化时是确定性的，并在鲁棒训练全程保持不变。由于此时要控制参数移动的范围还得额外约束 Jacobian 惩罚项，证明用到了参数移动的 1-范数、2-范数与无穷范数，而标准 NTK 的论证仅凭 2-范数便已足够。

第三步，核保持不变，训练动力学随之坍塌。整个学习轨迹化简为一个一阶线性常微分方程（ODE），其 t 趋于无穷时的解，正是一个用极限 JNTK 构造、并经一个携带正则强度 λ 的对角矩阵重新缩放后的核回归子。换句话说，宽 MLP 的鲁棒训练在极限下就是“用 Jacobian NTK 做的核回归”。第四步是实验：先验证收敛性结论，再用这个闭式解去研究准确率与鲁棒性何时能同时成立。

把各个部件写出来会更直观。鲁棒训练最小化的是均方误差，再加上 λ 乘以每个训练点上 Jacobian 各分量平方之和。一旦证明 JNTK 保持不变， t 趋于无穷时的解就有了闭式形式： $f_{\text{ntk}}(x) = \Theta_{\lambda}(x, X)^T \Theta_{\lambda}(X, X)^{-1} y$ ，即一个定义在训练输入 X 上的普通核回归子。其核 $\Theta_{\lambda} = \Lambda \Theta \Lambda$ ，无非就是把极限 JNTK (Θ) 用一个对角矩阵 Λ 包裹起来—— Λ 的第一个元素为 1，其余元素为 λ 的平方根。于是正则强度只通过这一步缩放进入最终解，这既让 λ 的作用格外容易分析，也正是论文后文得以在同等条件下对比鲁棒训练与标准训练所依赖的关键。

数值上，理论站得住脚吗？

第一组实验检验初始化结论：随着 MLP 变宽，其有限 JNTK 应当逼近确定性极限。作者用了一个受控的合成数据集——四维空间中 256 个点，近似均匀地覆盖球面——并遍历从 64 到 8192（2 的幂，从 2^6 到 2^{13} ）的每一个宽度，深度取 1、2、3。每种配置重复 10 次，报告 95% 的自助法（bootstrap）置信区间，协方差估计则基于一百万次蒙特卡洛采样。图 1 追踪缩放后有限 JNTK 与其极限之间的 max-norm 距离：在每个深度下，随着宽度增大，该距离稳步缩小，与“JNTK 在初始化时是确定性的”这一预测一致。




图 1 初始化时经 $(1/\kappa^2)$ 缩放的有限 JNTK 与其极限之间的 max-norm 距离，展示了四个代表性核分量。横轴为 MLP 宽度（64 到 8192），纵轴为误差；颜色对应深度 $L = 1, 2, 3$ 。在每个深度内，误差都随网络变宽而下降，支持“JNTK 在无限宽极限下变为确定性”的论断。

第二组实验更具挑战性：JNTK 不仅要在初始化时确定，还要在鲁棒训练过程中保持不变。这里作者改用 Algerian forest fire 数据集（UCI，224 个点，11 维输入），把它当作正负一（ ± 1 ）回归任务，并在同样的宽度范围内，追踪核在每个训练步与其初始化极限的偏差。这是一个比初始化结论严格更难的论断，因为它不能只在某一时刻成立，而要在整条优化轨迹上都成立。

这里的鲁棒训练取 Jacobian 系数 $\lambda = 0.01$ 、缩放常数 $\kappa = 0.1$ 、学习率为 1，并在从 0 到 2048 的一系列训练步 t 上测量核。图 2 展示了结果：在检验过的每一个训练步上，核与极限的偏差都随宽度单调缩小。换句话说，网络越宽，JNTK 在整个训练过程中就越忠实地保持其初始值——这正是不变性定理所预测的。




图 2 鲁棒训练过程中，缩放后有限 JNTK 与其初始化极限之间的偏差，按宽度作图，并覆盖一系列训练步 t （颜色， $t = 0$ 到 2048）。在整个扫描范围内，误差在每一步都随宽度下降，说明在宽极限下，JNTK 在鲁棒训练全程近似保持不变。

作者对这组验证的边界很坦诚。在测试到的最大宽度（8192）处，max-norm 误差仍大于相关 Gram 矩阵的最小特征值，因此实验并未完全证实精确保证所需的那个界。但趋势毫不含糊：每一步都是越宽越接近；要彻底弥合这个差距，只需要比当前算力预算所允许的更宽的网络。

真正的收获：准确率与鲁棒性不再互相拖累

有了闭式的核回归解，作者就能直接审视它的特征向量（eigenfeature），去问：让解更准确的那些特征，是不是也正是让它更鲁棒的那些特征？这里的鲁棒性用测试准确率在特征受到小扰动（0.01 与 0.1）后能保持多少来衡量。一个醒目的发现是：在 Jacobian 正则下，准确率与鲁棒性是同向变化的——越准确的特征往往也越鲁棒。




图 3 鲁棒训练（带 Jacobian 正则）解的特征向量：测试准确率与其在 0.01、0.1 扰动后准确率的三两散点图，颜色编码正则系数。点云沿对角线分布，说明越准确的特征也越鲁棒——准确率与鲁棒性彼此对齐，而非此消彼长。

标准训练则讲了个相反的故事。对普通（无正则）解做同样的分析，图 4 显示准确率与鲁棒性之间几乎没有相关性。同样重要的是，标准训练从未产生早前有限 NTK 工作（Tsilivis and Kempe, 2022）中报告的那种“高准确但脆弱”的特征。这一对比表明：Jacobian 正则并不是拿一点准确率去换鲁棒性，而是重塑了解的结构，让这两种性质彼此强化。




图 4 对标准（无正则）训练做同样的两两散点图；椭圆为高斯拟合的 4-sigma 置信区域，用来让相关性更清晰。准确率与鲁棒性几乎不相关，也没有出现“高准确但脆弱”的特征，与图 3 的鲁棒训练解形成对比。

一个提醒：满秩假设并不牢靠

这套干净的核回归叙事建立在一个假设之上（论文的 Assumption 4.4）：极限 JNTK 必须有非零的最小特征值，也就是其 Gram 矩阵满秩。作者检验了这个条件何时真正成立，答案是一条很实用的警示。图 5 按深度画出 JNTK 与标准 NTK 的最小特征值，覆盖两种激活函数。JNTK 的最小特征值远低于 NTK，且只有在网络更深时才转正：GeLU 需要深度 11 及以上，而 erf 激活最浅在深度 6 处便已满足。




图 5 JNTK (绿) 与标准 NTK (蓝) 的最小特征值随网络深度的变化，分别对应 GeLU (左) 与 erf (右) 激活。圆圈标记满足“最小特征值非零”假设的深度，叉号标记违反该假设的深度。JNTK 在 GeLU 下需要深度 ≥ 11 ，在 erf 下只需 ≥ 6 ，说明理论背后的这个假设远非自动成立。

这与其说是一个脚注，不如说是一个真正有用的诊断：它告诉实践者，Jacobian 正则训练的无限宽保证依赖于激活函数与深度，并给出了一个具体的经验法则，来判断底层条件大致何时能够成立。

结语

归结起来，无限宽理论现在触及的不再只是网络的输出，而是网络的 Jacobian。用 Jacobian 正则训练一个宽 MLP，在极限下它的行为就像一次“用 Jacobian 神经正切核做的核回归”；而同一个正则项让准确率与鲁棒性朝同一个方向使劲，而不是互相比较。这是第一次从无限宽视角，对“为什么惩罚 Jacobian 能得到既准确又鲁棒的网络”给出有原则的解释，还附带了一个（通过最小特征值判断的）实用检验，来判断其关键假设何时成立。

同时也值得把边界看清楚：实验是刻意做小、做受控的——都是合成或低维数据上的 MLP，而要完全从数值上证实不变性那个界，需要比目前测试的更宽的网络。但作为一项理论工作，它把一套成熟工具推广到了一个新对象上，也把一个广为人知的经验技巧，变成了我们能够真正去推理的东西。