

NeurIPS 2023 | 让 CNN 把颜色当作一种对称性，而不是捷径

代尔夫特理工大学提出 Color Equivariant Convolution（颜色等变卷积）：抵御测试时的色调偏移，又不丢弃颜色信息。

颜色是卷积神经网络最容易利用的线索之一：成熟的番茄是红的，校车是黄的，某种花有着独特的紫蓝色。网络很快就会学到这些规律，多数时候这也确实有帮助。但一旦测试时遇到的颜色与训练时不同，这种依赖就变成了软肋。一个主要从红色、银色样本里学到汽车的模型，看到一辆蓝色汽车时可能就认不出来了，哪怕形状一目了然。

对付这个问题的常规做法是追求颜色不变性（color invariance）：把图像转成灰度，或者用大量 color-jitter（颜色抖动）增强，直到网络不再在意色调。这样确实能换来鲁棒性，但代价很实在。灰度直接删掉了一个本来有用的信号，而强增强又会抹平区分类别所依赖的颜色差异。结果是，你恰恰通过拒绝使用颜色来获得对颜色的鲁棒性。

代尔夫特理工大学（TU Delft）计算机视觉实验室发表于 NeurIPS 2023 的一篇论文提出了另一种取舍。与其在「利用颜色」和「对颜色变化鲁棒」之间二选一，不如把一次色调偏移当作此前工作处理旋转或翻转那样的对象：把它视为网络理应在结构上遵守的一种对称性。承担这一职责的构件就是 Color Equivariant Convolution（CEConv，颜色等变卷积），它无需改动架构，就能作为标准模块直接嵌入 ResNet 这类现有骨干网络。




图 1 核心思想。色调变换 T_g 把花 A 变成花 B。普通 CNN 会把两者映射到彼此无关的预测上，于是在一种颜色下学到的类别，换个颜色就可能认不出来。颜色等变网络（CECNN）则把它们映射到由一个可预测的置换 T'_g 相联系的表示上，因此为某种颜色学到的形状知识可以迁移到其他颜色。

论文地址：<https://arxiv.org/abs/2310.19368>

代码地址：<https://github.com/Attila94/CEConv>

问题：颜色有用，直到颜色变了

真实世界的外观有一条长尾。对几乎任何一个物体类别来说，训练集中总有些颜色常见、另一些颜色罕见甚至完全缺席，任何现实数据集都无法覆盖全部变化。由于标准 CNN 把每一种颜色都当作独立的视觉模式，它为某种充分出现的颜色所建立的形状知识，并不会自动迁移到出现不足的颜色上。恰恰是那些罕见颜色最容易被错分，而收集一个颜色完全均衡的数据集在实践中并不可行。

论文首先把这层张力讲清楚：CNN 明显能从颜色中获益，却对基于颜色的分布偏移并不鲁棒。灰度模型和颜色增强能恢复鲁棒性，但代价是丢弃了原本有用的判别性颜色信息。目标是既保留颜色、又能跨颜色泛化，让在色谱某一段学到的形状，在整个色谱上都能用得上。

思路：色调偏移就是 RGB 空间里的一次旋转

群等变卷积（group equivariant convolution）教会网络在旋转、反射等几何变换间共享参数，从而在这些对称性上大幅提升数据效率。而像色调偏移这样的光度变换却一直被搁置，尽管对已训练 CNN 的研究表明，早期层会学到高度颜色选择性的滤波器。换句话说，颜色本身就是一个天然适合施加等变性的坐标轴。

关键的观察是几何性的。HSV 空间中的一次色调偏移，对应到 RGB 空间就是绕着从黑到白的灰度对角线（即 $[1,1,1]$ 轴）的一次旋转。作者把离散色调偏移的集合形式化为群 H_n ，即绕该对角线做 n 次、每次 $360/n$ 度旋转所构成的群。颜色等变卷积于是不再只用单个滤波器与输入做相关，而是用一组经过色调旋转的滤波器副本，产生的特征图会多出一个维度，用来标记每个响应来自哪一次色调旋转。

对于输入层，这意味着用色调矩阵 $H_n(k)$ 旋转每个滤波器；对于隐藏层，滤波器副本沿颜色维度做循环置换，从而让等变性在整个网络中一直保持。具体地，空间位置 x 、色调索引 k 处的响应为：

$[f * \psi^i](x, k) = \sum_{y \in Z^2} \sum_{c=1..C} f_c(y) \cdot H_n(k) \psi_c^i(y - x)$ ，其中的求和遍历所有空间位置 y 与输入通道 c 。

多出来的颜色维度会成倍增加特征图数量，因此作者把每个滤波器分解为一个空间分量和一个逐点分量，把运算量与参数量的增长控制在色调旋转次数的小倍数以内。他们还提供了混合（hybrid）变体：只在 ResNet 早期、颜色选择性最强的阶段使用 CEConv，随后在颜色维度上做池化，在网络较深处引入颜色不变性，同时控制模型容量。

在不牺牲干净精度的前提下获得鲁棒性

最重要的结论是：颜色等变性几乎是「免费」地换来了在干净数据上的鲁棒性。在原始、未偏移的测试集上，CE-ResNet 与普通 ResNet 表现相当。差距只有在把测试图像按 -180 到 180 度逐步做色调偏移、并对整个范围取平均精度时才显现出来，而此时差距会急剧拉开。

图 2 用 Flowers-102 讲清了这个故事。先看普通 CNN（蓝线）：它在 0 度、也就是训练颜色所在处形成一个尖峰，色调一旦偏离就迅速跌到只有几个百分点。颜色等变模型（橙线）则出现三个峰，分别在 -120、0、120 度处，因为它的离散色调对称性让它在这几次旋转之后仍能认出同一朵花。再叠加 color-jitter 增强（橙色虚线），曲线会被抹平成在各个色调上都很高的精度。




图 2 Flowers-102 上测试精度随测试时色调偏移的变化。普通 CNN（蓝线）只在训练颜色附近有峰值、其余处崩塌；颜色等变的 CE-CNN（橙线）在每一次离散色调旋转处都能恢复精度；再加上颜色增强（虚线）后，精度在整个色调范围内都保持在高位。

在整个色调扫描上取平均，Flowers-102 的精度从基线的 13.41% 提升到等变模型的 33.33%，大约是 2.5 倍，CIFAR-100 和 Stanford Cars 上也有相似幅度的提升。关键在于，这些鲁棒性收益并没有以干净精度为代价，而且它与颜色增强是叠加关系，而非彼此竞争。

一个受控压力测试：长尾 ColorMNIST

为了把机制单独拎出来，作者构造了一个合成基准——长尾 ColorMNIST：数字既要按形状、又要按颜色分类，且类别严重不均衡。由于颜色等变性会把一个形状模板共享到整个色谱，网络可以从常见颜色里学到某个数字的形状，再在罕见颜色下认出它——而这恰恰是普通网络样本用尽的地方。




图 3 长尾 ColorMNIST 上的逐类别测试精度，灰色柱表示类别频率。颜色等变的 CECNN（绿线）即便在右侧的罕见类别上也能保持高精度，而普通 Z2CNN（蓝线）及其灰度变体（橙线）会随着类别变得稀少而急剧下滑。

这一效果相当显著。在所有类别上取平均，颜色等变网络达到 91.35%，而普通网络为 71.59%，提升了 19.76 个百分点，并且改进集中在最罕见、也正是参数共享意在拯救的那些类别上。这个受控实验印证了自然图像基准所暗示的结论：跨颜色共享形状，正是把罕见颜色样本从失败变为成功的关键。

表 1 在完整的测试时色调扫描（-180 到 180 度）上的平均测试精度（%）。颜色等变 ResNet 远比普通基线鲁棒，同时在原始、未偏移的测试集上与之持平。

数据集	普通 ResNet	CE-ResNet
Flowers-102	13.41	33.33
CIFAR-100	47.01	62.11
Stanford Cars	55.59	68.17

颜色等变性在什么时候有用？

颜色等变性并非万能，论文也坦诚地说明了它在什么情况下才划算。作者用一个颜色选择性（color selectivity）度量来量化一个数据集的神经元对颜色的响应程度，并把等变性的收益，与数据集的颜色选择性、以及等变阶段深入到网络多深，联系了起来。

Color Equivariant stages vs. accuracy improvement




图 4 在不使用（左）和使用（右）color-jitter 增强的情况下，随着颜色等变性被嵌入到某一 ResNet 阶段为止，等变模型相对普通模型的精度提升。神经元高度颜色选择的 Flowers-102（颜色选择性 0.70）随等变性延伸到更深阶段而稳步获益；颜色选择性较弱的数据集则几乎没有提升。

规律很清楚：像 Flowers-102 这样颜色选择性很高的数据集（颜色选择性 0.70），把颜色等变性一直用到网络较深的阶段都能获益，而神经元不太在意颜色的数据集则几乎没有变化。另外两项消融进一步补全了设计图景。增加离散色调旋转的次数能提升测试时鲁棒性，但会略微牺牲容量，因为要保持参数量不变，通道数必须相应缩小。而群陪集池化（group coset pooling）正是带来色调不变性的机制；把它去掉，网络就退化得和普通网络一样。

共享滤波器到底学到了什么

由于等变性是被写进架构、而非从数据中学出来的，内部滤波器具有可解释的结构。对在 Flowers-102 上训练的 CE-ResNet18 做神经元特征可视化可以看到，一个共享滤波器的每一次旋转，都会响应同一个形状、只是渲染成不同的颜色——这正是参数共享被「看见」的样子。




图 5 在 Flowers-102 上训练的 CE-ResNet18，其神经元特征及最强激活图块在四个阶段上的可视化。每个区块内，各行是同一个共享滤波器的不同色调旋转，每一行都在同一形状、不同颜色上激活，与颜色等变性的预言完全一致。

结论与边界

留下的核心信息是：颜色理应享有平移与旋转早已获得的那种等变待遇。通过在整个色谱上共享形状特征、同时把颜色保留在特征图的一个专用维度里，颜色等变卷积让网络得以同时做到「利用颜色」与「对颜色偏移鲁棒」，而不必二者取一。这一构件可以嵌入 ResNet 等现有架

构，与颜色增强互补，并且恰好在它被设计去帮助的地方——颜色选择性强的数据集与出现不足的颜色——带来最大的收益。

诚实的边界在于，这份收益是有条件的。在神经元并不特别在意颜色的数据集上，等变性只是增加了参数却换不来多少提升；而多出来的颜色维度带来的计算开销，虽被滤波器分解压低，却并未消除。但只要用在颜色确实重要的地方，CEConv 就提供了一条干净、实用的通往颜色鲁棒识别的路径，也提醒我们：一个值得拥有的对称性，通常也值得直接内建进网络。

对实践者而言，它的吸引力还在于：这一切都不需要新的架构或新的训练流程。CEConv 可以直接替换标准卷积，参考实现也已开源，而混合变体让你能在计算预算与颜色等变的深度之间自由权衡。当任务依赖颜色、数据又无法覆盖所有外观时，它是一个在动用更重的不变性手段之前，值得优先一试、成本低廉的对称性。