


NeurIPS 2022 | 把随机性从隐变量搬到编码器 器：Langevin 自编码器

东京大学提出摊销 Langevin 动力学（ALD），让 MCMC 也能像 VAE 一样高效，在测试似然上稳定超过 VAE

训练一个深度隐变量模型（deep latent variable model, DLVM），最直接的想法是最大化数据的似然。但只要模型里有隐变量 z ，这个目标就绕不开一个对后验分布 $p(z|x)$ 的期望，而这个后验通常没有闭式解，必须逐点做蒙特卡洛估计。围绕“如何近似这个后验”，深度生成模型这些年基本分成了两条路。

第一条路是变分推断（variational inference, VI），也就是我们熟悉的 VAE。它用一个编码器网络一次性为所有数据点预测隐变量，这种“摊销（amortization）”让训练变得非常高效。代价是：编码器只能输出一个可解析的分布（通常是高斯），所以它的近似能力天然被这个分布族卡住了。第二条路是马尔可夫链蒙特卡洛（MCMC），尤其是 Langevin 动力学。它能精确地从复杂后验里采样，但一直有个老问题：慢。传统做法要为每一个数据点单独跑一条采样链，而且收敛不快，因此几乎没法用来训练深度模型。

这篇来自东京大学、发表于 NeurIPS 2022 的工作想问的是：能不能把 VI 的“摊销效率”和 MCMC 的“采样灵活性”合到一起？他们给出的答案是 Langevin 自编码器（Langevin Autoencoder, LAE），核心是一个叫“摊销 Langevin 动力学（Amortized Langevin Dynamics, ALD）”的新采样算法。一句话概括：把 Langevin 采样里的随机噪声，从隐变量空间搬到编码器的参数上。



(a) Variational Inference (b) Langevin Dynamics (c) Hoffman [2017] (d) ALD (ours)

图 1 四种后验近似方法的对比。(a) 变分推断用高斯等可解析分布去逼近后验；(b) 传统 Langevin 动力学直接在隐变量上逐点跑采样迭代；(c) Hoffman [2017] 用编码器为传统 Langevin 采样提供初始点，但仍然要逐点迭代；(d) 本文的 ALD 同样用编码器，但直接把编码器的输出当作后验样本，采样过程通过更新编码器参数隐式完成。

论文与代码链接：

· 论文：<https://arxiv.org/abs/2209.07036>

· 代码：<https://github.com/iShohei220/LAE>

问题：MCMC 明明更准，为什么没人拿它训练

先把矛盾摆清楚。基于梯度的最大似然学习，需要对后验 $p(z|x)$ 求一个期望，而这个后验没有闭式表达。VI 的解法是找一个可解析的替身分布去逼近它，好处是编码器一次前向就能给出所有数据点的隐变量，坏处是替身分布的形状被写死了——高斯就是高斯，遇到多峰或强相关的后验只能勉强拟合。

MCMC 走的是另一条路：不假设后验长什么样，而是直接从中采样，因此原则上能逼近任意复杂的后验。Langevin 动力学是其中一种，它沿着对数后验的梯度走、再叠加一点高斯噪声，逐步把样本推向高概率区域。问题在于它的“逐点”本性：每来一个数据点，就要为它单独跑一整条采样链，训练时数据点成千上万，成本无法接受。已有的折中方案（如 Hoffman [2017]）用编码器给采样链提供一个更好的起点，但采样迭代本身还是逐点进行的，训练和测试时都要付这份钱。

方法：让 Langevin 噪声作用在编码器参数上

ALD 的关键一步，是换一个施加随机性的对象。传统 Langevin 把随机微分方程（SDE）跑在每个隐变量 z 上；ALD 则定义一个确定性的编码器 $f(x; \phi)$ ，把数据映射到隐变量，然后把 Langevin 方程跑在编码器的参数 ϕ 上。因为隐变量是编码器算出来的，参数 ϕ 的动力学就会诱导出隐变量空间上的动力学，于是可以直接把编码器的输出当作后验样本。

参数上的 Langevin 更新写出来是这样： $d\phi = -\nabla_{\phi} V(\phi) dt + \sqrt{2} dB$ ，其中势能 $V(\phi) = \sum U(x^{(i)}, f(x^{(i)}; \phi); \theta)$ 把所有数据点的负对数联合概率加在一起。离散化后每一步就是从一个小高斯里采样： $\phi' \sim N(\phi - \eta \nabla_{\phi} V(\phi), 2\eta I)$ 。注意这里所有数据点共享同一组参数 ϕ ，一次更新就同时推进了全部数据点的采样——这正是“摊销”的含义。

但把噪声搬到参数上不会白搬，需要一个保证：这样采出来的隐变量，真的服从我们想要的后验吗？论文的 Theorem 1 给出了条件。当编码器写成 $f(x; \Phi) = \Phi g(x)$ ，即一个固定的特征提取器 g 后面接一个可训练的最后一层线性映射 Φ ，并且这个线性层的维度 d 不小于当前 batch 的数据点数 n 时，ALD 诱导出的隐变量样本会收敛到真实后验。两个漂亮的特例随之而来：传统 Langevin 动力学是 ALD 的特例，而普通的自编码器则是 LAE 的特例。

Langevin 自编码器（LAE）就是把这套采样直接嵌进训练循环：每次更新解码器参数之前，先在编码器最后一层上跑 T 步 ALD 得到后验样本，可选地再加一个 Metropolis-Hastings（MH）拒绝步来消除离散化带来的偏差。从代码上看，它和一个标准自编码器几乎一模一样，区别只是编码器多走了几步带噪声的更新。

这个 $d \geq n$ 的条件不是纸上谈兵。下图在一个二元高斯的玩具例子上，直接改变编码器最后一层的输入维度 d ，观察采样结果。




图 2 编码器容量对采样的影响（二元高斯玩具例子）， d 为编码器最后一层线性映射的输入维度。当 $d > n$ 和 $d = n$ 时，三个数据点的样本都准确覆盖了各自的真实后验（GT）；一旦 $d < n$ ，中间那个数据点的样本塌缩成了一个点，直接印证了 Theorem 1 里 $d \geq n$ 的秩条件。

证据一：ALD 能采到 VI 采不到的后验

灵活性到底体现在哪？论文用一个“神经似然”玩具例子来看：让似然由一个随机初始化的神经网络定义，人为造出一个既多峰、又强相关的复杂后验，然后比较不同方法能否还原它。这类形状正是高斯替身分布的软肋。




图 3 神经似然例子中的后验对比。从左到右依次是真实后验（GT）、均场变分推断（Mean-field VI）、全变分推断（Full VI）和本文 ALD 的样本。均场 VI 只能覆盖单个峰，全 VI 也只能拟合一个带相关性的椭圆，而 ALD 的样本几乎复现了真实后验的多峰、弯曲结构。

结论很直接：均场 VI 把整个后验压成了一个孤立的峰，全 VI 稍好但也只是一个倾斜的椭圆，两者都丢掉了后验真实的多峰和弯曲结构；ALD 的样本则贴合了真实后验的形状。这说明把采样换成真正的 MCMC，确实带回了变分族拿不到的表达能力。

证据二：更准的后验，换来更好的生成模型

玩具例子说明 ALD 采得准，但训练深度生成模型时这份“准”值不值？论文在 MNIST、SVHN、CIFAR-10、CelebA 四个标准数据集上做了图像生成实验。为了公平，所有方法都用同样的全连接网络，用每维负 ELBO（negative evidence lower bound，越低越好）在三个随机种子上评测。

表 1 四个数据集上的图像生成结果，指标为每维负 ELBO（三个种子的均值，越低越好）。LAE 在全部四个数据集上都取得了最低值，稳定优于 VAE、VAE-flow 和 Hoffman [2017]。

方法	MNIST	SVHN	CIFAR-10	CelebA
VAE	1.189	4.442	4.820	4.671
VAE-flow	1.183	4.454	4.828	4.667
Hoffman [2017]	1.189	4.440	4.831	4.662
LAE (ours)	1.177	4.412	4.773	4.636

四个数据集上 LAE 都拿到了最低的负 ELBO：MNIST 从 VAE 的 1.189 降到 1.177，CIFAR-10 从 4.820 降到 4.773，CelebA 从 4.671 降到 4.636，SVHN 从 4.442 降到 4.412。绝对提升不算大，但方向一致——更准的后验采样确实转化成了更好训练的生成模型。代价是训练时间：LAE 大约比 VAE 慢 2.24 倍，不过和同样带采样的 Hoffman [2017] 基本持平。而且这些结果只用了 $T = 2$ 步 ALD 迭代。

什么在起作用：MH 步和迭代次数 T

既然 $T = 2$ 就够了，那 T 到底重不重要？MH 拒绝步又值不值得加？论文在 MNIST 上画出了测试集负 ELBO 的学习曲线来回答。




图 4 MNIST 测试集负 ELBO 的学习曲线。 $T = 2$ 与 $T = 10$ 两条曲线几乎重合，说明只要迭代步数不小于 2，增加 T 对性能几乎没有影响；而去掉 MH 拒绝步（No MH steps）后曲线剧烈震荡，说明 MH 步对稳定训练很关键。

两个观察很清楚。其一， $T = 2$ 和 $T = 10$ 的曲线基本贴在一起，说明只要 ALD 迭代不少于 2 步，再增加步数收益微乎其微——这也是为什么图像实验只用 $T = 2$ 。其二，一旦拿掉 MH 拒绝步，曲线开始大幅上下抖动，训练明显不稳定；MH 步虽然要额外算一点，却是把训练稳住的关键。配合前面的图 2，这两个消融从理论条件（ $d \geq n$ ）和工程细节（MH、 T ）两头把方法的行为交代清楚了。

小结：把自编码器重新理解为一种有偏差修正的采样器

这篇工作最优雅的地方，是它对“随机性放在哪里”的重新安排。把 Langevin 噪声从隐变量搬到编码器参数上，采样一下子既高效（因为在所有数据上摊销），又灵活（因为它是货真价实的 MCMC，而不是被约束的高斯）。由此得到的 LAE 在理论上是一个合法的 MCMC 方法，在代码上几乎就是一个标准自编码器，却能在测试似然上稳定超过 VAE。

换个角度看，它其实是把我们熟悉的自编码器，重新解释成了变分推断的一个“采样版、带偏差修正”的替代方案。当然，边界也要说清楚：它的收敛保证依赖“固定特征提取器 + 可训练线性末层，且 $d \geq n$ ”这样的编码器结构，实验也集中在全连接网络和这几个标准数据集上，绝对提升幅度温和，并且要付出约 2.24 倍的训练时间。它更像是打开了一扇门——让 MCMC 第一次真正被摊销进深度生成模型的训练里。