

ICML 2022 | 用「类比」告诉机器人该做什么

Berkeley 与 Meta AI 提出目标条件双模拟（GCB）：让相似任务在表示空间里对齐，用简单的向量加法描述目标。

大多数目标条件强化学习（goal-conditioned RL）都建立在一个方便的假设上：你可以直接把智能体要到达的目标状态交给它，通常是一张目标图像。给策略一张「抽屉已关」的图片，它就学着把世界变成图里的样子。这个设定很干净，在实验室里也确实好用。

问题在于，你往往拿不到那张图片。让机器人去关一个它从没见过的抽屉，你事先并不知道对这个抽屉而言「关好」长什么样：颜色、位置、周围的杂物都不确定。恰恰是精确的目标状态，是你无法指定的那个东西。你通常能提供的，是一个例子：这里有另一个抽屉被关上了，你照着做。

这篇来自 UC Berkeley 与 Meta AI 的 ICML 2022 论文，把这个想法认真做了下去。它提出目标条件双模拟（goal-conditioned bisimulation，GCB）：学习一种表示，让彼此类比的任务——关红色抽屉、关蓝色抽屉——落在同一个位置。任务一旦这样对齐，目标就不必再用图像描述，而可以用类比给出，并通过隐空间里的简单算术还原出来。




图 1 贯穿全文的类比。切胡萝卜和切萝卜，用到的是不同的物体，却是相同的技能、相同的「从初始到目标」的功能变化。GCB 想利用这种类比，为全新的、没见过的环境描述目标。

蔬菜的例子是全文的指北针。一个会切胡萝卜的人，不需要别人给他看最终那堆萝卜片，就能去切萝卜；他脑中带着的任务表示，忽略了无关的东西（是什么菜），保留了真正重要的东西（怎么切）。论文要回答的问题是：如何让强化学习智能体，直接从像素中学到这样一种表示。

论文：<https://arxiv.org/abs/2204.13060> · 项目主页：<https://sites.google.com/view/gc-bisimulation>

从「等价的状态」到「等价的任务」

GCB 建立在双模拟（bisimulation）这一经典概念之上。双模拟用来给状态分组：如果在任意动作序列下，两个状态产生的奖励序列都无法区分，它们就是双模拟等价的；双模拟度量（bisimulation metric）则把它放松成一个距离，衡量两个状态在行为上有多相似。近期的表示学习工作用这类度量，让智能体对视觉干扰更鲁棒——但都是针对单个任务。

论文的关键一步，是改变「被分组的对象」。GCB 不再对等价的状态分组，而是对等价的任务分组——也就是行为一致的「状态-目标」对。当两个 (s, g) 需要相同的动作、并导向相同的未来目标分布时，它们被视为等价。作者把由此捕捉到的性质称为功能等变性（functional equivariance）：表示对无关细节（颜色、背景物体）保持不变，对真正变化的因素（哪个抽屉、按没按下）则随之可预测地改变。

方法：两个编码器，让目标可以做加减法

为了把这个原则变成可学习的目标，GCB 同时训练两个编码器。状态-目标编码器 ϕ 把一对 (s, g) 映射成一个向量，训练目标是让两个编码之间的 ℓ_1 距离，去匹配一个 on-policy 的目标条件双模拟度量，也就是两个任务之间的行为距离。另一个状态编码器 ψ 只编码单个状态，训练目标是让 $\psi(g) - \psi(s)$ 等于 $\phi(s, g)$ 。第二个约束才是关键：它逼着任务表示表现得像「两个状态表示之差」，而这正是让目标可以做加减法的原因。




图 3 GCB 的表示学习核心。状态-目标编码器 ϕ 去拟合双模拟度量（损失 $\mathcal{L}_\phi$ ）；共享权重的状态编码器 ψ 则被训练成让 $\psi(g) - \psi(s)$ 对齐 $\phi(s, g)$ （损失 $\mathcal{L}_\psi$ ）。虚线表示梯度被截断。

既然 $\psi(g) - \psi(s) \approx \phi(s, g)$ ，这个关系就能反过来用。拿你当前的状态 s ，再拿一个演示了你想做之事的类比对 (s_a, g_a) ，计算 $\psi(s) + \phi(s_a, g_a)$ 。按照构造，这个结果应当落在你真正想要的目标的 ψ 附近。由于 ψ 编码的是单个状态，你只要在候选状态里找 ψ 空间中的最近邻，就能读出一个具体的目标。不需要目标图像，只需要一个类比。

$$\psi(\text{🍷}) + \phi(\text{🥕}, \text{🥕}) = \psi(\text{🍷})$$

图2 把目标当作算术。关系式 $\psi(\text{状态}) + \phi(\text{类比任务}) = \psi(\text{目标})$ 让「切胡萝卜」这一任务的表示，可以作用到新的初始状态上，产生对应的目标——这里是切好的萝卜。

整个系统在离线（offline）设定下训练。 ϕ 、 ψ 和策略 $\pi(\psi(s), \phi(s, g))$ 在隐式 Q 学习（Implicit Q-Learning, IQL）之上同时学习，数据来自一个由带噪专家收集的固定回放缓冲区。两个编码器都是六层 CNN，输出 256 维的嵌入。

表示真的如设想那样运作吗？

最有说服力的证据，先是定性的、再是定量的。如果 ψ 和 ϕ 真的编码了功能等变性，那么算术 $\psi(s) + \phi(s_a, g_a)$ 应当返回这样一些状态：它们在功能上与类比任务一致，却在无关细节上不同。作者从模拟器里组合真实的「状态-目标」对，再查找这个结果的最近邻。

$$\begin{aligned} \psi(\text{🏠}) + \phi(\text{🔧}, \text{🔧}) &= \psi(\text{🏠}) \\ \psi(\text{🏠}) + \phi(\text{🔧}, \text{🔧}) &= \psi(\text{🏠}) \end{aligned}$$

图4 真实状态上的类比算术。最右侧是 $\psi(s) + \phi(s_a, g_a)$ 的最近邻。上排：还原出的目标里，机械手指正按着按钮，与类比目标的功能一致，但位姿不同。下排：还原出的目标里抽屉被关上，功能一致，却忽略了颜色与位姿。

还原出的目标做对了事：如果类比是「按下按钮」，算术就返回一个按钮被按下的状态，位姿则随当前场景而定；如果类比是「关上抽屉」，它就返回一个抽屉关好的状态，不管颜色如何。位姿被保留，颜色和杂物被忽略——等变与不变，出现在同一张图里。

直接探查 ϕ ，也能看到同样的结构。采样一批「状态-目标」对，在 ϕ 空间里找它们的最近邻，应当浮现出一批功能相似、但视觉不同的任务。




图 5 ϕ 空间中的最近邻。每个采样的「状态-目标」对（上行）与它的最近邻（下行）并列。任务无关的特征——抽屉颜色、干扰物体——自由变化，而任务相关的结构——机器人相对目标物的位置、动作的语义——被保留下来。

在 ϕ 里互为近邻的样本，共享的是任务而非外观。这正是蔬菜类比所要求的不变性，在学到的空间里被看见了。

实验结果

在定量评测上，GCB 在一个 PyBullet 操作套件里测试：工作空间随机生成，物体从 84 种几何形状中抽取，涵盖三类环境——抽屉（Drawer）、按钮加抽屉（Button-and-Drawer, BD）以及专门的类比（Analogy）任务，每类都额外叠加视频干扰（Video Distractors, VD）作为背景。成功率相对真实目标衡量，5 个随机种子取平均，并与八种表示学习基线比较。

表 1 5 个种子上的最终平均成功率（论文中另附标准误）。BD 指按钮加抽屉环境，VD 指视频干扰。GCB 在 6 个设定中的 5 个上最优，并在每一个带干扰的任务上都最强；在 Analogy 任务上，它是唯一能从示例推断目标的方法，成绩约为次优基线的两倍。

方法	Drawer	Drawer+VD	BD	BD+VD	Analogy	Analogy+VD
GCB (本文)	0.533	0.448	0.440	0.322	0.403	0.303
CPV	0.400	0.209	0.228	0.198	0.176	0.121
GC-DBC	0.269	0.261	0.358	0.255	NA	NA
CCVAE	0.443	0.231	0.452	0.225	0.234	0.095
VAE	0.463	0.261	0.522	0.115	0.280	0.112
CPC	0.305	0.207	0.363	0.154	0.148	0.145
CURL	0.259	0.283	0.382	0.198	0.162	0.123
RAD	0.245	0.207	0.159	0.108	0.157	0.110
Pixel	0.483	0.256	0.117	0.136	0.132	0.121

有两点尤其突出。其一，GCB 在每个带视频干扰的任务上都胜出——Drawer+VD 上 0.448、BD+VD 上 0.322、Analogy+VD 上 0.303——这正是一个「为丢弃任务无关变化而设计」的表示应有的表现。其二，在 Analogy 任务上，目标必须从示例推断、而非直接给出，GCB 达到 0.403，而次优的 CPV 只有 0.176，几乎翻倍。它唯一没拿下的，是不带干扰的普通 BD：那里一个 VAE 基线以 0.522 略微领先——在无干扰、变化小的任务上，通用的重建目标最难被超越。

消融实验支持了主要设计。在 ψ 的目标里加入接地项 $\phi(g_i, g_i)$ 作为归一化常数会带来提升；用 ℓ_1 度量损失拟合 ϕ 优于 ℓ_2 ；把隐空间维度从 32 变到 512，下游成功率几乎不动，因此 256 更像是一个稳妥的默认值，而非需要精细调校的参数。

它的意义

概念上的转变很小，后果却很大：把双模拟看成任务之间的等价，而不只是状态之间的等价。一旦行为等价的「状态-目标」对映射到相同表示，目标就变得可组合，智能体也就能被指向一个示例、而非一张目标图像。作者还从理论上证明，学到的表示不仅足以支撑目标条件控制，也足以支撑任何由「仅依赖状态的奖励函数」定义的任务。

诚实地说，边界在于适用范围：结果都在仿真中，任务是带演示策略、离线缓冲区的操作类任务，类比也仍需来自同一个任务族。但作为一种交互方式，「给我看一个相似的任务」远比「给我一张精确的最终图像」更接近人们真正委派工作的方式——而这篇论文，是朝着支持这种交互的表示迈出的一个具体步子。