

NeurIPS 2023 | 不只是让视频「生成」，还要让运动「可控」

阿里巴巴与蚂蚁集团提出 VideoComposer：把视频拆成文本、空间、时间三类条件，用压缩视频里的运动向量为生成过程装上「方向盘」

这两年，图像生成的可控性进步得很快：给一张草图、一张深度图、一句提示词，模型就能画出结构、构图、风格都合你意的图片。但把同样的思路搬到视频上，事情立刻变难。视频比图像多了一根「时间轴」，不同片段的运动模式千差万别，而且每一帧都要和前后帧保持一致，不能各画各的。为图像设计的那套空间控制信号，搬到视频里并不能告诉模型「东西该怎么动」。

换句话说，图像生成解决的是「画什么」，而可控视频生成还要解决「怎么动」。来自阿里巴巴与蚂蚁集团、发表于 NeurIPS 2023 的 VideoComposer，正是冲着这个「运动可控」的问题去的。它的核心主张是：想控制一段视频，就得同时控制它的内容与运动，而不只是外观。

为此，论文把一段视频拆解成三类可以自由组合的条件——文本条件（textual）、空间条件（spatial）、时间条件（temporal）——用户给出其中任意一个子集，模型就重新「组合」出同时满足这些条件的视频。这就是标题里「Compositional（组合式）」的含义。而其中最关键的一步，是把压缩视频里本就存在的运动向量（motion vectors）拿来当作显式的时间控制信号。

论文：<https://arxiv.org/abs/2306.02018> · 项目主页：<https://videocomposer.github.io>
码：<https://github.com/damo-vilab/videocomposer> · 项目主




图 1 组合式视频生成总览。(a-c) VideoComposer 可以生成同时遵循文本、空间、时间条件（或其任意子集）的视频；(d) 更进一步，仅凭两笔手绘——红色笔画指定运动方向、白色笔画指定形状轮廓——模型就能合成符合预期运动与形状的视频。这张图先建立一个直觉：条件可以自由拼装，运动本身也变成了用户可编辑的一维。

问题：可控视频难在「运动」

过去一年里，扩散模型（diffusion model）让定制化图像生成变得相当可控。很自然地，人们希望把同样的能力延伸到视频。但视频有两个图像没有的麻烦：一是时间动态的多样性，同样一句「一只老虎在走」，可以慢走、快跑、左行、右行，运动模式空间极大；二是时序一致性，生成的每一帧都要在内容上与相邻帧连贯，否则画面会闪烁、跳变。

以往的定制化图像方法主要提供空间层面的控制，能规定「长什么样」，却没有一个原则性的手段去规定「随时间如何演变」。如果只是把草图、深度图这类为单帧设计的控制信号逐帧堆上去，又很容易破坏帧与帧之间的一致性。可控视频生成因此长期是个开放难题——缺的正是一个既能显式描述运动、又不牺牲一致性的接口。

方法：把视频当作「条件的组合」

VideoComposer 建立在视频潜在扩散模型（Video Latent Diffusion Model, VLDM）之上——先把视频压到一个低维潜在空间里去噪，以此换取效率。训练时，一段视频被分解为三类条件：文本条件、空间条件（如单帧图像、单张草图）、时间条件（如运动向量、深度序列、掩码序列、草图序列）。这些条件可以任意组合，模型学会「无论给到哪一组，都重新拼出满足全部条件的视频」。

下面这张架构图是理解全篇的钥匙。请重点看三条通路：所有「序列型」条件如何汇入同一个编码器、文本与风格如何单独注入、以及编码后的条件如何与噪声一起喂给扩散主干。




图 2 VideoComposer 总体架构。左侧：一段视频被分解为文本、空间、时间三类条件；各类序列条件统一送入 STC-encoder 编码，文本与风格则经 CLIP 注入。中部：编码后的条件在 Condition Fusion 中逐元素相加，再沿通道维与带噪潜变量拼接，共同引导视频潜在在扩散模型（VLDM）去噪，最后由解码器还原视频。右侧：STC-encoder 内部为两层 Conv2D + 池化捕捉空间结构，再接一个时序 Transformer 建模跨帧变化。它是把「多种异构条件」统一成一种表示、同时提升时序一致性的关键模块。

把这套流程拆开看，有三个设计值得记住。其一，统一接口：无论是运动向量、深度图、掩码还是草图序列，都先过同一个 Spatio-Temporal Condition 编码器（STC-encoder）——两层卷积加池化抓住局部空间结构，再由时序 Transformer 建模「跨帧如何变化」。这样既容纳了异构

条件，又因为显式建模了时间关系而改善了帧间一致性。其二，融合方式：编码后的各条件逐元素相加后，沿通道维与带噪潜变量拼接进入扩散网络；文本与风格则通过交叉注意力（cross-attention）注入。其三，两阶段训练：先做纯文本到视频（text-to-video）预训练，再做组合式训练；推理时用 DDIM 采样配合无分类器引导（classifier-free guidance）。

整个去噪目标其实就是标准的扩散损失，模型学习从带噪潜变量 z_t 中、在条件 c 与时间步 t 下预测所加噪声 ϵ ：

$$L_{\text{VLDM}} = E[\|\epsilon - \epsilon_{\theta}(z_t, c, t)\|^2] \quad (c \text{ 即上面那组可自由组合的条件})。$$

关键一招：把压缩视频的运动向量拿来当控制信号

VideoComposer 最有辨识度的想法，是给「运动」找到一个现成、廉价又显式的表示：运动向量。它本就存在于 H.264 这类压缩视频格式里，用来编码相邻帧之间的位移变化。论文把它抽取出来，作为一路时间条件——于是「东西往哪儿动、动多快」不再是模型自由发挥，而是用户可以直接规定的量。




图3 运动向量示例。红色小箭头叠加在原视频上，方向与长度分别表示每个局部区域的运动方向与幅度：帆船的帆面向上、水面向外扩散，越野车整体向右下行进。可以看到运动向量几乎剥离了静态外观，只保留「哪里在动、往哪动」的信息——这正是它适合当时间控制信号的原因。

效果：文本到视频不打折，条件控制更细

一个自然的担心是：加了这么多组合条件，会不会拖累最基本的文本到视频质量？论文在 MSR-VTT 基准上给出了答案。在零样本（zero-shot）设置下，VideoComposer 取得 FVD 580、CLIPSIM 0.2932，与当时领先的文本到视频方法相当；更值得注意的是，它比自己第一阶段的纯文本到视频预训练（FVD 803）还要好。也就是说，引入组合式的多条件控制不但没有牺牲文生视频质量，反而略有提升。

在定性层面，模型能忠实地跟随用户给的各类条件。下图展示的是「组合式图像到视频生成」：同一张单帧图像加一句文本可以生成一段视频，而再叠加一路时间条件（深度序列、掩码序列或运动向量）后，对随时间演变的结构就有了更细的控制。



图 4 组合式图像到视频生成。六个例子，每个上下两段：上段仅用「单帧图像 + 文本」生成，下段额外加入一路时间条件。对比每组上下两行可以看到，加入时间条件后，主体的运动与结构随时间的演变更贴合预期，同时画面主体身份保持一致。

运动控制最直观的演示，是仅凭手绘的简单笔画来「导演」一段视频。下图把 VideoComposer 与只能做粗略运动控制的 CogVideo 放在一起对比：给定一个方向箭头（甚至一段弧线），VideoComposer 就能让盒子沿指定方向平移、让老虎沿弧线行走，运动细粒度且灵活。



图 9 用手绘运动实现多样化运动控制。(a) CogVideo 只能做有限的运动控制；(b) VideoComposer 凭一段红色手绘笔画指定运动轨迹，就能让「盒子从左往右移动」「老虎沿弧线在草地上行走」，运动方向与路径都清晰可控。这说明运动向量 + STC-encoder 让「运动」真正成为一个可由用户手绘编辑的维度。

消融：运动向量与 STC-encoder 各自贡献了什么

论文用一个「运动控制误差」（motion-control error，越低越好）来量化这两个部件各自的作用。只用文本时误差为 4.03；把运动向量作为显式时间条件加入后，误差降到 2.67；再打开

STC-encoder，进一步降到 2.18。两个部件缺一不可：运动向量提供了时间信号，而 STC-encoder 让模型真正「用上」这个信号，从而锐化运动控制、增强帧间一致性。

表 1 运动可控性消融（motion-control error，越低越好）。运动向量与 STC-encoder 分别带来显著下降，二者叠加效果最好。

配置	运动控制误差 ↓
仅文本（text only）	4.03
+ 运动向量	2.67
+ 运动向量 + STC-encoder（完整）	2.18

定性消融也印证了这一点：去掉 STC-encoder 后，生成视频对指定时序结构的贴合度和帧间一致性都会变差。下图用红框标出了这些缺陷区域。




图 10 定性消融。三个代表性例子，第三、四行分别是「去掉 STC-encoder」与完整 VideoComposer 在同一文本 + 单路时间条件（草图/深度/运动向量）下的生成结果。红框标出缺陷区域：没有 STC-encoder 时，结构还原与帧间一致性明显更弱。

小结：让「运动」成为可编辑的一维

VideoComposer 的价值，不在于某个单点指标的刷新，而在于它把可控视频生成重新组织成了一个清晰的框架：把视频看作文本、空间、时间三类条件的组合，再用压缩视频里现成的运动向量为时间维度提供显式信号，配上统一的 STC-encoder 来消化异构条件、维持一致性。它训练于两个公开数据集——WebVid10M（约 10.3M 视频-字幕对）与 LAION-400M，支持文本、单帧图像、单张草图、运动向量、深度/掩码/草图序列、风格等 8 种以上条件的任意组合。

需要保持清醒的是，论文报告的是零样本文生视频指标与定性演示，运动可控性用的是在 1000 个字幕-视频对上定义的专门误差，而非某种通用的「运动正确率」；生成分辨率、时长与真实感也仍受底层 VLDM 能力限制。但它给出的方向是明确的：当我们把一段视频拆成条件、并单独给运动一个显式信号时，视频生成会变得可控得多——用户可以同时驾驭内容与运动，输入既可以是文本、草图、深度图，也可以只是两笔手绘。