

比较两个网络时,请改用累积量,而不是矩

一个可以直接替换的改动,让网络的双样本检验获得显著更高的统计功效、可靠的解析零分布,甚至在只观测到单个图时也能工作,而计算代价分文不增。

描述一个网络,最常用的办法是数它的小结构:有多少条边,有多少个楔形(wedge,即共享一个节点的两条边),有多少个三角形。这些子图或基元(motif)的密度,是网络分析里最基础的特征,从刻画脑连接组到比较生物相互作用网络,处处都在用。当我们需要区分两组网络时,自然的做法就是比较它们的基元密度,再问一句:这些差异在统计上显著吗?

然而这个自然的做法里藏着一个微妙的问题。原始的基元密度彼此高度纠缠:边多的网络往往楔形也多,楔形多的网络往往三角形也多。这种跨阶次的冗余,意味着这些密度所携带的独立信息远少于它们的数量所暗示的,于是任何直接建立在它们之上的检验都会被削弱,尤其是在只观测到少数几个图的时候。许多现有方法为了掩盖这一弱点,不得不从拟合出的模型中做代价高昂的重采样,仅仅是为了判断一个观测到的差异是否真实。

Gecia Bravo-Hermesdorff、Lee M. Gunderson、Pierre-Andre Maugis 与 Carey E. Priebe 的一篇论文(发表于 2023 年的 JMLR)指出,换一套更好的坐标就能解决这个问题。与其使用原始的图矩(graph moments,也就是基元密度),不如使用图累积量(graph cumulants):它是经典累积量为单个随机变量提供的均值、方差、偏度这一套量的组合类比。累积量剔除了低阶冗余,把它替换进去,就能把一个弱检验变成强检验,而你所计算的东西和付出的代价都不变。




图 1:图累积量与经典累积量一一对应。上面三行展示了前几个经典矩如何展开为累积量(均值,方差加均值平方,依此类推),做法是对一组点的所有划分求和。最下面一行把完全相同的组合配方用到子图上:一个图矩,通过对子图各条边的所有“尊重连通性”的划分求和,展开为图累积量。

论文:<https://arxiv.org/abs/2107.11403> (arXiv:2107.11403)。

问题:在没有标签的情况下比较网络

这里的场景是网络的双样本检验。你拿到两组图,每组都独立地采自某个未知分布,任务是判断这两个分布是否不同。棘手之处在于:节点没有共享的标签,没有任何对应关系能把第一个图里的“节点一”和第二个图里的“节点一”对上。你能用的,只有可交换、无标签的边的统计量,而这在实践中就意味着子图的计数。判断两个脑连接组是否来自同一群体,或者两个物种的基因相互作用网络在结构上是否不同,背后都是这一类问题。

既然唯一可用的信号就是子图计数,那么检验的好坏就完全取决于:如何把这些计数转化为特征。喂进去冗余的特征,检验就会因信息匮乏而变弱;你必须估计的协方差矩阵会变得病态,而显著性在不做大量重采样的情况下就很难确立。作者提出的问题是:仅仅换一套坐标,能不能让同样的子图计数给出一个更锐利、也更便宜的检验?

从图矩到图累积量

这里的直觉直接来自普通统计学。一个随机变量的二阶矩等于方差加均值平方;原始的矩把均值已经告诉你的东西又数了一遍。累积量正是那套去掉这种重叠的坐标,使得方差只度量真正新增的离散程度,三阶累积量只度量真正新增的偏斜。图累积量对子图做的是同一件事:每一个都刻画某个结构“超出其更小组成部分已能预测的那部分”的额外倾向。

具体来说,图累积量是通过一个组合式的 Mobius 变换从图矩得到的。要展开一个子图 g 的图矩,你要枚举 g 的边的每一个“尊重连通性”的划分,再对每个划分的各个块上的累积量求积再求和: $\mu_g = \sum_{\pi} \prod_{b \in \pi} \kappa_{g_b}$ 。把这个关系反解,就能从图矩得到累积量。这个变换纯粹是组合性的,因此几乎不增加任何代价。

两种检验随后都遵循同样的三步配方:选定一个最大子图阶次,估计每个样本的统计量,再度量两个估计之间的距离。这个距离是平方 Mahalanobis 距离,它用一个解析计算出的协方差矩阵为各坐标的差异加权: $d^2 = (k_A - k_B)^T (\Sigma_A + \Sigma_B)^{-1} (k_A - k_B)$ 。图矩检验与图累积量检验之间唯一的区别,就是代入这个公式的坐标不同。作者使用最多 $r = 3$ 条边的连通子图;计算协方差需要数到 $2r$ 条边的子图,因此两种检验的复杂度相同,都由 $O(n^\omega)$ 的矩阵运算主导。显著性是解析计算的,不需要从拟合模型中采样。

在合成网络上的正面对决

为了公平地比较两种检验,作者刻意设计了一场高难度的较量。他们让一个异质随机块模型(SBM,度分布不均但没有社区结构)对阵一个同配的随机块模型(有社区结构但度分布均匀),并固定边密度,使两者确实难以区分。每个样本包含 s 个图,每个图有 $n = 128$ 或 $n = 256$ 个节点,检验使用最多 $r = 3$ 条边的连通子图。




图 2:某一个设定下的 ROC 曲线(每个样本 $s = 4$ 个图, $n = 256$ 个节点, $r = 3$)。纵轴是真阳性率,横轴是假阳性率;曲线越贴近左上角越好,对角线代表随机猜测。图累积量的曲线明显位于图矩曲线之上,因此在常用的假阳性率 0.05 处,图累积量检验能更频繁地检测出差异。

这条 ROC 曲线让差距一眼可见:图累积量的曲线几乎立刻朝着“完美”的那个角攀升,而图矩的曲线则落在后面。但单个设定只是一个数据点。真正的考验在于:当每个样本里的图数减少时会发生什么,而这恰恰是实践者常常受困的区间。




图 3:ROC 曲线下面积(AUC)随每个样本的图数 s 变化的情况,分别对应 128 个节点和 256 个节点的图。纵轴被大幅拉伸,从随机猜测一直到完美。图累积量检验始终优于图矩检验,且 s 越小差距越大。图矩检验在 s 小于 4 时无定义(其协方差估计是奇异的),而图累积量检验一直工作到每个样本仅有单个图。

有两点特别醒目。第一,累积量在每一个样本量下都胜出,而且恰恰在数据最稀缺时优势最大。第二,图矩检验在每个样本少于四个图时干脆就不存在了:图太少时,它的协方差估计是奇异的,无法求逆。图累积量检验没有这堵墙;它在 $s = 1$ 时依然有定义、依然有用,让你能够比较两个单独观测到的网络,而这正是图矩检验连写都写不出来的区间。

一个可以信赖的零分布

更高的功效只是让一个检验好用的一半。要控制假阳性率,你还得知道当两个分布其实完全相同时,检验统计量会如何表现。当每个样本的图数非常大时,两种统计量都收敛到自由度为 5 的卡方(chi-squared)分布。实际要问的是:这个极限收敛得有多快。




图 6:零假设下每种检验统计量(平方 Mahalanobis 距离)的经验分布,与自由度为 5 的极限卡方分布(黑色曲线)对比,分别对应每个样本 4 个图和 8 个图。图累积量统计量即使在图数很少时也紧贴卡方曲线,而图矩统计量则明显偏移、形状走样,使得在小样本区间用图矩做解析误差控制并不可靠。

图累积量统计量即使每个样本只有寥寥几个图,也紧贴卡方曲线,于是实践者可以解析地设定阈值,并信赖由此得到的假阳性率。相比之下,图矩统计量在小样本时明显偏离,同样的解析阈值就会失准。这是累积量第二个、也更低调的优势:不只是更高的功效,还有一个在你真正需要时能按理论所言那样表现的零分布。

真实生物网络上的同一个故事

合成模型是一个可控的试验场,但更有意思的问题是:这一优势能否在杂乱的真实数据上保持下来。作者转向了 FunCoup 数据库中的基因相互作用网络,把拟南芥 (*Arabidopsis*, 约 1.3×10^4 个节点、 7.9×10^5 条边) 与小鼠 (*Mouse*, 约 1.4×10^4 个节点、 9.2×10^5 条边) 进行比较。关键在于,每一对网络都被调整到具有相同的边密度,因此一个朴素的低阶检验无法仅凭数边就把它它们分开;任何真实的差异都藏在更高阶的结构里。




图 4:随着最大子图阶次 r 增大,比较拟南芥 (Arabidopsis) 与小鼠 (Mouse) 的基因相互作用网络。在 $r = 1$ 时(左),两个网络边密度相同,因此两种检验都无法区分。在 $r = 2$ 时(中),图累积量检验已经领先。在 $r = 3$ 时(右),图累积量检验继续提升,而图矩检验则过拟合、表现变差。每个样本包含 $s = 4$ 个图。

这个关于子图阶次的消融最清楚地说明了坐标为什么重要。加入更多子图,给两种检验的都是严格更多的信息,可图矩检验却把它浪费掉了:那些冗余、相关的特征使它过拟合,精度从 $r = 2$ 到 $r = 3$ 反而倒退。而工作在去相关坐标下的图累积量检验,把每一个额外的阶次都转化成了真实的收益。只有当你的特征真能用得上时,更多的信息才有帮助。




图 5:在 $r = 3$ 下,随着每个样本的图数从 4 增加到 16,比较人类 (Human, 约 1.6×10^4 个节点、 13.9×10^5 条边) 与大鼠 (Rat, 约 1.1×10^4 个节点、 9.0×10^5 条边) 的基因相互作用网络。图累积量检验再次占优,在仅有 4 个图时差距最大,而随着图数增加,两种检验都趋向完美。

人类对大鼠的比较,在真实数据上重演了合成实验的发现:图累积量全面优于图矩,而且恰恰在每个样本的图数最少时优势最大。当图更多时,两种检验最终都会在接近完美处饱和,但在最要紧的数据稀缺区间,已经能工作的是图累积量检验。

结论

这条建议干脆而具体。每当你要通过子图或基元密度来分析网络时,在比较之前多做一步组合变换,把它们转成图累积量。你在计算代价上分文不损,却一次得到三样东西:显著更高的统计功

效、一个用于解析地控制误差率的可靠卡方零分布,以及即使只有单个观测网络也能下结论的能力。

表 1:图矩与图累积量的逐项对比。

性质	图矩 (moments)	图累积量 (cumulants)
每个样本的最少图数 s	4(更少则失效)	1
统计功效 (AUC)	较低	更高,小 s 时尤甚
解析卡方零分布	小 s 时偏离	小 s 时仍准确
加入更多子图阶次	过拟合、变差	稳步提升
计算复杂度	$O(n^\omega)$	$O(n^\omega)$,完全相同

有几点提醒能让结论保持诚实。实验使用最多 $r = 3$ 条边的连通子图,框架假设边是可交换、无标签的,因此它针对的是无标签的双样本场景,而不是已知节点对应关系的问题。但在这一范围之内,信息很清晰:图累积量是比较网络局部结构时更自然的第一层特征,而切换到它本质上是免费的。比较两个网络时,请伸手去拿累积量,而不是矩。