

NeurIPS 2022 | 三百万张卫星雷达图，能不能省下专家标注的力气？

夏威夷大学团队用自监督对比学习读取 Sentinel-1 海面雷达影像，并诚实报告了它的边界

欧洲空间局的 Sentinel-1 雷达卫星有一个很省心的本事：它用 C 波段合成孔径雷达（SAR）成像，不靠可见光，因此白天黑夜、有云无云都能拍。它每个月能从全球开阔海面上获取近 120,000 张「波模式」（Wave mode，WV）影像，每张覆盖 20 公里 × 20 公里、分辨率 5 米。这些图像里藏着风、湍流、海洋锋面、生物膜等一系列大气与海面现象，是研究海气相互作用和边界层动力学的宝库。

问题在于，机器要「读懂」这些雷达图并不容易。深度学习方法离不开带标签的训练数据，而 SAR 图像的标注只能由受过训练的专家完成，标到几千张就已经是极限。标签稀缺，一直是把这批海量影像用起来的最大瓶颈。

夏威夷大学马诺阿分校（University of Hawai'i at Mānoa）的 Yannik Glaser、Peter Sadowski 与 Justin E. Stopa 在 NeurIPS 2022 的 ML4PS 工作坊上提出一个直接的问题：既然带标签的数据这么少，能不能让模型先在三百万张无标签的 Sentinel-1 影像上「自学」表征，再用少量标注去微调？这正是自监督对比学习（self-supervised contrastive learning）擅长的场景。




图 1 五类典型 SAR 海面影像（每张 20 × 20 km），按大气稳定度从不稳定到稳定排列：(a) 强不稳定的微尺度对流单体（MC）；(b) 对流单体与风条纹共存（MC/WS）；(c) 近中性的风条纹（WS）；(d) 稳定、几乎无变化的海面（NV）；(e) 生物表面膜，在本研究中归为「其他」（OT）。这几类现象常常在同一片海面同时出现，正是本文改用多标签标注的原因。

论文地址：https://ml4physicalsciences.github.io/2022/files/NeurIPS_ML4PS_2022_158.pdf

问题：标签稀缺，而且旧数据集本身是「偏」的

此前，Stopa 等人用 Wang 等人的卷积网络模型（下文记作 CmWV）把 SAR 图像分成三类海面稳定度状态：不稳定、近中性、稳定。这套做法有两个结构性缺陷。其一，训练集是「挑」出来的，每一类只选了典型样本，并不能代表真实的 WV 影像分布。其二，标注协议规定每张图

只能有一个标签，可现实中风条纹与对流单体等多种现象往往同时出现在同一张图里。结果就是一个不具代表性的数据集。

本文先从数据入手，重建了一个更可信的基准：约 2300 张随机采样的 WV 影像，由多位专家标注并形成共识标签，且允许多标签共存。任务聚焦四类——微尺度对流单体（MC）、风条纹（WS）、可忽略的大气变化（NV）、以及其他现象（OT）。其中 NV 定义为「不存在 WS、MC 及任何其他现象」，OT 则是「没有 WS 和 MC，但存在其他被标注的现象」。整个数据集按 60/20/20 分为训练、验证与留出测试集。

方法：先用 SwAV 自学表征，再用三种协议评估它

自监督对比学习的核心思路，是让同一张图的不同增强视图在表征空间里靠得更近，而不同图片彼此推远，整个过程不需要人工标签。本文采用的是 SwAV（Swapping Assignments between multiple Views）框架。它的巧妙之处在于用一个「聚类预测」的代理任务：把表征分配到若干聚类中心，再让网络从一个视图去预测另一个视图的聚类归属。相比 SimCLR 需要极大 batch，SwAV 通过把过往批次的聚类分配存进一个队列，可以在较小的 batch 下训练，对算力更友好。

作者用一个标准的 ResNet-50 作为骨干网络，以 batch size 1024、分布在 8 张 NVIDIA V100 32GB GPU 上、队列长度 16 个批次、1000 个聚类中心的配置训练 SwAV，因时间与算力所限在 65 个 epoch、约 10 天后停止。微调本身在单张 V100 GPU 上以 batch size 128 进行。得到无监督表征后，如何衡量它到底好不好？本文用了三种由浅入深的下游评估协议，来把「预训练本身的价值」与「微调带来的价值」区分开：

第一，加权 k 近邻（kNN）分类：直接在表征上按欧氏距离做最近邻投票，只有一个超参数 k，几乎不需要调参，是衡量表征质量最干净的探针。第二，线性评估（linear evaluation）：冻结整个 ResNet，只在表征之上训练一层 softmax 分类器。第三，端到端微调（fine-tuning）：解冻全部权重，在标注数据上整体训练。后两种协议都分别用 ImageNet 预训练权重和 SwAV 权重各跑一遍，以便对照。

结果：都大幅超越旧模型，但自监督并没有赢过 ImageNet

结果可以从两个角度看。先看表征本身：在不微调主干的两种协议里（kNN 与线性评估），SwAV 的自监督权重确实比 ImageNet 权重略好——kNN 上 0.864 对 0.859，线性评估上 0.841 对 0.836。这说明当骨干被冻住时，在海量 SAR 影像上自学的表征确实握有一点优势。

表 1(a) 不同评估协议下的 micro 平均 AUROC。评估协议：kNN、Linear（线性评估）、Fine-tune（端到端微调）。骨干冻结时（kNN、Linear）SwAV 权重略占优；一旦端到端微调，ImageNet 权重反而略高。所有差距都很小。

评估协议	Contrastive (SwAV) 权重	ImageNet 权重
kNN	0.864	0.859
Linear	0.841	0.836

Fine-tune	0.929	0.931
-----------	-------	-------

但真正拿来用的是微调后的模型，而这里的对比恰好反转：一旦解冻全部权重做端到端微调，ImageNet 初始化反而略微领先（0.931 对 0.929），最佳的 micro 平均 AUROC 约为 0.93。换句话说，自监督预训练的那点优势，在整个网络都被允许自适应之后就消失了。

不过，跟旧模型比，进步是实打实的。在两类最难的大气现象上，无论用哪种新权重都显著超过 CmWV：风条纹（WS）从 CmWV 的 0.727 提升到 0.831–0.850，对流单体（MC）从 0.793 提升到 0.872–0.873。而在稳定海面（NV）这一类上，三种模型旗鼓相当，都在 0.95 上下。由于新旧数据集的标注标准和类别不同，OT 类无法与 CmWV 直接比较。

表 1(b) 微调后模型在各单独类别上的 micro 平均 AUROC。SwAV 与 ImageNet 为两种权重初始化，CmWV 为旧的最先进模型。在最难 WS 与 MC 两类上，新模型大幅超越 CmWV；NV 类三者接近；OT 类因标注口径不同无法与 CmWV 比较（记为 -）。

模型	MC	WS	NV	OT
SwAV	0.872	0.831	0.952	0.910
ImageNet	0.873	0.850	0.960	0.905
CmWV	0.793	0.727	0.946	-

结论：一次诚实的初步探索

这篇论文最值得称道的地方，是它的诚实。作者没有把结论包装成「自监督大获全胜」，而是明确写道：在这次初步实验里，自监督对比学习相比「从自然图像迁移特征」这一更省事的标准做法，改进是边际的甚至并不存在，却要付出多得多的算力代价。

但这并不否定自监督的潜力。作者强调这些只是初步结果：更长的训练时间、更充分的超参数搜索、以及为遥感数据量身设计的代理任务，都还没来得及探索，而这些都可能是自监督真正发挥作用的关键。对于标注只能靠专家、数据却极其充裕的遥感领域来说，能利用海量无标签影像的半监督/自监督路线依然极具价值。

而对下游应用而言，一个更直接的收获是：无论走自监督还是 ImageNet 迁移这条路，检测精度都比旧的最先进模型有了大幅跃升。对于依赖 SAR 影像做海面稳定度自动分析的科学与环境任务，一个更可靠的模型意味着更可信的自动化流程——这一点，当下就能兑现。