

没有重置，也没有示范：机器人如何完全自主地学会技能

IBC 用一个会自动退场的辅助智能体，加上一套基于最优传输的课程，让强化学习真正做到无需人工干预（ICML 2023）

几乎每一个强化学习的成功案例，背后都悄悄依赖着一个现实世界并不提供的便利：重置（reset）。在仿真器里，一个 episode 一结束，环境就会瞬间回到固定的初始状态，随时准备下一次尝试。可是在真实机器人上，这个“瞬间复位”意味着有人走过去把积木重新摆好、跑一段写死的归位程序，或者搭一套专门的机械装置，既慢又贵，和“自主”二字恰恰相反。

自主强化学习（Autonomous RL, ARL）想要抛掉重置这个假设，让智能体从一条不间断的经验流中持续学习。问题在于，现有的大多数自主方法只是把一根拐杖换成了另一根：它们依赖示范（demonstrations），比如专家轨迹，或者一小批“感兴趣状态”的样例，用来引导课程，或者用来定义智能体该回到哪里。而一旦关键交互本身非常稀疏、几乎不可能碰巧发生，这些依赖示范的方法就会力不从心。

来自首尔国立大学、发表于 ICML 2023 的一篇工作，追问的正是这样一个问题：智能体能不能真正从零学起，既不重置，也不用任何示范？他们提出的方法叫 IBC（Implicit and Bidirectional Curriculum，隐式与双向课程），让智能体仅凭自己收集到的经验，就能为自己制造出训练信号。这个想法由两个部件构成，示意如下图。




图 1. IBC 为前向（forward）和后向（backward）两类 episode 同时生成一套双向课程。训练早期，辅助智能体（蓝色）不断把“主智能体”（红色）带回到有用的起始状态；随着前向智能体越来越强，辅助智能体被触发的次数越来越少，直到收敛时只剩下前向 episode。

论文：<https://arxiv.org/abs/2305.09943>

代码：https://github.com/snu-larr/ibc_official

为什么“无示范的自主强化学习”这么难

在标准的分幕（episodic）设定里，每次尝试都从同一个地方出发，学习因此是稳定的。可一旦去掉重置，脚下的地面就开始移动。在策略收敛之前，一个失败了的前向智能体会径直走偏，被扔在某个任意的状态里。下一次尝试便从这个任意状态开始，于是智能体实际上是在一个不断漂移、往往毫无用处的起点上练习。仅凭这一点，朴素的无重置学习就会崩溃。

以往的无重置方法各有各的补救办法，但都在悄悄地把人力重新请回来。有的仍然需要偶尔的人工重置；有的只有在关键交互碰巧发生时才管用。与本文最直接可比的两个方法 VaPRL 和 MEDAL，都依赖示范数据：VaPRL 用它来播下子目标课程的种子，MEDAL 用它来定义后向智能体应当返回的状态分布。这项工作的目标，是让智能体只用它自己见过的东西，就能为自己提供锚点，也为自己提供课程。

方法：两套课程，一个自主循环

IBC 在训练全程中交替扮演两个角色。前向智能体去完成任务；辅助智能体则把系统带回到一组目标初始状态，好让前向智能体再试一次。两者都是普通的 Soft Actor-Critic（SAC）策略，各自拥有独立的回放缓冲区（replay buffer）。真正让这个循环变得自主的，是这两个角色如何被调度，以及它们的目标如何被挑选。

一套会自己退场的隐式课程

第一个想法刻意地简单：辅助智能体只在前向智能体失败时才被激活。训练早期，前向智能体经常失败，于是辅助智能体频繁介入，承担了把系统带回良好起点的大部分工作。随着前向智能体越来越强，它失败得越来越少，辅助智能体的介入也就越来越稀疏。没有人手工去安排这个“淡出”过程，它是从激活规则本身自然涌现出来的一套隐式课程。到训练结束时，辅助智能体实际上已经消失，论文也证实：一旦前向智能体训练充分，辅助智能体所占的 episode 比例就会趋向于零。

一套来自最优传输的显式课程

在这个会淡出的“帮手”之上，还叠着一套显式的、双向的目标课程，而示范数据本来正是要用在这里的。IBC 不用专家数据，而是从自己的回放缓冲区里采样候选状态，把课程生成表述成一个最优传输（optimal transport）问题：一个 Wasserstein Barycenter，再加上一个基于价值的偏置项，好让那些既靠近目标、当前又够得着的状态优先被选中。由此得到的分配问题被当作二部图匹配（bipartite matching），用最小费用最大流（Minimum Cost Maximum Flow）算法求解，为前向智能体产出一组中间目标，也为辅助智能体产出配套的一组。对目标条件价值函数的一个 Lipschitz 连续性假设，让方法可以把真实目标松弛成一个可解的下界；一个多样性约束则避免选出的目标塌缩到同一条轨迹上。

实际的收益相当惊人。为了指定智能体应当瞄准的目标分布，IBC 只需要约 10 个示例状态，有时甚至只要一个，而不是以往自主方法所假设的成千上万条示范转移。图 3 展示了训练过程中

的效果：前向智能体的初始状态分布一开始是散乱的，在课程的牵引下被温柔地拉动，直到聚拢到真正重要的那些状态附近。




图 3. 训练过程中前向智能体初始状态分布的变化。在课程的引导下，它从早期散开的分布，逐步移动到那一小组目标状态附近，全程只用了少数几个示例状态，而非示范数据。

它真的管用吗？

作者在 6 个稀疏奖励环境上评测 IBC，覆盖操作（manipulation）与运动控制（locomotion）两类任务。其中两个，Tabletop Manipulation 和 Sawyer Door，来自自主强化学习的成熟基准 EARL；另外 4 个，Fetch Pick&Place、Fetch Push、Fetch Reach 和 Point-U-Maze，是标准的基于 MuJoCo 的 Gym 任务，被改造到无重置设定下。评测遵循 EARL 协议：智能体只被生成一次，之后持续交互，极少被重置，性能以部署策略的成功率衡量，并在 5 个随机种子上取平均。

最亮眼的结果是：IBC 在这些环境上取得了当前最好（state-of-the-art）的成功率，而且一条示范都没用。它超过了 VaPRL 和 MEDAL 这两个实实在在用了近专家级示范数据的强基线，并且在许多任务上，它的成功率已经逼近 oracle，也就是在轻松的、可完全重置的分幕设定下训练出来的标准强化学习智能体。依赖示范的基线在 Fetch 系列环境上跌得最狠，因为那里关键交互稀疏，评测目标又是散布在一整片区域上，而不是几个离散的点。把 VaPRL 的示范拿掉以做公平比较，它会明显变差，这更凸显了以往方法对那份额外数据的依赖有多深。




图 4. 某个代表性环境上训练过程中的评测成功率。分幕 oracle（灰色虚线）在轻松的可重置设定下学习，标示了性能上界；IBC（蓝色）在无重置、无示范的条件下攀升到接近满分的成功率，而无示范的基线（底部平坦的曲线）始终没有起色。阴影为 5 个种子上的标准差。

到底是哪一部分在起作用？

一项消融实验把方法拆开，检验两个部件是否都名副其实。去掉双向课程，会带来一致的性能下降；在此基础上再去掉辅助智能体（这时 IBC 就退化成朴素的无重置强化学习），性能会下降得更多，尤其是在物体操作类任务上。这种影响也和任务有关：在状态空间简单的 Tabletop Manipulation 里，双向课程带来的帮助很有限；而在起点本就离目标很远的 Point-U-Maze 里，辅助智能体的作用也相对较小。但总体而言，无论拿掉哪一个部件，效果都会变差。




图 7. 某个代表性环境上的消融。完整的 IBC（蓝色）冲到上限；去掉双向课程（橙色）后学习更慢、更低；再去掉辅助智能体、只剩朴素无重置强化学习（绿色）后则彻底崩掉。两个部件缺一不可。

IBC 改变了什么

下面这张表把 IBC 和它最接近的邻居们并排放在一起。它的与众不同之处，恰恰在于那一列空白：据作者所知，它是第一个既不需要人工重置、也不需要示范，就能稳定学会这些任务，同时还追平了依赖专家数据方法的算法。

表 1. 在自主强化学习想要消除的两项成本上，IBC 与其他方法的对比。

方法	需要示范	需要人工重置
Oracle RL (分幕)	否	是 (每个 episode)
VaPRL	是	否
MEDAL	是	否
IBC (本文)	否	否

这套配方值得再复述一遍，因为它实在轻巧：拿两个 SAC 智能体，一个前向、一个辅助；只在前向智能体失败时才激活辅助智能体，它的帮助便会作为一套隐式课程自动淡出；再给两个智能体喂入由最优传输匹配从它们已经访问过的状态里挑出的中间目标，就得到了一套显式的双向课程，只需要一小把示例状态，而不是一整个示范数据集。

该讲清楚的局限，作者也讲得很直白。IBC 假设环境是可逆的（遍历性的），这样辅助智能体原则上才能撤销前向智能体做过的事；不可逆的错误不在讨论范围内。它同样仍然需要人来指定一个稀疏奖励。作者把一个无奖励（reward-free）的变体，也就是他们用 C-learning 实验所暗示的方向，视为自然的下一步。即便有这些限制，IBC 依然干净利落地证明了一件事：智能体可以靠自己学会操作与运动控制技能，用它已经拥有的经验，为自己生成所需要的课程。