

ICML 2022 | 逻辑回归只能解一半：不可知地学半空间到底难在哪

UIUC、MIT、Google Research、CMU 合作，证明逻辑回归被卡在 $\sqrt{\text{OPT}}$ 的紧下界，并用「逻辑回归 + 一步感知机」的两阶段算法恢复近最优精度

逻辑回归 (logistic regression) 大概是被部署得最多的分类算法：一行调用、一个凸优化，几乎所有人的第一反应都是它。但一个很基础的问题一直没有说清楚——当标签被噪声污染时，逻辑回归到底学得有多好？

这篇 ICML 2022 的论文把镜头对准了学习理论里最经典的对象：不可知地学习齐次半空间 (agnostically learning homogeneous halfspaces)。所谓「半空间」就是一个过原点的线性分类器；所谓「不可知」，可以理解成有一个对手被允许翻转 OPT 比例的标签，把原本线性可分的数据弄脏。我们能指望的最好结果，就是把零一错误率做到 OPT 附近——也就是那个最优线性分类器本身的错误率。

在此之前，理论界对逻辑回归的评价夹在两个界之间，中间是一道很宽的缝：一方面有下界说，任何凸代理损失 (convex surrogate loss) 都别想比 $\Omega(\text{OPT})$ 更好；另一方面已知的上界只保证逻辑回归能做到 $\tilde{O}(\sqrt{\text{OPT}})$ 。到底哪个界才是逻辑回归的真实速率？本文把这道缝彻底合上了，并顺手给出一个便宜得惊人的修复方案。

论文：<https://arxiv.org/abs/2201.13419> (ICML 2022)

背景：什么叫「不可知地学半空间」

设定很干净。我们从一个未知分布里拿到一批「特征-标签」样本，目标是找一个线性分类器，让它的零一错误率尽量接近 OPT —— OPT 是所有齐次半空间里能达到的最小零一错误率。等价地说，把一份本来完美线性可分的数据交给对手，允许它翻转其中 OPT 比例的标签，我们要在这份被污染的数据上尽量逼近原来的那条分界线。

逻辑回归是这里最自然的启发式做法：它最小化一个光滑的凸损失，好优化、好分析。麻烦在于它的最坏情况相当吓人——Ben-David 等人 (2012) 早就指出，在对手精心构造的分布上，逻辑回归的最优解可能错到 $1-\text{OPT}$ ，几乎全错。为了排除这种病态，理论界通常把注意力收缩到「良态分布」(well-behaved distributions，比如各向同性的对数凹分布) 上，那里能证明强得多的保证。但即便加了这层假设，逻辑回归在良态分布上究竟是 OPT 量级还是 $\sqrt{\text{OPT}}$ 量级，一直悬而未决——而这恰恰决定了我们该不该放心地推荐它。

坏消息：逻辑回归被卡在 $\sqrt{\text{OPT}}$ ，而且是紧的

论文的第一个结果是一个下界，回答了「哪个界是真的」这个问题：即使在良态分布上，逻辑回归也逃不出 $\sqrt{\text{OPT}}$ 。作者的做法不是抽象论证，而是亲手造了一个反例。下图就是这个分布 Q ——一个二维、各向同性、完全满足良态条件的分布，却能稳稳地把逻辑回归难住。




图 1 论文构造的反例分布 Q （二维、各向同性、well-behaved）。单位圆盘上铺着一个「背景」成分 Q_4 ，标签由 x_1 的符号决定（红色为 +1，蓝色为 -1），所以真正的最优半空间就是竖直的纵轴。四个带阴影的小方块 Q_1 、 Q_2 、 Q_3 精心放置了一小撮带噪声的样本：它们合计只占 OPT 比例，却足以把逻辑回归的最优解从纵轴「拽偏」，最终逼出 $\sqrt{\text{OPT}}$ 量级的零一错误。

图里的关键在于「杠杆」。背景 Q_4 让整个分布看起来规规矩矩，最优分界线明明就是那条纵轴；但角落里那几个小方块虽然质量很轻（只有 OPT 那么多），位置却选得极巧，逻辑损失在优化时会被它们过度「拉扯」，最终收敛到一个偏离纵轴的方向。作者证明，在这个 Q 上，逻辑风险的全局最小解 w^* 的零一错误至少是 $\sqrt{\text{OPT}}/(60\pi)$ （当 OPT 足够小，论文的构造要求 $\text{OPT} \leq 1/100$ ）。这个 $\sqrt{\text{OPT}}$ 正好匹配 Frei 等人已知的 $\tilde{O}(\sqrt{\text{OPT}})$ 上界——也就是说，逻辑回归单打独斗时， $\sqrt{\text{OPT}}$ 就是它的真实速率，一分都快不了。这就是所谓「把缝合上」的确切含义。

什么时候逻辑回归本来就够用：径向 Lipschitz 条件

既然 $\sqrt{\text{OPT}}$ 的病根来自密度在不同半径上的不均匀「拉扯」，一个自然的问题是：加上什么条件能让这种拉扯消失？论文给出的答案很干净——密度的径向 Lipschitz 性（radial Lipschitzness）。直观地说，只要特征密度沿半径方向变化得足够平缓，逻辑回归就不会被角落里的小噪声带偏，它自己就能直接达到近最优的 $\tilde{O}(\text{OPT})$ 速率。

更精细地看，论文的上界写成 $O((1+C_k)\cdot \text{OPT})$ ，其中常数 C_k 是径向 Lipschitz 模的一个积分；密度沿半径越平滑， C_k 越小，当密度径向对称时它直接消失。同一套上界论证还很「通用」：它既能作为特例复现出此前 $\tilde{O}(\sqrt{\text{OPT}})$ 的结论，也同样适用于 hinge 损失——最后这一点，正是下面那个两阶段算法能成立的关键。

便宜的修复：逻辑回归 + 「一步感知机」

径向 Lipschitz 毕竟是个额外假设。论文最实用的贡献，是给出一个不需要任何此类假设、对所有良态分布都成立的两阶段算法，而且简单到几乎是「逻辑回归再走一步」。

第一阶段就是逻辑回归本身：在半径为 $1/\sqrt{\epsilon}$ 的球里对逻辑风险做投影梯度下降，拿到一个方向 v 。由前面的分析， v 与真实方向 $\bar{u}$ 的夹角是 $\tilde{O}(\sqrt{\text{OPT}+\epsilon})$ ——方向大致对了，但零一错误还停在 $\sqrt{\text{OPT}}$ 。第二阶段接着用 hinge 损失做投影随机梯度下降，其更新规则恰好就是经典的感知机（perceptron）：从 v 这个「热启动」出发，把优化限制在一个有界的区域里继续磨。这一步把夹角进一步收紧，零一错误随之被压到 OPT 量级。

省下来的代价才是真正惊人的地方。此前能做到 $O(\text{OPT}+\epsilon)$ 的算法，要在二分搜索 OPT 的同时求解 $O(\log(1/\text{OPT}))$ 个最小化问题；而这里只需要两步凸优化——逻辑回归加一步感知机。样本复杂度也从此前非凸方法的 $\tilde{O}(d/\epsilon^4)$ 降到 $\tilde{O}(d/\epsilon^2)$ ，是一个平方级的改进。

表 1 两阶段算法与此前非凸方法的对比：错误率相当，但凸优化次数与样本复杂度都大幅下降。

方法	零一错误	凸优化次数	样本复杂度
此前非凸方法	$O(\text{OPT} + \epsilon)$	$O(\log(1/\text{OPT}))$	$\tilde{O}(d/\epsilon^4)$
本文两阶段	$O(\text{OPT} + \epsilon)$	2	$\tilde{O}(d/\epsilon^2)$

一张表看清各种速率

把上面的结果并排放在一起，逻辑回归「差在哪、怎么补」就一目了然：单靠逻辑回归卡在 $\sqrt{\text{OPT}}$ ；加径向 Lipschitz，或者接一步感知机，都能回到 OPT 量级。

表 2 不同设定下的零一错误速率。**OPT** 是任意线性分类器能达到的最优错误率；良态分布下逻辑回归只能到 $\sqrt{\text{OPT}}$ ，且这一速率被本文的反例证明是紧的。

设定 / 方法	零一错误率
最优线性分类器（基准）	OPT
逻辑回归，一般良态分布（已知上界）	$\tilde{O}(\sqrt{\text{OPT}})$
逻辑回归在反例 Q 上（本文下界）	$\geq \sqrt{\text{OPT}}/(60\pi)$
逻辑回归 + 径向 Lipschitz	$\tilde{O}(\text{OPT})$
两阶段算法，有界分布	$O(\text{OPT} + \epsilon)$
两阶段算法，次指数分布	$O(\text{OPT} \cdot \ln(1/\text{OPT}) + \epsilon)$

小结与边界

这篇论文留下两句可以带走的话。第一，对不可知地学半空间来说，逻辑回归自己只能到 $\sqrt{\text{OPT}}$ ，而且这个速率是紧的——论文用一个明确的良态分布把它逼到了墙角。第二，补救的成本低得出奇：从逻辑回归的解热启动，追加一步感知机式的凸最小化，就能在任意良态分布上把保证提升到近最优的 $\tilde{O}(\text{OPT})$ ，比此前任何方法都更简单、样本效率也更好。顺带地，论文还点明了径向 Lipschitz 是让逻辑回归「本来就够用」的那个自然条件。

需要说明边界：这是一篇纯理论工作，结论是带明确常数的定理，而不是数据集上的实验曲线；所有保证都建立在「良态分布」这一族假设之上（各向同性、有界或次指数、满足软间隔与正则条件）。反例分布 Q 也是精心构造的二维实例，用来证明下界，而非真实数据。换句话说，它回答的是「逻辑回归在理论上能到多好、缺的那一步怎么补」，把这份直觉带回到实际的带噪线性分类任务里，往往是最有价值的读法。