

人人都在用的优化器，终于被证明会收敛

Ruinan Jin、Yu Xing、Xingkang He 证明了带静态动量的 mSGD 与标准 AdaGrad 在非凸损失上的几乎必然收敛 (arXiv 2201.11204)

你训练过的几乎每一个深度模型，背后的优化器其实都没有被完全证明过。普通的随机梯度下降 (SGD) 已经研究得比较透彻，但真正被大家频繁使用的两个变体，动量 SGD (mSGD) 和 AdaGrad，理论基础反而更薄弱。动量通过混入过去梯度的滑动平均来平滑更新方向；AdaGrad 则用累积的梯度大小来自适应地缩放每一步的步长。二者在实践中都稳定地优于原始 SGD，但直到最近，它们在理论上都只得到了部分的证明。

这个缺口并不是学术上的吹毛求疵。对于描述真实神经网络的光滑、且可能非凸的损失函数，这两种方法现有的最强结果也只能保证较弱形式的收敛：要么某个子序列 (subsequence) 最终稳定下来，要么迭代的时间平均 (time average) 稳定下来。这两种说法都没有保证你实际跑出来的那条轨迹会趋近于一个平稳点。而那种更强的、对单次运行成立、以概率 1 成立的保证，恰恰是每个人在点下「开始训练」时默认相信的东西。

这篇论文把这个缺口补上了一大半。作者直接针对大家真正使用的静态动量系数，以及真正部署的标准范数形式 (norm-form) AdaGrad，证明了即使损失非凸，两种方法也几乎必然收敛到一个由平稳点组成的连通集合。他们还量化了 mSGD 到达那里的速度，把「动量能加速 SGD」这条经验之谈，变成了一个可以从公式里直接读出来的结论。

论文链接：<https://arxiv.org/abs/2201.11204>

我们在跑的，和我们能证明的，之间的落差

教科书里的分析和真实实践之间，隔着两处错位。第一，大多数关于动量方法的收敛证明都要求动量系数随时间逐渐趋于零，而实践者会把它固定在一个静态值上，比如 0.9，然后就再也不去动它。第二，文献里的 AdaGrad 结果往往针对的是一个修改过的算法版本，而不是优化器里真正在用的标准范数更新。除此之外，经典证明还依赖一些非凸学习会违反的假设：损失的凸性、迭代点停留在有界区域内，或者梯度噪声的幅度在整个参数空间上被一致地上界约束。

最后那个假设比看上去更脆弱。对梯度噪声施加一致上界，对于二次或三次这样再普通不过的目标函数都会失效，因为它们的梯度会随着参数远离原点而无限增大。任何需要这个假设的理论，其实已经悄悄地把它声称要描述的大片损失曲面排除在外了。这篇论文瞄准的损失类别是刻意放宽的：非负、连续可微、梯度满足 Lipschitz 条件的函数，允许非凸，也允许存在许多彼此分离的临界点。




图 1. 论文明确点名、并被其假设覆盖的两个非凸目标：周期函数 $\sin^2(x)$ 与四次多项式 $(x-1)(x-2)(x-3)(x-4)$ 。二者都有多个平稳点（红色），这正是收敛定理必须处理的多谷结构。

工具：把优化器看成一个带噪声的动力系统

整套分析建立在随机逼近（stochastic approximation）之上，这是一个经典思想：带噪声的迭代更新可以被看作某个连续动力系统在离散时间上的近似。从这个角度看，mSGD 和 AdaGrad 不只是更新规则，而是一条应当渐近地跟随梯度流、朝平稳点集合前进的轨迹。证明的任务，就是说明噪声在长期中不会把这条轨迹从梯度流上甩出去。

有两个要件让这件事成为可能。一个稳定性引理（stability lemma）保证整个训练过程中期望损失始终有界，因此迭代点不会跑向无穷。另一个是一个放宽的噪声条件，它用一个更温和的界替换了那个脆弱的一致上界：梯度方差可以增长，但只被允许与损失值本身成比例，形式为 $E\|\nabla g(\theta) - \nabla g(\theta, \xi)\|^2 \leq M(1 + g(\theta))$ 。损失大的地方，容忍更多噪声；损失小、需要精度的地方，噪声被收紧。这恰恰是二次或三次目标所需要、而一致上界给不了的行为。

对于 mSGD，随机性由一个递减步长来驯服，它满足经典的 Robbins-Monro 条件，即步长之和发散、而其平方之和有限，最典型的取法是 $\epsilon_n = 1/n$ 。关键在于，动量系数保持静态，让步长去做这件工作，这与方法被使用的方式一致，而不是与它通常被分析的方式一致。

结果一：动量 SGD 几乎必然收敛

第一个主定理指出，mSGD 的迭代以概率 1 收敛到损失的一个由平稳点组成的连通集合。当这个集合退化为单个点时，迭代就直接收敛到那个点。这确实是一个比它所取代的子序列收敛结果更强的论断：不是某个精心挑选的子序列表现良好，而是整条轨迹表现良好，并且对训练噪声的几乎每一次实现都成立。

为什么动量能加速，被写成了精确的形式

除了收敛，论文还量化了速率。mSGD 的期望梯度平方范数以指数量级衰减，其指数与累积步长除以 $(1-\alpha)^2$ 成正比。动量系数完全通过这个 $(1-\alpha)^2$ 项进入公式，这给了我们一个清晰的方式去看它的作用：乘子 $1/(1-\alpha)^2$ 位于指数前面，因此更大的 α 会让指数更大、让这个界衰减得更快。

两个极限把整幅图景钉死。取 $\alpha = 0$ ，乘子等于 1：速率恰好退化为已知的普通 SGD 速率，这是一个令人安心的一致性检验。把 α 推向 1，乘子会无界增长，对应的时间平均收敛速率提升到 $O(1/T)$ 量级。这就是消融实验（ablation）的解析版本。一篇实证论文会去扫描 α 并画出精度曲线，而这篇论文直接从速率公式里读出了这种依赖关系。




图 2. 缩放 mSGD 速率指数的动量相关乘子 $1/(1-\alpha)^2$ 。在 $\alpha = 0$ 时它等于 1，此时界与 SGD 一致；在 $\alpha = 0.9$ 时它是 100，并在 α 趋近 1 时发散，那正是时间平均速率达到 $O(1/T)$ 的区间。

结果二：标准 AdaGrad 同样收敛

第二个主定理把同样的几乎必然渐近收敛推广到了标准范数形式的 AdaGrad，同样针对非凸损失。达到这个结果比 mSGD 更费力，原因很具体：AdaGrad 没有一个外部强加的递减步长来抵消噪声，而它的自适应步长本身就是一个依赖于当前梯度噪声的随机量。这种依赖破坏了动量分析所依赖的朴素条件期望操作，因为在给定历史的条件下，步长与它所乘的梯度不再相互独立。作者构造了新的界来精确地控制这些条件相依的项，把 AdaGrad 的保证从子序列收敛提升到整条轨迹的收敛。

证明放弃了什么，又保留了什么

下表总结了论文的条件与常见分析工具箱之间的对比。规律是一致的：那些在真实非凸训练中会失效的假设被丢掉了，剩下的是实践者真正可以检验的条件。

表 1. 相对于常见既有分析所放宽的假设。

假设	常见既有分析	本文
损失凸性	通常需要	不需要（允许非凸）
迭代有界	通常假设	不假设
梯度噪声	在空间上一致有界	相对损失有界： $M(1 + g(\theta))$
动量系数	时变，趋于 0	静态（如 0.9）
AdaGrad 形式	修改过的变体	标准范数形式
收敛模式	子序列 / 时间平均	几乎必然渐近收敛

结语

对每一个训练模型的人来说，这个结论都令人安心。在温和且现实的条件下，带固定动量系数的动量 SGD 和标准 AdaGrad 都被保证几乎必然收敛到一般非凸损失的平稳点，而且动量是可被证明地加速 SGD，而不只是看上去在加速。通过卸下早期证明所背负的凸性、迭代有界与一致噪声假设，这项工作缩小了这些优化器强大实证表现与其理论理解之间长期存在的落差。

该讲清楚的边界也值得一提。这是一份纯理论贡献，没有实验，也没有基准数字，而且它的保证是渐近的：它描述的是迭代最终落到哪里，而不是需要多少步才能足够接近，同时收敛到一个平稳点集合也不等同于收敛到全局最小值。在这些限制之内，它做成了一件有价值的事，为该领域最常用的两个优化器提供了普通 SGD 早已享有的那种收敛依据。