

CVPR 2023 | 让位姿估计告诉你「最坏会错多少」

NVIDIA Research 在标准两阶段流程中加入 conformal 关键点检测与几何不确定性传播，首次为物体位姿估计给出可证明、可计算的最坏误差界。

估计一个物体的 6D 位姿（相对相机的三维旋转与平移）是增强现实、自动驾驶、机器人操作、空间机器人等系统的基础能力。目前主流做法是两阶段流程（two-stage pipeline）：先用神经网络在图像上检测语义关键点（semantic keypoints），再用几何求解器通过 Perspective-n-Points (PnP) 最小化重投影误差，反解出位姿。这个流程在各类基准上成绩领先，但它只会给出一个位姿，却不告诉你这个结果有多可信。

对一个 demo 来说，这点无所谓；但对自动驾驶或机械臂而言，这是个真问题。流程无法保证检测到的关键点接近真值，无法保证优化器找到的是正确位姿而不是一个「看起来对」的错误解，也无法给出估计与真值之间最坏误差的形式化上界。一个要依据位姿去行动的系统，真正想的不只是「估计值是多少」，还有「它最坏可能偏多少」。

这篇来自 NVIDIA Research 的 Heng Yang 与 Marco Pavone、发表于 CVPR 2023 的工作，正是要补上这个缺口。它保留了熟悉的两阶段结构，只注入两个部件：conformal 关键点检测，把启发式的热力图（heatmap）检测变成能以用户指定概率覆盖真实关键点的预测集合（prediction set）；以及几何不确定性传播，把这些集合沿几何关系传播到位姿，得到一个以同样概率覆盖真实位姿的集合。据作者所知，这是第一个能为输出附上可证明、可计算最坏误差界的物体位姿估计器。




图 1 完整流程。从 (a) 输入图像及其关键点热力图出发，conformal prediction 生成 (b) 以指定概率（如 90%）覆盖真实关键点的圆形或椭圆形预测集合；将这些集合沿位姿几何传播，得到 (c) 以同样概率包含真实位姿的位姿不确定性集合（PURSE）；RANSAC 从 PURSE 中采样得到 (d) 平均位姿，再由半定松弛（semidefinite relaxation）计算 (e) 最坏旋转与平移误差界（蓝鸭：最坏旋转；红鸭：最坏平移）。

论文：<https://arxiv.org/abs/2303.12246>
码：<https://github.com/NVlabs/ConformalKeypoint>

代

问题：平均很准，最坏情况却说不清

作者点出两阶段流程通往「可信位姿」的三个挑战。其一，神经网络给出的关键点可能任意偏离真值：遮挡或语义模糊的部位会产生远离真实位置的离群检测（outlier）。其二，几何阶段必须剔除这些离群点，而这是一个非凸优化问题；RANSAC 之类的快速启发式是标准工具，却无法保证找到的是全局最优，还可能「无声地」失败。其三，也是最根本的一点，上述环节都无法提供可证明正确的不确定性量化：估计与真值之间没有形式化的概率误差界。近期有工作能证明优化确实达到了全局最优，缓解了第二个挑战，但一个「被认证的优化器」仍然不会告诉你，最终位姿离真值到底有多近。

Conformal 关键点检测：从热力图到预测集合

第一个部件把「一个点的检测」替换成「一个带覆盖保证的集合」，用的工具是归纳式 conformal 预测（inductive conformal prediction）。作者留出一个带标注的校准集（calibration set），对每张图计算一个非一致性分数（nonconformity score），衡量检测器对真实关键点有多少「意外」。把这些分数排序就得到一个阈值：任何新的检测都会被扩展成「分数低于该阈值的所有像素」组成的集合。这个保证干净且与分布无关：对给定的错误率 ϵ ，真实关键点落在其预测集合内的概率至少为 $1 - \epsilon$ （ $\epsilon=0.1$ 时即 90%），前提是校准图像与测试图像可交换（exchangeable）。

集合的形状取决于分数怎么定义。峰值（peak）设计衡量真实关键点与热力图最可能像素之间的缩放距离，得到圆形集合（ball）；协方差（covariance）设计在若干最强检测上衡量马氏距离（Mahalanobis distance），得到椭圆形集合，可沿检测器最不确定的方向拉伸。圆形集合更简单，椭圆形集合能适应各向异性的不确定性，实验中其覆盖通常不逊于甚至更好。

几何不确定性传播：从关键点集合同到位姿集合

关键点上的保证，只有在传到位姿后仍然成立才有价值。每个关键点预测集合都转化为对 6D 位姿的一个约束：该位姿必须把对应的三维模型点重投影到这个关键点的集合内。把所有约束相交，就定义出位姿不确定性集合（Pose Uncertainty Set, PURSE），即与每个关键点预测集合都一致的全部位姿。由于每个关键点都以 $1 - \epsilon$ 的概率被覆盖，PURSE 也以同样概率包含真实位姿。难点在于 PURSE 是 $SE(3)$ 上的非凸集合，无法直接从中读出点估计或误差棒。

论文从 PURSE 中提取两样东西。为得到可用的点估计，随机采样平均（RANDOM SAMPLE AVERAGE, RANSAG）反复采样三个关键点、求解最小的 P3P 问题、保留落在 PURSE 内的位姿，再把这些位姿的旋转与平移平均成一个平均位姿（average pose）。为得到误差界，作者提出一个最坏情况问题：在仍属于 PURSE 的所有位姿中，离平均位姿最远能有多远？这个最大化是非凸的，但可以做半定松弛（SDP relaxation），其解要么精确、要么是一个有效上界。只要 PURSE 确实包含真实位姿（以 $1 - \epsilon$ 概率发生），这个数值就是对旋转与平移误差的认证最坏界。

保证在实际中站得住吗？

实验在 LineMOD Occlusion (LM-O) 上进行，这是一个有挑战性的基准，包含 1214 张测试图，展示桌面上 8 类物体在严重遮挡下的情形。BOP 挑战选出的 200 张图作为 conformal 预测所需的校准集，全部 1214 张用于测试。作者评估四种设置，交叉两个选择：关键点来自真值边界框还是 Faster-RCNN 检测器，预测集合是圆形还是椭圆形。

首先要检验覆盖率：目标 90% 是否真的兑现 90%？conformal 预测保证的是在校准集上的期望覆盖，而任何单个校准集给出的覆盖都带一点随机性。图 2 展示了这种随机性如何随校准集增大而收窄。




图 2 目标 90% (epsilon=0.1) 下，不同校准集规模 n 所达到覆盖率的分布。即使 $n=200$ ，分布也已经以 0.9 为中心；随着 n 增至 1000、5000，分布向目标紧紧收拢，说明更大的校准集让实际覆盖更可靠。

结论是：即便 LM-O 上只有 200 张校准图，也足以把覆盖率的中心压在目标上；更多校准数据主要是收紧分布的宽度。

覆盖率还必须逐个物体成立，而不仅是平均成立，否则一个漂亮的总体数字可能正掩盖着某个困难类别上的失败。




图 3 四种设置 (gt-ball、gt-ellipse、frcnn-ball、frcnn-ellipse) 下每类 LM-O 物体的经验覆盖率。8 类物体在所有设置下都达到或超过 90% 目标，验证了实际中的覆盖有效性。

每类物体在每种设置下都越过 90% 线，说明覆盖保证并不是一个掩盖了困难物体失败的平均值。误差界本身也如约成立：在论文中「认证界 vs 实际误差」的散点图里，凡是 PURSE 覆盖真实位姿的点都落在对角线下方，意味着在保证成立时，界从不小于真实误差。

精度：保证不是用更差的位姿换来的

如果一个保证要以牺牲精度为代价，那就得不偿失，但这里并没有。按 2D 投影指标衡量（平均重投影误差小于 5 像素即算正确），从 PURSE 得到的平均位姿与强基线持平或更好。在真值边界框加椭圆集合下，它达到 70.6% 的平均成功率，高于最强基线 PVNet 的 61.1%。而在 Faster-RCNN 检测下，数字与 PVNet 接近而非领先，作者对此如实报告。

表 1 LM-O 上的平均 2D 投影成功率（平均重投影误差小于 5 像素即算正确）。本文平均位姿取 $\epsilon=0.1$ 。

方法	成功率 (%)
Tekin	6.16
PoseCNN	17.20
Oberweger	60.90
PVNet (最强基线)	61.06
本文：gt-ball	67.33
本文：gt-ellipse	70.61
本文：frcnn-ball	56.93
本文：frcnn-ellipse	57.73

有两个旋钮在塑造这个取舍。错误率 ϵ 像一个刻度盘：更小的 ϵ (0.1) 给出更大、更保守的预测集合与更强覆盖；更大的 ϵ (0.4) 收缩集合、提高平均位姿成功率、降低覆盖。而由协方差设计得到的椭圆集合通常与圆形持平或更好，这也是 `gt-ellipse` 在表中领先的原因。

它意味着什么，又止步于何处

这项工作留下的核心信息是：一个标准的两阶段位姿估计器，可以被升级成「会告诉你自己可能错多少」的估计器，且带着真正的统计保证，几乎不损失精度。`conformal` 预测在关键点上提供覆盖，几何把这份覆盖传播到位姿形成 `PURSE`，半定松弛再把集合转成具体的最坏误差界。由于这层「外壳」套在任意基于热力图的关键点检测器之上，它在很大程度上与具体检测器无关。

边界同样值得如实说明。覆盖保证依赖校准数据与测试数据的可交换性，这在 `LM-O` 上成立（位姿大致均匀采样），但在流式或强相关的场景中需要谨慎。最坏误差界是正确的，却可能偏保守，有时远大于实际误差，论文也研究了收紧它的方法。此外，保证是针对关键点及由此得到的集合，而不是承诺某个单一点估计一定落在固定距离内。即便有这些前提，这一框架仍指向一个方向：为那些「安全比刷分更重要」的几何视觉问题，提供可证明正确的感知。