

ICML 2023 | 换一把更细的尺子：用等变多项式 衡量图神经网络的表达能力

Weizmann、MIT、NVIDIA 与 Meta 给出等变图多项式的完整基，并据此设计出刷新分子基准的 PPGN++

衡量一个图神经网络（GNN）到底“有多强”，长期以来的标准答案是 Weisfeiler-Lehman (WL) 层级，一族用来判定图是否同构的测试。一个模型在 WL 层级里的位置越高，它能区分的图就越多，理论上也就越强。这套尺子被大量论文引用，几乎成了讨论 GNN 表达能力时的默认语言。

但 WL 这把尺子有两个让人别扭的地方。第一，它的定义是组合式的，只会告诉你“这个模型卡在第几级”，却不会告诉你“缺了哪一步、加上什么才能更强”，对想改进模型的人几乎没有可操作的指导。第二，它的刻度太粗：许多结构差别很大的现代 GNN，落在 WL 层级里却是同一级，根本分不开。

这篇 ICML 2023 的论文换了一把尺子。作者提出：不要问模型“通过了哪一级同构测试”，而要问它“能算出哪些图的等变多项式（equivariant polynomial）”。这里的等变多项式，指那些对节点重新编号保持一致的邻接矩阵多项式，子图计数、许多结构特征都恰好是这样的多项式。谁能算的多项式次数越高，谁就越强，而“还差哪个多项式”正好就是一张可执行的待办清单。




图 1 两个等变图多项式基元的例子：上方为节点值（node-valued），下方为边值（edge-valued）。每个基元都对应一个带一条红色特殊边的小多重图（multi-graph），在图上取值就等于按这个多重图做一次张量收缩（einsum）。这张图是全文的核心直觉：一个“多项式”其实就是一个小图。

论文地址：<https://arxiv.org/abs/2302.11556>

代码地址：<https://github.com/omri1348/Equivariant-Polynomial>

问题：WL 层级为什么不够用

GNN 的表达能力，说白了就是“它能表示哪些关于图的函数”。这一点是有上界的：无论怎么堆层数，标准的消息传递网络都无法区分某些非同构的图。学界用 WL 层级来刻画这个上界，但正如前面所说，它既不构造、又太粗。作者想要的是一把既能细分现有模型、又能直接指出“该补什么运算”的尺子。

在此之前，已有工作只刻画了很低次（low-degree）的等变映射，或者仍然依赖 WL，缺一个完整且便于计算的描述：一个 GNN 到底“应该”能输出哪些量。这篇论文补上的正是这块拼图。

方法一：等变多项式的完整基，每个基元就是一个多重图

论文的第一个贡献，是给出了所有次数不超过 d 的等变图多项式的一组完整基。定理 2.1 说：这组基可以用有向多重图 $H = (V, E, (a, b))$ 来枚举，其中顶点数 $|V| \leq \min\{n, 2+2d\}$ 、边数 $|E| \leq d$ ， (a, b) 是一条被标成红色的特殊边。换句话说，“等变多项式”这个抽象空间，被一一对应地翻译成了“一批小图”。

更关键的是，每个基元在图上怎么取值？答案是一次张量收缩，也就是深度学习里熟悉的 einsum：按 H 的每条黑边把邻接矩阵的元素相乘，再对内部节点求和。下面这张最简单的例子，就是我们再熟悉不过的矩阵乘法。




图 2 矩阵乘法 XY 作为一次张量收缩的例子：三个节点、两条黑边加一条红色输出边，对应的 einsum 恰好就是 (XY) 这个矩阵乘积。这说明作者所谓的“张量收缩”并不神秘，它就是把常见的图上线性代数运算统一写成了多重图的语言。

怎么保证这些多项式是等变的？作者用 Reynolds 算子（Reynolds operator）把普通的单项式在所有节点置换上做平均。论文进一步证明，这个平均恰好等于对 H 的轨道（orbit，即 H 在所有置换下得到的所有同构副本）求和。于是“构造一个等变多项式”这件事，被化简成了“枚举一个多重图的轨道”这件纯组合的事情。




图3 常数（粗竖线左侧）与线性（粗竖线右侧）等变图多项式的完整基：每个格子里都是一个小多重图，红色边标出输出的位置。整张表就是低次等变多项式空间的一份“完整清单”，任何等变的常数或线性映射都是这些基元的线性组合。

方法二：一个线性时间算法，读出模型的“多项式功力”

有了基，就能问一个非常具体的问题：给定一个 GNN，它到底能算出上面哪些多项式？论文的第二个贡献，是把一个网络看成一套“原始收缩操作”（contraction bank） F ，并给出一个在 $|V|$ 、 $|E|$ 上线性时间的算法（Algorithm 1），精确判定某个目标多项式能否被这套操作反复收缩组装出来。

用这套工具，作者把常见 GNN 的表达能力做成了一张对照表，并得到两个漂亮的结论：只允许“节点收缩”的操作集 F_n 恰好等价于 1-WL；允许“边收缩”的更强操作集 F_e 恰好等价于 2-FWL（也就是常说的 3-WL）。下图把这两套操作的原始积木画了出来。




图 4 (论文 Figure 7) 原型化的节点型 (左) 与边型 (右) 收缩操作库：灰色节点表示被收缩掉的节点。节点型操作库 F_n 对应 1-WL，边型操作库 F_e 对应 2-FWL (3-WL)。边型多出的几个积木，正是它比节点型更强的来源。

这张对照表不是纸面练习。论文的 Table 1 给出了量化：在 3 次多项式上，边型模型 F_e 只有 0/18 个基元算不出来，而节点型 F_n 有 2/8 个算不出来，直观印证了 F_e 是 5 节点、4 边多项式精确的，而 F_n 只到 2 节点多项式精确。

方法三：把理论变成模型，PPGN++ 与预计算多项式特征

既然理论已经指出“还差哪些多项式”，第三步自然就是去补。作者在强大的矩阵乘法网络 (PPGN/Ring-GNN) 基础上做了两件事：一是用一小组“原始”运算替换掉原来需要为全部 15 个线性基元分别配置参数的臃肿设计，得到一个更精简高效的骨干，称为 PPGN++；二是把高次的等变多项式特征预先算好 (precomputed polynomial features)，直接喂给网络。

第二点是点睛之笔。这些多项式特征本身就编码了 3-WL 无法捕捉的结构信息，而且因为是预计算的，网络在几乎不增加运行开销的前提下，表达能力被证明严格超过了 3-WL。PPGN++ 的单层更新写成如下形式，其中三个 $\bar{m}$ 是可学习的原始运算， $\otimes$ 表示逐元素乘：

$$Z^{(k+1)} = \bar{m}_3[\bar{m}_1(Z^{(k)}, Z^{(k)T}) \otimes \bar{m}_2(Z^{(k)}), Z^{(k)}]$$

实验：分子基准全面刷新，SR 图上跨越 3-WL

作者在两类任务上验证。真实性能方面，用三个标准的分子图回归数据集：ZINC-12K (约一万二千个分子)、更大的 ZINC-full (二十多万个) 和 Alchemy，指标是测试集平均绝对误差 (MAE，越低越好)，所有模型都严守 500K 参数预算，遵循 Dwivedi 等 (2020) 和 Lim 等 (2022) 的协议。表达能力方面，用强正则图 (Strongly Regular graphs) 这类出了名难区分、连 3-WL 都分不开的图，衡量区分非同构图对的失败率。

表 1 三个分子图回归基准上的测试集 MAE (越低越好，均在 500K 参数预算内)。带 degree-6 多项式特征的 PPGN++ 在三项上全部取得当前最好成绩。

模型	ZINC-12K	ZINC-full	Alchemy
----	----------	-----------	---------

GIN	0.163	—	0.180
CIN	0.079	0.022	—
PPGN++ (degree 6)	0.071	0.020	0.109

三项基准的头名都由带 degree-6 多项式特征的 PPGN++ 拿下：ZINC-12K 上 0.071（对比 CIN 的 0.079、GIN 的 0.163），ZINC-full 上 0.020，Alchemy 上 0.109。更有意思的是，这些多项式特征是“即插即用”的：给一个普通的 GatedGCN 骨干加上 degree-6 特征，它在 ZINC-12K 上的 MAE 从 0.265 直接降到 0.106。也就是说，收益并不依赖某个特定架构。

特征的次数（degree）也确实越高越好。在 ZINC-12K 上，基础版为 0.076，加 degree-5 特征降到 0.072，加 degree-6 再降到 0.071，趋势单调。而在强正则图上，这个趋势更为剧烈。




图 5（论文 Figure 10）在各族强正则图上区分非同构图对的失败率（纵轴对数刻度，越低越好）。无论是 GatedGCN 还是 PPGN 骨干，一旦加入多项式特征，随着次数从 5 升到 7，失败率成数量级地下降；而 3-WL 本身对这些图完全无能为力。这直接印证了“预计算多项式特征把模型推过了 3-WL 屏障”。

小结：让“有多强”变成一个可检查、可执行的问题

这篇论文最持久的价值，是把一个含糊的问题“这个 GNN 有多强”变成了一个具体的问题“它能算出哪些等变图多项式”。每个这样的多项式都只是一个多重图，取值就是一次张量收缩，于是我们既得到了一把比 WL 更细的尺子，也得到了一张“缺哪些运算”的清单。

顺着这张清单动手，作者用预计算的多项式特征把普通图网络推过了 3-WL 屏障，并在分子性质预测上取得了当前最好的精度，而这一切都在 500K 参数的适度预算内完成。作者也坦诚指出了后续方向，例如用一组“生成元”而非完整基来减少喂入网络的特征数量，以及把暂时不可计算的多项式作为层内的计算原语（而非预计算特征）来进一步提升表达能力。对做图学习的人来说，这项工作把“把模型改强”从玄学变成了一件有清单、可核对的工程。