

NeurIPS 2023 | 让机器人真正「挤进人群」： SiT 行人轨迹数据集

汉阳大学提出首个由移动机器人在真实人群中采集的社交交互行人轨迹数据集，多传感器时间同步，配套语义地图与感知—预测统一基准

要让一台机器人安全地穿过熙攘的走廊或路口，它必须把身边的行人当成一个个独立的三维目标去感知，并预测他们下一步往哪走。这件事听上去像是自动驾驶的老问题，但两者的处境其实很不一样：汽车和行人大多分处车道与人行道，很少近距离交汇；而一台在商场里、在过街斑马线上导航的机器人，是真真切切地和人「肩并肩」。

问题在于，我们用来训练这类模型的数据，几乎没有反映机器人真实的处境。经典的行人轨迹数据集(如 ETH、UCY、SDD)是用架在屋顶或无人机上的固定相机俯拍的，镜头里根本不存在人与机器人的互动；而大规模自动驾驶数据集(如 nuScenes、Waymo Open、Argoverse2)虽然传感器丰富，行人却常常远在一侧的人行道上。两类数据都缺了关键的一环——近距离、共享空间的人机交互(human-robot interaction, HRI)。

NeurIPS 2023 上的这项工作给出的答案是 SiT 数据集(Socially Interactive Pedestrian Trajectory)。它不是又一批俯拍视频，而是让一台移动机器人真正开进首尔市区的室内外人群中采集的:同步的 LiDAR、相机、IMU 与 RTK 原始数据，2D 与 3D 标注，多层语义地图，外加一套覆盖 3D 检测、跟踪、轨迹预测与端到端运动预测的统一基准。



图 1 SiT 一个户外场景(Cafe_Street_3)的可视化。上排是五路相机拼出的 360 度环视;下方点云中,黄色是机器人已经走过的轨迹、绿色是它未来的轨迹,蓝色与红色分别是每个行人的过去与未来轨迹,方框为各目标的 3D 边界框。可以直观看到机器人正身处人群中央,与行人共享同一片空间。

论文地址: https://papers.nips.cc/paper_files/paper/2023/hash/4d6a000c216974f59e597bc878cd6325-Abstract-Datasets_and_Benchmarks.html

代码与开发工具包:<https://github.com/SPALaboratory/SiT-Dataset>

为什么现有数据集还不够用

人机交互研究早已发现:机器人的运动会改变附近人们的走路方式,而这种影响在双方近距离、共享同一空间时最为明显。要研究并建模这种行为,训练数据就必须来自一台真正在人群里移动的机器人,而不是钉在墙上的一台相机。

此前也有机器人采集的数据集,但各有短板:STCcrowd 的传感器固定在一个位置,场景几乎不变;JRDB 虽然采于交互场景,却没有把数据整理成轨迹形式,多个传感器之间也没有做完整的时间同步,限制了传感器融合。SiT 正是冲着填补这些空白而设计的。



图 3 SiT 的四类典型采集场景:室内走廊、餐饮街、户外小巷与过街斑马线。四张照片里都能看到那台机器人被行人紧紧包围,说明数据采集是在真实、密集的人流中完成的。

数据是怎么采出来的

采集平台是一台可远程操控的 Clearpath Husky 无人地面车。它搭载两台 16 线的 Velodyne VLP-16 激光雷达、五台 Basler 相机(合起来覆盖完整 360 度)、两台 IMU 以及 RTK 定位。要把相机和 LiDAR 可靠地融合,时间对齐是前提——SiT 用一个集中式的秒脉冲(PPS)信号发生器同时触发所有传感器,让各路数据在时间上精确对齐。




图 2 采集平台 Husky UGV 的传感器布置:顶部五路 Basler 相机拼出 360 度视野(左上示意各相机朝向),两台 Velodyne VLP-16 激光雷达分居上下,加上 MTI-680G 与 VN-100 两台 IMU 和 RTK。彩色箭头标注了各传感器的坐标轴方向。

机器人自身的位姿在室外由 RTK 给出,在室内则依靠 LiDAR 惯性 SLAM 算法估计——这一步是为了补偿机器人自身的运动(ego-motion),才能正确地把行人轨迹拼接出来,并对齐语义地图。语义地图采用 12 层的分层结构,由点云生成后人工分割标注。3D 立方体框由标注专家以 5 Hz 标出,再插值到 10 Hz;2D 框则从共享同一目标 ID 的 3D 框推导而来。出于隐私考虑,所有人脸和车牌都做了模糊处理。

数据规模与四项基准

整个 SiT 共有 60 个场景,约合 60K 张图像与 12K 帧点云,携带约 470K 条 2D 标注与 320K 条 3D 标注。每段片段是 20 秒、10 Hz 的连续数据,可产出 9 秒、以位姿向量表示的轨迹。标注类别不止行人,还包括汽车、公交、卡车、骑行者与摩托车骑手。

在这批数据之上,论文定义了四项基准任务:3D 行人检测(以中心距离阈值 0.25/0.5/1.0/2.0 米下的 AP 计分)、3D 跟踪(sAMOTA、AMOTA、MOTA 等标准指标)、轨迹预测(输入 2 秒历史、预测未来 7 秒,以 K 条候选轨迹里最优者的 ADE 与 FDE 计分),以及一项从原始传感器直通到未来框与轨迹的端到端运动预测任务。

关键结论:SiT 抓住了驾驶数据缺失的近距离交互

SiT 是否真的捕捉到了它想要的那种交互?把行人相对机器人的空间分布画成核密度估计(KDE)图,答案很直观。




图 7 三个数据集中行人相对本体的空间分布(核密度估计,红叉为机器人/车辆中心)。左为 SiT,中为 Waymo Open,右为 nuScenes。SiT 中行人从四面八方紧贴机器人聚集;而在两个驾驶数据集里,行人明显分裂到左右两侧,对应人行道与车道分离的场景。

更定量地看:如果统计同时满足「共享空间」(机器人与行人处于同一语义空间)和「近距离」(彼此在 2 米以内)两个条件的实例数量,SiT 远远多于 nuScenes、Waymo Open 和 Argoverse2。这说明驾驶数据严重低估了社交导航机器人真正要面对的近距离人机交互。




图 8 与自动驾驶数据集的对比。左图为行人到本体距离的归一化密度:SiT(蓝)在近距离段明显更高。右图统计满足空间共享、近距离、以及两者兼具三种条件的实例数:无论哪一项, SiT(蓝)都大幅领先其余数据集。

语义地图确实让预测更准

SiT 附带的语义地图不只是好看的配套——把它作为场景上下文喂给轨迹预测模型,准确率会稳定提升。对 Y-Net,加入地图后 ADE20 从 0.836 降到 0.675、FDE20 从 1.878 降到 1.547;对表现最好的 NSP-SFM, ADE20 从 0.634 降到 0.517、FDE20 从 1.087 降到 0.925。两个模型都因地图而受益,印证了 SiT 提供的这份场景上下文的价值。

表 1 语义地图对轨迹预测的影响(ADE20 / FDE20,越低越好;输入 2 秒、预测 7 秒)。加入地图后两个模型均一致提升,NSP-SFM + 地图取得最佳成绩。

模型	无语义地图 ADE20 / FDE20	加入语义地图 ADE20 / FDE20
Y-Net	0.836 / 1.878	0.675 / 1.547
NSP-SFM	0.634 / 1.087	0.517 / 0.925

在检测一侧,规律也很清晰:融合相机与 LiDAR 的模型优于单模态模型——TransFusion(体素骨干)以 0.531 的 mAP 领先 CenterPoint 的 0.518 和仅用相机的 FCOS3D 的 0.244;而体素骨干(SECOND)整体优于柱状(PointPillar)骨干。跟踪任务中,CenterPoint 跟踪器以 sAMOTA 0.6070、AMOTA 0.2007 居首。

小结与边界

一句话总结:如果你想造出能在人群中安全、得体地移动的机器人,就需要能从机器人视角、近距离看到人群的训练数据,而且各路传感器要在时间上对齐、周围场景要以地图形式记录下来。SiT 是第一个把这几样凑齐的数据集——由机器人在真实人群中采集、多传感器完整同步、配套语义地图,并给出一套横跨检测、跟踪、预测到端到端预测的统一基准。

需要留意的是, SiT 的采集地集中在首尔市区的室内外场景,行人行为、街景布局与文化习惯都带有地域性;能否直接迁移到其他城市或人群仍需验证。不过数据集、开发工具包与训练好的基线模型都已公开,社区可以在此基础上继续构建——这正是一个「基准型」数据集应有的样子。