

NeurIPS 2023 | 差分隐私训练里最难调的那个旋钮，其实可以删掉

AWS AI 与 UC Santa Barbara 提出自动裁剪 (automatic clipping)：一行代码去掉裁剪阈值，效果追平甚至超过精调后的最优基线。

给神经网络加上差分隐私 (differential privacy, DP) 保证，通常遵循一套固定流程：对一个 batch 里的每个样本单独求梯度，把该梯度的范数缩放到不超过某个固定阈值 R ，再按 R 校准加入高斯噪声，最后才更新参数。这一步“逐样本梯度裁剪” (per-sample gradient clipping) 既限制了任何单个样本对模型的影响，也是隐私核算能够成立的前提。但它同时引入了一个超参数 R ，而这个 R ，恰恰是整条流程里最关键、也最不容出错的选择之一。

麻烦在于， R 完全不是一个“温和”的旋钮。设得偏大，随 R 一同放大的噪声会淹没真实梯度；设得偏小，所有梯度又会被压成同样的极小范数。由于最优取值和任务、模型强相关，实践中人们只能在 R 和学习率上做联合网格搜索：对大模型而言，这样一轮二维搜索动辄需要几天到几个月的算力。更棘手的是，这个搜索过程会读取隐私训练数据，因此还会在训练本身之外，悄悄多花掉一部分隐私预算。

这篇来自 AWS AI 与 UC Santa Barbara 的论文《Automatic Clipping: Differentially Private Deep Learning Made Easier and Stronger》，给出的判断很干脆： R 不需要调，因为它根本不需要存在。作者证明，几乎只用改一行代码，就能把裁剪阈值从任意 DP 优化器中移除，得到一个同样私密、同样高效、精度追平甚至超过最优精调基线的方法，并且带有和普通 SGD 相同的收敛保证。

论文：<https://arxiv.org/abs/2206.07136> | 代码：<https://github.com/awsmlabs/fast-differential-privacy>

为什么裁剪阈值这么让人头疼

标准的 DP-SGD 沿用 Abadi 等人的做法，用系数 $\min(R / \|g\|, 1)$ 裁剪每个逐样本梯度 g ：范数超过 R 的梯度被缩放到长度 R ，没超过的保持不变。但在实践中，能带来最好精度的阈值往往非常小，小到几乎每个逐样本梯度都比 R 长，于是每一步、每个样本都会被裁剪。这时 $\min$ 几乎总是取到前一支 $R / \|g\|$ ， R 的具体数值不再携带任何逐样本的幅度信息，只相当于一个全局缩放系数。论文正是从这个观察撬开了缺口。




图 1 ImageNet 上 ResNet18 在 DP-SGD 下的测试准确率，横轴为裁剪范数（clipping norm），纵轴为学习率。准确率在好的配置下约为 60%，在差的配置下会跌到个位数；即便沿着一条不错的学习率取值，一旦把裁剪范数调得过大，准确率也会明显下滑。决定成败的不只是学习率，还有这个阈值本身。

从阈值到归一化：AUTO-V

既然几乎每个梯度反正都在乘 $R / \|g\|$ ，那还留着这个 $\min$ 干什么？自动裁剪干脆把它去掉，对所有梯度无条件地做这一步归一化。作者把这个朴素版本称为 AUTO-V (vanilla)：

$$\text{Clip_AUTO-V}(g; R) = R / \|g\|。$$

把每个梯度都归一化到相同长度有一个实在的好处：它让聚合后的私有梯度与真实梯度的方向尽可能一致，因为不再有个大梯度样本主导整个求和。图 2 把这一点直接画了出来：训练全过程中，AUTO-V 的私有梯度与真实梯度之间的逐步点积，明显高于 Abadi 裁剪。




图 2 每一步中，私有（裁剪并加噪后）梯度与真实梯度之间的点积相似度。AUTO-V 归一化（蓝色）让私有梯度与真实梯度的对齐程度远高于 Abadi 裁剪（橙色），这正是“去掉阈值、直接归一化”背后的直觉。

但纯归一化用力过猛。如果强行把每个梯度都拉到同样的幅度，那些本该变小的小梯度（出现在接近好解的区域、我们希望更新随之收缩的地方）就会被重新放大回原来的大小。训练由此进入一个“惰性区”（lazy region），迟迟无法稳定下来，单靠 AUTO-V 可能无法收敛。

把幅度找回来：AUTO-S，以及消失的阈值

修法很小，也很精准。AUTO-S 不再除以 $\|g\|$ ，而是除以 $\|g\| + \gamma$ ，其中 γ 是一个很小的正稳定常数： $\text{Clip_AUTO-S}(g; R) = R / (\|g\| + \gamma)$ 。对大梯度来说 γ 可以忽略，AUTO-S 表现得和 AUTO-V 一致；但当梯度趋近于零，裁剪结果趋向 g / γ 而不是某个固定长度，于是小梯度依然是小梯度。这一项把归一化丢掉的幅度信息重新补了回来，也正是它让方法能够一路收敛到梯度范数为零的解。

最后一步，才是阈值真正消失的地方。给每个裁剪后的梯度都乘上常数 R ，在数学上等价于把 R 固定为 1、转而缩放学习率，而噪声尺度会一起跟着走，因此隐私保证丝毫不受影响。于是作者索性令 $R = 1$ 。剩下的，就是一个没有裁剪阈值需要选的优化器：一个默认的稳定常数（论文取 $\gamma = 0.01$ ）替代了整整一个维度的超参搜索。同样的替换可以直接套进 DP-SGD、DP-Adam 或 DP-LAMB，也能通过替换一个裁剪函数嵌入 Opacus 等现有库。

删掉这个旋钮，会牺牲精度吗？不会

最核心的实验，就是要回答一个固定的、无阈值的规则能否真的追平精调过的 R 。图 3 给出了直接的答案。热力图里每个格子是 RoBERTa-base 在 SST-2、 $\epsilon = 3$ 下、某个（裁剪范数，学习率）组合的测试准确率；右侧多出来的 AUTO-S 一列则完全不使用任何调过的阈值。它落在了

与最优精调 R 相同的准确率上，也就是说，你只需搜索学习率，整条 R 维度可以直接跳过，调参成本大约省下 5 倍（连同这部分调参本会花掉的隐私预算）。




图 3 RoBERTa-base 在 SST-2 上的测试准确率（DP-Adam， $\epsilon = 3$ ），横轴为裁剪阈值 R，纵轴为学习率。红线右侧的 AUTO-S 一列不调阈值，却达到了与最优精调 R 相同的准确率；只搜索学习率，就能把超参网格大约缩小到原来的五分之一。

这个规律在各类任务上都成立，而且往往不只是“追平”，而是明显更好。在图像基准上，相同隐私预算下，AUTO-S 在论文报告的每一个任务上都超过了 Abadi 裁剪，提升最大的地方，正是准确率本来最有空间的任务。

表 1 相同隐私预算 ϵ 下，**AUTO-S** 与精调基线的对比。数值为测试准确率（%），越高越好。

任务（模型）	ϵ	基线（Abadi / 先前最优）	AUTO-S
MNIST（4 层 CNN）	3	98.15	99.11
CIFAR-10（SimCLRv2）	2	92.70	94.42
ImageNette（ResNet9）	8	60.71	71.11
SST-2（RoBERTa-base）	3	91.86	92.32
SST-2（RoBERTa-large）	8	93.81	94.61

语言任务上的结论如出一辙。在 GLUE 的 RoBERTa 微调上，AUTO-S 追平或超过了此前最好的 DP 微调结果；在 GPT2 的 E2E 表格到文本生成上，它拿到了 64.18 的 BLEU（GPT2-large， $\epsilon = 3$ ），位居所报告模型的前列。反复出现的主题是：达到这些成绩，方法从不需要一个调过的阈值。

不仅有效，而且讲得清为什么有效

自动裁剪并不只是一个经验技巧，论文还证明了它会收敛。在非凸目标下，采用 AUTO-S 的自动 DP-SGD 能让最小期望梯度范数以 $O(T^{-1/4})$ 的速率随步数 T 下降，这与标准的、非私有的 SGD 的渐近速率完全相同。图 4 画出了这个上界在若干“梯度不对称比” r 取值下随 T 的变化，每条曲线最终都落到了标准 SGD 的斜率上。分析还表明，方法对 γ 基本不敏感：任何正值都给出相同的渐近速率，这正是“发一个默认值即可、不必再多调一个超参”的理由。




图 4 采用 AUTO-S 的自动 DP-SGD 的收敛情况：纵轴为 $\min_t E ||g_t||$ 的上界，横轴为迭代步数 T ，双对数坐标，对应若干“梯度不对称比” r 的取值。每条曲线最终都以标准 SGD 的速率 $O(T^{-1/4})$ 趋于平缓，说明去掉阈值在渐近意义上不付出任何代价。

小结

自差分隐私深度学习诞生以来，裁剪阈值一直被当作一个必须仔细调的关键旋钮。自动裁剪想说的是：它其实可以被直接删掉。把每个逐样本梯度归一化，加上一个很小的稳定常数，再把阈值固定为 1，你就得到了一个和最优精调 DP 方法同样私密、同样高效、同样准确的优化器，还附带与 SGD 相同的收敛保证。需要诚实说明的边界是：自动裁剪改变的是“梯度怎么裁剪”，而不是差分隐私本身的隐私-效用权衡，噪声该加还得加，极紧的隐私预算依然困难。但它去掉的，是一处庞大、昂贵、且在很大程度上并不必要的摩擦，这已经足以让私有训练用起来更接近普通训练。

由于这一改动只是裁剪步骤的即插即用替换，尝试它的成本几乎为零：作者已将其开源在 fast-differential-privacy 库中，把现有的 DP-Adam 或 DP-SGD 训练切换到自动裁剪，只需替换一个函数、并从搜索空间里删掉阈值这一维。对多数使用者而言，这把原本二维的超参搜索变成了一维，而在精度和隐私上都没有可测量的代价。