

ICLR 2024 | 更大的图神经网络，并不会给你更可信的置信度

密歇根大学与劳伦斯利弗莫尔国家实验室提出 G- Δ UQ：一种单模型、可扩展的图神经网络认知不确定性估计方法

图神经网络（Graph Neural Network, GNN）正在被越来越多地放到高风险场景里：分子性质预测、材料筛选、异常检测。这些场景有一个共同点——真正的测试数据几乎不可能和训练时长得一模一样。图的规模会变、结构会变、类别与属性的关联也会变。这时候我们通常不只看模型「答得对不对」，还要看它给出的置信度（confidence indicator，通常来自 softmax 概率或熵）「可不可信」，因为校准误差、分布外（OOD）拒识、泛化间隙估计这些安全指标，全都建立在这个置信度之上。

计算机视觉领域早就知道：一旦发生分布偏移，模型的置信度质量就会明显变差。但对图神经网络来说，置信度在分布偏移下如何、以及为什么会退化，研究得要少得多。本文（ICLR 2024）系统地补上了这一课，并给出了一个直接的解决方案。

一个很自然的想法是：换更强、更有表达力的架构，校准问题是不是就能顺带解决？作者用一个受控实验给出的答案是——不能。图 1 把这个反直觉的结论摆得很清楚。




图 1 结构失真分布偏移下的校准表现。作者在标准 super-pixel MNIST 上训练模型，再把它放到由「先旋转、再构图」得到的 k-近邻图上评测，用旋转角度模拟由弱到强的结构失真。上排是准确率（越高越好），下排是期望校准误差 ECE（越低越好）。随着偏移加剧，准确率下降在意料之中，但 ECE 也急剧变差——而且换成图 transformer（GPS）、加位置编码（LPE）、加深加宽网络，都救不回来。只有本文提出的 G- Δ UQ（蓝色）在几乎不牺牲准确率的前提下，把 ECE 大幅压了下去。

换句话说，堆表达力并不是校准问题的解药，有时加深加宽反而让校准更糟。真正需要的是对「认知不确定性（epistemic uncertainty）」的显式建模。这正是本文的出发点。

论文链接与代码

论文：<https://arxiv.org/abs/2309.10976>

代码：<https://github.com/pujacomputes/gduq>

项目主页：<https://pujacomputes.github.io/gduq/>

本文做了什么

本文有三个层层递进的贡献。第一，用一个受控案例研究证明：提升 GNN 的表达力并不能修复分布偏移下的置信度校准。第二，提出 G-ΔUQ，一种把「随机中心化（stochastic centering / anchoring）」框架搬到图数据上的单模型不确定性估计方法，并且支持「部分随机化（partial stochasticity）」——只让网络的一部分变成随机的，还给出一个可以直接复用预训练模型的变体。第三，在三类分布偏移、三项安全任务上做了大规模评测。

值得强调的是「单模型」这一点：不像深度集成（Deep Ensembles）需要训练很多个模型再平均，G-ΔUQ 只需要一个模型，就能给出既是预测、又是不确定性的输出。

G-ΔUQ 是怎么工作的

先看方法总览。核心思路叫「锚定（anchoring）」：不再让模型直接看原始输入，而是先从训练分布里随机抽一个锚点 c ，把输入改写成「相对表示」——减去锚点、再把锚点拼回来，即 $[X - c || c]$ 。每次迭代换一个不同的锚点，模型就好像在从「一族假设」里采样；对同一个样本用 K 个不同锚点跑 K 次，这些预测的方差就刻画了认知不确定性。




图 2 G-ΔUQ 总览。作者提出三种随机中心化变体，向 GNN 注入不同程度的随机性：在节点特征上锚定（Node Feature）、在中间某个消息传递层锚定（Int. MPNN）、或在 READOUT 之后锚定（Readout）。蓝色表示随机部分、红色表示固定部分。其中 READOUT 变体只让读出后的分类头随机，因此可以直接套用预训练好的骨干网络。右侧是锚定推理（Anchored Inference）：对 K 个锚点求平均得到预测 μ ，用预测的标准差 σ 度量不确定性，并给出校准后预测 $\mu_{calib} = \mu(1 - \sigma)$ 。

为什么要在特征空间、而不是在图结构上做锚定？因为如果直接对邻接矩阵做「减去锚图」，会凭空造出并不存在的边，破坏图本身的语义。所以作者选择在节点特征或隐藏表示空间里锚定。三个变体对应从早到晚不同的注入位置：越晚注入，随机的部分越少、越轻量。特别是

那个「冻结预训练骨干、只训练一个带锚定的分类头」的变体，几乎是零成本地给已有模型加上了不确定性能力——这就是「部分随机化」在实践中的意义。

三类分布偏移下的表现

作者的评测刻意做得很宽。结构失真用前面的旋转 super-pixel MNIST；规模偏移（size shift）用 D&D、NCI1、NCI109、PROTEINS 四个图分类数据集，配 GCN、GIN、PNA 三种骨干；概念偏移与协变量偏移（concept / covariate shift）则用 GOOD 基准套件（GOODCMNIST-color、GOODMotif-basis、GOODMotif-size、GOODSST2-length）。对比方法包括 Vanilla、深度集成 DEns、温度缩放 Temp、蒙特卡洛 Dropout（MCD）。先看规模偏移。




图 4 规模分布偏移下的预测不确定性。每组对比 G- Δ UQ（蓝色）与不加锚定的基线 Base（灰色），上排为准确率（越高越好）、下排为 ECE（越低越好）。跨 D&D、NCI1、NCI109、PROTEINS 四个数据集与 GCN/GIN/PNA 三种骨干，随机中心化几乎都在降低校准误差的同时，保持甚至提升了准确率。

在概念与协变量偏移上，作者把与其他单模型 UQ 方法的对比放到了一起看。




图 5 概念偏移与协变量偏移下的预测不确定性。横跨 GOOD 套件的四个数据集，每个数据集又分 concept 与 covariate 两种偏移；四行分别是分布内准确率（ID Acc）、分布外准确率（OOD Acc）、分布内校准（ID Cal L2）、分布外校准（OOD Cal L2）。随机中心化在保持有竞争力的分布内 / 分布外准确率的同时改善了校准，尤其是和其他单模型 UQ 方法相比时优势更明显。

一句话总结这三张图：不管偏移来自结构、规模还是概念 / 协变量，G- Δ UQ 都能给出比其他单模型方法更可信的置信度，而准确率基本不受影响。

更可信的置信度，能换来什么

校准本身只是手段。真正的价值在于：当这些校准过的置信度被送进下游安全任务时，能不能带来更好的结果。作者考察了两项任务——泛化间隙预测和分布外检测。




图 6 泛化间隙预测。用不同方法得到的置信度分数去预测泛化误差，报告平均绝对误差 MAE（越低越好），上排为分布内、下排为分布外。虽然没有哪种方法全面占优，但随机中心化非常有竞争力，在单模型 UQ 估计器里给出了数一数二低的 MAE；尤其是预训练版 G-ΔUQ 表现突出，甚至超过了端到端训练的版本。

泛化间隙预测（在不看测试标签的情况下估计模型会掉多少点）对图来说几乎是一个尚未被探索的任务。这里预训练变体反而比端到端版本更强，是一个很实用的信号：你不必为了拿到好的不确定性而从头重训。




图 7 分布外检测。报告检测 OOD 样本的 AUROC（越高越好）。在概念偏移下，G-ΔUQ 的各变体与包括深度集成在内的基线都很有竞争力；在协变量偏移下，除了 GOODMotif-basis 这一个例外，预训练版 G-ΔUQ 相比所有基线（包括端到端 G-ΔUQ）都取得了显著提升。

把两项下游任务放在一起看，会发现一个反复出现的规律：预训练版 G-ΔUQ 在协变量偏移这种最棘手的情形下，往往是最强的那一个。也就是说，最便宜的用法（冻结骨干、只训分类头）常常也是效果最好的用法。

一个关键的消融：锚定层选在哪

既然锚定可以放在早、中、晚三个位置，那位置到底要不要紧？作者在规模偏移最严重的 D&D 数据集上做了消融：把锚定放在 READOUT 之后（也就是最后一层），随着网络加深，准确率 and 校准会同时明显变好；而放在更早的层则收敛得没那么理想。由此他们给出一个实用建议——当模型预计会遇到规模偏移时，就在最后一层做随机中心化。此外，作者用神经正切核（NTK）分析确认：在中间层做常数平移是真的改变了 GNN 所表示的函数，而不是一个可被抵消的平凡重参数化。

小结与边界

本文的核心信息其实很朴素：不要指望「更大、更有表达力的图神经网络」会自动给你可信的置信度——在分布偏移下，它们不会。真正管用的做法，是把随机锚定这套原理迁移到图上。G-ΔUQ 提供了一个灵活、可扩展的单模型框架，在结构、规模、概念、协变量等多种偏移、以及校准 / 泛化间隙预测 / 分布外检测三项安全任务上，都能给出可靠且校准良好的不确定性。

而它的预训练变体，让这一切几乎可以零成本地加到你已经训练好的模型上。需要留意的边界是：这些结论建立在文中特定的数据集、骨干与偏移设定之上，锚定层的最佳位置也依任务而变（例如规模偏移推荐最后一层）；把它用到新场景时，仍值得按同样的思路做一次验证。