

ICML 2024 | 大部分脉冲神经元其实不需要「记住时间」

北京大学、中科院自动化所等提出 T-RevSNN：训练显存降到 $O(L)$ 、推理成本降到 $O(1)$ ，在 ImageNet 上取得 CNN 类脉冲网络的最好精度

脉冲神经网络（Spiking Neural Network, SNN）一直被寄予「类脑、低功耗」的期待：它用离散的脉冲而不是连续的浮点数传递信息，天然契合神经形态芯片。但要让 SNN 真正好用，通常得把网络在时间维度上模拟很多步（timestep），而这一步恰恰把成本推高了。

问题出在两头。训练时，反向传播需要保存每一层、每一个时间步的中间激活，显存开销大致是 $O(L \times T)$ ， L 是层数、 T 是时间步数；推理时，同一张图要被重复输入 T 次，能耗也随 T 线性增长。更让人无奈的是，现有的训练优化方法往往只能缓解其中一头：要么省训练显存，要么省推理能耗，很难兼得。

这篇发表于 ICML 2024 的工作提出了 T-RevSNN（Temporal Reversible SNN，时间可逆脉冲神经网络），从一个略显反直觉的观察出发：网络里绝大多数脉冲神经元的「时间梯度」其实并不重要。既然如此，为什么要让每个神经元都付出完整的时间代价？作者的做法是——关掉大多数神经元的时间动态，只在少数关键位置保留，并把这些保留下来的时间连接做成「可逆」的。结果是训练显存降到 $O(L)$ 、推理成本降到 $O(1)$ ，同时保持了很高的精度。




图1 普通 SNN 与 T-RevSNN 的时间前向对比。(a) 普通 SNN 沿时间维度展开，每个时间步都重复输入图像、复用全部参数，所有神经元都参与时间动态，因此显存和推理成本分别是 $O(L \times T)$ 和 $O(T)$ 。(b) T-RevSNN 只让少数关键神经元（图中红色）传递时间信息，配合多级时间可逆设计，显存降到 $O(L)$ ；图像只编码一次，编码后的特征被切成 T 组分给各时间步，整个网络也拆成 T 个共享参数的子网络，于是推理成本降到 $O(1)$ 。

论文：<https://arxiv.org/abs/2405.16466>

代码：<https://github.com/BICLab/T-RevSNN>

为什么 SNN 一直「训不大」

SNN 的显存瓶颈并非小问题。以 spiking ResNet-19 为例，在 10 个时间步下训练，显存开销大约是同规模普通 ResNet-19 的 20 倍。这直接把 SNN 挡在了大模型的门外——即便算法上可行，硬件也吃不消。

已有工作各有侧重。OTTT、SLTT 这类方法把训练与时间步解耦，主要缓解显存压力；另一些工作则通过微调把推理时间步压到更小，主要省推理能耗。但它们都只解决了「训练显存」或「推理能耗」中的一半，没能同时收拾这两头。T-RevSNN 想问的是：能不能两头一起解决？

关键观察：多数时间梯度并不重要

作者的切入点是去看「时间梯度」到底有多重要。他们在 CIFAR-10 上用 spiking ResNet-18 做了一个对照实验：case 1 只保留每个 stage 最后一层脉冲神经元的时间梯度，case 2 则丢掉这些、保留其余的。然后把两种情形算出来的空间梯度，与完整基线（baseline）逐一对比余弦相似度。




图 2 空间梯度的余弦相似度对比（左：case 1，右：case 2）。case 1 只保留每个 stage 最后一层神经元的时间梯度，其空间梯度与完整基线始终高度相似（左图相似度接近 1）；case 2 保留其余神经元的时间梯度，相似度却很低（右图）。这说明每个 stage 最后一层的时间梯度才是关键，前面各层的时间梯度可以忽略。横轴为训练轮数（Epoch），不同曲线对应不同时间步 T 与衰减系数 τ 。

结论很清楚：只有每个 stage 最后一层神经元的时间梯度举足轻重，前面各层的时间梯度几乎可以忽略。既然如此，就没必要让所有神经元都维持完整的时间动态——把大多数神经元在时间上「关掉」，只在关键位置「开着」，精度几乎不受影响，却能同时省下显存和计算。这正是 T-RevSNN 全部设计的出发点。

方法：关掉时间动态，再把保留的连接做成可逆

T-RevSNN 的前向流程和普通 SNN 有一个本质区别。它不再在每个时间步重复输入同一张图，而是把图像只编码一次，再把编码后的特征切成 T 组，每个时间步只喂其中一组。相应地，整个网络也被拆成 T 个子网络，它们共享参数，只在关键的「开启」神经元处交换时间信息。这样一来，推理时无需重复 T 遍，成本自然降到 $O(1)$ 。

那些被保留下来的关键时间连接，遵循一条「多级时间可逆」的规则：某个时间步的膜电位，可以由下一时间步的状态和输入脉冲精确地反推回来。换句话说，前向是可逆的。




图3 T-RevSNN 中的时间可逆连接。蓝色箭头是层内的空间前向传播，金色箭头是跨时间步、跨 stage 的时间前向传播 (τ_1 、 τ_2 为不同的衰减)。只有每个 stage 最后一层的关键神经元（红色）在相邻时间步之间传递并融合信息，且这一融合是多级、可逆的——正是这条可逆规则让反向传播时无需保存中间激活。

可逆性带来的直接好处是：反向传播时，不必再保存每一层、每一个时间步的激活，只需保留最后一个时间步的膜电位，其余的都能在反向时重新算出来。这就把训练显存从 $O(L \times T)$ 压回了 $O(L)$ 。为了让这种稀疏的时间信息交互仍然有效，作者还在多级特征之间做了融合（用上/下采样对齐不同 stage 的特征），把跨 stage 的时间交互补齐。

除了时间维度上的改造，作者还重新设计了基本的 SNN Block：采用 ConvNeXt 风格，用深度可分离卷积 (DWConv/PWConv)，去掉了 Batch Normalization，并加入一个带缩放系数 α 的残差连接 (scaled residual connection)，让稀疏时间交互下的网络也能稳定、快速地收敛。

把训练方法放在一起看

为了说清 T-RevSNN 与既有训练方法的差别，作者把各种方法的前向与反向画在了一起。关键区别不在前向，而在反向：STBP 需要同时沿时间和空间两个维度展开；OTTT/SLTT 只沿空间

维度展开；S-RevSNN 沿两个维度展开但在空间上可逆；而 T-RevSNN 对大多数神经元直接「关掉」时间动态，对少数「开启」的神经元则让反向在时间上可逆。




图 5 各训练方法的前向（forward）与反向（backward）示意。(a) 现有方法都不改变 SNN 的前向；(b) STBP 的反向同时沿时间和空间展开；(c) OTTT/SLTT 的反向只沿空间展开；(d) S-RevSNN 沿两维展开但空间可逆；(e) (f) 为本文「关闭」时间动态神经元的前向与反向；(g)(h) 为本文「开启」神经元的前向与反向，与 (a)(b) 基本一致，区别在于 (h) 的反向是可逆的，因此只需保存最后一个时间步的膜电位。

实验结果

在静态图像 ImageNet-1K (224×224) 上，T-RevSNN 用一个 ResNet-18 骨干（最后一级 512 通道、约 29.8M 参数、T=4）取得了 73.2% 的 top-1 精度，同时只占用 85.7 MB/img 的训练显存、2.8 mJ 的推理能耗。这是卷积类脉冲 ResNet 中最好的精度，而且训练显存、训练时间、推理能耗三项都是同类最低。所有显存与时间都在 6 张 NVIDIA A100-40GB 上、float16 混合精度下测得。

与精度相近的脉冲 Transformer (Spike-driven Transformer, 74.6%) 相比，T-RevSNN 在几乎不损失精度的前提下，把显存效率提升了 8.6 倍、训练速度提升了 2.0 倍，推理能耗也降低了 1.6 倍，训练与推理两端的成本全面占优。

表 1 与精度相近的脉冲 Transformer (Spike-driven Transformer, 74.6% top-1) 相比，T-RevSNN 在三项训练/推理成本上的提升。

维度	相对提升
训练显存效率	8.6 倍
训练速度	2.0 倍
推理能耗	1.6 倍

作者还在神经形态数据集 CIFAR10-DVS 和 DVS128 Gesture 上验证了方法，进一步说明 T-RevSNN 在事件相机数据上同样有效。

消融：每个设计都在起作用

消融实验说明各项设计各司其职。最直接的一组：把时间可逆直接套到标准的 MS-ResNet-34 上，训练显存从 267.1 MB/img 骤降到 88.1 MB/img，单轮训练时间从 11.2 分钟缩到 7.4 分钟，而精度只变化约 1.6 个百分点（68.3% → 66.7%）。

表 2 把时间可逆应用到 MS-ResNet-34 基线上的消融。显存与单轮训练时间大幅下降，精度仅变化约 1.6 个百分点。

设置	精度	显存 (MB/img)	时间 (分钟/轮)
MS-ResNet-34 基线	68.3%	267.1	11.2
+ 时间可逆	66.7%	88.1	7.4

其余设计也各有贡献：stage 之间的多级时间特征融合，本身值约 1.2 个百分点的精度（68.6% 对 67.4%）；带缩放系数的残差连接让收敛明显更快，达到 60% 精度只需 25 轮而非 32 轮；改变时间步 T 则是在精度与成本之间权衡。作者还验证了时间可逆与空间可逆是正交的，可以叠加使用。

小结与边界

这篇工作的核心信息可以浓缩成一句：你并不需要在每个神经元上都维持完整的时间动态。既然 SNN 里大多数时间梯度并不重要，那么关掉多数神经元的时间动态、只把少数关键连接做成可逆，就能同时拿到 O(L) 的训练显存和 O(1) 的推理成本，而精度几乎不打折扣。

更长远地看，T-RevSNN 拆掉的是长期挡在 SNN 面前的显存与训练时间瓶颈，让脉冲网络朝着更大规模、更实用的方向多迈了一步。当然，它的收益建立在「多数时间梯度不重要」这一观察之上，主要在图像分类与神经形态识别任务上得到验证；这条经验能否推广到更依赖长程时间依赖的任务，仍有待后续检验。