

ICML 2024 | 深度网络为什么会“记住”训练数据，终于有了理论解释

Purdue University 提出隐私、记忆化与输入曲率之间的三角形理论框架

训练一个深度神经网络时，我们通常希望它学到的是“规律”，而不是把某些训练样本原封不动地背下来。但大量研究已经发现，深度网络确实会记住（memorize）一部分训练数据，尤其是那些罕见、困难、带噪声的样本。这种“记忆化”既和泛化、噪声学习有关，也直接关系到隐私：如果一个模型把某个人的数据背了下来，攻击者就有可能把它还原出来。

问题在于，怎么量化“一个模型到底记住了哪些样本”。Feldman 提出的基于稳定性的记忆化分数（memorization score）给出了严谨的定义，但代价极高：要估计单个样本的分数，需要在“包含该样本”和“不包含该样本”的数据集上反复训练成百上千个模型。于是研究者开始寻找便宜的替代指标，其中最有希望的是输入损失曲率（input loss curvature），也就是损失对输入的 Hessian 矩阵的迹（trace）。它的计算成本大约只有记忆化分数的千分之一。

此前，曲率能作为记忆化的代理，纯粹是经验观察：两者在实验里同涨同落，但没人说得清为什么，更没人知道它们和差分隐私（differential privacy）之间是什么关系。这篇来自 Purdue University、发表于 ICML 2024 的论文补上了缺失的理论，把记忆化、输入损失曲率、差分隐私三者用一组严格的上界连成了一个三角形。




图 1 论文的核心框架：Theorem 5.1 证明输入损失曲率是记忆化的上界，Theorem 5.3 证明差分隐私参数是平均曲率的上界，Theorem 5.4 则把两者串起来，用隐私直接约束记忆化。三条边构成一个闭合三角形。

论文与代码：arXiv 论文见 <https://arxiv.org/abs/2402.18726>。

为什么“便宜的代理”需要一个理论

在深度学习里，研究“去掉某个样本会发生什么”这类反事实（counterfactual）问题，常用的工具是影响函数（influence function）。但影响函数依赖一个强假设：损失的 Hessian 是凸的、正定的。对真实的深度网络来说，这个条件几乎不成立。相比之下，输入损失曲率只需要对损失做一次二阶展开，不需要任何关于 Hessian 凸性或正定性的假设，因此更适合分析深度网络。

但“便宜”和“好用”不等于“正确”。如果不能证明曲率确实约束了记忆化，那么用曲率替代记忆化分数就只是一种碰运气的经验做法。这篇论文要回答的正是这个问题：曲率和记忆化之间的联系，能不能被写成一个可以验证的数学上界？

曲率到底在衡量什么

在深入理论之前，先建立一点直觉。如果对训练集里的样本按输入损失曲率排序，会看到一个很清晰的分层：曲率低的样本是该类别的“典型代表”，曲率高的样本则是罕见、困难、更可能被模型死记硬背的个例。这与记忆化分数所刻画的现象高度一致，正是曲率能作为代理的直观来源。



图 2 用单个 ResNet18 在 ImageNet 上计算的输入损失曲率对训练样本排序，每行是一个类别。左侧十列是曲率最低的样本，姿态、背景都很“标准”；右侧十列是曲率最高的样本，构图罕见、遮挡多、更接近被记住的个例。

三条上界：把三角形的每条边都证出来

论文的理论从损失的二阶泰勒展开出发，借助 Nesterov-Polyak 上界引入输入 Hessian。关键技巧是选取一个零均值的扰动，使一阶项在取期望后消失，剩下的正是用输入损失曲率表示的记忆化上界，外加一个与数据无关的常数项（它把稳定性、泛化、模型偏置等因素打包在一起）。这就是 Theorem 5.1：记忆化被曲率控制。

沿着类似的思路，再结合差分隐私的定义，可以证明一条全新的结果（Theorem 5.3）：更强的隐私保护（即更小的隐私预算 ϵ ）会强制降低平均输入损失曲率。把这两条边接起来，就得到 Theorem 5.4：隐私直接给出了记忆化的上界。整套推导不需要任何 Hessian 凸性或正定性假设，因此可以直接套用到真实的深度网络上。

为了让曲率真正可算，作者用 Hutchinson 迹估计器（Hutchinson's trace estimator）来近似 Hessian 的迹，配置为有限差分步长 $h = 1e-3$ 、 $n = 10$ 个 Rademacher 探测向量，避免了显式计算整个 Hessian。

第一条边：记忆化随曲率线性上升

理论要落地，就得在真实数据上验证。作者直接使用 Feldman & Zhang (2020) 预计算的记忆化分数和他们公开的模型集合：CIFAR100 上 1000 个 Small Inception，ImageNet 上 100 个 ResNet50，把每个样本的记忆化分数和曲率在这些模型上取平均。




图 4 训练结束时，CIFAR100 上平均记忆化分数（横轴）与平均曲率分数（纵轴）的关系（1000 个 Small Inception 模型平均）。蓝色叉是经验数据，红色虚线是理论最佳拟合，绿色虚线是子群（sub-population）上界。经验点紧贴理论曲线，验证了 Theorem 5.1。

散点几乎沿着理论预测的曲线排列：记忆化分数越高，输入损失曲率越大，二者呈现清晰的单调、近线性关系。论文指出这一趋势在 ImageNet 上尤其干净。这说明曲率不只是“碰巧相关”，而是按理论预测的方式约束着记忆化。

第二条边：更强的隐私压低曲率

对于隐私这条边，作者用 DP-SGD 训练 ResNet18，把隐私预算 ϵ 在 1、10、20、30、40、50 之间扫描（固定 $\delta = 1e-5$ ），每个预算下对 10 个随机种子取平均，再测量对应的输入损失曲率。




图 7 隐私预算（横轴，越小隐私越强）与输入损失曲率（纵轴）的关系，CIFAR10 与 CIFAR100。虚线是 Theorem 5.3 预测的最佳拟合曲线，经验点落在其上：预算越小，曲率越低。

当隐私预算收紧（ ϵ 变小）时，输入损失曲率随之下降，且下降的形状与理论预测的最佳拟合曲线一致。换句话说，差分隐私机制确实在按理论刻画的方式压低曲率，这正是 Theorem 5.3 想说的。

第三条边：隐私为记忆化封顶

最后一条边把隐私和记忆化直接连起来。在 CIFAR100 上，作者观察加了差分隐私之后记忆化分数如何随预算变化，并与 Theorem 5.4 给出的理论上界对照。




图 8 CIFAR100 上差分隐私预算（横轴）与记忆化（纵轴，对数刻度）的关系。蓝色叉是经验记忆化分数，红色虚线是 Theorem 5.4 的理论上界。经验值始终远低于上界，说明隐私确实为记忆化封了顶。

随着预算放宽，被记住的样本（尤其是最容易被记住的那批）记忆化分数如预期上升，但始终稳稳待在理论上界之下。三条边至此全部闭合：曲率约束记忆化，隐私约束曲率，隐私因此也约束记忆化。

关键数字一览

表 1 论文的关键设定与数字

项目	设定 / 数值
曲率相对记忆化分数的计算成本	约低 3 个数量级 ($\sim 1/1000$)
记忆化模型集合	CIFAR100 : 1000 个 Small Inception ; ImageNet : 100 个 ResNet50
隐私实验模型	ResNet18 (用 DP-SGD 训练)
隐私预算 ϵ 扫描	1, 10, 20, 30, 40, 50 ($\delta = 1e-5$)
曲率估计器	Hutchinson 迹估计, $h = 1e-3$, $n = 10$ 个 Rademacher 向量
三条定理	Theorem 5.1 / 5.3 / 5.4

意义与边界

这项工作的价值在于：过去只是经验巧合的“曲率约等于记忆化”，现在有了严格的理论支撑。曲率被证明是记忆化的上界，而曲率本身又被差分隐私参数封顶，于是隐私也约束了记忆

化。因为整套框架不依赖 Hessian 凸性假设，它可以直接用于真实的深度网络，其预测也在 CIFAR 和 ImageNet 上得到了验证。

对实践者来说，最直接的收益是一个筛查工具。既然高曲率样本正是那些罕见、困难、更可能被记住的样本（见图 2），而曲率的计算又很便宜，那么只需一个训练好的模型加上 Hutchinson 估计器，就能在不训练 Feldman 分数所需的上千个模型的前提下，标记出最可能被记忆化、隐私风险最高的训练样本。正是这套理论，让“把曲率当作记忆化的读数”从一种碰巧相关变成有据可依的做法。

隐私这条边则提供了第二个抓手。既然更紧的隐私预算可以被证明地同时压低曲率和记忆化，那么曲率本身也就成了一个便宜的诊断量：它能间接反映一次差分隐私训练究竟把记忆化压低了多少，而这个量原本很难直接审计。

需要注意边界：这些是上界结果，依赖误差稳定性、泛化、模型偏置、数据集邻接等假设与有界损失条件；实验也集中在图像分类和标准视觉架构上。但对实践者来说，结论足够清晰：用便宜的曲率测量替代昂贵的记忆化分数，如今有了理论许可，而隐私机制之所以能减少泄漏，也因为可证明地同时压低了曲率和记忆化。