

ICML 2023 | 数据再多也救不了 MLE：用专家的选择约束离线强化学习的世界模型

哈佛大学与帝国理工学院提出贝叶斯逆转移学习（Bayesian Inverse Transition Learning, ITL），一种无需梯度、把近最优专家的决策转化为对世界模型硬约束的方法。

在医疗和教育这样的领域，我们几乎没有随意做实验的机会：不能凭一时兴起就随机分配某种治疗方案，也不能把一个学期重上十遍，看哪种教法更有效。因此当强化学习进入这些场景时，它必须以离线（offline）的方式工作，也就是从别人已经收集好的一批固定经验中学出一个好策略。麻烦在于，这批数据只记录了人们真正采取过的动作，状态与动作空间中很大一部分从未被观察到。

强化学习需要一个描述世界如何对动作作出反应的模型，也就是转移动态（transition dynamics） T 。教科书式的做法是用极大似然（MLE）来估计 T ，统计每个状态在每个动作之后转移到各处的频次。但在离线设定下，这个估计非常脆弱：凡是数据稀疏的地方，计数要么噪声很大、要么根本缺失，得到的策略会在不同数据集之间剧烈摇摆，并自信地推荐一些本不该采取的动作。更糟的是，多收集数据也解决不了问题：因为这批数据来自一个始终在选择好动作的专家，那些无用的区域无论再增加多少条轨迹都不会被探索到。

这篇来自哈佛大学与帝国理工学院的 ICML 2023 论文，把这一局限转化成了优势。生成数据的人（比如临床医生）通常都在接近最优地行动，他们的选择悄悄编码了哪些动作好、哪些不好，而这恰恰是朴素极大似然完全丢弃掉的信息。作者提出了贝叶斯逆转移学习（Bayesian Inverse Transition Learning, ITL）：一种无需梯度、基于约束的方法，它把近最优专家的决策读作对动态的约束，再对 T 的贝叶斯后验进行“裁剪”，使得保留下来的每一个动态都能给出安全且高性能的策略。

论文地址：<https://arxiv.org/abs/2308.05075>

为什么离线估计动态很危险

想想极大似然估计 T_{MLE} 究竟看到了什么。对于专家反复访问过的状态-动作对，转移计数是可靠的；而对于专家刻意回避的状态-动作对，可能只有一个样本、甚至一个都没有，此时的估计基本靠猜。用这样的估计去做规划，就会在模型最不可信的区域里恰恰选出真正糟糕的动作。

论文的消息实验点出了一个令人不安的事实：这并不是一个随着规模增大就会消失的小样本问题。即便在高数据规模下，MLE 依然会犯作者所说的“坏错误”（bad mistakes），也就是选择那些落在专家绝不会考虑的集合之外的动作，因为专家生成的数据在结构上就永远覆盖不到这些区域。这是偶然不确定性（aleatoric uncertainty），而非认知不确定性：同一种数据再多，也无法消除它。

把专家的选择读作约束

出发点很简单。如果一个专家是近最优的（形式化地说，是 ϵ 最优的），那么在它只选择单一动作的状态上，这个动作至少要和其他所有备选一样好，最多相差一个很小的松弛量 ϵ 。论文把这一点精确地写了下来。借助闭式的 Bellman 方程，也就是把策略价值表示为 $V^\pi = (I - \gamma T_\pi)^{-1} R_\pi$ ，作者推导出对动态的线性约束：要求专家采取过的动作，其价值高于专家从未采取过的动作。

任何满足这些约束的转移模型，都会重现作者所称的专家 ϵ 球（ ϵ -ball）结构：在每个状态周围，价值与最优动作相差不超过 ϵ 的那组动作。 ϵ 球中只含单一动作的状态称为确定性策略状态（deterministic-policy states），多个动作并列的状态则称为随机性策略状态（stochastic-policy states）。这个区分，对于该方法如何被评估至关重要。

裁剪贝叶斯后验

ITL 并不去优化单一的 T ，而是保持贝叶斯视角。它在动态上放置一个 Dirichlet-Multinomial 后验 $P(T|D)$ ，这是转移计数的自然共轭选择，然后对它进行裁剪：从中采样若干个 T ，只保留满足专家约束的那些，其余全部丢弃。留存下来的样本构成一个新的分布 $P(T|D, \pi_\epsilon)$ ，它同时尊重数据和专家展示出来的偏好。

算法 1 将这一过程具体化，并为每个状态-动作引入一个松弛项 δ ，即使在价值函数非线性、否则会破坏 ϵ 球性质的地方也能强制保持该性质；论文还分别给出了面向完全最优专家、以及面向部分不确定（随机性策略）专家的两套约束。整个流程无需梯度，从而绕开了以往基于梯度的逆强化学习方法在表格型 MDP 上固有的不稳定性。

它有效吗？

实验采用一个合成的表格型 MDP，规模小到足以精确计算一切、细致考察方法的行为：15 个状态外加一个终止状态、6 个动作、折扣因子 0.95，真实动态被刻意设计为在均匀与高度偏斜之间混合，以制造多样的行为。两种覆盖规模，低数据为 15 条轨迹、高数据为 300 条，与三种专家最优程度 $\epsilon = 0, 3, 4$ 交叉，后者分别留下 0、3、6 个随机性策略状态。下面的每个数字，都是在 1000 个独立生成的数据集上平均得到的。

为了给学到的策略打分，作者使用 Q^* metric：它在所有状态上累加策略所选动作的价值比真实最优动作低多少。数值越低越好，为零意味着策略实际上已达到最优。下图逐个数据集地展示了这一指标，分别绘制两条基线以及本文方法 ITL 的曲线以作对比。




图 1 三种估计转移动态的方法在 1000 个数据集上的 Q^* metric，覆盖三种专家最优程度（epsilon = 0、3、4）与两种数据规模。数值越低越好。红线（ITL，我们裁剪后的后验）几乎贴着零、波动极小；而 MLE（蓝线）在数据集之间剧烈震荡，未裁剪的贝叶斯后验（橙线）则始终高得多。

结果非常鲜明。在全部六个子图中，红线（ITL 裁剪后的后验）基本贴着零，波动带几乎看不见；相比之下，蓝色的 MLE 线在数据集之间剧烈跳动，橙色的未裁剪后验 $P(T|D)$ 则始终居高不下。在这里，保留完整的贝叶斯分布却不加专家约束，反而比朴素 MLE 更差，因为它把许多规划表现很差的动态一并平均了进来。只有当专家约束把这个分布裁剪之后，它才真正变得有用。

表 1 六种设置下的 Q^* metric（越低越好）。ITL（写作 $P(T|D, \pi_\epsilon)$ ）达到接近最优专家的水平，并消除了困扰 MLE 的跨数据集方差。

设置	$P(T D)$	MLE	ITL (本文)	专家
epsilon = 0, 低数据	142.17 ± 8.66	59.75 ± 51.99	0 ± 0	0 ± 0
epsilon = 0, 高数据	99.0 ± 9.73	14.75 ± 6.98	0 ± 0	0 ± 0
epsilon = 3, 低数据	141.81 ± 8.92	62.71 ± 51.32	3.56 ± 0.1	3.60 ± 0
epsilon = 3, 高数据	100.83 ± 10.45	16.32 ± 9	3.56 ± 0.25	3.60 ± 0
epsilon = 4, 低数据	143.52 ± 9.02	65.85 ± 50.83	9.45 ± 0.23	9.4 ± 0
epsilon = 4, 高数据	101.54 ± 10.81	20.11 ± 9.85	8.79 ± 0.6	9.4 ± 0

表 1 给这张图配上了具体数字。面对完全最优的专家（epsilon = 0），ITL 在两种数据规模下都达到恰好 0 ± 0 的 Q^* metric，而低数据下 MLE 为 59.75、未裁剪后验高达 142.17。在最难的

设置（ $\epsilon = 4$ ，高数据）下，ITL 得到 8.79 ± 0.6 ，优于 MLE 的 20.11 ± 9.85 ，并大致追平近最优专家自身的 9.4。真正的看点在标准差：MLE 在不同数据集之间的波动极大（ $\epsilon = 0$ 、低数据时达到 ± 51.99 ），而 ITL 的波动收缩到不足一分。在若干设置下，ITL 甚至略微超过了生成数据的专家，学出了比示范本身更好一点的策略。

在关键处准确，在各处安全

除了聚合指标，论文还按状态类型拆解了准确率。在确定性策略状态（只有唯一最优动作需要答对）上，ITL 在每一种设置下都是 100% 正确，而 MLE 在 67% 到 92% 之间波动，未裁剪后验则更差。同样重要的是 $a \in \epsilon$ 球这一列：它衡量一个方法所犯的错误中，有多少至少仍落在专家的 ϵ 球之内，也就是所选动作依然接近最优、而非真正有害。ITL 从不离开 ϵ 球，因此在构造上就不会犯坏错误。

表 2 高数据规模下的准确率与安全性。确定性（**Deterministic**）：专家有唯一最优动作的状态上的准确率；随机性（**Stochastic**）：多个动作都接近最优的状态上的准确率； $a \in \epsilon$ 球：所犯错误中仍落在专家 ϵ 球内的“安全错误”所占比例。ITL 在确定性状态上达到 100%，且从不离开 ϵ 球。

设置	方法	确定性	随机性	$a \in \epsilon$ 球
$\epsilon = 0$	P(T D)	61 ± 6	N/A	N/A
$\epsilon = 0$	MLE	83 ± 7	N/A	N/A
$\epsilon = 0$	ITL	100 ± 0	N/A	N/A
$\epsilon = 3$	P(T D)	67 ± 8	33 ± 25	30 ± 30
$\epsilon = 3$	MLE	87 ± 7	53 ± 28	70 ± 38
$\epsilon = 3$	ITL	100 ± 0	55 ± 29	100 ± 0
$\epsilon = 4$	P(T D)	81 ± 7	31 ± 17	38 ± 20
$\epsilon = 4$	MLE	92 ± 6	52 ± 20	77 ± 25
$\epsilon = 4$	ITL	100 ± 0	59 ± 19	100 ± 0

更微妙的结果出现在随机性策略状态上。尽管约束并没有明确指定在多个近最优动作中该选哪一个，ITL 在这些状态上仍然比基线更准确，这表明约束把专家的不确定性结构隐式地传递进了模型，而不只是钉住那些只有单一最优动作的状态。

这为什么重要

务实的结论是：在离线设定中，专家的行为不仅仅是训练策略的数据，它本身就是关于世界模型的信息。把它当作对动态的约束，能换来极大似然和朴素贝叶斯后验都给不了的安全保证。由此得到的策略在计算上无需梯度，可证明地停留在专家的安全集合之内，在不同数据集之间方差大幅降低，甚至能超过生成数据的专家。同一套“约束加不确定性”的配方，还能在不确定的状态上给出动作排序，这正是医疗等高风险规划所需要的、有信息量又留有余地的推荐。

诚实地说明边界：本研究基于一个小规模的合成表格型 MDP，且方法假设奖励函数 R 已知、示范专家确实近最优；裁剪思想能否扩展到大规模或连续状态空间、以及它对真正次优专家的敏感度，都留待未来工作。但原则很清楚：离线数据里已经存在的那些选择，是一条值得强制执行约束，而不是应当被平均掉的信号。