

NeurIPS 2022 | 让专家少标一点：表格语言模型的主动学习实践

Siemens 与 LMU Munich 在工业表格 NER 上验证主动学习，发现「批内多样性」有用，「强制表间多样性」反而更差

工业界跑在电子表格上。工厂里的设备、传感器、容器，往往就记录在一张张结构松散的表里。想把这些信息自动抽取出来，需要在带标注的样本上微调「表格语言模型（tabular language model）」。问题出在标注成本：这些表格用的是高度专业、领域特定的术语，只有少数专家看得懂、标得动，于是「凑够训练标签」这件事很快变得非常昂贵。

主动学习（active learning）恰恰是为这种场景设计的：未标注数据很多、专家标注很贵，它试图把每一次标注的价值榨到最大。但一个尴尬的现实是，尽管这个契合看起来很明显，此前却没有人把主动学习和表格语言模型放在一起研究。这篇由 Siemens 的 Martin Ringsquandl 与 Aneta Koleva（Koleva 同时来自 LMU Munich）完成、发表在 NeurIPS 2022 Table Representation Learning Workshop 的工作，正是来填这个空白。

他们研究的是表格上的「子单元格命名实体识别（sub-cell NER）」：一张表里有很多单元格，每个单元格内又可能同时含有多个 token 级别的标签。这让它成为一个此前少见的「嵌套多实例（nested multi-instance）」主动学习问题——到底应该在 token、单元格，还是整张表这一层去挑选要标注的样本，并不显然。




图 1 工业子单元格 NER 与主动学习采集示意：一张设备表里 QUANT（物理量）、UoM（单位）、TAG（设备标识）、EQ（设备名）四类实体交织出现，模型需向专家 Oracle 请求标注，核心问题是按 token、cell 还是整张 table 挑选最有信息量的样本。

论文地址：<https://arxiv.org/abs/2211.04128>

问题：标注贵在哪里

微调一个工业任务上的表格语言模型，需要大量标签，而这些标签只能由能读懂专业表格的专家来提供，采集成本因此居高不下。更麻烦的是任务本身的结构：子单元格 NER 是一个嵌套多实例问题，一张表包含很多单元格，一个单元格又携带多个 token 标签，所以「在哪个粒度上采集标注」本身就是个开放问题。

另一层约束来自模型。大型 Transformer 没法像经典主动学习那样一次只更新一个样本，它需要成批数据、每轮训练多个 epoch，因此采集函数必须一次挑出「一整批」单元格。而单纯按不确定性挑选，往往会抓来一堆高度相关、彼此冗余的单元格（常常来自同一张表甚至同一行），白白浪费标注预算。

方法：一个表格语言模型加四种采集函数

模型部分是一个「表格偏置」的 Transformer 编码器：它用「行-列可见性矩阵（row-column visibility matrix）」替换了普通注意力，并配合「单元格内位置编码（within-cell positional encoding）」，让每个 token 的表示都能感知整张表的上下文。之上是一个分类解码器，用 IO 标注方式给每个 token 打上四类实体标签——TAG（设备标识）、EQ（设备名）、QUANT（物理量）、UoM（计量单位）。

作者提出了一个关键设计判断：既然编码器已经让每个单元格「看得见」整张表的上下文，那么在单元格（cell）这一粒度上采集就够了，不需要再额外做「先选表、再选单元格」的层级式选择。在这个判断之上，他们把主动学习组织成常见的池式（pool-based）流程：每一轮从未标注池里挑出一批「最有信息量」的单元格，交给专家 Oracle 标注，再用新标签继续训练。

真正被对比的，是四种单元格采集函数。MNLP 按归一化对数概率的不确定性给单元格打分，是纯不确定性采样；MNLP+ 在 MNLP 之上加了一条「强制轮转、最大化表间多样性」的约束；BADGE 则对每个单元格的梯度嵌入做 k-MEANS++ 聚类，试图一次选出既不确定又彼此多样的一批；Rand 均匀随机采样，作为基线。

数据：一批真实的工业表格

评测用的不是学术基准，而是一批真实的工业电子表格：来自多个工厂，被降采样到每张表最多 5 行，再由专家用 prodi.py 这一基于 span 的标注工具逐格标注。随机切分后，得到 55 张训练表和 24 张测试表。真正棘手的是标签的稀疏与不均衡。

表 1 训练集表格统计。

统计项	数值
表格数 (#tables)	55
单元格数 (#cells)	4774

NER 标签数 (#labels)	1112
平均每单元格标签数	0.23

55 张训练表里有 4774 个单元格，却只有 1112 个 NER span 标签，平均每个单元格只有 0.23 个标签——换句话说，约 77% 的单元格里只有 O 标签（没有任何实体）。这种极端的类别不均衡，正是作者强调的、工业数据里非常典型的情形。实验从一个分层抽样的 100 个已标注单元格的种子开始，之后每轮新增 50 个单元格，所有结果在 5 个随机种子上取平均；骨干网络是 bert-base-uncased，每轮最多训练 30 个 epoch。

结果：BADGE 一枝独秀，强制多样性反而垫底

衡量指标是留出测试集上、随主动学习轮次变化的 micro 平均 F1。下图把四种采集函数和「用全部数据训练」的天花板（full）画在了一起，横轴是累计标签数。读图时可以重点看两件事：哪条曲线最先逼近橙色的 full 水平线，以及各方法之间的高低顺序。




图 2 四种采集函数的 micro F1 随标签数变化（5 种子平均）：绿色 badge 最先冲上橙色 full 天花板并越过；蓝色 mnlp 约 500 标签后才略超红色 rand，且方差更大；紫色 mnlp+（强制最大表间多样性）全程垫底，甚至低于随机基线。

结论相当鲜明。BADGE（批内多样的梯度方法）是唯一明显跑赢随机、并且越过「全量训练」F1 天花板的方法——用少得多的标签就摸到了上限。纯不确定性采样的 MNLP 表现令人失望，直到大约 500 个标签之后才略微领先 Rand，而且方差更大，说明它在这种高度不均衡的场景里对初始种子更敏感。最耐人寻味的是 MNLP+：这个「强制最大化表间多样性」的变体是四者中最差的，甚至低于随机基线，说明把多样性推到极致反而有害。

为什么？多样性不是越多越好

这四种采集函数其实构成了一次关于「多样性」的消融。为了看清机制，作者统计了每一轮各方法从多少张不同的表里取样：MNLP 会盯着少数几张表反复取，MNLP+ 则在预算允许的范围内尽量摊到最多的表上，而 BADGE 落在两者之间。把这条线索和上面的 F1 结果对起来看就很清楚了——制胜关键不是「最大多样性」，而是在「多样性」与「单元格不确定性」之间做出恰当的权衡：内建批内多样性（BADGE）有益，强制最大表间多样性（MNLP+）有害。

小结与边界

这项工作留下的核心信息是：对表格语言模型做主动学习，确实能大幅削减专家标注成本，但前提是对「多样性」拿捏得当。在单元格粒度上采集、并内建批内多样性（如 BADGE），能用零头的标签逼近全量训练的表现；而生硬地强制最大表间多样性会适得其反，甚至不如随机。可落地的配方是：在多样性与不确定性之间做权衡，而不是单方面最大化其中之一。

作为该问题上的第一项研究，它也坦率地留下了两个开放前沿：一是表间多样化采集本身的计算开销，二是它给人类标注者带来的额外认知负担——每换一张新表，专家都要重新理解一次上下文。这些正是把主动学习真正推向工业标注流水线时，接下来要面对的问题。