

ICLR 2023 | 多语言大模型的数据配比，不该只调一个温度

Google Research 提出 UniMax 采样：给高资源语言更均匀的预算，给低资源语言的重复次数上限

训练一个覆盖上百种语言的多语言大模型，第一个绕不开的问题是：每种语言到底喂多少数据？现实中的语料严重失衡，如果照原始比例采样，英语这类高资源语言会淹没一切；如果强行拉平，低资源语言的那点数据又会被反复重复。业界的标准答案是「温度采样（temperature sampling）」，用一个超参数 τ 在「按比例」和「均匀」之间调一个折中。

问题在于，这个折中并不是免费的。以常用的 mC4 语料为例，英语约有 9.7 万亿字符，是最低资源语言约鲁巴语（Yoruba）的约 92,000 倍。为了照顾头部语言而调高的温度，会让尾部语言被过度重复：在 $\tau=3.33$ 、约一万亿 token 的预算下，最低资源语言会被重复 100 多次。而温度这个旋钮到底该怎么拧、在不同模型规模下是否稳定，此前从未被系统地评估过。

本文提出 UniMax（uniform + max），一种简单直接的采样方法：先把预算尽量均匀地分给各语言，同时为任何一种语言的重复次数设一个硬上限。它比温度采样给了头部语言更均匀的覆盖，又从机制上杜绝了尾部语言被重复太多次。结论是：在多个基准、多个模型规模上，UniMax 都稳定优于温度采样，而且优势随模型变大保持不变。




图1 每种语言的训练轮数（epoch）随语言资源排名的变化。横轴按字符量排序，越往右资源越低。温度采样（虚线， $\tau=3.33$ ）让最低资源语言被重复上百次，而 UniMax（实线）把任何语言的重复次数都压在设定的上限内（此处为 1 轮）。

论文：<https://arxiv.org/abs/2304.09151> | 代码与模型（T5X）：<https://github.com/google-research/t5x>

问题：数据失衡，温度采样并非免费午餐

多语言预训练的核心矛盾，是不同语言的数据量差了好几个数量级。过度重复低资源语言的数据，会带来三个具体代价：一是过拟合，反而拖累下游任务；二是更容易记住并泄露训练语料中的隐私内容；三是把算力浪费在重复样本上。更麻烦的是，论文观察到这些问题会随着模型规模变大而加重，因此小模型上「看起来还行」的温度设置，放到大模型上未必成立。

另一端同样有风险：如果温度偏低、低资源语言被采样得太少，它们就会训练不足。下面这张图把这种张力画了出来。




图2 高资源语言英语（en）与低资源语言约鲁巴语（yo）在留出集上的预训练交叉熵损失，覆盖 Large、XL、XXL 三种规模。约鲁巴语的损失在每个规模上都明显高于英语：配比一旦失衡，低资源语言就会训练不足。论文同时观察到，在偏高的温度下，过拟合会随模型增大而更严重。（不同采样策略因词表不同，损失数值不能直接横向比较。）

换句话说，温度采样是在「低资源语言训练不足」和「低资源语言过拟合」两个坏结果之间走钢丝，而钢丝的最佳落点还会随模型规模移动。UniMax 想做的，就是把这根钢丝换成一条更稳的规则。

方法：UniMax = 均匀分配 + 重复上限

UniMax 从一个固定的字符预算 C 出发，把语言按资源量从低到高排序，然后依次处理。每一步它都问一个问题：剩下的预算如果均匀分给还没处理的语言，某种语言会不会超过 N 个 epoch（即把自己的语料重复超过 N 遍）？如果会，就把这种语言封顶在 N 个 epoch，把省下来的预算再均匀地摊给其余语言；如果不会，就均匀分配。

用一句话写成规则：每种语言拿到的预算 U 取「 N 乘以它的语料量」与「剩余预算均分到剩余语言数」两者中的较小值，分完即从总预算中扣除。默认 $N=1$ ，意味着任何语言的数据最多只用一遍、不做任何重复。这样一来，头部语言得到了比温度采样更均匀的覆盖，尾部语言则被明确保护，不会被重复上百次。整个方法几乎没有需要精细调的超参数，可以直接替换掉温度采样。

实验结果：多基准、多规模，一致领先

作者在刷新版 mC4 上预训练，并在一整套多语言基准上评测：TyDi QA GoldP、WMT21 机器翻译、XNLI、XQuAD、MLQA、PAWS-X。模型规模从 Small 一路放大到 XXL，专门用来检验「优势是否随规模保持」这个关键问题。先看阅读理解 TyDi QA 的整体表现。




图 4 三种模型规模下 TyDi QA GoldP 的平均分（EM 与 F1 的平均）。UniMax（蓝）在每个规模上都高于 $\tau=3.33$ （绿）和 $\tau=1$ （红），且优势随规模保持。

UniMax 在所有规模上都领先两个温度基线。更细的逐语言分解显示，它在高资源和低资源语言上都胜过 $\tau=3.33$ ，只有在最大规模、且面向高资源语言时才略逊于 $\tau=1$ ，这也符合直觉： $\tau=1$ 本就把最多的数据给了头部语言。




图 5 在 XXL 模型上逐语言的 TyDi QA 表现，横轴大致从高资源（en）排到低资源（sw）。UniMax 在低资源语言（如斯瓦希里语 sw、id、bn、te）上领先尤为明显；只有在英语这类高资源语言上略逊于 $\tau=1$ 。

一个直观的例子是斯瓦希里语（Swahili, sw）：即使 UniMax 见到的斯瓦希里语样本比温度采样更少，它在该语言上仍然胜过 $\tau=3.33$ 。这说明关键不在「重复多少遍」，而在整体配比是否合理。翻译任务上也是同样的故事。




图 6 WMT21 多语言翻译在各规模下、按所有语言对平均的 chrF 分数。UniMax（蓝）在每个规模上都优于两种温度基线，而且绝大多数语言对都从中受益。

把最有代表性的数字单独列出来：在把字符预算放大 4 倍（论文记作 1/2 预算）的 Large 模型上，三种策略的 TyDi QA 平均分如下。

表 1 4× 更大 (1/2) 字符预算下、Large 规模模型的 TyDi QA 平均分：UniMax 优于两种温度采样基线。

采样策略	TyDi QA (1/2 预算, Large)
UniMax	83.1
$\tau = 3.33$	82.8
$\tau = 1$	81.2

至于那个重复上限 N 该设多少，作者在 Large 模型上做了消融：N=1、5、10 分别得到 82.2、81.5、81.8——完全不允许重复 (N=1) 反而最好，尽管差距不大。他们也指出，最优的 N 会随字符预算变化，因此把它理解为「一个稳健的默认值」比「一个需要精调的旋钮」更合适。

顺带交付：刷新版 mC4 与 umT5

除了方法本身，论文还交付了两样能直接用的东西。其一是刷新、扩容后的 mC4 语料：29 万亿字符、107 种语言，相比原版扩大约 35%。其二是用 UniMax 训练的 umT5 系列模型权重。作为对照，umT5-XXL 在 TyDi QA 上达到 81.2/89.7 (EM/F1)，优于同规模的 mT5-XXL 的 79.5/88.7。

小结与边界

UniMax 的主张很朴素：为每种语言的重复次数设上限，再把剩下的预算尽量均匀地铺开，就能在多语言预训练上稳定胜过温度采样，而且这一优势随模型规模保持。它几乎不需要调参，是温度采样的一个「即插即用」替代品，并且附带了刷新版语料和 umT5 权重。需要留意的是，这些结论来自 mC4 与 mT5/umT5 这一族设定，评测集中在跨语言理解与翻译任务；最优的重复上限也与字符预算相关。换到别的语料、别的模型族或别的任务上时，默认值仍值得按同样的思路重新检验一遍。