

NeurIPS 2023 | 给「只训练最后一层」一个真正紧的泛化保证

巴塞尔大学等提出有限秩核岭回归 (finite-rank KRR) 测试误差的双向非渐近界：
对任意正则强度都保持紧致，包括无正则的 ridgeless 极限。

有一种做法你几乎一定用过：拿一个预训练网络，冻住主干，只重新训练最后一层线性层。它快、省、而且到处都是，从少样本迁移到 reservoir computing 都在用。不那么显然的是，这个做法本质上就是一次有限秩核 (finite-rank kernel) 上的核岭回归 (KRR)。冻住的特征定义了一个固定的、有限维的特征映射，训练最后一层就是在这个特征空间里做岭回归，其核的秩正好等于特征的个数。

一个自然的问题随之而来：这最后一层的测试误差有多大？我们能不能在还没碰测试集之前就给它一个可信的保证？统计学习理论对一般的 KRR 是有答案的，但落到有限秩这个具体场景，这些答案往往很松。经典的界通常是单向的（只有上界），不少要求岭参数 λ 不能太靠近零，还有一些恰好在最后一层训练最想接近的无正则极限 $\lambda \rightarrow 0$ 处变得平凡 (vacuous)。更麻烦的是，没有一个匹配的下界，你就无法判断一个看起来很小的上界究竟是真的小，还是只是过于乐观。

这篇 NeurIPS 2023 的工作补上了这个缺口。针对欠参数化区间（样本量 N 大于核的秩 M ）下的有限秩 KRR，作者推出了相互匹配的、非渐近的高概率上界与下界。这组界对任意岭参数 λ 都保持紧致，包括 ridgeless 极限；而在实验中，新的上界能贴着真实误差走，而此前最接近的界却高出它一个数量级以上。




图 1 有限秩 KRR 在截断神经正切核 (tNTK) 上的表现。左：在 $N=50$ 个样本、核秩 $M=7$ 下，回归器 (绿) 尽管面对含噪样本 (红) 仍紧贴目标函数 (蓝)。右：测试误差中位数 (10 次重复) 随 N 从 10 增长到 200 迅速下降，阴影为四分位带。

论文： <https://arxiv.org/abs/2310.00987> （NeurIPS 2023）。作者：Tin Sum Cheng、Aurelien Lucchi、Ivan Dokmanić、Anastasis Kratsios、David Belius。

为什么有限秩场景会让教科书里的界失灵

一个有限秩核在再生核希尔伯特空间（RKHS）里只张成一个有限维子空间，对应 M 个特征函数构成的特征基。而模型要学的目标函数，几乎从不完全落在这个子空间里。它会分成两部分：一部分落在子空间内，有限秩 KRR 原则上可以复原；另一部分正交于子空间，估计器永远无法表示。后者就是不可约的有限秩误差：一层再多数据也抹不掉的测试误差下限，也是分析里必须老老实实追踪、而不能一笔带过的项。

以往的有限秩分析各自漏掉了这幅图的一块。有的只在渐近的高维极限下成立；有的只有当 λ 按一个与样本量 N 绑定的时间表衰减时才有效；有的只界住期望误差，而不是某一次真实运行的误差；几乎没有谁给出下界。当你手上只有一个冻住的主干、一份数据、一个 λ 取值时，一个单向的、渐近的、依赖衰减时间表的保证并不是你想要的东西。

偏差-方差分解，放到特征函数基里去做

出发点是普通的 KRR 估计器，也就是在 RKHS 上最小化一个带正则的最小二乘目标：

$$f_{[Z, \lambda]} = \operatorname{argmin}_{f \in H} (1/N) \sum_i (f(x_i) - y_i)^2 + \lambda \|f\|_H^2.$$

测试误差被定义为与真实目标的期望平方偏差，它干净地分成一个偏差项（无噪标签下的误差）和一个方差项（由标签噪声驱动）。作者对这两块分别给出高概率的界。真正让常数变紧的一步是换坐标：不在 RKHS 基里做，而是把目标放到 L^2 特征函数基 $\{\psi_k\}$ 里分析。这样就把核的谱和「样本恰好落在哪里」的随机性解耦开来，而正是这种耦合把以往的界撑松了。

证明由两个技术要件支撑：一个针对随机协方差矩阵的 sub-Gaussian 集中不等式，以及对岭项里出现的矩阵逆的 Neumann 级数展开。二者合在一起，让界对任意与 N 无关地选取的 λ 都成立，而不只是对必须随样本增大而衰减的岭参数成立。具体地，方差满足如下形式的界：

$$\text{variance} \leq \sigma^2 \cdot (2M/N) \cdot (1 + \sqrt{(\log N / N)}) + C_2 \cdot (\log N / N),$$

也就是说，它按「噪声方差乘以两倍的秩再除以样本量」的量级增长，残差项以 $\log N / N$ 的速率淡出。这个衰减速率，比一般 Rademacher 复杂度论证给出的 $O(\sqrt{(\log N / N)})$ 速率快了一个数量级。

回报：真正把误差夹在中间的界

最直观的收益来自与最接近的前人结果（Bach 的界）的对比。下图在自然对数尺度下画出两个上界，一次让样本量 N 变化，一次让岭的倒数 $1/\lambda$ 变化。新的界全程都远在 Bach 的界之下，而且更关键的是，它在朝 ridgeless 方向（ $1/\lambda$ 增大）时还在持续变好，而 Bach 的界却在这里掉头变差。这个对比把改进的主要来源锁定在了对岭的依赖上。




图2 新上界（绿）与 Bach 上界（蓝）在 tNTK 上的对比，自然对数尺度。左：随 N 变化；右：随岭的倒数 $1/\lambda$ 变化。新界低出若干数量级，且正则越弱越好，而 Bach 的界在此掉头变差。

把一个好的上界变成一个紧的界，靠的是下界。下图把论文的上界和下界（为清楚起见略去了小的残差项）叠在两个受控有限秩核的实测测试误差上——一个是 tNTK，一个是单独构造的低秩核（LK）。两条界在整个 N 的范围内把误差中位数夹在中间，并随 N 增大彼此收拢，这正是「紧」在实验上的标志。由于略去了残差，简化后的界在 N 很小时不再夹住误差，恰好落在理论所说、这些项仍然重要的地方；当样本增大、残差淡出后，界又重新夹住了误差。




图3 上界与下界（略去残差）对实测测试误差（10 次重复）的对比，左为 tNTK、右为低秩核 LK，自然对数尺度。两条界夹住误差中位数并随 N 增大收拢；小 N 处的缝隙在预期之内。

一览：新分析补了什么

表 1 新分析相比以往有限秩 KRR 界的增量。

性质	以往的有限秩界	本文
上界	有	有
下界	几乎没有	有，且随 N 增大与上界匹配
Ridgeless 极限 $\lambda \rightarrow 0$	常常平凡	非平凡
非渐近、固定 λ	并非总是	是，任意与 N 无关的 λ
上界衰减速率	至多 $\sqrt{(\log N / N)}$	$\log N / N$

--	--	--

它意味着什么，又止步于哪里

从实践角度读，有限秩 KRR——也就是最后一层微调背后的模型——如今有了一份诚实的、双向的测试误差证书。这些界以高概率成立（对随机采样至少 $1 - 2/N$ ），对任意岭都保持紧致，哪怕完全无正则；它还把不可约的有限秩误差下限显式地摆出来，而不是藏起来。而使这一切成立的核心想法——在特征函数基里分析目标、把谱和采样噪声分开——是一个其他有限秩分析也能借用的模板。

诚实地划出边界：这些结果针对的是 N 超过秩 M 的欠参数化区间，验证用的是谱和目标分解都已知的受控合成核（tNTK 与 LK），而非自然图像数据集。在 ridgeless 极限下，分析进一步表明偏差完全由有限秩误差主导、方差完全由噪声水平 σ^2 主导。在这些限定之内，这是一份远比以前那些松散、单向、渐近的保证都更锐利的证书。