

不给人脸贴标签，而是问人「哪张最不像」： Sony AI 用 638,180 次人类判断学习人脸表征

ICLR 2023 · Sony AI 与东京大学 · 638,180 次相似性判断，全程不使用任何人口统计标签

要判断一个人脸数据集是否「足够多样」，业界的第一反应几乎总是去看人口统计标签（demographic labels）：种族、性别、年龄。这个默认做法其实站得并不稳。这类标签常常是缺失的，采集上又受到法律限制，而一旦需要靠模型或标注者去「推断」而不是直接读取，它就变得很不可靠。

更根本的问题在于，这些标签把本来连续的东西压成了离散的格子。「肤色」被简化成深或浅；被归到同一类别的两张脸，看上去可能毫无相似之处；而僵硬的分类体系会抹去多族裔个体的存在，一旦贴错标签还可能造成真实的心理伤害。问题不在于某个分类体系没选好、换一个更好的就能解决，而在于「人的外貌可以被干净地装进离散盒子」这个前提本身。

ICLR 2023 上来自 Sony AI 与东京大学的论文 A View From Somewhere (AVFS, 「来自某处的视角」) 选择了相反的前提。它不去给人脸贴标签，而是问一个更朴素的问题：给你三张脸，哪一张是「最不像」的那一个？作者收集了 638,180 次这样的判断，覆盖 4,921 张人脸，并据此学习出一个与人类感知对齐的连续嵌入空间——训练信号里没有出现任何一个人口统计标签。




图 2 一个学出来的维度长什么样。沿某个 AVFS 维度得分最高的一组人脸，上方是人类给出的高频主题词，下方是 CelebA / FairFace 属性——三者独立地指向同一个概念。出于隐私考虑，图中人脸为合成的 StyleGAN3 图像。

为什么人口统计标签是一把错的尺子

类别标签回答的是错误的问题。它至多能告诉你一张脸被归入哪一类，却无法说清同一类里两张脸到底有多相似——而「相似程度」恰恰是多样性审计真正关心的东西。人的外貌是连续变化的，同一张脸在不同观察者眼里也可能不同，因此任何固定标签都是对人类实际感知的一次有损、且忽略观察者视角的压缩。

早先也有工作尝试从人类判断中学习人脸的感知嵌入，但都撞上了两堵墙。一类方法只能安放训练时见过的那些刺激，完全无法为一张新面孔生成嵌入；另一类方法则把所有判断汇成一个「平均观察者」，丢掉了标注者内部与标注者之间的差异——而这份差异恰恰在告诉你：相似与否，取决于是谁在看。AVFS 要做的，是同时穿过这两堵墙。

方法：三选一判断，加上「每人一张」的掩码

数据来自一个「找不同」式的三选一任务（odd-one-out，即 triplet 判断）：看三张脸，标注者挑出与另外两张最不相似的那一张。这逼出的是相对比较而非绝对标签，人做起来也更容易保持一致。关键之处在于，这 638,180 次判断里的每一次，都记录下了做出该判断的标注者身份与其自报的人口统计信息——数据集记下的不只是「判断了什么」，还有「是谁在判断」。

在这份数据之上是一个条件模型。一个 ResNet18 卷积网络把每张脸映射为 128 维的嵌入。每位标注者配有一个可学习的门控向量，经过 sigmoid 后用来缩放每一维嵌入对该标注者的重要程度。两张脸的相似度，就是它们经掩码与整流后的嵌入的点积；模型再据此从一个三元组内的三对相似度中预测「哪张最不像」的概率。写成公式，单个标注者的相似度为 $\text{sim}_a(i,j) = (\sigma(\phi_a) \odot \text{ReLU}(w_i)) \cdot (\sigma(\phi_a) \odot \text{ReLU}(w_j))$ ，其中 ϕ_a 是标注者 a 的掩码， w_i 是第 i 张脸的嵌入。

两个设计让这个空间不只是「准」，更是「可用」。把所有掩码都置为 1，就去掉了条件、退化为一个统一的无条件空间（AVFS-U）；保留掩码则得到条件版本 AVFS-C 以及事后版本 AVFS-CPH。而一个「稀疏 + 非负」的惩罚项会把大多数维度压到零，只留下约 22 个非负且人能读懂的维度——论文在保留 22 个可解释维度的同时，验证准确率达到 61.9%。上方的图 2 就展示了其中一个维度：它得分最高的人脸、人类用来描述它的词、以及独立对上号的 CelebA/FairFace 属性三者一致，这正是这里所说的「可解释」。

一个与感知对齐的空间，真的能预测人类判断吗？

第一项测试留出的是模型训练时见过的那批脸上的判断，共 24,060 次，让模型预测人类会把哪张脸选为「最不像」。图 1 给出了各模型的准确率。用语义标签训练出的表征

(FairFace、CelebA、FFHQ、CASIA-WebFace) 都停留在 50% 出头，而 AVFS 系列明显甩开它们；哪怕只用 12.5% 的判断来训练的 AVFS-U 变体，也依然胜过所有语义基线。




图 1 同一批 24,060 张脸上留出判断的相似性预测。语义标签表征（左）落后于每一个 AVFS 模型（右）；即便是 AVFS-U-12.5% 也仍领先于基线。

更难的一关，是在 80,300 次针对全新面孔的判断上测试——这些脸模型在训练中从未见过。如果一个空间只是「记住」了训练样本，到这里就会崩掉。但如图 3 所示，AVFS 系列再次领先语义基线，而标注者专属掩码在陌生面孔上依然有效——这说明掩码抓住的是某个人判断相似性的可迁移方式，而不是对训练刺激的死记硬背。




图 3 在 80,300 次全新面孔判断上的相似性预测。条件模型（AVFS-C、AVFS-CPH）能泛化到完全由未见过的脸构成的三元组。

下面这张表把两项测试浓缩到一起。无论是同一批脸还是全新面孔，AVFS 系列相对最强的语义基线都提升了大约六到十二个百分点，而这一切都是在训练全程没见过任何人口统计标签的前提下做到的。

表 1 三选一准确率（%），最强语义基线对比 AVFS 系列。

模型	同批脸准确率 (%)	全新脸准确率 (%)
FairFace (best semantic baseline)	55.9	51.9
AVFS-U	62.0	57.5
AVFS-C	67.4	61.7
AVFS-CPH	66.5	61.4

标注者真的重要吗，还是那张掩码只是摆设？

如果每个人判断相似性的方式都一样，那么标注者掩码就是可互换的，随机打乱也不该有任何代价。作者正是这样做检验：把这 80,300 次全新面孔判断上各自绑定的标注者掩码随机重新分配，再重算准确率，重复 100 次。最强条件模型的准确率从 61.7% 掉到 52.8%——一个幅度大且稳定的下滑，说明标注者并不可互换，「谁在判断」本身就是信号的一部分。

第二项分析逐一剔除嵌入维度。只需 6–13 个维度，就能恢复 95–99% 的预测准确率；但要解释 95–99% 的完整相似性结构，则需要 15–22 个维度。这道差距正是重点所在：哪些维度重要，取决于比较所处的语境——而这恰恰是连续、条件化的空间该捕捉、固定标签却做不到的东西。




图 4 标注者的立场性 (positionality)。一个线性 SVM 仅凭掩码就能按人口统计群体把标注者显著区分开（远高于代表随机水平的横线），说明社会文化背景在人们判断人脸相似性时留下了可测量的痕迹。

图 4 从另一个方向印证了同一点。一个简单的线性分类器，仅凭标注者的掩码就能按人口统计群体把他们区分开，且每个置信区间都明显高于随机水平。模型从未在这些群体标签上训练过；这种结构之所以浮现，是因为不同的人确实在以不同的方式给各个视觉维度赋权。论文在这里措辞谨慎——这是在描述判断如何因人而异，而不是把任何一种分组当作事实真值来背书。

它的意义

AVFS 用「记录是谁做了哪次判断」换掉了「人口统计标签」，换回一种连续、可解释、与人类感知对齐的人脸表征——它能在不把人塞进离散盒子的前提下衡量多样性。对于在采集敏感性上受法律与伦理约束的团队来说，这是一个实用的替代方案，而不只是一种哲学立场。

该守住的边界也值得放在眼前：图中人脸都近似正面，标注者群体虽多元却终归有限，因此学到的维度反映的是这一群观察者，而非放之四海皆准的「人类」。但这套框架只需知道「哪次判断出自哪位标注者」，因此它并不专属于人脸——同样的配方，可以为几乎任何建立在人类比较之上的任务学出与感知对齐的表征。正是这份普适性，让这篇论文值得一读。